CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS
CAMPUS DIVINÓPOLIS

Victor Geraldo Faria Costa

PROJETO DE FÁRMACOS AUXILIADO POR COMPUTADOR:
Uma Abordagem Baseada em Triagem Virtual para o Combate à *Candida auris*

Divinópolis
2024

VICTOR GERALDO FARIA COSTA

PROJETO DE FÁRMACOS AUXILIADO POR COMPUTADOR:
Uma Abordagem Baseada em Triagem Virtual para o Combate à *Candida auris*

Trabalho de Conclusão de Curso apresentado no curso de Graduação em Engenharia de Computação do Centro Federal de Educação Tecnológica de Minas Gerais como requisito parcial para obtenção do título de Bacharel em Engenharia de Computação.

Orientador: Ms. Michel Pires da Silva
Coorientador: Dr. Eduardo Habib B. Maia

DIVINÓPOLIS
2024

VICTOR GERALDO FARIA COSTA

PROJETO DE FÁRMACOS AUXILIADO POR COMPUTADOR:
Uma Abordagem Baseada em Triagem Virtual para o Combate à *Candida auris*

Trabalho de Conclusão de Curso apresentado no curso de Graduação em Engenharia de Computação do Centro Federal de Educação Tecnológica de Minas Gerais como requisito parcial para obtenção do título de Bacharel em Engenharia de Computação.

Aprovado em 26 de setembro de 2025.

Michel Pires da Silva
Centro Federal de Educação Tecnológica de Minas Gerais

Eduardo Habib Bechelane Maia
Centro Federal de Educação Tecnológica de Minas Gerais

Tiago Alves de Oliveira
Centro Federal de Educação Tecnológica de Minas Gerais

RESUMO

As infecções fúngicas representam um desafio significativo à saúde pública global, com aproximadamente 150 milhões de casos registrados anualmente. A identificação eficaz dessas infecções é frequentemente comprometida por desafios substanciais, os quais, muitas vezes, são agravados pela escassez de literatura especializada. Entre os patógenos fúngicos mais emergentes e preocupantes, destaca-se a *Candida auris* (CA), evidenciada por sua resistência aos antifúngicos e pelas dificuldades da sua detecção e tratamento. Identificou-se compostos com possível potencial antagonista contra a CA, utilizando para isso estratégias de modelagem computacional, com foco especial na triagem virtual. A abordagem proposta envolveu a análise de extensos bancos de dados moleculares para a identificação de compostos antimicrobianos capazes de lidar com o problema. A síntese dos compostos resultantes permitiu estabelecer uma base para pesquisas de soluções específicas e eficazes para o tratamento da CA, contribuindo para o combate a infecções fúngicas resistentes e a expansão das opções terapêuticas disponíveis.

Palavras-chave: *Computer-Aided Drug Design*; Triagem Virtual; *Candida auris*.

ABSTRACT

Fungal infections represent a significant challenge to global public health, with approximately 150 million cases reported annually. The effective identification of these infections is often hindered by substantial challenges, frequently exacerbated by a lack of specialized literature. Among the most emerging and concerning fungal pathogens is Candida auris (CA), known for its resistance to antifungal agents and the difficulties associated with its detection and treatment. Compounds with potential antagonistic activity against CA have been identified using computational modeling strategies focusing on virtual screening. The proposed approach involved the analysis of extensive molecular databases to identify antimicrobial compounds capable of addressing the problem. By synthesizing the resulting compounds, it was possible to establish a foundation for researching specific and effective solutions for CA treatment, thereby advancing the fight against resistant fungal infections and expanding the available therapeutic options.

Keywords: Computer-Aided Drug Design; Virtual Screening; *Candida auris*.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo Metodológico do Trabalho 16
Figura 2 – Moléculas.sdf no DataWarrior 22
Figura 3 – Distribuição e conectividade entre as moléculas analisadas. 23
Figura 4 – Centróide da análise de moléculas e similares. 24
Figura 5 – Centróide da análise apenas das moléculas. 24
Figura 6 – K-means dos componentes. 25
Figura 7 – K-means dos componentes com seus Centroides. 25
Figura 8 – Centroide cluster 0 e 7. 25
Figura 9 – Centroide cluster 1, 4 e 9. 25
Figura 10 – Centroide cluster 2 e 8. 25
Figura 11 – Centroide cluster 3. 25
Figura 12 – Centroide cluster 5. 26
Figura 13 – Centroide cluster 6. 26
Figura 14 – Centroide cluster 7. 26
Figura 15 – Conformações do NDP (302 B) no sítio de ligação da CA 27
Figura 16 – Avaliação dos compostos com base no ADMET 33
Figura 17 – Centroide Molécular e dos *clusters* 2 e 8, detectado na análise de clusterização e identificado em todas as moléculas de possíveis hits desse trabalho (CHEMBL4281467) 33
Figura 18 – Fluconazol. 34
Figura 19 – Anexo A - 1º CHEMBL3736434 Completa no DiscoveryStudio 42
Figura 20 – Anexo A - 2º CHEMBL4475747 Completa no DiscoveryStudio 42
Figura 21 – Anexo A - 3º CHEMBL4458614 Completa no DiscoveryStudio 43
Figura 22 – Anexo A - 4º CHEMBL4870228 Completa no DiscoveryStudio 43
Figura 23 – Anexo A - 5º CHEMBL1255047 Completa no DiscoveryStudio 44
Figura 24 – Anexo A - 6º CHEMBL3221229 Completa no DiscoveryStudio 44
Figura 25 – Anexo A - 7º CHEMBL4294930 Completa no DiscoveryStudio 45
Figura 26 – Anexo A - 8º CHEMBL2018928 Completa no DiscoveryStudio 45
Figura 27 – Anexo A - 9º CHEMBL1254317 Completa no DiscoveryStudio 46
Figura 28 – Anexo A - 10º CHEMBL3221227 Completa no DiscoveryStudio 46
Figura 29 – Anexo B - 1º CHEMBL3736434 - Análise completa realizada no SwissADME 47
Figura 30 – Anexo B - 2º CHEMBL4475747 - Análise completa realizada no SwissADME 48
Figura 31 – Anexo B - 3º CHEMBL4458614 - Análise completa realizada no SwissADME 49

Figura 32 – Anexo B - 4º CHEMBL4870228 - Análise completa realizada no SwissADME 50
Figura 33 – Anexo B - 5º CHEMBL1255047 - Análise completa realizada no SwissADME 51
Figura 34 – Anexo B - 6º CHEMBL3221229 - Análise completa realizada no SwissADME 52
Figura 35 – Anexo B - 7º CHEMBL4294930 - Análise completa realizada no SwissADME 53
Figura 36 – Anexo B - 8º CHEMBL2018928 - Análise completa realizada no SwissADME 54
Figura 37 – Anexo B - 9º CHEMBL1254317 - Análise completa realizada no SwissADME 55
Figura 38 – Anexo B - 10º CHEMBL3221227 - Análise completa realizada no SwissADME 56
Figura 39 – Anexo B - Centroide *cluster* de relacionamentos - Análise completa realizada no SwissADME 57
Figura 40 – Anexo B - Centroide *cluster* 0 - Análise completa realizada no SwissADME 58
Figura 41 – Anexo B - Centroide *cluster* 1, 4 e 9 - Análise completa realizada no SwissADME 59
Figura 42 – Anexo B - Centroide *cluster* de relacionamentos das moleculas, *cluster* 2 e 8 - Análise completa realizada no SwissADME 60
Figura 43 – Anexo B - Centroide *cluster* 3 - Análise completa realizada no SwissADME 61
Figura 44 – Anexo B - Centroide *cluster* 5 - Análise completa realizada no SwissADME 62
Figura 45 – Anexo B - Centroide *cluster* 6 - Análise completa realizada no SwissADME 63
Figura 46 – Anexo B - Centroide *cluster* 7 - Análise completa realizada no SwissADME 64

LISTA DE TABELAS

Tabela 1 – Resumo das regras de propriedades farmacológicas. 20
Tabela 2 – Estruturas encontradas na coleta dos PDBs 21
Tabela 3 – Pares Selecionados 26
Tabela 4 – Ranking Molécular de Docking por Consenso 28
Tabela 5 – Ligações do resultado do Docking Molecular na CA (1º ao 5º) 29
Tabela 6 – Ligações do resultado do Docking Molecular na CA (6º ao 10º) 30
Tabela 7 – Violações e Biodisponibilidade dos compostos do *Docking* 31
Tabela 8 – Violações e Biodisponibilidade dos compostos centroides 31
Tabela 9 – Ranqueamento por Violação de Regras e Bioatividade das Moléculas . 32
Tabela 10 – Análise dos centroides dos *clusters* e das moléculas encontradas no Docking ranqueadas por consenso baseada no CHEMBL4281467 . . . 34

LISTA DE ABREVIATURAS E SIGLAS

CA	Candida auris
CADD	Design de Fármacos Assistido por Computador, do inglês *Computer-Aided Drug Design*
VS	Triagem virtual, do inglês *Virtual Screening*
SBDD	Modelagem de Fármaco Baseado na Estrutura, do inglês *Structure-Based Drug Design*
LBDD	Modelagem de Fármaco Baseado no Ligante, do inglês *Ligand-Based Drug Design*
FBDD	Modelagem de Fármaco Baseada em Fragmentos, do inglês *Ligand-Based Drug Design*
IFIs	Infecções Fúngicas Invasivas
ML	Aprendizado de maquina, do inglês *Machine Learning*
SBVS	Triagem virtual Baseada na Estrutura, do inglês *Structure-Based Virtual Screening*
LBVS	Triagem virtual Baseada no Ligante, do inglês *Ligand-Based Virtual Screening*
QSAR	Relação estrutura-atividade quantitativa (QSAR, do inglês *Quantitative Structure-Activity Relationship*
FBVS	Triagem virtual Baseada em Fragmentos, do inglês *Fragment-Based Virtual Screening*
RMSD	Desvio Médio Quadrático, do inglês *Root Mean Square Deviation*
ADMET	Absorção, Distribuição, Metabolismo, Excreção e Toxicidade
MCC	Máximo Componente Conectado
MW	Massa Molecular, do inglês *Molecular Weight*
LogP	Coeficiente de Partição, do inglês *Partition Coefficient* (também chamado *LogP*)
HBD	Doadores de Hidrogênio, do inglês *Hydrogen Bond Donors*
HBA	Aceitadores de Hidrogênio, do inglês *Hydrogen Bond Acceptors*
TPSA	Área de Superfície Polar Total, do inglês *Topological Polar Surface Area*

SUMÁRIO

1	**INTRODUÇÃO**	1
1.1	**Candida Auris**	2
1.2	**Desenvolvimento de Fármacos com Auxílio Computacional**	2
1.3	**Base de Ligantes**	3
1.4	**Objetivos**	4
2	**REFERENCIAL TEÓRICO**	5
2.1	**Candida auris e Infecções Fúngicas**	5
2.2	**Desenvolvimento de Fármacos com Auxílio Computacional**	6
2.3	**Triagem Virtual**	7
2.3.1	**Triagem Virtual Baseada em Estrutura**	8
2.3.2	**Triagem virtual Baseada no Ligante**	9
2.3.3	**Triagem Virtual Baseada em Fragmentos**	10
2.3.4	**Triagem Virtual Híbrida**	10
2.4	**Ferramentas de CADD**	11
2.4.1	**MolAr**	11
2.4.2	**MOE**	12
2.4.3	**GROMACS**	13
2.5	**Inteligência Computacional aplicada a Triagem Virtual**	13
2.5.1	**Algoritmos Baseados em Similaridade**	13
2.5.2	**Algoritmos Baseados em Aprendizado de Máquina**	14
2.5.3	**Algoritmos Genéticos**	14
2.5.4	**Algoritmos Baseados em Meta-Heurísticas**	15
2.6	**Considerações**	15
3	**METODOLOGIA**	16
3.1	**Coleta dos Dados**	17
3.2	**Análise de Dados**	17
3.3	**Realização do *Redocking***	18
3.4	**Realização do *Docking***	19
3.5	**Análise Final**	19
4	**RESULTADOS E ANÁLISES**	21
4.1	**Resultados da Coleta**	21
4.2	**Resultados da análise**	22
4.3	**Resultados do *Redocking***	26
4.4	**Resultados do *Docking***	27
4.5	**Resultados Complementares**	31
5	**CONCLUSÃO**	35
5.1	**Trabalhos futuros**	35

REFERÊNCIAS 36
ANEXO A 42
ANEXO B 47

1 INTRODUÇÃO

A computação, com seu vasto e diversificado espectro de aplicações, desempenha um papel crucial em diversos campos do conhecimento, incluindo a saúde. A incorporação de técnicas emergentes na área da saúde tem impulsionado avanços significativos no desenvolvimento de soluções terapêuticas, evidenciando a crescente relevância da computação no aprimoramento dos cuidados médicos e no tratamento de doenças (CAI *et al.*, 2023). Uma das abordagens de destaque dessa integração é o design de fármacos assistido por computador (CADD, do inglês *Computer-Aided Drug Design*), que emprega métodos computacionais para otimizar a descoberta de novos medicamentos, permitindo a análise detalhada das interações moleculares e a avaliação das relações entre proteínas e ligantes. Nesse contexto, a triagem virtual (VS, do inglês *Virtual Screening*) se destaca como uma técnica eficaz, proporcionando uma abordagem econômica e eficiente para a avaliação de grandes bibliotecas moleculares em ambientes simulados (MAIA *et al.*, 2020).

Apesar dos avanços proporcionados pelas abordagens de CADD, sua aplicação no combate aos patógenos microscópicos continua a apresentar desafios consideráveis. A levedura *Candida auris* (CA), em particular, emerge como uma preocupação crescente devido à sua alta resistência a uma ampla gama de antifúngicos e às dificuldades associadas à sua detecção precoce. Essas características frequentemente resultam em diagnósticos tardios e tratamentos prolongados, exacerbando o problema das infecções fúngicas resistentes (CRISTINA *et al.*, 2023). Tal cenário destaca a necessidade urgente de desenvolver novas estratégias para superar as limitações no tratamento desse patógeno que tem se tornado cada vez mais prevalente.

A aplicação de abordagens computacionais avançadas, como a VS, apresenta uma alternativa promissora no enfrentamento dos desafios impostos pelo patógeno supracitado. Com essa técnica, torna-se viável identificar novos compostos capazes de atuar como antagonistas [1] eficazes, contribuindo significativamente para a descoberta de terapias inovadoras. A exploração de grandes volumes de dados moleculares e a simulação de interações potenciais permitem acelerar o processo de descoberta e reposicionamento de fármacos, ampliando a capacidade de resposta às infecções fúngicas resistentes. Este trabalho, portanto, dedica-se a explorar e expandir o uso de métodos computacionais com o objetivo de desenvolver estratégias terapêuticas mais eficazes e acessíveis para combater a CA.

[1] Composto ou agente que interfere ou inibe a ação de outra substância.

1.1 Candida Auris

O reino Fungi é fascinante, abarcando organismos pluricelulares e unicelulares, muitos dos quais desempenham papéis essenciais em nossa alimentação. Entretanto, alguns desses organismos são responsáveis por diversas doenças, como as micoses, incluindo os dermatófitos, os fungos filamentosos não dermatófitos e, em particular, as leveduras, que constituem o foco deste estudo (LEMES *et al.*, 2021).

Dentre as leveduras, as espécies do gênero *Candida* se destacam, sendo responsáveis por infecções que variam desde manifestações leves até condições graves, potencialmente letais. Em 2009, no Japão, foi relatado o primeiro caso de infecção por CA, um fungo multirresistente a medicamentos (SATOH *et al.*, 2009). Desde então, casos isolados foram registrados em cerca de quarenta países, com taxas de mortalidade que variam entre 30% e 60% (CHOWDHARY; JAIN; CHAUHAN, 2023).

A CA ganhou destaque por sua notável resistência a medicamentos comuns, como fluconazol e anfotericina B, além de sua capacidade de sobreviver a altas temperaturas. Estudos laboratoriais revelaram uma taxa de mortalidade alarmante associada a esse fungo, justificando sua classificação como extremamente virulento (PHARKJAKSU *et al.*, 2021). Essas características suscitam sérias preocupações em caso de surtos, devido à limitada eficácia das respostas terapêuticas disponíveis. Além disso, o processo de investigação e desenvolvimento de novos agentes terapêuticos antagonistas é oneroso em termos de tempo e custo, o que pode restringir o acesso a tratamentos eficazes para uma parcela significativa da população, tornando a CA uma ameaça particularmente preocupante.

1.2 Desenvolvimento de Fármacos com Auxílio Computacional

Com o avanço da tecnologia e a busca constante pela redução de custos na descoberta e reposicionamento de fármacos, o processo se expandiu, saindo do âmbito laboratorial para integrar-se a ambientes computacionais e simulações. A habilidade de modelar as propriedades moleculares detalhadamente transformou a descoberta de novos agentes terapêuticos em uma prática mais eficiente e menos onerosa. Isso possibilitou o desenvolvimento de simulações de ligações moleculares, uma abordagem que, há algumas décadas, parecia impraticável, mas que hoje se tornou uma técnica amplamente utilizada no desenvolvimento de novos agentes terapêuticos (CAI *et al.*, 2023).

No contexto da computação, o CADD pode ser observado como um processo exploratório aplicado sob várias vertentes, sendo as mais exploradas a modelagem baseada na estrutura (SBDD, do inglês *Structure-Based Drug Design*), a modelagem baseada no ligante (LBDD, do inglês *Ligand-Based Drug Design*) e a modelagem

baseada em fragmentos (FBDD, do inglês *Fragment-Based Drug Design*).

A SBDD se subdivide em duas principais técnicas: o *Molecular Docking*, que são simulações para analisar a estabilidade e afinidade da interação entre fármaco e proteína, e o VS, que permite testar uma grande quantidade de compostos contra um alvo e classificá-los com base na sua capacidade de se ligar ao seu alvo (VEMULA *et al.*, 2023).

Já o LBDD inclui *Quantitative Structure-Activity Relationship* (QSAR), técnica que gera modelos matemáticos com as propriedades dos ligantes e suas atividades biológicas para usar essas informações, cujo objetivo é encontrar compostos promissores baseados em semelhanças com esses parâmetros estruturais. Outra técnica fundamental é o *Pharmacophore Modeling*, uma abstração das características necessárias dos ligantes para sua interação com o alvo, e a partir disso são projetados modelos geométricos de compostos químicos para auxiliarem na busca de moléculas que tenham sucesso na interação com o alvo biológico (VEMULA *et al.*, 2023).

Além dessas abordagens, existem os modelos híbridos, que tentam ampliar as propriedades exploratórias ao assumir elementos da SBDD e da LBDD, gerando uma abordagem mais flexível e robusta para o desenvolvimento de fármacos. O objetivo deste trabalho é combinar o processo de SBDD com VS para explorar virtualmente a CA. Sendo um dos ramos de aplicação do CADD que, baseado no conhecimento prévio do alvo biológico e da estrutura detalhada, e em 3D, da macromolécula, possibilita a análise físico-química dos locais de ligamento do fármaco no receptor de maneira mais rápida e e barata do que os testes *in vitro* (LIN; LI; LIN, 2020), com o principal limitador ligado ao detalhamento do alvo molecular (MAIA *et al.*, 2020) do banco que ele for extraído.

Para a realização do VS, existem várias ferramentas gratuitas e pagas disponíveis. O *docking* e o processo de visualização dos compostos do SBVS serão realizados em ferramentas gratuitas e acadêmicas como MOE, MOLAR, GROMACS, DrugHunter, DockThor, Chimera e ChEMBL.

1.3 Base de Ligantes

A organização de uma base de dados é um dos pontos cruciais para a VS, estima-se que seja levada em consideração a escolha do local que dará início ao *docking*. Visto isso, em 2021, o ChEMBL era o quinto serviço mais utilizado segundo o estudo de impacto de banco de dados do European Molecular Biology Laboratory (EMBL) (BEAGRIE; HOUGHTON, 2021) e continha dados de ensaios biológicos de aproximadamente 2,3 milhões de compostos (KHAN; KANDWAL; FAYNE, 2023). O alto número de moléculas documentadas gera bancos de dados extremamente densos, necessitando de um tratamento e abordagens específicas para contemplar o maior número de possíveis bons alvos. Por esses motivos, e pela necessidade das informações detalhadas das moléculas por causa do processo de SBDD, a base de dados usada será

montada a partir dos dados do ChEMBL.

1.4 Objetivos

O objetivo primário deste estudo é identificar compostos com potencial antagonista contra a CA, utilizando estratégias de modelagem computacional, com ênfase na VS. As contribuições esperadas incluem a expansão da exploração de bases moleculares, a avaliação das propriedades farmacocinéticas dos compostos candidatos e o fornecimento de soluções terapêuticas eficazes para o tratamento da CA. O estudo visa descobrir novos agentes antimicrobianos eficazes e promissores para o tratamento de infecções causadas por este fungo, especialmente nas cepas altamente resistentes.

Para alcançar tais objetivos, o restante deste trabalho segue deste modo: No capítulo 2, tem-se o Referencial Teórico, onde é consolidada uma base de conhecimentos aplicados ao processo do trabalho. Presente no capítulo 3, está a metodologia, que aprofunda como serão realizados os processos de coleta e análise de dados, além da realização do Redocking e do Docking e a análise final dos resultados. Logo após, no capítulo 4, em Resultados e Análises, ocorre uma síntese e verificação de todos os pontos cruciais encontrados no trabalho. Por fim, no capítulo 5, uma conclusão para o estudo é realizada, assim como uma proposição de trabalhos futuros que se baseiam no presente experimento.

2 REFERENCIAL TEÓRICO

Neste capítulo, são apresentadas as bases do estudo necessárias para o entendimento do design de fármacos assistido por computador aplicado à Candida auris, a formulação dos objetivos e a estruturação da solução proposta por este trabalho. Dentre os diversos contextos abordados, são discutidos em detalhe os aspectos relacionados à CA e suas implicações nas infecções fúngicas invasivas (IFIs), assim como os conceitos aprofundados sobre CADD e suas ferramentas disponíveis na literatura. Prosseguiremos explorando a triagem virtual (Virtual Screening - VS) e sua integração com as diferentes modalidades do CADD. Por fim, o capítulo integra esses conceitos com modelos de inteligência computacional, oferecendo uma visão abrangente da abordagem adotada.

2.1 Candida auris e Infecções Fúngicas

Os fungos abrangem uma ampla diversidade de organismos eucarióticos[1], que podem ser multicelulares ou unicelulares, e sobrevivem através de parasitismo, saprofitismo[2] e/ou simbiose[3] (WEBSTER; WEBER, 2007). Eles são geralmente classificados em dois grupos principais: os fungos filamentosos, que são multicelulares e formam hifas[4], e as leveduras, predominantemente unicelulares, que podem ou não formar pseudohifas e se reproduzem assexuadamente por fissão ou brotamento (LIU, 2024).

Considerando seu impacto como agentes patogênicos, especialmente nas IFIs que afetam tecidos profundos do corpo humano, os fungos aumentam significativamente os riscos e a taxa de mortalidade associada a esse contexto (FANG *et al.*, 2023).

Dentre os fungos de maior relevância para a saúde humana, a família *Candida* tem sido uma preocupação persistente no contexto de infecções hospitalares, sendo responsável por 70% a 90% das sepses fúngicas associadas aos cuidados de saúde nas últimas décadas, com a CA como o principal agente causador (DELALOYE; CALANDRA, 2014). No entanto, o uso profilático [5] de antifúngicos em pacientes imunocomprometidos e desnutridos, aliado às dificuldades na identificação desses patógenos, tem criado condições favoráveis ao surgimento de fungos multirresistentes, como a CA.

Além de sua alta resistência a tratamentos antifúngicos convencionais, como fluconazol e anfotericina B, a CA possui a capacidade de tolerar altas temperaturas e formar biofilmes[6] robustos, com colônias revestidas por substâncias produzidas pelo

[1] Células que apresentam um núcleo definido.
[2] Nutrição a partir de matéria orgânica em decomposição.
[3] relação entre duas espécies em que uma ou ambas se beneficiam de alguma forma.
[4] filamentos de células que formam o micélio dos fungos.
[5] Tratamento realizado como precaução.
[6] Comunidades biológicas estruturadas e organizadas para proteger as células.

próprio patógeno, que prolongam seu ciclo de vida por até quatorze dias (PHARKJAKSU *et al.*, 2021; SHAH; DESHPANDE; SHAH, 2024). Esse fungo emergente, cuja disseminação foi agravada pela pandemia de COVID-19, é atualmente classificado como uma prioridade na busca por novos agentes antimicrobianos com capacidade antagonista (SHAH; DESHPANDE; SHAH, 2024). Durante esse periodo, observou-se um aumento dos casos em hospitais de campanha, em parte devido ao uso prolongado de luvas e aventais, que proporcionaram um ambiente favorável à sua multiplicação e elevaram a taxa de mortalidade (CHOWDHARY; JAIN; CHAUHAN, 2023).

2.2 Desenvolvimento de Fármacos com Auxílio Computacional

O avanço da computação transformou significativamente diversos campos científicos, possibilitando a introdução de abordagens inovadoras para lidar com processos complexos e trabalhosos. Um desses campos beneficiados é o da descoberta e reposicionamento de fármacos, onde técnicas computacionais têm desempenhado um papel cada vez mais importante na busca por soluções eficazes contra patógenos resistentes, como a Candida auris. No cenário computacional, o CADD surgiu como uma abordagem revolucionária a partir da popularização dos computadores gráficos na década de 1980. Antes dessa época, a análise das interações entre moléculas e enzimas era um processo altamente manual e demorado, limitando o progresso na descoberta de novas soluções para problemas de saúde. Com o advento do CADD, tornou-se possível visualizar e manipular cadeias enzimáticas simuladas em três dimensões, facilitando a análise de interações moleculares e acelerando o desenvolvimento desses novos compostos. Essa capacidade de simulação em 3D não apenas facilitou a compreensão das interações moleculares, mas também acelerou o desenvolvimento de novos compostos terapêuticos, destacando a importância crescente da computação na área farmacêutica (MARSHALL, 1987).

Recentemente, os avanços em inteligência artificial e aprendizado de máquina, em conjunto com a química medicinal e os processos quânticos, têm melhorado a previsão de interações entre moléculas e alvos biológicos. O uso de redes neurais profundas e métodos de aprendizado de máquina (ML, do inglês *Machine Learning*) facilita a criação de estruturas moleculares e suas simulações, coisas que antes eram de difícil acesso por métodos tradicionais (ZHAVORONKOV, 2018).

Embora a computação tenha provido benefícios relevantes aos processos acima citados, sistemas biológicos continuam sendo um desafio complexo. Modelos computacionais avançados, mesmo que os simplifiquem, não conseguem capturar todas as informações das interações moleculares. Dados incompletos e concatenação podem levar a resultados enganosos e para simulações moleculares, a alta precisão dos dados experimentais continua sendo uma área que necessita de intensa pesquisa para melhorar

a previsibilidade e consistência dos modelos de CADD (JIMÉNEZ-LUNA; GRISONI; SCHNEIDER, 2020).

O CADD possui uma estrutura bem definida, com caminhos e ferramentas disponíveis para sua realização. Os dois métodos principais são o SBDD e o LBDD, cuja escolha depende dos recursos dispostos para o processo. Caso haja a projeção tridimensional do alvo biológico, é possível realizar o SBDD para prever compostos com alta afinidade de ligação a essa molécula. Em situações em que a estrutura do alvo não está disponível, é necessário utilizar o LBDD junto às informações químicas e estruturais dos compostos ativos conhecidos para pesquisar possíveis ligações no alvo (MAIA *et al.*, 2020).

2.3 Triagem Virtual

A VS compõe parte do processo de CADD, nela as propriedades físico-químicas de compostos são exploradas para encontrar potencial de interação com objetivo de identificá-las. Ao invés de realizar experimentos laboratoriais fisicamente que demandam dinheiro, recursos e tempo, a VS utiliza simulações computacionais, chamadas simulações *in silico*, para identificar quais moléculas apresentam maior afinidade com um alvo, como uma proteína ou enzima, com base nos seus atributos químicos, físicos e espaciais (GIORDANO *et al.*, 2022).

Esta técnica se destaca por sua eficiência e custo-benefício, permitindo processar e testar rapidamente inúmeras moléculas armazenadas em bancos de dados. Por exemplo, entre 2016 e 2023, o número de moléculas disponíveis para triagem aumentou de 3.5 milhões para mais de 29 bilhões (LYU; IRWIN; SHOICHET, 2023). Esse crescimento exponencial de dados disponíveis, embora necessite de uma pré-seleção e trabalho para simplificá-los, reforça a vantagem da VS em relação à verificação laboratorial como passo inicial da produção de fármacos.

Com a identificação dos chamados ”hits”[7], a produção é guiada nos próximos passos pelos compostos mais promissores para dar início aos processos posteriores laboratoriais, economizando tempo e recursos valiosos (LYU; IRWIN; SHOICHET, 2023; GIORDANO *et al.*, 2022). A VS proporciona uma plataforma robusta para o desenvolvimento inicial de medicamentos, crucial em situações de emergência ou para a melhoria de tratamentos existentes. Com o avanço da área foram geradas abordagens mais refinadas de seleções de candidatos como a triagem baseada em estruturas, ligantes, fragmentos ou abordagens híbridas.(GIORDANO *et al.*, 2022)

Especificamente no contexto do combate à *Candida auris*, a VS é fundamental para identificar rapidamente novos agentes antifúngicos promissores, e que sejam capazes de superar os desafios impostos por essa levedura resistente.

[7]Moléculas com grande potencial.

2.3.1 Triagem Virtual Baseada em Estrutura

A Triagem Virtual Baseada em Estrutura (SBVS, do inglês *Structure-Based Virtual Screening*), inicialmente chamada de *Target-Based Virtual Screening* (OPREA; MATTER, 2004), é uma abordagem para casos em que um modelo tridimensional do alvo é conhecido.

A SBVS segue quatro etapas principais: a preparação do alvo molecular, a seleção do banco de dados de compostos, o *docking* molecular e a análise pós-*docking* (VEMULA *et al.*, 2023).

A preparação do alvo envolve a verificação e o refinamento da estrutura 3D. Essa estrutura pode ser obtida de bancos de dados públicos, como ChEMBL (ZDRAZIL *et al.*, 2024), PubChem (KIM *et al.*, 2023) e DrugBank (KNOX *et al.*, 2024), ou gerada por métodos experimentais, como a cristalografia de raio X, que cria uma imagem computacional 3D baseada na dispersão dos raios ao atravessar o cristal de uma estrutura (MAVEYRAUD; MOUREY, 2020). Alternativamente, pode-se utilizar a Ressonância Magnética Nuclear (RMN), método que analisa a interação dos núcleos atômicos em um campo magnético intenso (GUO *et al.*, 2023). Caso não seja possível utilizar nenhum dos processos citados, ferramentas como MODELLER podem ser utilizadas para prever e modelar a estrutura do alvo.

Para a seleção do banco de dados utilizado na VT é necessário ter em mente qual abordagem é almejada. Alguns métodos são mais eficazes quando há um grande número de amostras disponíveis, enquanto outros podem ser menos precisos, mas funcionam com um número menor. Independentemente do método, é essencial utilizar uma biblioteca que possua quantidades significativas de candidatas capazes de interagir com o alvo. Bancos de moléculas como os ChEMBL (ZDRAZIL *et al.*, 2024), PubChem (KIM *et al.*, 2023) e DrugBank (KNOX *et al.*, 2024) citados anteriormente são comumente utilizados para esse propósito, oferecendo coleções de compostos prontos para serem examinadas.

Após a seleção do complexo a ser estudado, o *docking* molecular constitui a etapa em que os compostos escolhidos são testados em relação ao alvo terapêutico, visando avaliar sua capacidade de ancoragem. Nesse estágio, o composto é submetido a diferentes orientações e rotações de sua estrutura, com o objetivo de identificar a melhor conformação possível entre o receptor e o ligante. Esse processo busca determinar a interação mais favorável entre as moléculas, maximizando a afinidade e a estabilidade do complexo formado.

Por fim, os resultados são analisados com a finalidade de procurar os melhores índices de afinidade de ligação, além de quais deles apresentaram interações relevantes. Avaliando força, orientação espacial e outras possíveis interações eletrostáticas ou hidrofóbicas que possam ser exploradas para o desenvolvimento de novos fármacos ou pro-fármacos (VEMULA *et al.*, 2023).

2.3.2 Triagem virtual Baseada no Ligante

Diferente da estratégia SBVS, a Triagem virtual Baseada no Ligante (LBVS, do inglês *Ligand-Base Virtual Screening*) é usada quando não se tem acesso às informações completas sobre o alvo terapêutico estudado. Nesse modelo exploratório, tem-se como foco a utilização das informações dos ligantes para buscar compostos promissores a se adequarem nas informações presentes para o estudo. As etapas para esse método são: o bioensaio, a seleção de banco de biblioteca de compostos, a aplicação do QSAR ou a criação de um farmacóforo, a triagem e, por fim, a análise (VEMULA *et al.*, 2023).

A criação do modelo inicial desse método se baseia em compostos conhecidos por se ligarem na estrutura de real interesse. Esses já conhecidos, são usados como modelo para gerar um grupo de características estruturais e funcionais em comum como peso molecular, valor de pH e área de superfície polar que serão procuradas em grandes bancos para escolher alvos satisfatórios para a pesquisa. Além disso, é possível obter maior precisão e exatidão ao selecionar descritores mais relevantes para a triagem, cujo objetivo é gerar uma ligação com a estrutura alvo mais eficaz, mesmo que ela não esteja disponível (JAYARAJ; AJAY *et al.*, 2016).

A seleção de compostos segue o mesmo caminho da SBVS, é realizado um *docking* molecular em que os compostos escolhidos são testados em relação ao alvo, mas ao invés de focar em um específico, encontram-se compostos que compartilham o máximo possível de semelhanças com os ligantes conhecidos, seguindo uma ideia de que com uma similaridade físico-química e/ou estrutural terão propriedades de ligação semelhantes. (JAYARAJ; JAIN, 2019; CHAN, 2018)

O processo pode seguir um de dois caminhos: a relação estrutura-atividade quantitativa (QSAR, do inglês *Quantitative Structure-Activity Relationship*) ou a criação de um farmacóforo[8].

O QSAR baseia-se na hipótese de que moléculas com estruturas semelhantes terão funções semelhantes (JOHNSON; MAGGIORA; MEETING, 1990) então utiliza de parâmetros físico-químicos, como eletronegatividade, hidrofobicidade e efeitos estéricos para criar um modelo de correlação para o alvo biológico. Esse método é altamente paramétrico e baseado numa estruturação de modelos matemáticos para simular as interações com os compostos na VS (RUDRAPAL; CHETIA, 2020).

Por outro lado, a criação do farmacóforo segue um caminho mais abstrato, buscando identificar padrões-chave (posições geométricas ou interações moleculares) de como seria a modelagem da estrutura química 3D do alvo. Quanto à geração de um farmacóforo, há a necessidade de escolha de um conjunto de ligantes, análise de estruturas semelhantes entre si, a superposição molecular para identificação de pontos comuns e, por fim, a abstração do modelo superposto. Com o farmacóforo criado, é

[8]Estrutura com características idealizadas baseadas no ligante.

possível seguir para etapa de validação (ZHAO *et al.*, 2021).

Considerando os resultados obtidos, tanto do modelo QSAR quanto do farmacóforo, tem-se uma análise que os abrange de maneira semelhante. A VS fornecerá previsões de possíveis novos ligantes que interajam com o alvo biológico. E, após esse estágio, assim como na SBVS, os mais promissores são classificados e avaliados para o seguimento de estudos laboratoriais (VEMULA *et al.*, 2023).

2.3.3 Triagem Virtual Baseada em Fragmentos

A Triagem Virtual Baseada em Fragmentos (FBVS, do inglês *Fragment-Based Virtual Screening*), diferente do SBVS e do LBVS, trabalha com pequenos fragmentos moleculares ao invés dos compostos inteiros na realização dos processos de interação molecular. Esses fragmentos, pelo seu tamanho, são de menor complexidade e podem se ligar mais facilmente ao sítio do alvo. (VEMULA *et al.*, 2023)

Para definirmos se o composto é apto a realização do processo baseado nos fragmentos são necessárias algumas verificações, como a regra dos 3, que corresponde à estratégia para escolha de fragmentos de menor complexidade, baseada na regra dos 5 de Lipinski (PICCIRILLO; AMARAL, 2018). Esse princípio propõe que: o peso molecular deve ser menor que 300; que o número de doadores de ligações de hidrogênio seja menor ou igual a 3; que o número de possíveis ligações de hidrogênio seja menor ou igual a 3; e que o ClogP[9] menor que 3 (CONGREVE *et al.*, 2003). Após isso, essas moléculas de complexidade reduzida estão aptas a serem testadas através dessa VS, podendo seguir caminhos para a geração de organismos mais complexos.

Haja vista os fatores supracitados, a FBVS é usada quando se tem alvos com informações detalhadas dos seus sítios de ligação ativos ou quando ligantes maiores não apresentaram a eficácia necessária. Ela permite uma ”evolução” do fragmento por construção a partir do fragmento inicial, que se ligou ao alvo em locais de interesse (ERLANSON *et al.*, 2016), partindo da exploração de espaços químicos onde outros métodos de VS mais tradicionais talvez não encontrassem solução.

2.3.4 Triagem Virtual Híbrida

Fechando o ciclo de métodos mais usados de VS, a triagem virtual híbrida (HVS, do inglês *Hybrid Virtual Screening*), se destaca por usar uma abordagem que tem como parâmetro a estrutura e o ligante com chance de um resultado satisfatório por superar algumas limitações individuais dos métodos LBVS e SBVS, quando usados separadamente (VÁZQUEZ *et al.*, 2020). Ela se mostra muito eficiente em conjunto com a inteligência artificial e aprendizagem de máquina, criando modelos preditivos mais

[9] Índice de solubilidade.

eficientes (MAIA *et al*., 2020).

2.4 Ferramentas de CADD

Em relação aos processos de CADD e de VS, entende-se que exista diferentes formas de realizá-los. Atualmente, utiliza-se ferramentas específicas, cada uma com seus focos e especialidades, nas quais uma triagem pode ser produzida com a junção de mais de uma delas.

2.4.1 MolAr

O MolAr, ou Molecular Architect, é um *software* desenvolvido para facilitar o fluxo de trabalho no desenvolvimento de fármacos. Com o objetivo de centralizar os processos em uma interface automatizada, minimizando os erros humanos e facilitando processos como: a instalação de programas; a instalação de bibliotecas; a preparação do alvo; a execução e análise dos resultados.(MAIA *et al*., 2020)

Seu funcionamento ocorre de maneira estruturada, começando pela previsão da estrutura tridimensional com base na sequência de aminoácidos do alvo biológico. Quando esta não é conhecida ou apresenta lacunas, o MODELLER é aplicado. Após esse processo, caso necessário, realiza-se a protonação. Trata-se de uma etapa crucial, pois se ela não estiver em um estado adequado, interfere-se negativamente no processo de *docking*, já que influencia diretamente as reações biológicas (MAIA., 2019).

O processo de VS no MolAr segue três caminhos principais. O primeiro é o uso do AutoDock Vina (TROTT; OLSON, 2010), um *software* de *docking* e VS que gera uma lista ordenada pelos melhores resultados baseados na verificação de pontuações considerando seus argumentos e gradientes, derivada das funções de pontuação pelos argumentos passados anteriormente. Essa função de pontuação empregada realiza um processo de mutações e otimizações locais chamado Broyden-Fletcher-Goldfarb-Shanno (BFGS) (NOCEDAL; WRIGHT, 1999), considerando a posição, a orientação do ligante, os valores das torções para as ligações rotativas ativas no ligante e resíduos flexíveis, e os gradientes desses argumentos (TROTT; OLSON, 2010).

O segundo caminho é o DOCK 6, com um foco maior no processo de modelagem das interações do RNA e pequenas moléculas, utilizando métodos como Grid Score e abordagens mais específicas chamadas Generalized Born with Solvent-Accessible Surface Area (GB/SA) e Poisson-Boltzmann with Solvent-Accessible Surface Area (PB/SA). Esses métodos recalculam o posicionamento das moléculas e preveem suas poses de ligação, utilizando o modelo de mecânica molecular AMBER (Assisted Model Building with Energy Refinement) que difere do uso apenas do *Grid Score* que, por sua vez, é mais rápido e simples, mas não considera a energia do sistema, apenas nas

interações posicionais do receptor e ligante. Essa metodologia considera a energia total do sistema e a flexibilidade do receptor e do ligante. Permite-se, com isso, modelar melhores interações, e mais realistas, aumentando a precisão das previsões delas em ambientes biológicos (LANG *et al.*, 2009).

A terceira opção, quando possível, é a aplicação do Consensus Virtual Screening (CVS). Uma estratégia que, ao buscar robustez de resultados, utiliza da premissa de que a combinação de diferentes abordagens pode resultar em uma previsão mais precisa do modo de ligação de ligantes às proteínas, do que em relação ao uso de um único programa de forma isolada (MAIA., 2019). Usando dos dois últimos *softwares* citados, os seus resultados são combinados para gerar um resultado com as vantagens de aumento de precisão, redução de falsos positivos e melhoria nos posicionamentos de ligantes.

Todo processo é integrado numa interface simplificada, pensada para ser acessível as pessoas sem experiência em programação.

2.4.2 MOE

Desenvolvido pela Chemical Computing Group (CCG), o MOE é uma ferramenta do ramo da química medicinal que integra várias ferramentas, permitindo modelagem QSAR (Quantitative Structure-Activity Relationship) e o acoplamento molecular, além de outras funcionalidades em um único *software*. Sua principal função é o cálculo dos descritores moleculares 2D que são propriedades físicas, áreas superficiais subdivididas, contagens de átomos e descritores de matriz de adjacência, i3D (descritores tridimensionais internos) e x3D (descritores tridimensionais externos) que podem ser energia potencial, área de superfície, volume, forma, e cargas dependentes da conformação (VILAR; COZZA; MORO, 2008). Além desses descritores, é possível personalizar seu desenvolvimento a partir do SVL que, por sua vez, é uma linguagem própria do MOE na qual o usuário pode criar códigos para adequar sua pesquisa dentro do *software*. As metodologias suportadas por ele são: Regressão Linear Múltipla (MLR), Análise de Componentes Principais (PCA) e redes neurais artificiais (ANN), cada uma com sua aplicação específica nas atividades biológicas.

Além disso, o MOE tem outra aplicação importante, seu módulo de *docking* molecular, o MOE-Dock, que facilita a simulação do encaixe da molécula em ambiente tridimensional permitindo a previsão da interação das moléculas com os ligantes. As simulações, que podem ser ajustadas pelo próprio usuários, baseadas nos dados dos compostos que estão interagindo, ajudam a prever informações úteis à pesquisa.

2.4.3 GROMACS

Desenvolvido inicialmente na Universidade de Groningen, o GROMACS é uma ferramenta de código aberto utilizada extensamente pela sua eficiência e precisão no *docking* molecular de sistema biomoleculares como proteínas, lipídios, ácidos nucleicos, complexos e membranas celulares. Devido à sua excepcional capacidade de simulações em larga escala em nível atômico, ele permite que pesquisadores analisem o comportamento dinâmico das biomoléculas e investiguem as interações proteína-ligante de maneira eficiente. Durante o *docking*, o GROMACS integra equações de movimento de newton para cada átomo do sistema para gerar sua trajetória, representando a passagem de tempo da estrutura.

Ele foi pensado para aproveitar as arquiteturas modernas de CPU e GPU, reduzindo significantemente o tempo de espera para a realização de simulações. Esta capacidade de paralelização cria oportunidades de abranger sistemas de milhões de átomos, sendo um programa funcional em plataformas variadas como computadores até *clusters* de alta performance, mostrando-se uma ferramenta versátil para diversos estudos na área da química medicinal.

O GROMACS também se beneficia da sua comunidade ativa de desenvolvedores que contribuem continuamente para sua evolução, resultando em regulares adições de novos recursos e melhorias contínuas em sua interface e funcionalidade, fazendo-o conquistar um espaço grande no campo de pesquisa molecular (KUMARI *et al.*, 2014).

2.5 Inteligência Computacional aplicada a Triagem Virtual

A aplicação de Inteligência computacional para suporte do processo de VS tem sido mais forte ao longo das últimas décadas (ERLANSON *et al.*, 2016; CHAN, 2018). O suporte e a otimização geradas pelo seu uso melhorou os processos, conseguindo reduzir seu custo em tempo e melhorando sua assertividade baseado no uso desses algoritmos, criando um processo de constante evolução e mescla de técnicas computacionais avançadas na criação de novos medicamentos pelo uso de modelos preditivos.

2.5.1 Algoritmos Baseados em Similaridade

Os algoritmos baseados em similaridade usam como base o argumento, muito difundido, de que as estruturas semelhantes compartilham atividades biológicas semelhantes (JOHNSON; MAGGIORA; MEETING, 1990; OLIVEIRA *et al.*, 2023). O método de funcionamento baseado em similaridade vem da comparação de uma molécula referencial de atividade biológica conhecida com o resto da biblioteca escolhida para realização da triagem. Utilizando métodos matemáticos, como o coeficiente de Tanimoto

que é muito utilizado na química computacional (BAJUSZ; RÁCZ; HÉBERGER, 2015), são quantificadas as semelhanças entre as moléculas pelos seus atributos moleculares.

Além da possibilidade de uso em representações em duas dimensões, três dimensões ou de formas mais complexas como campos de interação molecular (MIFs, do inglês *Molecular Interaction Fields*), esse método é mais simples e rápido que os demais, pois não necessita de extensas quantidades de dados para criar modelos e pode ser combinado com outras abordagens para a melhoria de resultados (OLIVEIRA *et al.*, 2023). Por outro lado, pequenas variações na estrutura podem facilmente gerar falsos resultados.

2.5.2 Algoritmos Baseados em Aprendizado de Máquina

Algoritmos baseados em ML permitem a análise de gigantescas quantidades de dados com precisão e rapidez, pois eles conseguem identificar padrões nos atributos das moléculas de maneiras simples (BIAN *et al.*, 2023).

Ao receberem grandes conjuntos de dados, os algoritmos de ML são treinados, de maneira supervisionada ou não, a prever como atividades biológicas irão interagir entre si (OLIVEIRA *et al.*, 2023). Os tipos de algoritmos de ML mais usados incluem redes neurais artificias (ANNs), máquinas de vetores de suporte (SVMs), e métodos de aprendizagem profundos (*Deep Learning*).

Suas principais vantagens são a alta precisão na predição, o grande volume e a adaptação de dados (LAVECCHIA, 2015). Contudo, eles requerem uma extensa massa de dados para treinamento, tendo um grande custo computacional (OLIVEIRA *et al.*, 2023).

2.5.3 Algoritmos Genéticos

Algoritmos genéticos vem da abstração computacional do método de evolução natural para criar soluções para problemas. Eles são extremamente úteis em situações em que é possível realizar uma vasta busca e não é possível testar cada uma das possibilidades de maneira exaustiva (ALHIJAWI; AWAJAN, 2024).

No contexto do CADD, os algoritmos genéticos começam com uma população inicial de moléculas que vão se modificando ao longo de várias gerações, passando pelos processos comuns como mutações e cruzamento (i.e., *crossover*) ou recombinação (ALHIJAWI; KILANI, 2020). Após isso, usa-se uma análise baseada em uma *Fitness function* para quantificar a pontuação de cada indivíduo. Os melhores passam para a próxima geração até uma solução satisfatória ser encontrada.

Na etapa de VS desse algoritmo, são usadas as interações dos indivíduos com o alvo biológico. É possível explorar sua pontuação baseada em parâmetros como taxa de toxicidade, afinidade ou propriedades ideais (HASSANAT *et al.*, 2018).

Como vantagens, essa solução computacional tem um grande destaque para problemas complexos de otimização, mas como revés se destacam seu alto custo computacional e tempo de processamento, este que pode ser extenso dependendo do espaço de busca usado (OLIVEIRA *et al.*, 2023).

2.5.4 Algoritmos Baseados em Meta-Heurísticas

Meta-Heurísticas são estratégias que visam aproximar soluções para problemas complexos (PERES; CASTELLI, 2021). Essas técnicas geralmente são usadas quando métodos tradicionais falham em encontrar ótimas soluções de forma eficiente. No domínio da CADD, essas estratégias testam diferentes soluções e se ajustam baseando-se em um conjunto de regras guiado por métodos como: a busca tabu, a busca simulada (i.e., *simulated annealing*) e a otimização por enxame de partículas (PSO)(OLIVEIRA *et al.*, 2023).

Esse método apresenta bom desempenho para otimizações de *docking*, ele identifica espaços conformacionais dentro do sítio de ligação, explora e busca formas eficazes de posicionar o composto. Ao lidar com esse processo, podem existir múltiplos locais de energia, dificultando o processo de *docking*, mas com o uso da meta-heurística é possível maximizar a chance de encontrar posições mais favoráveis para o composto dentro do sítio ativo. Portanto, ele garante uma busca de posicionamento mais eficaz, mesmo em cenários de múltiplos locais de energia (OLIVEIRA *et al.*, 2023).

Suas principais vantagens estão na capacidade de evadir de soluções locais, em que o algoritmo se estagna, encontrando uma solução global ótima. Sua alta flexibilidade e aplicabilidade em diferentes problemas é uma grande qualidade. No entanto, seu processamento computacional pode ser extensivo e não garantir uma solução ótima, mas uma aproximação (CHOPARD *et al.*, 2018).

2.6 Considerações

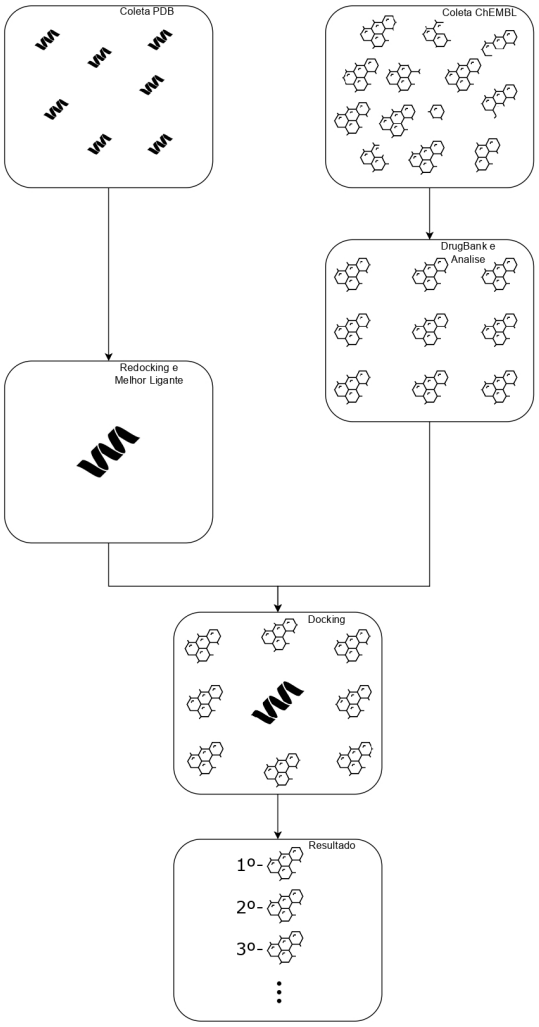
Em síntese, o processo de desenvolvimento de fármacos tem evoluído significativamente pelo auxílio computacional e, atualmente, apresenta diversas formas de ser implementado. Essas técnicas permitem acelerar a identificação de compostos promissores *hits* que podem servir como antagonistas eficazes para doenças emergentes e resistentes como, nesse caso, a infecção causada pela CA.

3 METODOLOGIA

Neste capítulo será abordado os processos necessários para a realização da VS baseada na estrutura da CA, uma levedura com grande virulência. As sessões a seguir têm como objetivo descrever os processos da CADD aplicada a VS. Para isso, foi escolhida uma estruturação em tópicos para melhor inteligibilidade do fluxo dos passos realizados no processo de pesquisa, desde a escolha do composto até a seleção das moléculas mais promissoras para produção de um futuro fármaco.

A Figura 1 detalha o processo adotado neste trabalho para compor a estratégia, a partir da identificação do melhor alvo, utilizada na identificação de bons *hits* para a CA.

Figura 1 – Fluxo Metodológico do Trabalho



Fonte: Próprio Autor.

3.1 Coleta dos Dados

O processo se iniciou com a identificação, o tratamento e a seleção de dados para exploração, a fim de aplicar a CADD no estudo da CA, foco deste trabalho. O primeiro passo é observar quais complexos moleculares seriam utilizados como alvos terapêuticos, servindo como base para a análise dos múltiplos compostos extraídos. Nesse contexto, recorre-se ao banco de dados *Protein Data Bank* (PDB) para obter as enzimas diretamente associadas a CA. O processamento dos dados foi auxiliado por pacotes de Bioinformática especializados nessa coleta, esse que tem como objetivo a simplificação do CADD, além de um auxílio de especialistas para o direcionamento de escolha de melhores alvos.

A Coleta dos PDBs foi realizada com uma busca direcionada ao alvo "Candidaauris". O retorno esperado eram as proteínas que tinham a "Candidozyma auris"em seu campo de organismo, nome científico da levedura escolhida, atentando-se também se sua documentação foi realizada pelo processo de cristalografia de raio X. Após a obtenção, determinou-se quais estruturas possuíam uma qualidade superior para a utilização, realizando-se uma análise dos complexos presentes, verificando seu atributo de resolução, além dos ligantes conectados e a completude de informações da mesma.

Paralelamente, deu-se a varredura na base de dados ChEMBL, um repositório público de componentes com mais de 67.000 publicações e patentes de bio-ativos, aleém de 15 milhões de medições de bioatividade para 1,8 milhão de compostos distintos (MENDEZ *et al.*, 2019). O ponto de partida escolhido foi o "CHEMBL4513186", denominado pelo site como *[Candida] auris*. Ao catalogar todos os bioativos relacionados, foi identificado um vasto escopo de similares. A análise foi então restringida a abranger os bioativos de maior similaridade de suas concentrações inibitórias médias (IC50), resultando um total de 681 estruturas.

É importante ressaltar que esses bancos de dados têm limitações. Os dados do ChEMBL podem variar devido aos fatores como: ensaios experimentais de baixa qualidade; divergências metodológicas; condições específicas em que os experimentos de coleta foram realizados; a falta de atualizações em projetos. Essas questões podem comprometer a relevância e precisão das informações disponíveis, ou seja, uma análise mais crítica se torna necessária para utilizar os dados e assegurar a confiabilidade dos resultados.

3.2 Análise de Dados

Para a análise dos dados, computou-se a similaridade estrutural entre os similares obtidos no ChEMBL, justificando-se pela teoria de que as estruturas semelhantes tendem a apresentar propriedades biológicas semelhantes (JOHNSON; MAGGIORA; MEETING, 1990; CHAN, 2018).

A análise citada considerou a sobreposição da estrutura sobre o nosso alvo

molecular, cuja finalidade é verificar quanto as moléculas se alinham, já que as informações delas possuem funcionamentos similares, mas não são alinhadas diretamente, o que é respectivamente um método Alignment-free, (WILLETT, 2006) gerando os coeficientes de similaridade, calculados utilizando o coeficiente de Tanimoto como métrica e gerando um arquivo .CSV.

O arquivo .CSV em questão é um DrugBank de moléculas, em que foram amputadas as moleculas fragmentadas, ou com propriedades moleculares faltosas, que compartilham características que possivelmente podem antagonizar a CA, configurando-se assim a abordagem de um algoritmo baseado em similaridade (OLIVEIRA *et al.*, 2023).

Para a avaliação mais detalhada dos compostos que constituem esse DrugBank eles foram convertidos em um arquivo .SFD e abertos no *software* DataWarrior. Essa ferramenta é usada para análise de dados químicos e permite uma visualização interativa, possibilitando a identificação de quais padrões foram correlacionados para a formação desse grupo (SANDER *et al.*, 2015). Foram selecionados, para a etapa de docking, apenas os padrões com maior potencial, considerando tanto os valores de "Drug-likeness", entre 2 e 3, quanto se são mutagênicos ou tumorogênicos.

Ademais, realizou-se uma análise molecular de todos os padrões filtrados, gerando fingerprints, que são representantes das propriedades químicas e estruturais, além de físico-químicas, de conjuntos químicos em larga escala de uma forma de baixo custo computacional (YANG *et al.*, 2022). Utilizando os dados do DrugBank, performou-se o K-Means possibilitando organizar os *clusters* e sua visualização para o estabelecimento de centroides. Com essa identificação, são modeladas tabelas onde estão em evidência o Máximo Componente Conectado (MCC), seus dados são obtidos baseados em relacionamentos calculando o coeficiente Tanimoto para cada par de moléculas conectadas de um conjunto. O coeficiente de Tanimoto calculou a similaridades entre dois compostos com base em seus *fingerprints* binários, considerando o número de características presentes em cada molécula e o numero de características compartilhadas. Quanto maior a semelhança entre os compostos, mais proximo de 1 será o valor de Tanimoto, indicando alta similaridade. Além disso, as leis De Morgan são aplicadas em conjunto para realizar as operações de interseção e união entre os conjuntos de características encontrados, facilitando a análise e o cálculo preciso do coeficiente de Tanimoto (YING *et al.*, 2021).

3.3 Realização do *Redocking*

Em seguida, foi realizada a etapa de *redocking*, que se iniciou com uma análise visual detalhada das *pequenas moléculas* presentes na documentação do arquivo .PDB. O objetivo dessa análise foi identificar quais ligantes estavam melhor posicionados sobre

o sítio de ligação do receptor, descartando aqueles que não seriam boas opções para a etapa seguinte. Durante esse refinamento, foram removidos resíduos irrelevantes para a simulação, garantindo um foco exclusivo nos ligantes.

Após essa filtragem, procedeu-se ao *redocking*, que consiste na ancoragem do ligante selecionado novamente no receptor, utilizando o software Vina. Para validar o modelo gerado, comparou-se a pose original do ligante, conforme presente no PDB, com a nova pose obtida. O critério de avaliação utilizado foi o RMSD, que mede a diferença entre essas conformações. Valores baixos de RMSD indicam uma sobreposição significativa entre as poses, demonstrando que o Vina conseguiu reproduzir a conformação original do ligante. Dessa forma, um baixo RMSD valida o complexo ligante-receptor como uma boa estrutura para estudos posteriores, assegurando a confiabilidade da simulação de *docking*.

Antes do prosseguimento experimental, foi necessário verificar a presença de loops faltantes na estrutura. Caso algum loop fosse identificado como faltante, seria corrigido com auxílio do MODDELER no *software* Chimera.

3.4 Realização do *Docking*

Por fim, o *docking* foi realizado, ele consiste em posicionar o ligante específico dentro do sítio da proteína para identificar sua conformação e energia de ligação mais favoráveis entre os dois. Para aumentar a confiabilidade dos resultados, foram utilizadas mais de uma ferramenta de *docking*, neste caso o Vina e o Dock6. O uso de diferentes *softwares* se mostra vantajoso, haja vista que cada ferramenta pode explorar conformidades e calcular energias distintas, reduzindo os vieses individuais de cada programa e gerando uma análise de maior precisão. Esse dados foram quantificados mediante à utilização do conceito de consenso, realizando a média dos resultados gerados pelos 2 programas, além disso, os melhores desempenhos foram normalizados de 0 a 1. Esse processo tem como objetivo apresentar resultados mais robustos e destacar compostos mais promissores para estudos futuros.

3.5 Análise Final

Os compostos com as melhores pontuações pelo consenso, e com as ligações energéticas mais satisfatórias, foram abertos no DiscoveryStudio para verificar suas ligações. O critério estabelecido foi que, na interação, o ligante deveria apresentar mais de três ligações com o receptor da CA. Esses compostos também foram avaliados pela utilização do SwissADME, com o enfoque principal nas suas propriedades de Drug-likenness. (KIRKMAN *et al.*, 2023). A avaliação seguirá as diretrizes de duas regras apresentadas na Tabela 1.

A primeira regra considerada foi a *Rule of Five de Christopher Lipinski* (LIPINSKI *et al.*, 1997), que avalia adequação de compostos para farmacos com boa absorção oral. São definidos critérios baseados nas propriedades físico-químicas que, quando atendidos, aumentam a probabilidade de sucesso do composto como um fármaco. Elas incluem: Massa molecular (MW), uma vez que compostos grandes tendem a ter dificuldade de atravessar membranas celulares, números específicos de doadores (HBD) e receptores de hidrogênio (HBA), além de seu valor de logP que representa sua absorção pelo corpo humano.

A segunda regra utilizada foi a *Veber's Rules for Oral Bioavailability*, proposta por David F. Veber, que foca em dois fatores principais: a flexibilidade molecular e as interações hidrofílicas (VEBER *et al.*, 2002). O primeiro fator é avaliado pelo número de ligantes rotacionaveis, já que moléculas altamente flexíveis têm dificuldade em atravessar membranas celulares. O segundo fator é referente à área polar da superfície molecular (TPSA), pois áreas excessivamente grandes dificultam a difusão do composto através de membranas internas das células.

Essa abordagem é útil para tentar prever o comportamento dos compostos no organismo, pois as regras têm um caráter complementar e essas duas tendem a ser aplicadas juntas, logo, esse processo foi realizado com todos os compostos que possam vir a ser *hits* para o combate à CA.

Tabela 1 – Resumo das regras de propriedades farmacológicas.

Regra	**MW (Da)**	**LogP**	**HBD**	**HBA**	**TPSA (Å²)**	**Ligações Rotativas**
Lipinski	≤ 500	≤ 5	≤ 5	≤ 10	-	-
Veber	-	-	≤ 12	≤ 12	≤ 140	≤ 10

4 RESULTADOS E ANÁLISES

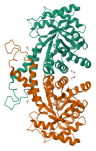
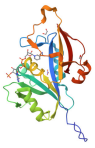
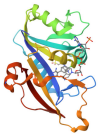
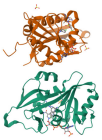
Ao longo desse capítulo, os resultados adquiridos em cada etapa do processo serão discutidos, além do que pode ou foi possível observar em cada um dos processos realizados durante a VS. O objetivo primário é encontrar *hits* capazes de se ancorar efetivamente na CA a partir do processo detalhado na metodologia.

Cada etapa experimental gerou dados específicos para a análise. O *workflow* desenvolvido demandou revisão contínua dos procedimentos anteriores, aumentando a consistência da pesquisa e facilitando o avanço nas fases posteriores.

4.1 Resultados da Coleta

A coleta dos PDBs retornou um conjunto de 5 estruturas (Tabela 2) que são representações da Candida auris documentadas no PDB, das quais, em seu artigo de estudo, a fonte não foi publicada até o momento de realização desse trabalho, seguindo 3 com a menor resolução, pois na situação de análise, apesar de resoluções mais baixas não capturarem detalhes finos, elas podem ser melhores para identificar a conformação geral de uma molécula (AMBROSIO; FRANCHINI, 2017).

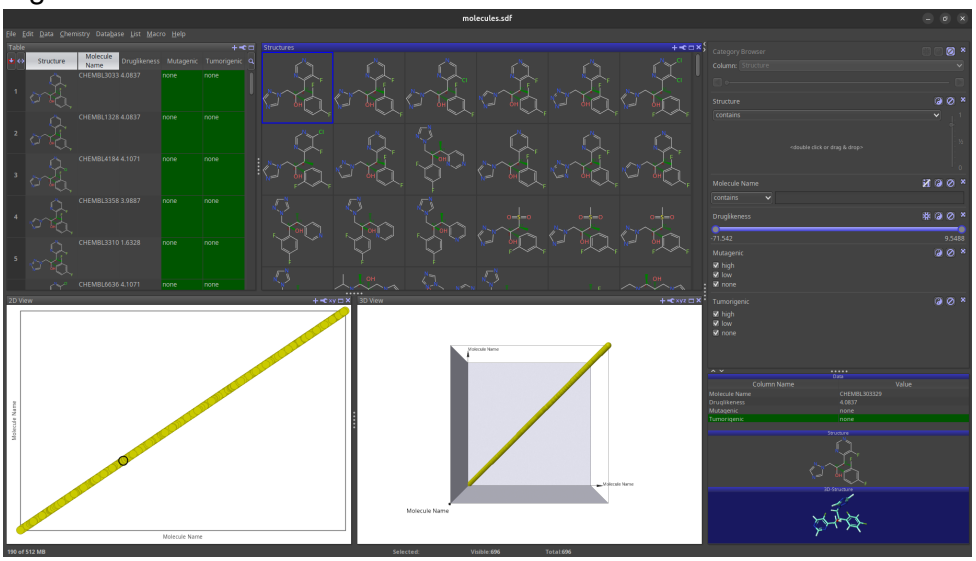
Tabela 2 – Estruturas encontradas na coleta dos PDBs

Molécula	**Resolução**	**Fonte**	**Estrutura**
6VSI	1.87 Å	(BASHIR *et al.*, 2020)	
7RGN	2.20 Å	A ser publicado	
8A0N	1.40 Å	(KIRKMAN *et al.*, 2023)	
8A0Z	1.70 Å	A ser publicado	
8CRH	1.30 Å	(KIRKMAN *et al.*, 2023)	

4.2 Resultados da análise

Durante a segunda fase, seguindo a metodologia, foi gerado o .CSV com os similares extraídos da base de dados ChEMBL em boas condições de uso experimental. Com esse arquivo foi montado o .SDF, possibilitando a análise que será realizada no *software* DataWarrior (Figura 7). Essa etapa permitiu avaliar propriedades físico-químicas, riscos toxicológicos e características de ADMET (Absorção, Distribuição, Metabolismo, Excreção e Toxicidade) ao utilizar as ferramentas de cálculo de propriedades químicas da estruturas presentes nesse *software*. Com as propriedades calculadas, foi gerado outro arquivo .CSV que facilitou a identificação e exclusão de compostos com potenciais riscos tumorogênicos, mutagênicos e com valor de DrugLikness fora do escopo de 2 e 3, otimizando a seleção de compostos para as etapas subsequentes do procedimento.

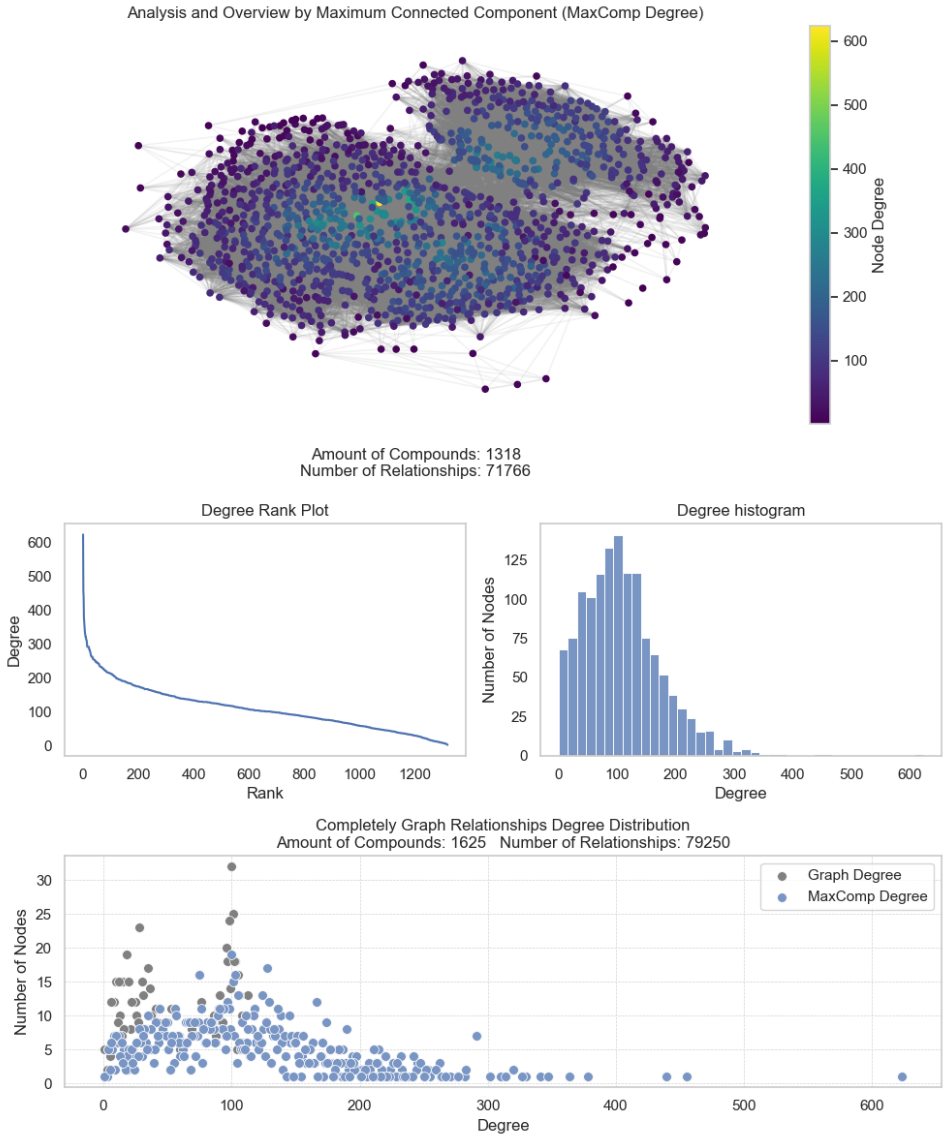
Figura 2 – Moléculas.sdf no DataWarrior



Fonte: DataWarrior.

Antes de prosseguir, foi realizada uma análise das moléculas reunidas nos processos anteriores, revelando informações significantes representadas pela Figura 3 que será explicada a seguir. Na plotagem do grafo de relacionamentos entre os componentes, observou-se um comportamento específico: a maior parte das moléculas similares apresenta menos de 300 conexões, num montante de 1318 componentes analisados. Apenas 0,99% dos compostos apresentando entre 300 e 600 relacionados, mostrando-se exceções.

Figura 3 – Distribuição e conectividade entre as moléculas analisadas.



Fonte: Próprio Autor.

Cada nó representa uma molécula, enquanto as arestas indicam as conexões entre elas. A escala de cores a direita, variando de roxo a amarelo, reflete o grau do nó, ou seja, seu número de relacionamentos. As variantes mais amarelas indicam maior grau, identificando visualmente moléculas mais centrais e com mais interações na rede.

Utilizou-se todas as moléculas adquiridas na primeira etapa pelo ChEMBL, incluindo seus similares, totalizando 1316 compostos analisados, somando 70.899 relacionamentos identificados.

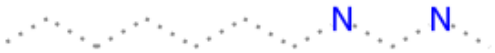
O *Degree Rank Plot*, à esquerda, ordena os nós conectados ao MMC de acordo com seu grau, do maior para o menor. Esse gráfico evidencia a queda do grau em função do *rank*, indicando que poucas moléculas possuem grau elevado e gerando poucos compostos centrais.

O *Degree histogram* apresenta a frequência de moléculas conectadas ao MMC para diferentes graus. A maior parte dos compostos está entre 0 e 300, enquanto uma pequena parcela está presente entre 300 e 600, reforçando a centralização da conectividade.

Por fim, a tabela *Completely Graph relationships Degree Distribuition* compara a distribuição dos graus entre dois conjuntos: *Graph Degree* (pontos cinza) que se refere ao grau total das moléculas não consideradas pelo MMC no grafo completo; e o *MaxComp Degree* (pontos azuis) que se refere ao grau das moléculas que possuem relações com o componente maximamente conectado. Essa comparação consolida a visão de que a maioria dos componentes possuem baixa conectividade, com poucos compostos se destacando como altamente conectados e também quantifica quantos compostos não foram considerados nessa análise.

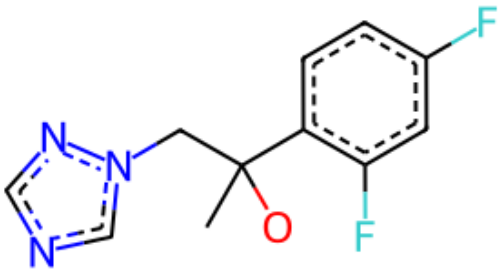
Com isso, os centroides desses grafos explicados acima, foram plotados para visualização e foram salvos para análise futura sendo apresentados nas figuras 9 e 10.

Figura 4 – Centróide da análise de moléculas e similares.



Fonte: Próprio Autor.

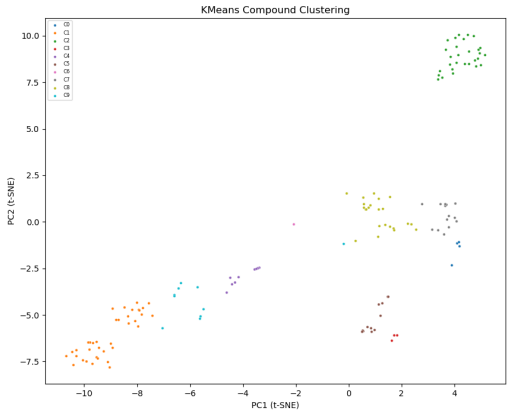
Figura 5 – Centróide da análise apenas das moléculas.



Fonte: Próprio Autor.

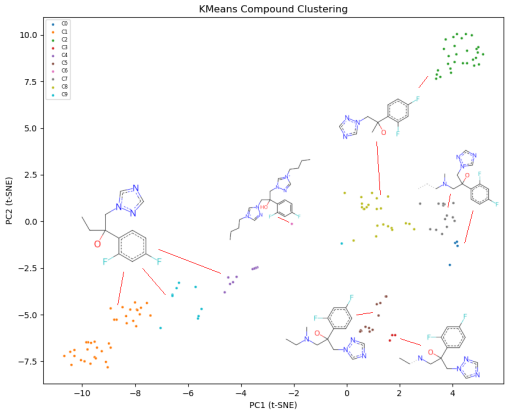
Com o uso do K-means foram plotados um total de 9 *clusters*. Escolha baseada na utilização do algoritmo de *elbow* (CUI *et al.*, 2020), que visa determinar o menor número possível ao identificar pontos que o aumento do número de *clusters* não impacta na sua variação, otimizando os dados sem comprometer sua representatividade. O ponto principal desse processo é a identificação dos *scaffolds*, ou os centroides, de cada um desses *clusters*, permitindo a análise aprofundada da possível sobreposição de padrões entre os diferentes grupos que pode apresentar um fragmento importante na busca de melhores fármacos.

Figura 6 – K-means dos componentes.



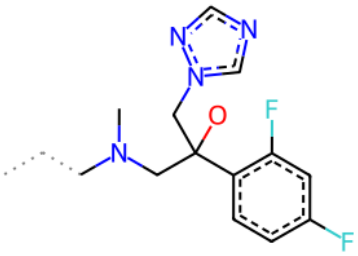
Fonte: Próprio Autor.

Figura 7 – K-means dos componentes com seus Centroides.



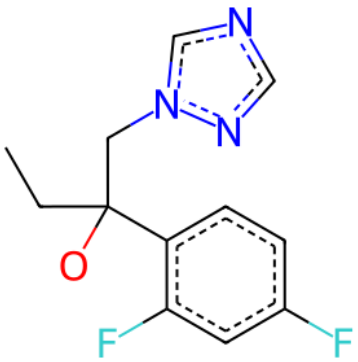
Fonte: Próprio Autor.

Figura 8 – Centroide cluster 0 e 7.



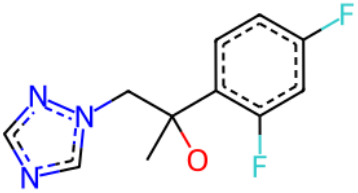
Fonte: Próprio Autor.

Figura 9 – Centroide cluster 1, 4 e 9.



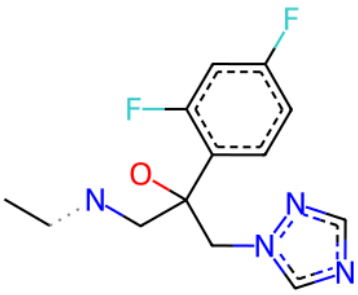
Fonte: Próprio Autor.

Figura 10 – Centroide cluster 2 e 8.



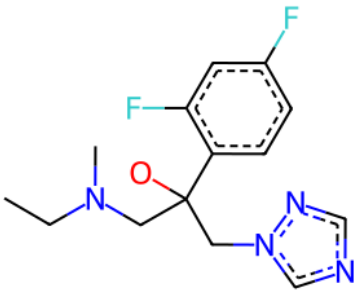
Fonte: Próprio Autor.

Figura 11 – Centroide cluster 3.



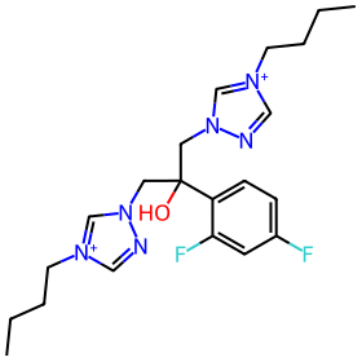
Fonte: Próprio Autor.

Figura 12 – Centroide cluster 5.



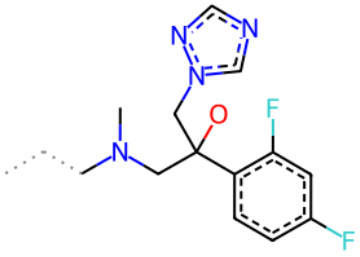
Fonte: Próprio Autor.

Figura 13 – Centroide cluster 6.



Fonte: Próprio Autor.

Figura 14 – Centroide cluster 7.



Fonte: Próprio Autor.

4.3 Resultados do *Redocking*

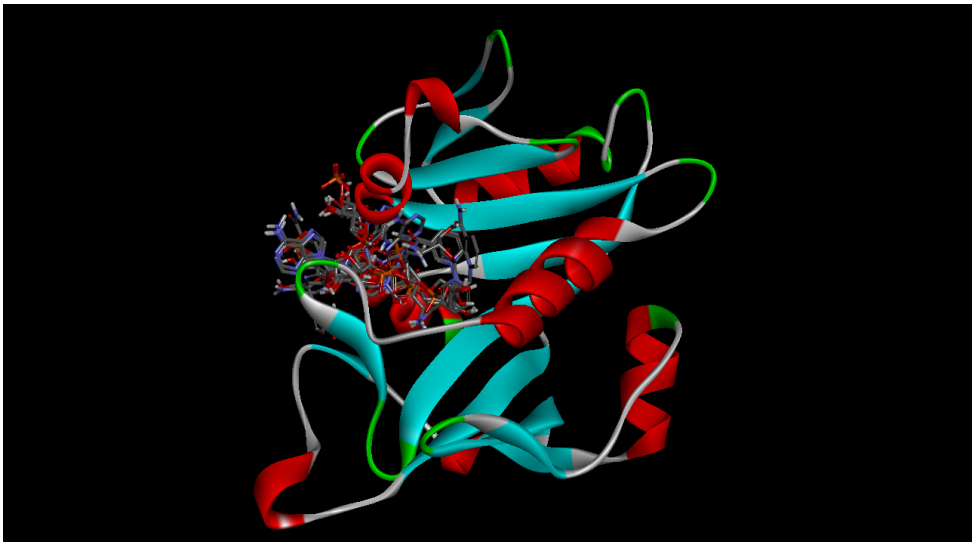
Como descrito na metodologia, para os PDBs selecionados da fase de coleta, foi realizada uma análise visual, baseada na documentação para separar os ligantes dos resíduos presentes nos arquivos do PDB. Em seguida, foi realizado o *redocking* para cálculo do valor de RMSD, a fim de validar os compostos mais relevantes para o seguimento do trabalho. Foram escolhidos para realização do *Redocking*: NDP para os PDBs 8A0N e 8CRH; CP6 para o 8A0Z; e o VIL para o 8CRH.

Tabela 3 – Pares Selecionados

PDB	Ligante	Número do Resíduo	Cadeia	Resolução (Å)	RMSD
8CRH	NDP	302	B	1.3 Å	1.024202823638916
8CRH	VIL	301	B	1.3 Å	1.1337494850158691
8A0N	NDP	301	B	1.4 Å	0.9357826113700868
8A0Z	CP6	302	B	1.7 Å	4.163762092590332

Seguindo a metodologia, o melhor alvo identificado na análise Receptor-Ligante foi o 8CRH-NDP, especificamente o 302, localizado na cadeia B, ilustrada. Este alvo foi selecionado pela sua alta qualidade estrutural, com 1.3 Å de resolução e um RMSD de 1.0242. Após essa escolha, foi realizada a verificação de possíveis loops faltantes com o *software* MODDELER com auxílio do Chimera, pois após encontrar o melhor receptor possível é necessário verificar se existem *loops* faltantes em toda a estrutura para garantir a integridade da próxima etapa.

Figura 15 – Conformações do NDP (302 B) no sítio de ligação da CA



Fonte: Proprio Autor.

4.4 Resultados do *Docking*

Com os 1319 compostos do DrugBank gerados com o auxílio do ChEMBL e o melhor receptor encontrado pelo *Redocking*, a ultima etapa foi executada. O *docking* foi realizado como descrito na metodologia seguindo primeiro no Vina, após isso com o Dock6 e seus resultados, 10 compostos foram tabelados do melhor, com o consenso mais proximo de 1.00 apos a normalização, ao pior e nomeados num padrão: Estrutura da CA_Composto ChEMBL utilizado.

Foi avaliada a localização de cada um desses compostos dentro da clusterização realizada na etapa de análise (Tabela 4). Observou-se que sete dos dez compostos estavam predominantemente no segundo cluster, enquanto os três restantes se encontravam nos *clusters* cinco e oito, que são próximos do segundo *cluster*, onde o centroide do *cluster* oito num cenário de overlapping, tem seu *scaffolds* idêntico ao dele. Essa distribuição gerou um ponto de atenção para o *cluster* dois.

Por fim, para provar o potencial das moléculas como possíveis *hits*, utilizou-se como descrito na metodologia o DiscoveryStudio para verificar o número de ligações de cada resultado obtido. O critério estabelecido foi que na interação o ligante deveria apresentar

Tabela 4 – Ranking Molécular de Docking por Consenso

Rank	Molécula	Vina	Dock6	Consenso	Cluster
1º	8CRH_CHEMBL3736434	1.00	0.75	0.88	5
2º	8CRH_CHEMBL4475747	0.67	1.00	0.84	2
3º	8CRH_CHEMBL4458614	0.82	0.73	0.77	2
4º	8CRH_CHEMBL4870228	0.63	0.86	0.74	5
5º	8CRH_CHEMBL1255047	0.67	0.78	0.73	2
6º	8CRH_CHEMBL3221229	0.77	0.68	0.73	2
7º	8CRH_CHEMBL4294930	0.83	0.61	0.72	8
8º	8CRH_CHEMBL2018928	0.92	0.53	0.72	2
9º	8CRH_CHEMBL1254317	0.59	0.83	0.71	2
10º	8CRH_CHEMBL3221227	0.71	0.70	0.71	2

mais de três ligações com o receptor da CA. Os resultados atenderam às expectativas e todas apresentaram um número de ligações superior ao mínimo. As imagens detalhadas do DiscoveryStudio, juntamente com as legendas das interações, podem ser encontradas no Anexo A.

Tabela 5 – Ligações do resultado do Docking Molecular na CA (1º ao 5º)

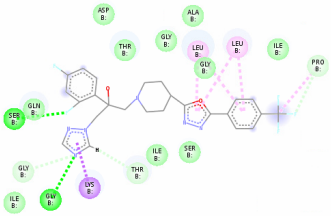
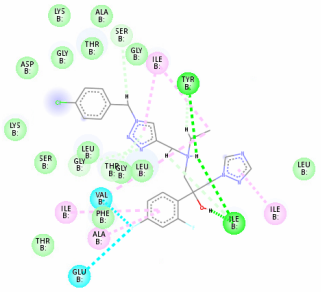
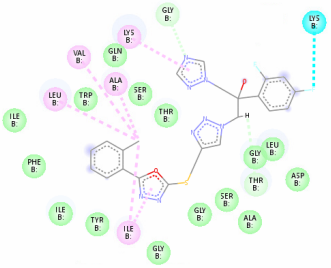
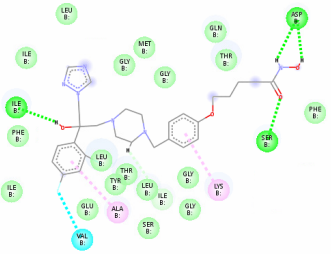
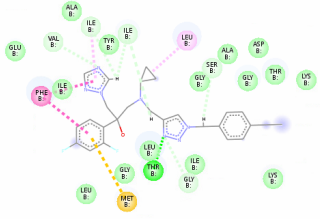
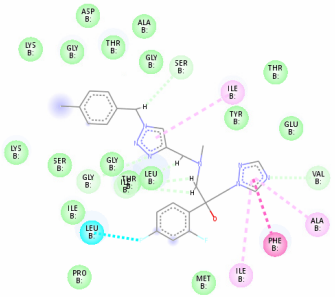
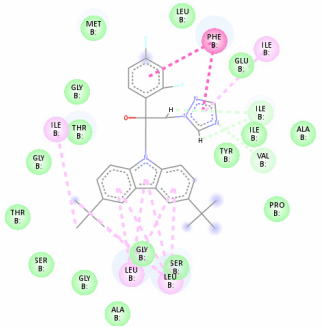
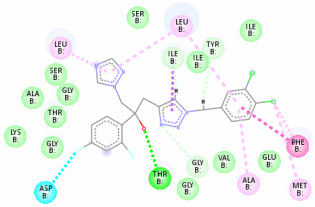
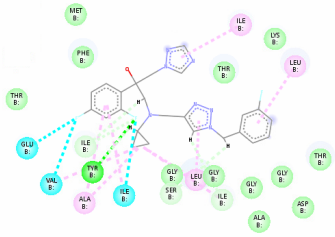
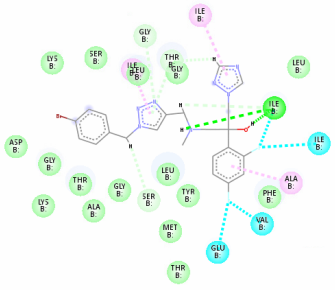
Ranking	Molécula	Estrutura
1º	CHEMBL3736434	
2º	CHEMBL4475747	
3º	CHEMBL4458614	
4º	CHEMBL4870228	
5º	CHEMBL1255047	

Tabela 6 – Ligações do resultado do Docking Molecular na CA (6º ao 10º)

Ranking	Molécula	Estrutura
6º	CHEMBL3221229	
7º	CHEMBL4294930	
8º	CHEMBL2018928	
9º	CHEMBL1254317	
10º	CHEMBL3221227	

4.5 Resultados Complementares

A apuração complementar se iniciou com uma síntese das dez estruturas resultantes do processo de *docking*, sendo analisadas uma a uma pelo *software* ”Swissadme” verificando suas propriedades farmacológicas baseadas nas regras de Lipinsk e Veber. Montou-se uma tabela para a visualização, com informações de aplicação farmacológica de cada um já presente.

Tabela 7 – Violações e Biodisponibilidade dos compostos do *Docking*

Rank	**Molécula**	**Lipinski**	**Veber**
1º	CHEMBL3736434	1	0
2º	CHEMBL4475747	0	0
3º	CHEMBL4458614	1	1
4º	CHEMBL4870228	1	1
5º	CHEMBL1255047	0	1
6º	CHEMBL3221229	0	0
7º	CHEMBL4294930	2	0
8º	CHEMBL2018928	0	0
9º	CHEMBL1254317	0	0
10º	CHEMBL3221227	1	0

Os centroides também foram considerados para realização da análise baseada nas regras para criação de fármacos, pois esses *scaffolds* apresentam bases para melhorias de moléculas que estão violando alguma regra e possam atrapalhar o desenvolvimento do processo de produção de fármaco. Os *cards* com as informações completas de cada um desses compostos se encontram no Anexo B.

Tabela 8 – Violações e Biodisponibilidade dos compostos centroides

Molécula	**Lipinski**	**Veber**
Ctr. análise	0	0
Ctr. Clust. 0 e 7	0	0
Ctr. Clust. 1 4 e 9 (CHEMBL4292090)	0	0
Ctr. Mol. Clust. 2 e 8 (CHEMBL4281467)*	0	0
Ctr. Clust. 3	0	0
Ctr. Clust. 5*	0	0
Ctr. Clust. 6 (CHEMBL1852085)	0	1

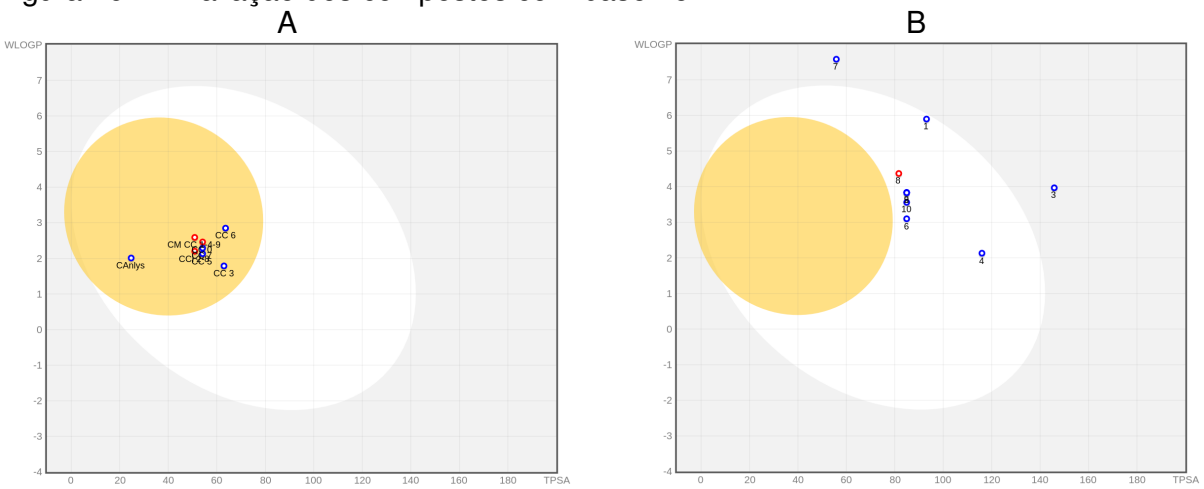
Adiante, efetuou-se um ranqueamento no qual priorizou-se os compostos com as melhores propriedades farmacológicas, conforme apresenta a metodologia baseada nas regras de Linpinsk. (SANTOS; GONSALVES; ARAÚJO, 2018), Ghose, Veber, Egan, Muegge (FERREIRA; ANDRICOPULO, 2019), além de verificar sua Biodisponibilidade e usar como parâmetro secundário de ordenação o número de átomos da estrutura.

Tabela 9 – Ranqueamento por Violação de Regras e Bioatividade das Moléculas

Molécula	**Lipinski**	**Veber**	**Numero de átomos**	**Total de Violações**
Ctr. Clust. 2 e 8 (CHEMBL4281467)*	0	0	17	0
Ctr. Clust. 1 4 e 9 (CHEMBL4292090)	0	0	18	0
Ctr. Clust. 3	0	0	20	0
Ctr. Clust. 5*	0	0	21	0
Ctr. Clust. 0	0	0	22	0
Ctr. Clust. 7	0	0	22	0
8º CHEMBL2018928	0	0	31	0
6º CHEMBL3221229	0	0	33	0
2º CHEMBL4475747	0	0	34	0
9º CHEMBL1254317	0	0	35	0
Ctr. análise	1	0	11	1
Ctr. Clust. 6 (CHEMBL1852085)	0	1	30	1
10º CHEMBL3221227	1	0	33	1
5º CHEMBL1255047	0	1	36	1
3º CHEMBL4458614	1	1	36	2
1º CHEMBL3736434	1	1	38	2
7º CHEMBL4294930	2	0	38	2
4º CHEMBL4870228	1	1	39	2

Outra análise pertinente realizada foi a das propriedades ADMET, (Figura 18) para prever se a molécula consegue passar pelo processo de absorção intestinal humana (parte branca) e/ou penetrar a barreira hematoencefálica (parte amarela), uma estrutura altamente seletiva e protetora que regula o fluxo de substâncias entre o sangue e o cérebro (DAINA; ZOETE, 2016). Logo, é visto que, exceto as moléculas ”3º CHEMBL4458614” e ”7º CHEMBL4294930” as restantes podem apresentar algum nível de absorção no corpo humano pelas suas posições dentro do grafico da figura 25.

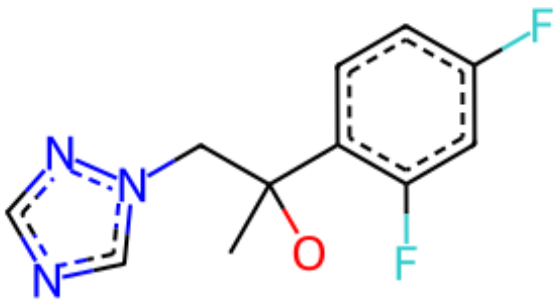
Figura 16 – Avaliação dos compostos com base no ADMET



Fonte: Próprio Autor.

O ponto de maior destaque foi a presença constante da CHEMBL4281467. Seu *scaffold* foi o centróide do *cluster* com o maior número de moléculas no *docking* o grupo 2 e apareceu novamente como centróide no grupo 8.

Figura 17 – Centroide Molécular e dos *clusters* 2 e 8, detectado na análise de clusterização e identificado em todas as moléculas de possíveis hits desse trabalho (CHEMBL4281467)



Fonte: Proprio Autor.

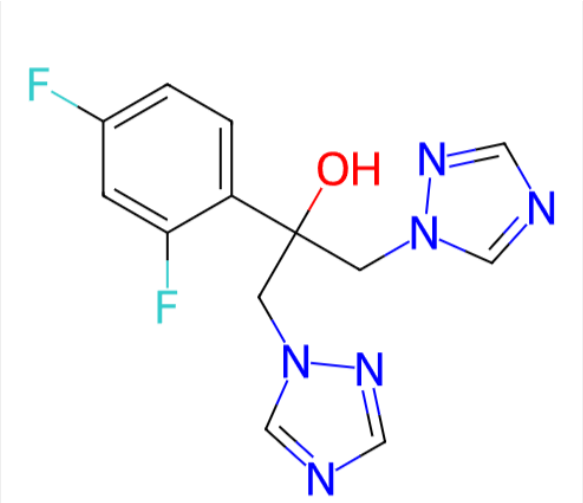
Esta foi a molécula com o maior número de interações na etapa de análise de dados (Figura 5). Sua presença continuou em todas as melhores moléculas do consenso e centroides como visto pela Tabela 10, demonstrando uma importância significativa para a pesquisa.

Tabela 10 – Análise dos centroides dos *clusters* e das moléculas encontradas no Docking ranqueadas por consenso baseada no CHEMBL4281467

Molécula	Consenso	SMILE Canônico
Ctr. Mol. Clust. 2 e 8 (CHEMBL4281467)	-	**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
Ctr. análise	-	CN(**CC(O)(Cn1cncn1)c1ccc(F)cc1F**)ccc
Ctr. Clust. 1 4 e 9 (CHEMBL4292090)	-	C**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
Ctr. Clust. 3	-	CCN**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
Ctr. Clust. 5	-	CCN(C)**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
Ctr. Clust. 6 (CHEMBL1852085)	-	CCCC[n+]1cnn(**CC(O)(Cn2c[n+]**(CCCC)**cn2)c2ccc(F)cc2F)c1**
Ctr. Clust. 0	-	CN(**CC(O)(Cn1cncn1)c1ccc(F)cc1F**)ccc
Ctr. Clust. 7	-	CN(Ccc)**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
1º - CHEMBL3736434	0.88	OC(CN1CCC(c2nnc(-c3ccc(C(F)(F)F)cc3)o2)CC1)**(Cn1cncn1)c1ccc(F)cc1F**
2º - CHEMBL4475747	0.84	CCN(Cc1cn(Cc2ccc(Cl)cc2)nn1)**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
3º - CHEMBL4458614	0.77	Cc1ccccc1-c1nnc(SCc2cn(**CC(O)(Cn3cncn3)c3ccc(F)cc3F)**nn2)o1
4º - CHEMBL4870228	0.74	O=C(CCCCOc1ccc(CN2CCN(**CC(O)(Cn3cncn3)c3ccc(F)cc3F)**CC2)cc1)NO
5º - CHEMBL1255047	0.73	CCc1ccc(Cn2cc(CN(**CC(O)(Cn3cncn3)c3ccc(F)cc3F)**C3CC3)nn2)cc1
6º - CHEMBL3221229	0.73	Cc1ccc(Cn2cc(CN(C)**CC(O)(Cn3cncn3)c3ccc(F)cc3F)**nn2)cc1
7º - CHEMBL4294930	0.72	CC(C)(C)c1ccc2c(c1)c1cc(C(C)(C)C)ccc1n2**CC(O)(Cn1cncn1)c1ccc(F)cc1F**
8º - CHEMBL2018928	0.72	**OC**(Cc1cn(Cc2ccc(Cl)c(Cl)c2)nn1)**(Cn1cncn1)c1ccc(F)cc1F**
9º - CHEMBL1254317	0.71	**OC**(CN(Cc1cn(Cc2cccc(F)c2)nn1)C1CC1)**(Cn1cncn1)c1ccc(F)cc1F**
0º - CHEMBL3221227	0.71	CN(Cc1cn(Cc2ccc(Br)cc2)nn1)**CC(O)(Cn1cncn1)c1ccc(F)cc1F**

Além disso, observa-se que a CHEMBL4281467 é um fragmento derivado do fluconazol, um fármaco antimicótico amplamente utilizado. Embora Candida auris apresente resistência a esse medicamento (PINTO *et al.*, 2023), o fato de essa pesquisa ter como um dos achados centrais fragmento estrutural do fluconazol indica que esta é uma abordagem promissora. Isso sugere que, a partir desse ponto de partida, é possível identificar um hit potencialmente eficaz contra esse fungo.

Figura 18 – Fluconazol.



Fonte: ChEMBL.

Logo, as moléculas pontuadas neste capítulo podem se apresentar como possíveis *hits* para o combate contra a CA.

5 CONCLUSÃO

Após a exposição dos principais aspectos abordados neste trabalho, pode-se observar que os mecanismos computacionais de auxílio na exploração e criação de fármacos se configuram como possíveis alternativas aos modelos tradicionais de descoberta. As investigações realizadas demonstram, de maneira consistente, que a VS desempenha um papel central nesse contexto, fornecendo diretrizes robustas tanto para abordagens baseadas na estrutura (SBVS) quanto para aquelas fundamentadas nas características dos ligantes (LBVS). Esses resultados sustentam a hipótese proposta de que os mecanismos de VS são suficientes para a identificação de compostos promissores no tratamento da *Candida auris*.

No contexto específico da CA, um fungo associado à graves complicações e ao elevado índice de mortalidade, torna-se evidente a importância de estratégias que explorem novas alternativas terapêuticas. Nesse sentido, os conceitos de triagem apresentados ao longo deste trabalho fundamentam a escolha metodológica e os passos realizados, que permitem a transposição da hipótese inicialmente proposta para apresentação de compostos com propriedades que possivelmente podem ajudar no combate a CA. Assim, reforça-se a relevância da aplicação dessas estratégias no desenvolvimento de tratamentos eficazes contra esse patógeno emergente.

A aplicação da abordagem metodológica permitiu redigir análises e identificar um fragmento central desta pesquisa. Além disso, foram encontrados compostos promissores, como CHEMBL3736434, CHEMBL4475747 e CHEMBL4458614, que apresentaram os melhores resultados no docking, fornecendo bases sólidas para uma avaliação mais aprofundada por outros pesquisadores. A próxima etapa consiste na simulação desses compostos para verificar se permanecem ligados à Candida auris. Sem o auxilio da computação, esse processo poderia demandar gastos significativos de recursos e tempo. Nesse contexto, a aplicabilidade de ferramentas computacionais nesse processo, portanto, não apenas otimiza os esforços de pesquisa, como também expande o escopo para o encontro de soluções eficazes, eficientes e direcionadas.

5.1 Trabalhos futuros

Como proposta de trabalhos futuros, deseja-se que seja realizado um processo de dinâmica molecular com os dez *hits*, com um foco nos ”8° CHEMBL2018928”, ”6° CHEMBL3221229”, ”2º CHEMBL4475747” e ”9º CHEMBL1254317”. Esses compostos citados anteriormente não infringiram nenhuma das regras utilizadas para o ranqueamento, o que os torna candidatos promissores numa análise de sua energia de atração. Seguindo, assim, para fornecer evidências que eles apresentam potencial de se tornarem fármacos eficazes contra a CA.

REFERÊNCIAS

ALHIJAWI, Bushra; AWAJAN, Arafat. Genetic algorithms: Theory, genetic operators, solutions, and applications. **Evolutionary Intelligence**, Springer, v. 17, n. 3, p. 1245–1256, 2024.

ALHIJAWI, Bushra; KILANI, Yousef. A collaborative filtering recommender system using genetic algorithm. **Information Processing & Management**, Elsevier, v. 57, n. 6, p. 102310, 2020.

AMBROSIO, André Luis Berteli; FRANCHINI, Kleber Gomes. Cristalografia macromolecular: a biologia sob a otica dos raios X. **Ciência e Cultura**, Sociedade Brasileira para o Progresso da Ciencia, v. 69, n. 3, p. 29–36, 2017.

BAJUSZ, Dávid; RÁCZ, Anita; HÉBERGER, Károly. Why is Tanimoto index an appropriate choice for fingerprint-based similarity calculations? **Journal of cheminformatics**, Springer, v. 7, p. 1–13, 2015.

BASHIR, Qamar *et al.* Crystal structure and transient dimerization for the FKBP12 protein from the pathogenic fungus Candida auris. **Biochemical and Biophysical Research Communications**, v. 525, n. 4, p. 1103–1108, 2020. DOI: 10.1016/j.bbrc.2020.03.059.

BEAGRIE, Neil; HOUGHTON, John. **The value and impact of EMBL-EBI managed data resources**. [*S. l.: s. n.*], 2021. Disponível em: www.beagrie.com.

BIAN, Yuemin *et al.* Target-driven machine learning-enabled virtual screening (TAME-VS) platform for early-stage hit identification. **Frontiers in Molecular Biosciences**, Frontiers Media SA, v. 10, p. 1163536, 2023.

CAI, Jiang Hong *et al.* **Recent updates in click and computational chemistry for drug discovery and development**. v. 11. [*S. l.*]: Frontiers Media S.A., fev. 2023. DOI: 10.3389/fchem.2023.1114970.

CHAN, M. **Ten years in public health 2007-2017: REPORT BY DR MARGARET CHAN DIRECTOR-GENERAL WORLD HEALTH ORGANIZATION**. [*S. l.*]: World Health Organization, 2018. ISBN 9789241512442. Disponível em: https://books.google.com.br/books?id=YmNnDwAAQBAJ.

CHOPARD, Bastien *et al.* Performance and limitations of metaheuristics. **An introduction to metaheuristics for optimization**, Springer, p. 191–203, 2018.

CHOWDHARY, Anuradha; JAIN, Kusum; CHAUHAN, Neeraj. Candida auris genetics and emergence. **Annual Review of Microbiology**, Annual Reviews, v. 77, n. 1, p. 583–602, 2023.

CONGREVE, Miles *et al.* A'rule of three'for fragment-based lead discovery? **Drug discovery today**, v. 8, n. 19, p. 876–877, 2003.

CRISTINA, Maria Luisa *et al.* An Overview on Candida auris in Healthcare Settings. **Journal of Fungi**, Multidisciplinary Digital Publishing Institute (MDPI), v. 9, 9 set. 2023. ISSN 2309608X. DOI: 10.3390/jof9090913.

CUI, Mengyao *et al.* Introduction to the k-means clustering algorithm based on the elbow method. **Accounting, Auditing and Finance**, Clausius Scientific Press, v. 1, n. 1, p. 5–8, 2020.

DAINA, Antoine; ZOETE, Vincent. A boiled-egg to predict gastrointestinal absorption and brain penetration of small molecules. **ChemMedChem**, Wiley Online Library, v. 11, n. 11, p. 1117–1121, 2016.

DELALOYE, Julie; CALANDRA, Thierry. Invasive candidiasis as a cause of sepsis in the critically ill patient. **Virulence**, v. 5, p. 161–169, 1 jan. 2014. ISSN 2150-5594. DOI: 10.4161/viru.26187.

ERLANSON, Daniel A *et al.* Twenty years on: the impact of fragments on drug discovery. **Nature reviews Drug discovery**, Nature Publishing Group UK London, v. 15, n. 9, p. 605–619, 2016.

FANG, Wenjie *et al.* Diagnosis of invasive fungal infections: challenges and recent developments. **Journal of Biomedical Science**, v. 30, p. 42, 1 jun. 2023. ISSN 1423-0127. DOI: 10.1186/s12929-023-00926-2.

FERREIRA, Leonardo LG; ANDRICOPULO, Adriano D. ADMET modeling approaches in drug discovery. **Drug discovery today**, Elsevier, v. 24, n. 5, p. 1157–1165, 2019.

GIORDANO, Deborah *et al.* Drug design by pharmacophore and virtual screening approach. **Pharmaceuticals**, MDPI, v. 15, n. 5, p. 646, 2022.

GUO, Xun *et al.* Application of quantitative NMR in pharmaceutical analysis: Method qualification and potency determination for two new chemical entities in early-stage clinical studies. **Journal of Pharmaceutical and Biomedical Analysis**, Elsevier, v. 234, p. 115561, 2023.

HASSANAT, Ahmad B *et al.* An improved genetic algorithm with a new initialization mechanism based on regression techniques. **Information**, MDPI, v. 9, n. 7, p. 167, 2018.

JAYARAJ, P.B.; JAIN, Samyak. Ligand based virtual screening using SVM on GPU. **Computational Biology and Chemistry**, v. 83, p. 107143, 2019. ISSN 1476-9271. DOI: https://doi.org/10.1016/j.compbiolchem.2019.107143. Disponível em: https://www.sciencedirect.com/science/article/pii/S1476927119300350.

JAYARAJ, PB; AJAY, Mathias K *et al.* GPURFSCREEN: a GPU based virtual screening tool using random forest classifier. **Journal of cheminformatics**, Springer, v. 8, p. 1–10, 2016.

JIMÉNEZ-LUNA, José; GRISONI, Francesca; SCHNEIDER, Gisbert. Drug discovery with explainable artificial intelligence. **Nature Machine Intelligence**, Nature Publishing Group UK London, v. 2, n. 10, p. 573–584, 2020.

JOHNSON, M.A.; MAGGIORA, G.M.; MEETING, American Chemical Society. **Concepts and Applications of Molecular Similarity**. [*S. l.*]: Wiley, 1990. (A Wiley-Interscience publication). ISBN 9780471621751. Disponível em: https://books.google.com.br/books?id=iGbJaz1ziWkC.

KHAN, Mohemmed Faraz; KANDWAL, Shubhangi; FAYNE, Darren. DataPype: A Fully Automated Unified Software Platform for Computer-Aided Drug Design. **ACS Omega**, American Chemical Society, v. 8, p. 39468–39480, 42 out. 2023. ISSN 24701343. DOI: 10.1021/acsomega.3c05207.

KIM, Sunghwan *et al.* PubChem 2023 update. **Nucleic acids research**, Oxford University Press, v. 51, n. D1, p. d1373–d1380, 2023.

KIRKMAN, Tim *et al.* Crystal structure of dihydrofolate reductase from the emerging pathogenic fungus Candida auris. **Acta Crystallographica Section D: Structural Biology**, International Union of Crystallography, v. 79, n. 8, p. 735–745, 2023.

KNOX, Craig *et al.* DrugBank 6.0: the DrugBank knowledgebase for 2024. **Nucleic acids research**, Oxford University Press, v. 52, n. D1, p. d1265–d1275, 2024.

KUMARI, Rashmi *et al.* g_mmpbsa A GROMACS tool for high-throughput MM-PBSA calculations. **Journal of chemical information and modeling**, ACS Publications, v. 54, n. 7, p. 1951–1962, 2014.

LANG, P Therese *et al.* DOCK 6: Combining techniques to model RNA–small molecule complexes. **Rna**, Cold Spring Harbor Lab, v. 15, n. 6, p. 1219–1230, 2009.

LAVECCHIA, Antonio. Machine-learning approaches in drug discovery: methods and applications. **Drug discovery today**, Elsevier, v. 20, n. 3, p. 318–331, 2015.

LEMES, Thiago Henrique *et al.* O estudo da interferência biológica entre dermatófitos e leveduras em onicomicoses. **International Journal of Health Sciences**, v. 1, n. 1, 2021.

LIN, Xiaoqian; LI, Xiu; LIN, Xubo. A Review on Applications of Computational Methods in Drug Screening and Design. **Molecules**, v. 25, p. 1375, 6 mar. 2020. ISSN 1420-3049. DOI: 10.3390/molecules25061375.

LIPINSKI, Christopher A *et al.* Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. **Advanced drug delivery reviews**, Elsevier, v. 23, n. 1-3, p. 3–25, 1997.

LIU, Dongyou. Chapter 138 - Classification of medically important fungi. *In:* TANG, Yi-Wei *et al.* (ed.). **Molecular Medical Microbiology (Third Edition)**. Third Edition. [*S. l.*]: Academic Press, 2024. p. 2763–2777. ISBN 978-0-12-818619-0. DOI: https://doi.org/10.1016/B978-0-12-818619-0.00034-4. Disponível em: https://www.sciencedirect.com/science/article/pii/B9780128186190000344.

LYU, Jiankun; IRWIN, John J; SHOICHET, Brian K. Modeling the expansion of virtual screening libraries. **Nature chemical biology**, Nature Publishing Group US New York, v. 19, n. 6, p. 712–718, 2023.

MAIA, Eduardo HB *et al.* Molecular architect: A user-friendly workflow for virtual screening. **ACS omega**, ACS Publications, v. 5, n. 12, p. 6628–6640, 2020.

MAIA., Alisson Silva; Alex Taranto;Eduardo. **Molecular Architect (MolAr): A Structure Based Virtual Screening software**. 2019. Tese (Doutorado) – 9TH BRAZILIAN SYMPOSIUM ON MEDICINAL CHEMISTRY, 2019, Pirenópolis. Anais eletrônicos, Campinas, Galoá,

MARSHALL, Garland R. Computer-aided drug design. **Annual review of pharmacology and toxicology**, v. 27, p. 193–213, 1987.

MAVEYRAUD, Laurent; MOUREY, Lionel. Protein X-ray crystallography and drug discovery. **Molecules**, MDPI, v. 25, n. 5, p. 1030, 2020.

MENDEZ, David *et al.* ChEMBL: towards direct deposition of bioassay data. **Nucleic acids research**, Oxford University Press, v. 47, n. D1, p. d930–d940, 2019.

NOCEDAL, Jorge; WRIGHT, Stephen J. **Numerical optimization**. [*S. l.*]: Springer, 1999.

OLIVEIRA, Tiago Alves de *et al.* Virtual screening algorithms in drug discovery: A review focused on machine and deep learning methods. **Drugs and Drug Candidates**, MDPI, v. 2, n. 2, p. 311–334, 2023.

OPREA, Tudor I; MATTER, Hans. Integrating virtual screening in lead discovery. **Current Opinion in Chemical Biology**, v. 8, n. 4, p. 349–358, 2004. ISSN 1367-5931. DOI: https://doi.org/10.1016/j.cbpa.2004.06.008. Disponível em: https://www.sciencedirect.com/science/article/pii/S1367593104000845.

PERES, Fernando; CASTELLI, Mauro. Combinatorial optimization problems and metaheuristics: Review, challenges, design, and development. **Applied Sciences**, MDPI, v. 11, n. 14, p. 6449, 2021.

PHARKJAKSU, Sujiraphong *et al.* Immunopathogenesis of emerging Candida auris and Candida haemulonii strains. **Journal of Fungi**, MDPI, v. 7, n. 9, p. 725, 2021.

PICCIRILLO, Erika; AMARAL, Antonia Tavares do. Busca virtual de compostos bioativos: conceitos e aplicações. **Química Nova**, SciELO Brasil, v. 41, n. 6, p. 662–677, 2018.

PINTO, Késsia Gomes *et al.* Candida auris: uma revisão de literatura. **Revista Scientia Vitae**, v. 13, n. 36, p. 32–39, 2023.

RUDRAPAL, Mithun; CHETIA, Dipak. Virtual screening, molecular docking and QSAR studies in drug discovery and development programme. **Journal of drug delivery and therapeutics**, v. 10, n. 4, p. 225–233, 2020.

SANDER, Thomas *et al.* DataWarrior: an open-source program for chemistry aware data visualization and analysis. **Journal of chemical information and modeling**, ACS Publications, v. 55, n. 2, p. 460–473, 2015.

SANTOS, Victória Laysna dos Anjos; GONSALVES, Arlan de Assis; ARAÚJO, Cleônia Roberta Melo. Abordagem didática para o desenvolvimento de moléculas bioativas: regra dos cinco de Lipinski e preparação de heterociclo 1, 3, 4-oxadiazol em forno de micro-ondas doméstico. **Química Nova**, SciELO Brasil, v. 41, n. 1, p. 110–115, 2018.

SATOH, Kazuo *et al.* Candida auris sp. nov., a novel ascomycetous yeast isolated from the external ear canal of an inpatient in a Japanese hospital. **Microbiology and Immunology**, v. 53, n. 1, p. 41–44, 2009. DOI: https://doi.org/10.1111/j.1348-0421.2008.00083.x. eprint: https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1348-0421.2008.00083.x. Disponível em: https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1348-0421.2008.00083.x.

SHAH, Krish; DESHPANDE, Mukund; SHAH, P. Healthcare-associated fungal infections and emerging pathogens during the COVID-19 pandemic. **Frontiers in Fungal Biology**, v. 5, fev. 2024. ISSN 2673-6128. DOI: 10.3389/ffunb.2024.1339911.

TROTT, Oleg; OLSON, Arthur J. AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. **Journal of computational chemistry**, Wiley Online Library, v. 31, n. 2, p. 455–461, 2010.

VÁZQUEZ, Javier *et al.* Merging ligand-based and structure-based methods in drug discovery: An overview of combined virtual screening approaches. **Molecules**, MDPI, v. 25, n. 20, p. 4723, 2020.

VEBER, Daniel F *et al.* Molecular properties that influence the oral bioavailability of drug candidates. **Journal of medicinal chemistry**, ACS Publications, v. 45, n. 12, p. 2615–2623, 2002.

VEMULA, Divya *et al.* CADD, AI and ML in drug discovery: A comprehensive review. **European Journal of Pharmaceutical Sciences**, Elsevier, v. 181, p. 106324, 2023.

VILAR, Santiago; COZZA, Giorgio; MORO, Stefano. Medicinal chemistry and the molecular operating environment (MOE): application of QSAR and molecular docking to drug discovery. **Current topics in medicinal chemistry**, Bentham Science Publishers, v. 8, n. 18, p. 1555–1572, 2008.

WEBSTER, J.; WEBER, R. **Introduction to Fungi**. [*S. l.*]: Cambridge University Press, 2007. ISBN 9781139461504. Disponível em: https://books.google.com.br/books?id=SApIn7IEnucC.

WILLETT, Peter. Similarity-based virtual screening using 2D fingerprints. **Drug Discovery Today**, v. 11, n. 23, p. 1046–1053, 2006. ISSN 1359-6446. DOI: https://doi.org/10.1016/j.drudis.2006.10.005. Disponível em: https://www.sciencedirect.com/science/article/pii/S1359644606004193.

YANG, Jingbo *et al.* Concepts and applications of chemical fingerprint for hit and lead screening. **Drug Discovery Today**, Elsevier, v. 27, n. 11, p. 103356, 2022.

YING, Cheng Zhi *et al.* Improving the Workflow of Chemical Structure Elucidation with Morgan Fingerprints and the Tanimoto Coefficient. *In:* SPRINGER. IRC-SET 2020: Proceedings of the 6th IRC Conference on Science, Engineering and Technology, July 2020, Singapore. [*S. l.: s. n.*], 2021. p. 13–24.

ZDRAZIL, Barbara *et al.* The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. **Nucleic acids research**, Oxford University Press, v. 52, n. D1, p. d1180–d1192, 2024.

ZHAO, Shizhen *et al.* Ligand-based pharmacophore modeling, virtual screening and biological evaluation to identify novel TGR5 agonists. **RSC Adv.**, The Royal Society of Chemistry, v. 11, p. 9403–9409, 16 2021. DOI: 10.1039/D0RA10168K. Disponível em: http://dx.doi.org/10.1039/D0RA10168K.

ZHAVORONKOV, Alex. **Artificial intelligence for drug discovery, biomarker development, and generation of novel chemistry**. v. 15. [*S. l.*]: ACS Publications, 2018. p. 4311–4313.

ANEXO A

Resultados encontrados pelo DiscoveryStudio

Análise realizada no DiscoveryStudio para verificar o número de ligações de cada resultado obtido com as moléculas do *docking* em ordem de *rank* do processo de consenso. A seguir se encontram as imagens detalhadas do *software* DiscoveryStudio, juntamente às legendas das interações presentes.

Figura 19 – Anexo A - 1º CHEMBL3736434 Completa no DiscoveryStudio

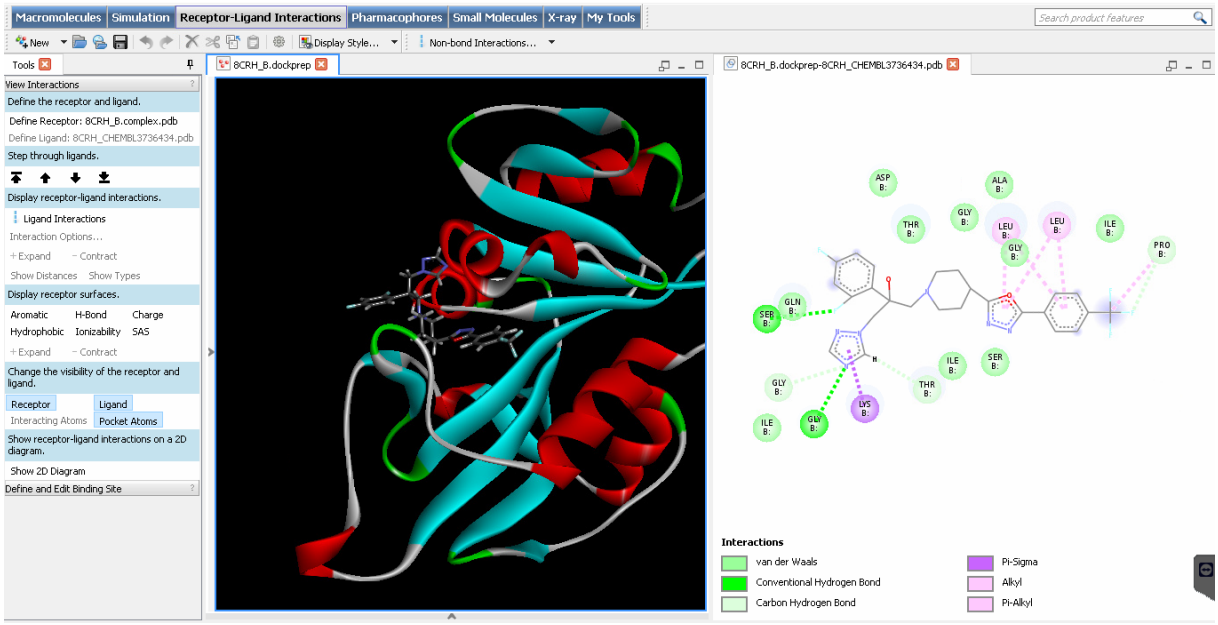


Figura 20 – Anexo A - 2º CHEMBL4475747 Completa no DiscoveryStudio

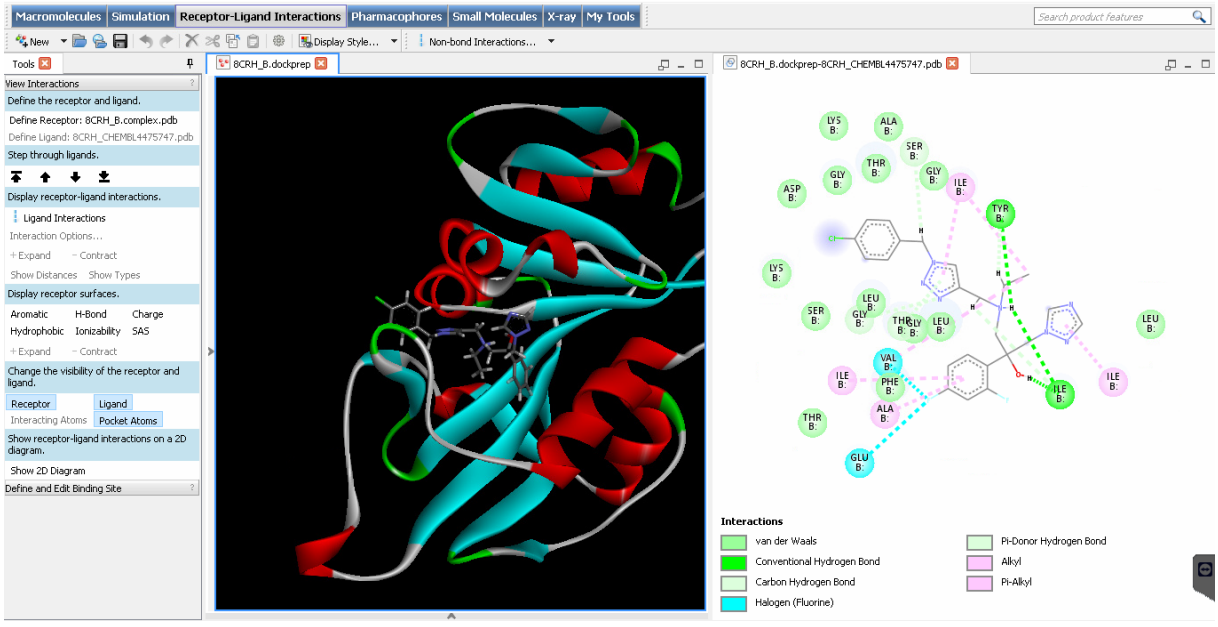


Figura 21 – Anexo A - 3º CHEMBL4458614 Completa no DiscoveryStudio

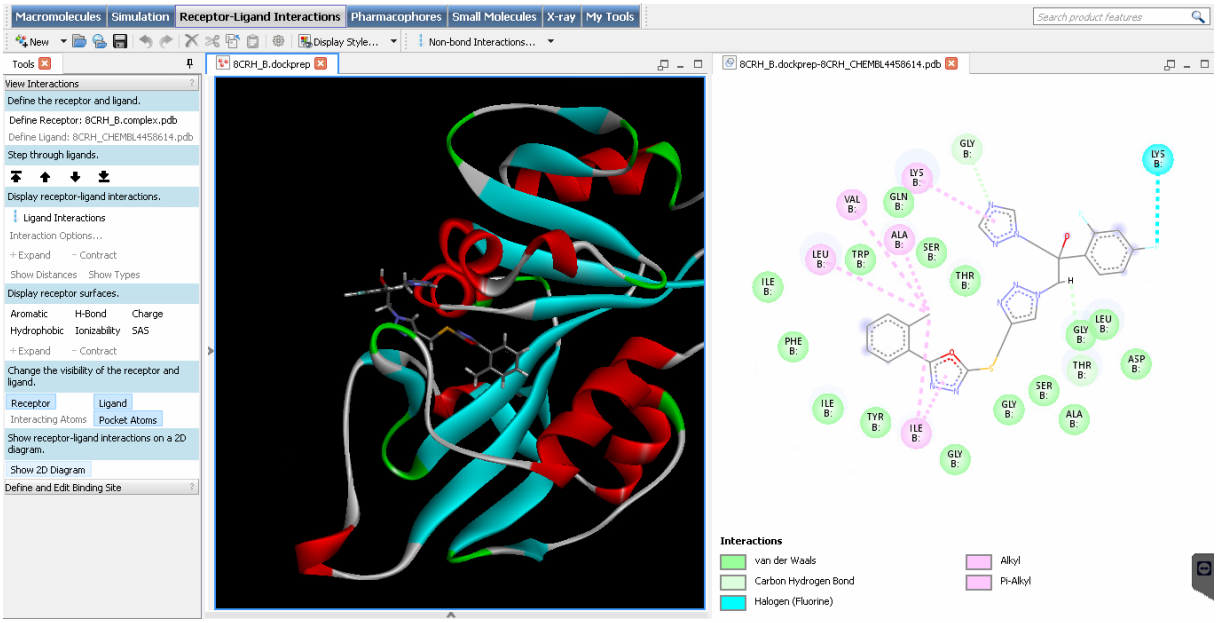


Figura 22 – Anexo A - 4º CHEMBL4870228 Completa no DiscoveryStudio

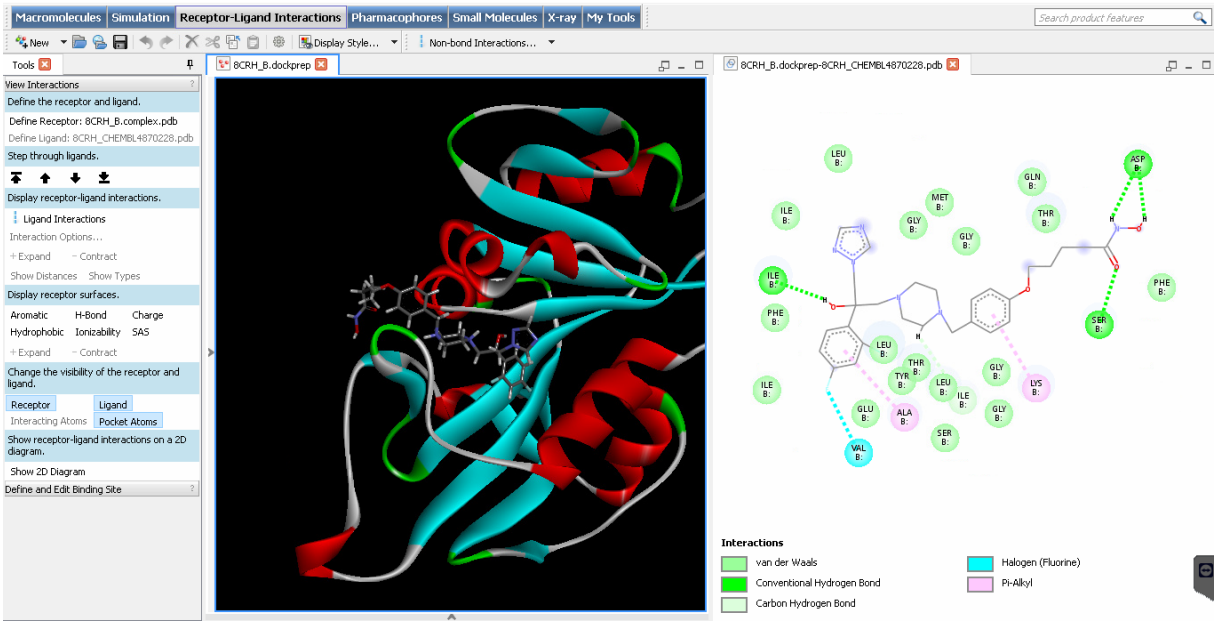


Figura 23 – Anexo A - 5º CHEMBL1255047 Completa no DiscoveryStudio

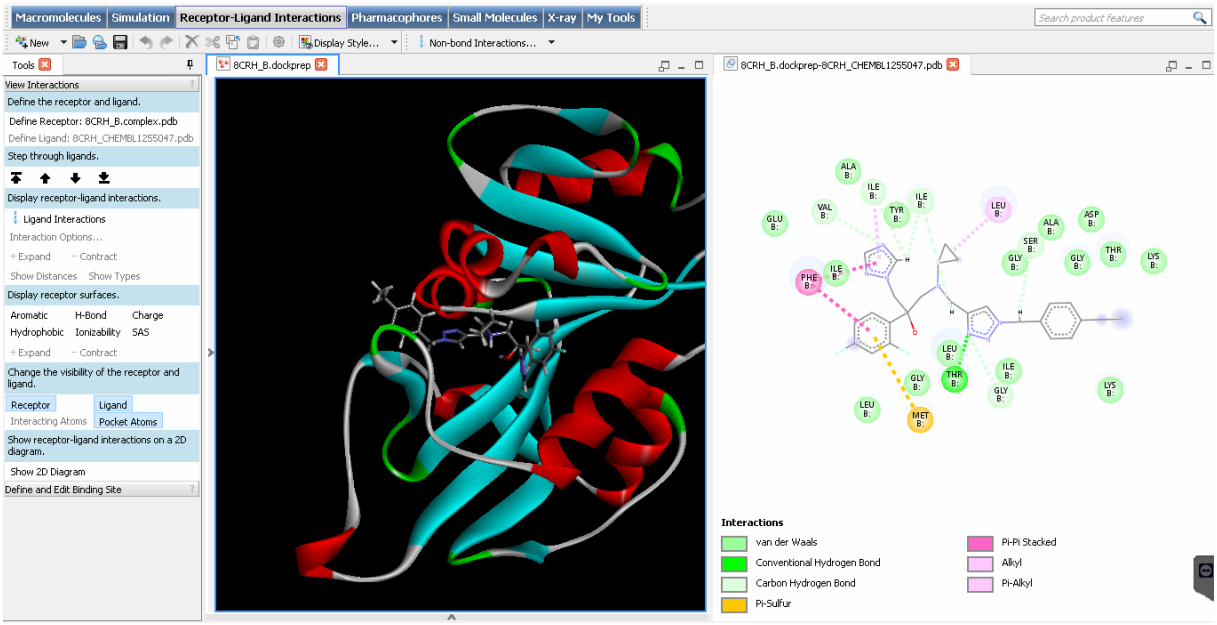


Figura 24 – Anexo A - 6º CHEMBL3221229 Completa no DiscoveryStudio

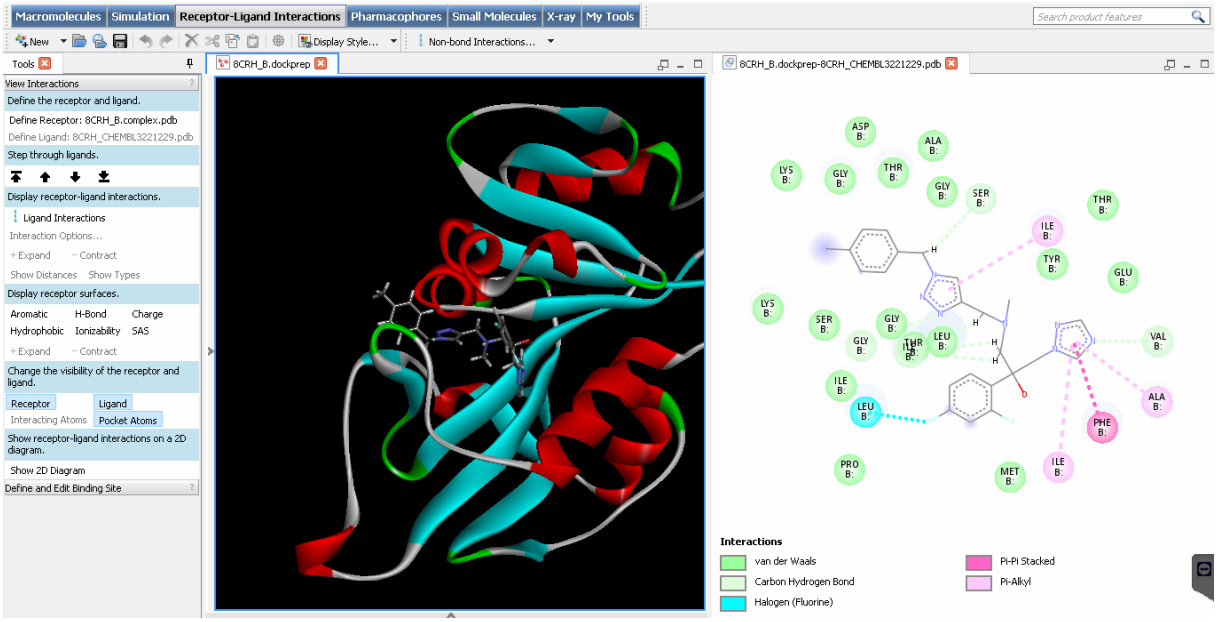


Figura 25 – Anexo A - 7º CHEMBL4294930 Completa no DiscoveryStudio

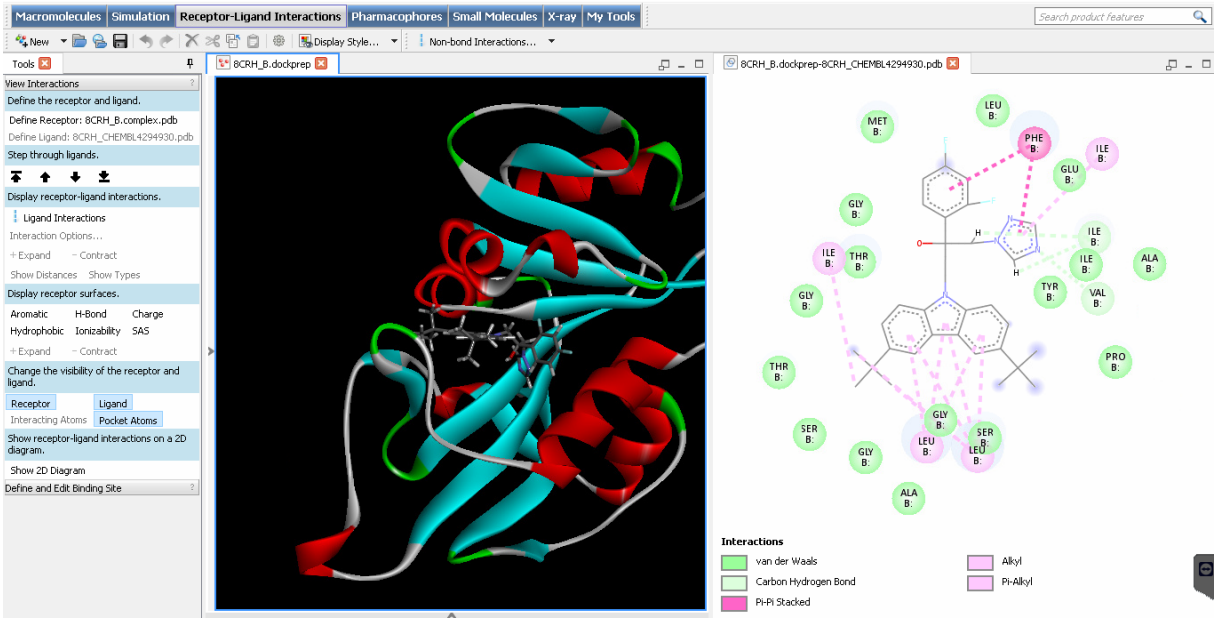


Figura 26 – Anexo A - 8º CHEMBL2018928 Completa no DiscoveryStudio

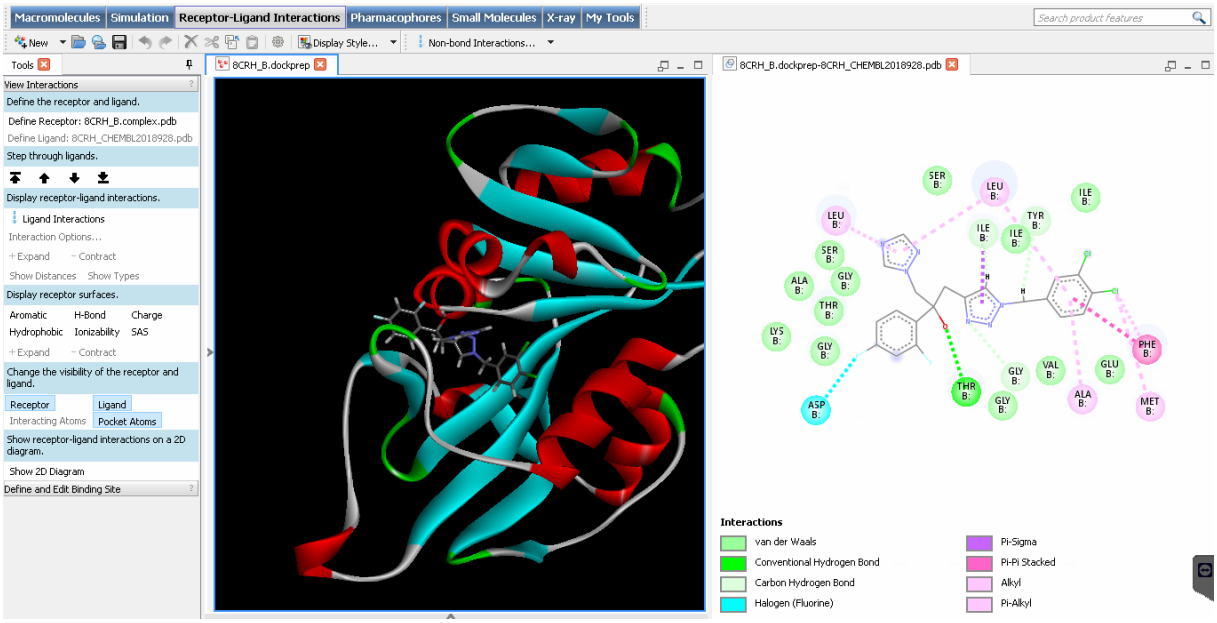


Figura 27 – Anexo A - 9º CHEMBL1254317 Completa no DiscoveryStudio

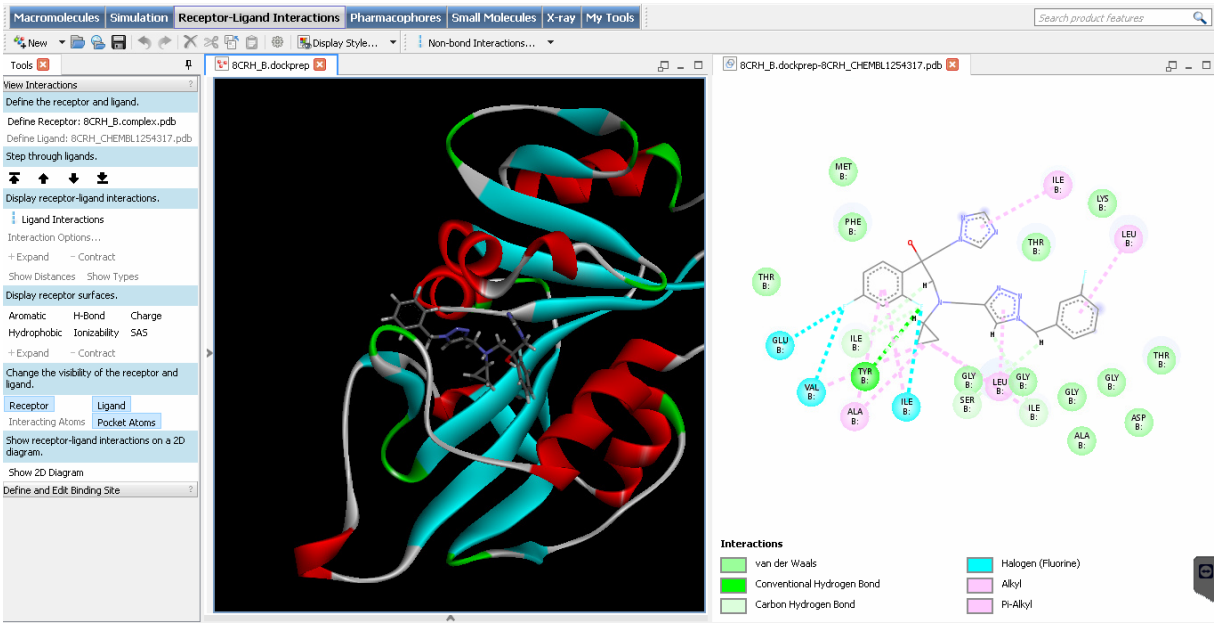
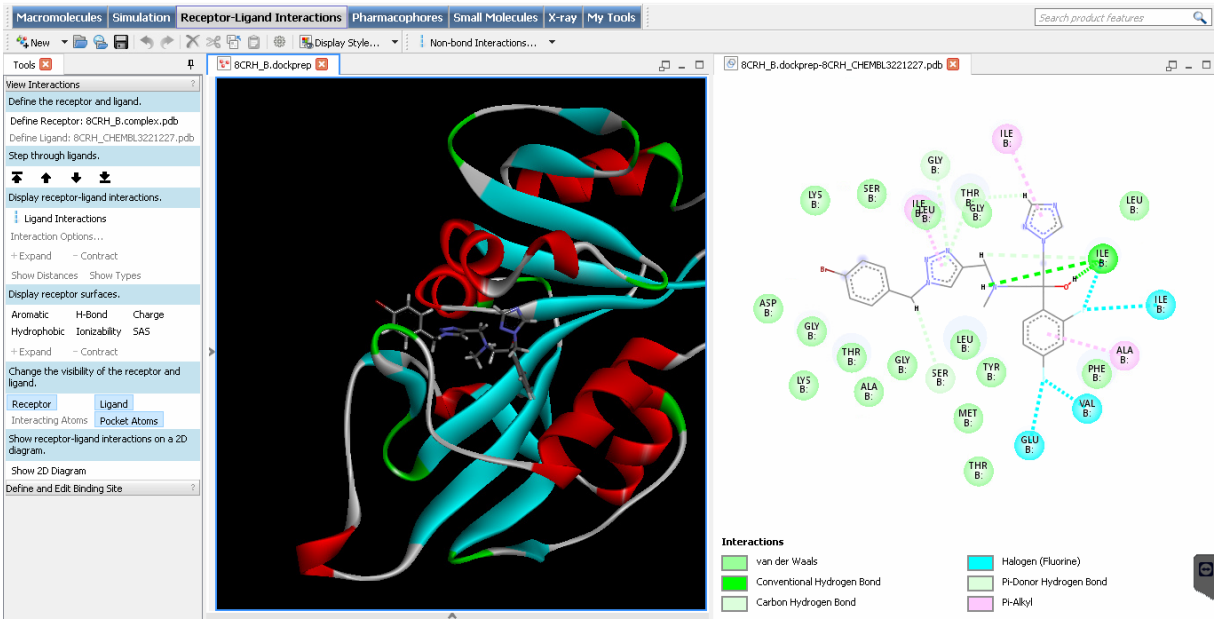


Figura 28 – Anexo A - 10º CHEMBL3221227 Completa no DiscoveryStudio



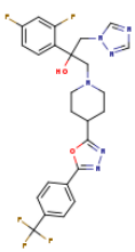
ANEXO B

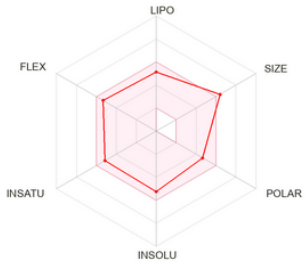
Swiss Drug Desing Análise

A partir das moléculas apresentadas na tabela 07, realizou-se uma análise com o auxílio do software SwissADME, no qual se aprofundam diversas informações que foram apresentadas parcialmente nos resultados.

Figura 29 – Anexo B - 1º CHEMBL3736434 - Análise completa realizada no SwissADME

1- CHEMBL3736434





SMILES Fc1ccc(c(c1)F)C(Cn1cncn1)(CN1CCC(CC1)c1nnc(o1)c1ccc(cc1)C(F)(F)F)O

Physicochemical Properties	
Formula	C25H23F5N6O2
Molecular weight	534.48 g/mol
Num. heavy atoms	38
Num. arom. heavy atoms	22
Fraction Csp3	0.36
Num. rotatable bonds	8
Num. H-bond acceptors	12
Num. H-bond donors	1
Molar Refractivity	127.86
TPSA	93.10 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	4.24
Log $P_{o/w}$ (XLOGP3)	3.49
Log $P_{o/w}$ (WLOGP)	5.90
Log $P_{o/w}$ (MLOGP)	4.03
Log $P_{o/w}$ (SILICOS-IT)	4.31
Consensus Log $P_{o/w}$	4.39

Water Solubility	
Log *S* (ESOL)	-5.25
Solubility	2.99e-03 mg/ml ; 5.59e-06 mol/l
Class	Moderately soluble
Log *S* (Ali)	-5.13
Solubility	3.98e-03 mg/ml ; 7.45e-06 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-8.06
Solubility	4.64e-06 mg/ml ; 8.69e-09 mol/l
Class	Poorly soluble

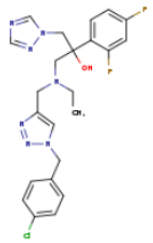
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	Yes
CYP2C19 inhibitor	No
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.08 cm/s

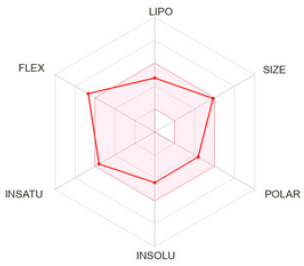
Druglikeness	
Lipinski	Yes; 1 violation: MW>500
Ghose	No; 2 violations: MW>480, WLOGP>5.6
Veber	Yes
Egan	No; 1 violation: WLOGP>5.88
Muegge	No; 1 violation: H-acc>10
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.67

Figura 30 – Anexo B - 2º CHEMBL4475747 - Análise completa realizada no SwissADME

2- CHEMBL4475747





SMILES CCN(CC(c1ccc(cc1F)F)(Cn1ncnc1)O)Cc1nnn(c1)Cc1ccc(cc1)Cl

Physicochemical Properties	
Formula	C23H24ClF2N7O
Molecular weight	487.93 g/mol
Num. heavy atoms	34
Num. arom. heavy atoms	22
Fraction Csp3	0.30
Num. rotatable bonds	10
Num. H-bond acceptors	8
Num. H-bond donors	1
Molar Refractivity	122.49
TPSA	84.89 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	3.66
Log $P_{o/w}$ (XLOGP3)	2.73
Log $P_{o/w}$ (WLOGP)	3.84
Log $P_{o/w}$ (MLOGP)	3.25
Log $P_{o/w}$ (SILICOS-IT)	3.21
Consensus Log $P_{o/w}$	3.34

Water Solubility	
Log *S* (ESOL)	-4.40
Solubility	1.93e-02 mg/ml ; 3.95e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-4.17
Solubility	3.32e-02 mg/ml ; 6.81e-05 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-7.46
Solubility	1.69e-05 mg/ml ; 3.47e-08 mol/l
Class	Poorly soluble

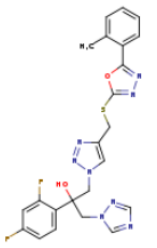
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	Yes
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.34 cm/s

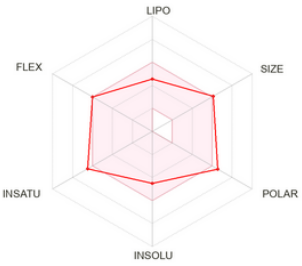
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	No; 1 violation: MW>480
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.08

Figura 31 – Anexo B - 3º CHEMBL4458614 - Análise completa realizada no SwissADME

3- CHEMBL4458614





SMILES Fc1ccc(c(c1)F)C(Cn1cncn1)(Cn1nnc(c1)CSc1nnc(o1)c1ccccc1C)O

Physicochemical Properties	
Formula	C23H20F2N8O2S
Molecular weight	510.52 g/mol
Num. heavy atoms	36
Num. arom. heavy atoms	27
Fraction Csp3	0.22
Num. rotatable bonds	9
Num. H-bond acceptors	10
Num. H-bond donors	1
Molar Refractivity	125.17
TPSA	145.87 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	2.35
Log $P_{o/w}$ (XLOGP3)	2.43
Log $P_{o/w}$ (WLOGP)	3.97
Log $P_{o/w}$ (MLOGP)	3.21
Log $P_{o/w}$ (SILICOS-IT)	3.02
Consensus Log $P_{o/w}$	3.00

Water Solubility	
Log *S* (ESOL)	-4.50
Solubility	1.63e-02 mg/ml ; 3.18e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-5.14
Solubility	3.73e-03 mg/ml ; 7.31e-06 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-7.77
Solubility	8.69e-06 mg/ml ; 1.70e-08 mol/l
Class	Poorly soluble

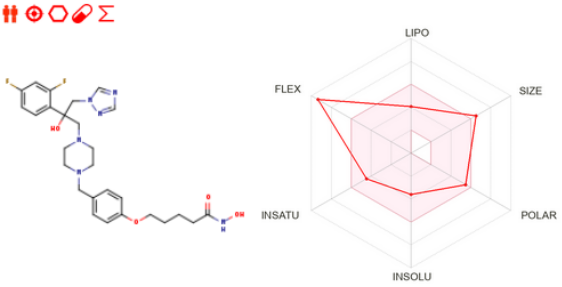
Pharmacokinetics	
GI absorption	Low
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	Yes
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	No
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.69 cm/s

Druglikeness	
Lipinski	Yes; 1 violation: MW>500
Ghose	No; 1 violation: MW>480
Veber	No; 1 violation: TPSA>140
Egan	No; 1 violation: TPSA>131.6
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.59

Figura 32 – Anexo B - 4º CHEMBL4870228 - Análise completa realizada no SwissADME

4- CHEMBL4870228



SMILES ONC(=O)CCCCOc1ccc(cc1)CN1CCN(CC1)CC(c1ccc(cc1F)F)(Cn1cncn1)O

Physicochemical Properties	
Formula	C27H34F2N6O4
Molecular weight	544.59 g/mol
Num. heavy atoms	39
Num. arom. heavy atoms	17
Fraction Csp3	0.44
Num. rotatable bonds	14
Num. H-bond acceptors	10
Num. H-bond donors	3
Molar Refractivity	145.83
TPSA	115.98 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	3.96
Log $P_{o/w}$ (XLOGP3)	1.59
Log $P_{o/w}$ (WLOGP)	2.13
Log $P_{o/w}$ (MLOGP)	2.01
Log $P_{o/w}$ (SILICOS-IT)	2.56
Consensus Log $P_{o/w}$	2.45

Water Solubility	
Log *S* (ESOL)	-3.62
Solubility	1.32e-01 mg/ml ; 2.42e-04 mol/l
Class	Soluble
Log *S* (Ali)	-3.64
Solubility	1.26e-01 mg/ml ; 2.31e-04 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-6.65
Solubility	1.21e-04 mg/ml ; 2.22e-07 mol/l
Class	Poorly soluble

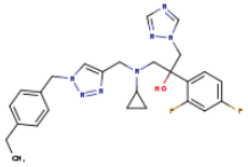
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-8.49 cm/s

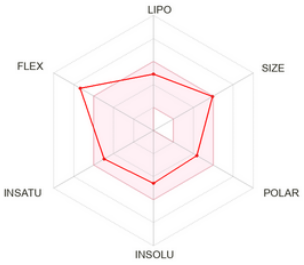
Druglikeness	
Lipinski	Yes; 1 violation: MW>500
Ghose	No; 3 violations: MW>480, MR>130, #atoms>70
Veber	No; 1 violation: Rotors>10
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	2 alerts: hydroxamic_acid, oxygen-nitrogen_single_bond
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.34

Figura 33 – Anexo B - 5º CHEMBL1255047 - Análise completa realizada no SwissADME

5- CHEMBL1255047





SMILES CCc1ccc(cc1)Cn1nnc(c1)CN(C1CC1)CC(c1ccc(cc1F)F)(Cn1cncn1)O

Physicochemical Properties	
Formula	C26H29F2N7O
Molecular weight	493.55 g/mol
Num. heavy atoms	36
Num. arom. heavy atoms	22
Fraction Csp3	0.38
Num. rotatable bonds	11
Num. H-bond acceptors	8
Num. H-bond donors	1
Molar Refractivity	129.94
TPSA	84.89 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	3.59
Log $P_{o/w}$ (XLOGP3)	3.09
Log $P_{o/w}$ (WLOGP)	3.83
Log $P_{o/w}$ (MLOGP)	3.39
Log $P_{o/w}$ (SILICOS-IT)	3.52
Consensus Log $P_{o/w}$	3.48

Water Solubility	
Log *S* (ESOL)	-4.57
Solubility	1.32e-02 mg/ml ; 2.67e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-4.54
Solubility	1.42e-02 mg/ml ; 2.88e-05 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-7.44
Solubility	1.80e-05 mg/ml ; 3.66e-08 mol/l
Class	Poorly soluble

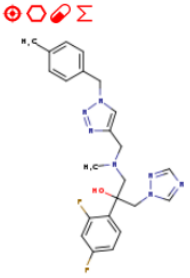
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	Yes
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.12 cm/s

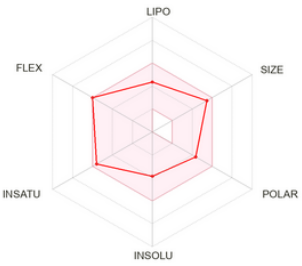
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	No; 1 violation: MW>480
Veber	No; 1 violation: Rotors>10
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.35

Figura 34 – Anexo B - 6º CHEMBL3221229 - Análise completa realizada no SwissADME

6- CHEMBL3221229





SMILES CN(CC(c1ccc(cc1F)F)(Cn1ncnc1)O)Cc1nnn(c1)Cc1ccc(cc1)C

Physicochemical Properties	
Formula	C23H25F2N7O
Molecular weight	453.49 g/mol
Num. heavy atoms	33
Num. arom. heavy atoms	22
Fraction Csp3	0.30
Num. rotatable bonds	9
Num. H-bond acceptors	8
Num. H-bond donors	1
Molar Refractivity	117.64
TPSA	84.89 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	3.24
Log $P_{o/w}$ (XLOGP3)	2.10
Log $P_{o/w}$ (WLOGP)	3.10
Log $P_{o/w}$ (MLOGP)	2.78
Log $P_{o/w}$ (SILICOS-IT)	2.69
Consensus Log $P_{o/w}$	2.78

Water Solubility	
Log *S* (ESOL)	-3.87
Solubility	6.06e-02 mg/ml ; 1.34e-04 mol/l
Class	Soluble
Log *S* (Ali)	-3.51
Solubility	1.39e-01 mg/ml ; 3.07e-04 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-6.86
Solubility	6.22e-05 mg/ml ; 1.37e-07 mol/l
Class	Poorly soluble

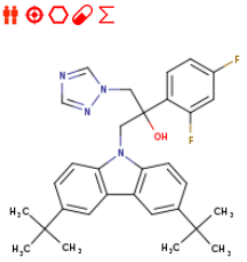
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.58 cm/s

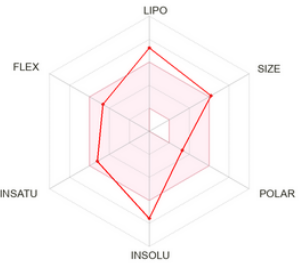
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.07

Figura 35 – Anexo B - 7º CHEMBL4294930 - Análise completa realizada no SwissADME

7- CHEMBL4294930





SMILES Fc1ccc(c(c1)F)C(Cn1c2ccc(cc2c2c1ccc(c2)C(C)(C)C)C(C)(C)C)(Cn1cncn1)O

Physicochemical Properties	
Formula	C31H34F2N4O
Molecular weight	516.62 g/mol
Num. heavy atoms	38
Num. arom. heavy atoms	24
Fraction Csp3	0.35
Num. rotatable bonds	7
Num. H-bond acceptors	5
Num. H-bond donors	1
Molar Refractivity	148.67
TPSA	55.87 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	4.81
Log $P_{o/w}$ (XLOGP3)	7.19
Log $P_{o/w}$ (WLOGP)	7.58
Log $P_{o/w}$ (MLOGP)	5.53
Log $P_{o/w}$ (SILICOS-IT)	6.63
Consensus Log $P_{o/w}$	6.35

Water Solubility	
Log *S* (ESOL)	-7.58
Solubility	1.36e-05 mg/ml ; 2.64e-08 mol/l
Class	Poorly soluble
Log *S* (Ali)	-8.19
Solubility	3.37e-06 mg/ml ; 6.52e-09 mol/l
Class	Poorly soluble
Log *S* (SILICOS-IT)	-9.87
Solubility	6.94e-08 mg/ml ; 1.34e-10 mol/l
Class	Poorly soluble

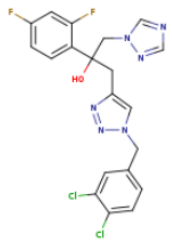
Pharmacokinetics	
GI absorption	Low
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-4.35 cm/s

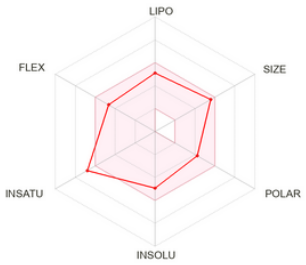
Druglikeness	
Lipinski	No; 2 violations: MW>500, MLOGP>4.15
Ghose	No; 4 violations: MW>480, WLOGP>5.6, MR>130, #atoms>70
Veber	Yes
Egan	No; 1 violation: WLOGP>5.88
Muegge	No; 1 violation: XLOGP3>5
Bioavailability Score	0.17

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, XLOGP3>3.5
Synthetic accessibility	4.31

Figura 36 – Anexo B - 8º CHEMBL2018928 - Análise completa realizada no SwissADME

8- CHEMBL2018928





SMILES Fc1ccc(c(c1)F)C(Cn1ncnc1)(Cc1nnn(c1)Cc1ccc(c(c1)Cl)Cl)O

Physicochemical Properties	
Formula	C20H16Cl2F2N6O
Molecular weight	465.28 g/mol
Num. heavy atoms	31
Num. arom. heavy atoms	22
Fraction Csp3	0.20
Num. rotatable bonds	7
Num. H-bond acceptors	7
Num. H-bond donors	1
Molar Refractivity	110.18
TPSA	81.65 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	2.48
Log $P_{o/w}$ (XLOGP3)	3.41
Log $P_{o/w}$ (WLOGP)	4.37
Log $P_{o/w}$ (MLOGP)	3.89
Log $P_{o/w}$ (SILICOS-IT)	3.89
Consensus Log $P_{o/w}$	3.61

Water Solubility	
Log *S* (ESOL)	-4.94
Solubility	5.39e-03 mg/ml ; 1.16e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-4.80
Solubility	7.30e-03 mg/ml ; 1.57e-05 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-7.57
Solubility	1.26e-05 mg/ml ; 2.71e-08 mol/l
Class	Poorly soluble

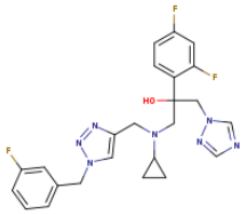
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	No
CYP1A2 inhibitor	No
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	No
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-6.72 cm/s

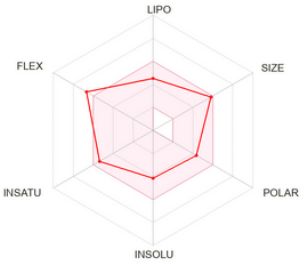
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 1 violation: MW>350
Synthetic accessibility	3.89

Figura 37 – Anexo B - 9º CHEMBL1254317 - Análise completa realizada no SwissADME

9- CHEMBL1254317





SMILES Fc1ccc(c(c1)F)C(CN(C1CC1)Cc1nnn(c1)Cc1cccc(c1)F)(Cn1ncnc1)O

Physicochemical Properties	
Formula	C24H24F3N7O
Molecular weight	483.49 g/mol
Num. heavy atoms	35
Num. arom. heavy atoms	22
Fraction Csp3	0.33
Num. rotatable bonds	10
Num. H-bond acceptors	9
Num. H-bond donors	1
Molar Refractivity	120.13
TPSA	84.89 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	3.10
Log $P_{o/w}$ (XLOGP3)	2.39
Log $P_{o/w}$ (WLOGP)	3.83
Log $P_{o/w}$ (MLOGP)	3.36
Log $P_{o/w}$ (SILICOS-IT)	3.02
Consensus Log $P_{o/w}$	3.14

Water Solubility	
Log *S* (ESOL)	-4.15
Solubility	3.43e-02 mg/ml ; 7.10e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-3.81
Solubility	7.42e-02 mg/ml ; 1.53e-04 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-6.93
Solubility	5.62e-05 mg/ml ; 1.16e-07 mol/l
Class	Poorly soluble

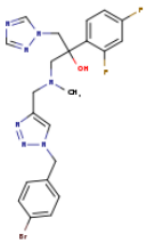
Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	Yes
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.55 cm/s

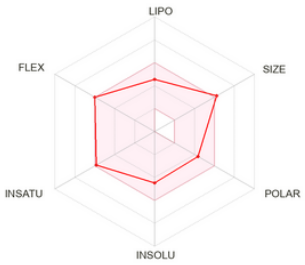
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	No; 1 violation: MW>480
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	4.15

Figura 38 – Anexo B - 10º CHEMBL3221227 - Análise completa realizada no SwissADME

10- CHEMBL3221227





SMILES CN(CC(c1ccc(cc1F)F)(Cn1ncnc1)O)Cc1nnn(c1)Cc1ccc(cc1)Br

Physicochemical Properties	
Formula	C22H22BrF2N7O
Molecular weight	518.36 g/mol
Num. heavy atoms	33
Num. arom. heavy atoms	22
Fraction Csp3	0.27
Num. rotatable bonds	9
Num. H-bond acceptors	8
Num. H-bond donors	1
Molar Refractivity	120.37
TPSA	84.89 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	2.87
Log $P_{o/w}$ (XLOGP3)	2.43
Log $P_{o/w}$ (WLOGP)	3.56
Log $P_{o/w}$ (MLOGP)	3.15
Log $P_{o/w}$ (SILICOS-IT)	2.85
Consensus Log $P_{o/w}$	2.97

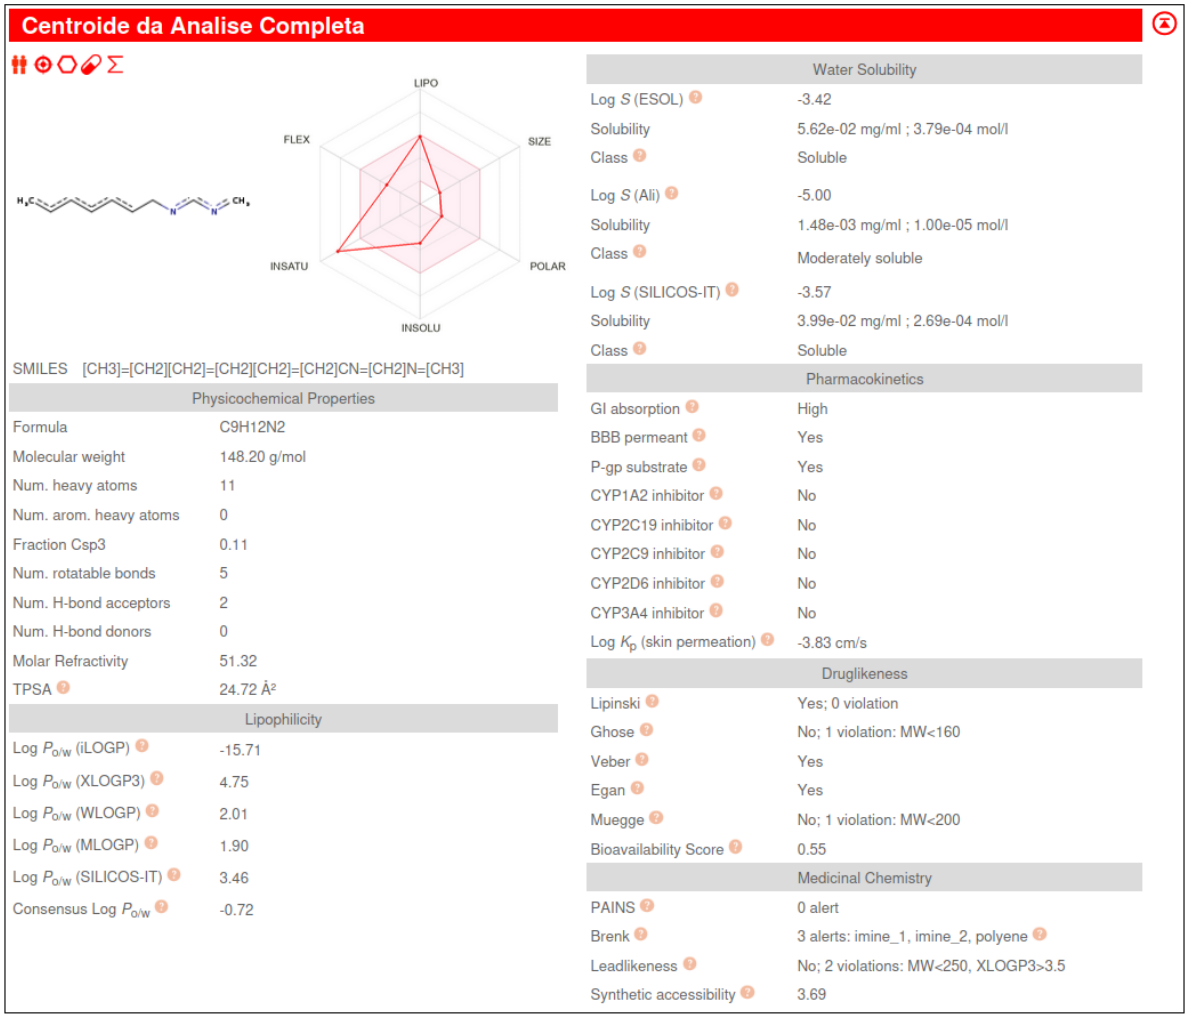
Water Solubility	
Log *S* (ESOL)	-4.48
Solubility	1.70e-02 mg/ml ; 3.28e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-3.86
Solubility	7.23e-02 mg/ml ; 1.39e-04 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-7.26
Solubility	2.87e-05 mg/ml ; 5.55e-08 mol/l
Class	Poorly soluble

Pharmacokinetics	
GI absorption	High
BBB permeant	No
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	Yes
CYP2C9 inhibitor	Yes
CYP2D6 inhibitor	Yes
CYP3A4 inhibitor	Yes
Log K_p (skin permeation)	-7.74 cm/s

Druglikeness	
Lipinski	Yes; 1 violation: MW>500
Ghose	No; 1 violation: MW>480
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	3.98

Figura 39 – Anexo B - Centroide *cluster* de relacionamentos - Análise completa realizada no SwissADME



Centroide da Analise Completa

SMILES [CH3]=[CH2][CH2]=[CH2][CH2]=[CH2]CN=[CH2]N=[CH3]

Physicochemical Properties	
Formula	C9H12N2
Molecular weight	148.20 g/mol
Num. heavy atoms	11
Num. arom. heavy atoms	0
Fraction Csp3	0.11
Num. rotatable bonds	5
Num. H-bond acceptors	2
Num. H-bond donors	0
Molar Refractivity	51.32
TPSA	24.72 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	-15.71
Log $P_{o/w}$ (XLOGP3)	4.75
Log $P_{o/w}$ (WLOGP)	2.01
Log $P_{o/w}$ (MLOGP)	1.90
Log $P_{o/w}$ (SILICOS-IT)	3.46
Consensus Log $P_{o/w}$	-0.72

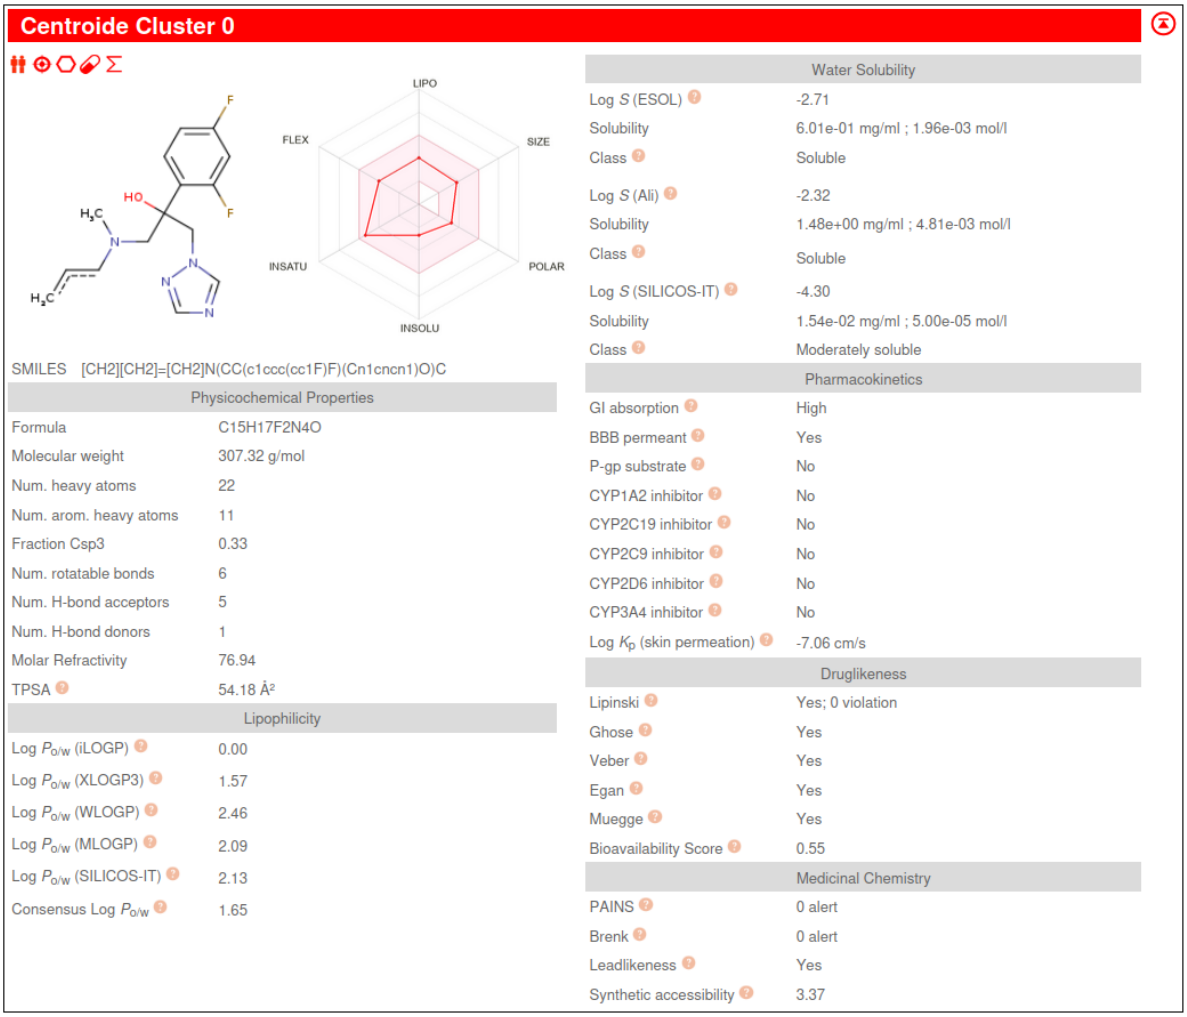
Water Solubility	
Log *S* (ESOL)	-3.42
Solubility	5.62e-02 mg/ml ; 3.79e-04 mol/l
Class	Soluble
Log *S* (Ali)	-5.00
Solubility	1.48e-03 mg/ml ; 1.00e-05 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-3.57
Solubility	3.99e-02 mg/ml ; 2.69e-04 mol/l
Class	Soluble

Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-3.83 cm/s

Druglikeness	
Lipinski	Yes; 0 violation
Ghose	No; 1 violation: MW<160
Veber	Yes
Egan	Yes
Muegge	No; 1 violation: MW<200
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	3 alerts: imine_1, imine_2, polyene
Leadlikeness	No; 2 violations: MW<250, XLOGP3>3.5
Synthetic accessibility	3.69

Figura 40 – Anexo B - Centroide *cluster* 0 - Análise completa realizada no SwissADME



Centroide Cluster 0

SMILES [CH2][CH2]=[CH2]N(CC(c1ccc(cc1F)F)(Cn1cncn1)O)C

Physicochemical Properties	
Formula	C15H17F2N4O
Molecular weight	307.32 g/mol
Num. heavy atoms	22
Num. arom. heavy atoms	11
Fraction Csp3	0.33
Num. rotatable bonds	6
Num. H-bond acceptors	5
Num. H-bond donors	1
Molar Refractivity	76.94
TPSA	54.18 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	0.00
Log $P_{o/w}$ (XLOGP3)	1.57
Log $P_{o/w}$ (WLOGP)	2.46
Log $P_{o/w}$ (MLOGP)	2.09
Log $P_{o/w}$ (SILICOS-IT)	2.13
Consensus Log $P_{o/w}$	1.65

Water Solubility	
Log *S* (ESOL)	-2.71
Solubility	6.01e-01 mg/ml ; 1.96e-03 mol/l
Class	Soluble
Log *S* (Ali)	-2.32
Solubility	1.48e+00 mg/ml ; 4.81e-03 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-4.30
Solubility	1.54e-02 mg/ml ; 5.00e-05 mol/l
Class	Moderately soluble

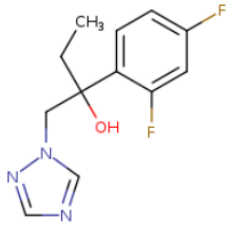
Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	No
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-7.06 cm/s

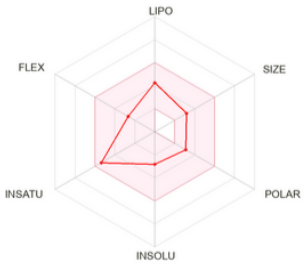
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	Yes
Synthetic accessibility	3.37

Figura 41 – Anexo B - Centroide *cluster* 1, 4 e 9 - Análise completa realizada no SwissADME

Centroide Moleculas e Cluster 1 4 e 9 (CHEMBL4292090)





SMILES CCC(c1ccc(cc1F)F)(Cn1cncn1)O

Physicochemical Properties	
Formula	C12H13F2N3O
Molecular weight	253.25 g/mol
Num. heavy atoms	18
Num. arom. heavy atoms	11
Fraction Csp3	0.33
Num. rotatable bonds	4
Num. H-bond acceptors	5
Num. H-bond donors	1
Molar Refractivity	61.15
TPSA	50.94 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	2.83
Log $P_{o/w}$ (XLOGP3)	1.95
Log $P_{o/w}$ (WLOGP)	2.59
Log $P_{o/w}$ (MLOGP)	2.23
Log $P_{o/w}$ (SILICOS-IT)	2.21
Consensus Log $P_{o/w}$	2.36

Water Solubility	
Log *S* (ESOL)	-2.83
Solubility	3.77e-01 mg/ml ; 1.49e-03 mol/l
Class	Soluble
Log *S* (Ali)	-2.64
Solubility	5.74e-01 mg/ml ; 2.27e-03 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-3.79
Solubility	4.13e-02 mg/ml ; 1.63e-04 mol/l
Class	Soluble

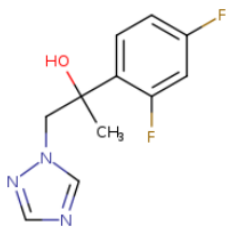
Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	No
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-6.46 cm/s

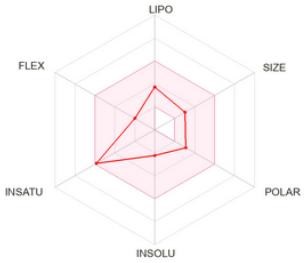
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	Yes
Synthetic accessibility	2.65

Figura 42 – Anexo B - Centroide *cluster* de relacionamentos das moleculas, *cluster* 2 e 8 - Análise completa realizada no SwissADME

Centroide Cluster 2 e 8 (CHEMBL4281467)





SMILES Fc1ccc(c(c1)F)C(Cn1cncn1)(O)C

Physicochemical Properties	
Formula	C11H11F2N3O
Molecular weight	239.22 g/mol
Num. heavy atoms	17
Num. arom. heavy atoms	11
Fraction Csp3	0.27
Num. rotatable bonds	3
Num. H-bond acceptors	5
Num. H-bond donors	1
Molar Refractivity	56.35
TPSA	50.94 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	1.94
Log $P_{o/w}$ (XLOGP3)	1.01
Log $P_{o/w}$ (WLOGP)	2.20
Log $P_{o/w}$ (MLOGP)	1.96
Log $P_{o/w}$ (SILICOS-IT)	1.86
Consensus Log $P_{o/w}$	1.79

Water Solubility	
Log *S* (ESOL)	-2.24
Solubility	1.38e+00 mg/ml ; 5.75e-03 mol/l
Class	Soluble
Log *S* (Ali)	-1.67
Solubility	5.13e+00 mg/ml ; 2.14e-02 mol/l
Class	Very soluble
Log *S* (SILICOS-IT)	-3.39
Solubility	9.84e-02 mg/ml ; 4.11e-04 mol/l
Class	Soluble

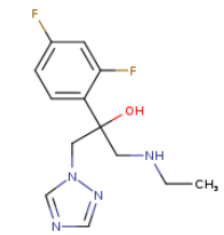
Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	No
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-7.04 cm/s

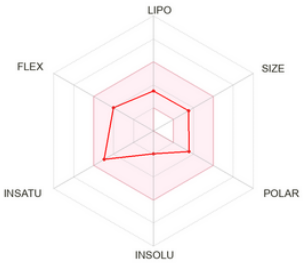
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	No; 1 violation: MW<250
Synthetic accessibility	2.54

Figura 43 – Anexo B - Centroide *cluster* 3 - Análise completa realizada no SwissADME

Centroide Cluster 3





SMILES CCNCC(c1ccc(cc1F)F)(Cn1cncn1)O

Physicochemical Properties	
Formula	C13H16F2N4O
Molecular weight	282.29 g/mol
Num. heavy atoms	20
Num. arom. heavy atoms	11
Fraction Csp3	0.38
Num. rotatable bonds	6
Num. H-bond acceptors	6
Num. H-bond donors	2
Molar Refractivity	68.76
TPSA	62.97 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	2.64
Log $P_{o/w}$ (XLOGP3)	0.58
Log $P_{o/w}$ (WLOGP)	1.79
Log $P_{o/w}$ (MLOGP)	1.66
Log $P_{o/w}$ (SILICOS-IT)	1.81
Consensus Log $P_{o/w}$	1.69

Water Solubility	
Log *S* (ESOL)	-1.97
Solubility	3.05e+00 mg/ml ; 1.08e-02 mol/l
Class	Very soluble
Log *S* (Ali)	-1.48
Solubility	9.45e+00 mg/ml ; 3.35e-02 mol/l
Class	Very soluble
Log *S* (SILICOS-IT)	-4.24
Solubility	1.64e-02 mg/ml ; 5.79e-05 mol/l
Class	Moderately soluble

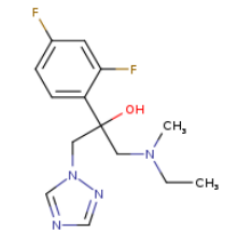
Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-7.61 cm/s

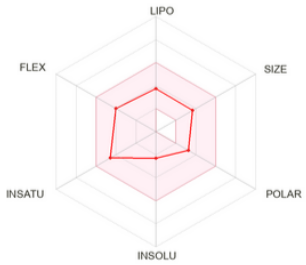
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	Yes
Synthetic accessibility	2.95

Figura 44 – Anexo B - Centroide *cluster* 5 - Análise completa realizada no SwissADME

Centroide Cluster 5





SMILES CCN(CC(c1ccc(cc1F)F)(Cn1cncn1)O)C

Physicochemical Properties	
Formula	C14H18F2N4O
Molecular weight	296.32 g/mol
Num. heavy atoms	21
Num. arom. heavy atoms	11
Fraction Csp3	0.43
Num. rotatable bonds	6
Num. H-bond acceptors	6
Num. H-bond donors	1
Molar Refractivity	73.66
TPSA	54.18 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	0.72
Log $P_{o/w}$ (XLOGP3)	1.04
Log $P_{o/w}$ (WLOGP)	2.13
Log $P_{o/w}$ (MLOGP)	1.92
Log $P_{o/w}$ (SILICOS-IT)	1.74
Consensus Log $P_{o/w}$	1.51

Water Solubility	
Log *S* (ESOL)	-2.32
Solubility	1.41e+00 mg/ml ; 4.74e-03 mol/l
Class	Soluble
Log *S* (Ali)	-1.77
Solubility	5.05e+00 mg/ml ; 1.71e-02 mol/l
Class	Very soluble
Log *S* (SILICOS-IT)	-3.90
Solubility	3.70e-02 mg/ml ; 1.25e-04 mol/l
Class	Soluble

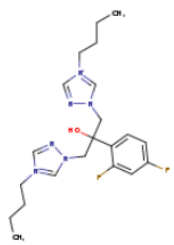
Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-7.37 cm/s

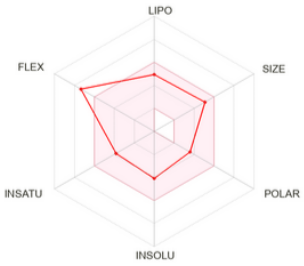
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	0 alert
Leadlikeness	Yes
Synthetic accessibility	3.05

Figura 45 – Anexo B - Centroide *cluster* 6 - Análise completa realizada no SwissADME

Centroide Cluster 6 (CHEMBL1852085)





SMILES CCCC[n+]1cnn(c1)CC(c1ccc(cc1F)F)(Cn1nc[n+](c1)CCCC)O

Physicochemical Properties	
Formula	C21H30F2N6O++
Molecular weight	420.50 g/mol
Num. heavy atoms	30
Num. arom. heavy atoms	16
Fraction Csp3	0.52
Num. rotatable bonds	11
Num. H-bond acceptors	5
Num. H-bond donors	1
Molar Refractivity	111.14
TPSA	63.63 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	-7.51
Log $P_{o/w}$ (XLOGP3)	3.15
Log $P_{o/w}$ (WLOGP)	2.85
Log $P_{o/w}$ (MLOGP)	2.96
Log $P_{o/w}$ (SILICOS-IT)	2.41
Consensus Log $P_{o/w}$	0.77

Water Solubility	
Log *S* (ESOL)	-4.10
Solubility	3.34e-02 mg/ml ; 7.94e-05 mol/l
Class	Moderately soluble
Log *S* (Ali)	-4.16
Solubility	2.93e-02 mg/ml ; 6.98e-05 mol/l
Class	Moderately soluble
Log *S* (SILICOS-IT)	-5.02
Solubility	4.04e-03 mg/ml ; 9.62e-06 mol/l
Class	Moderately soluble

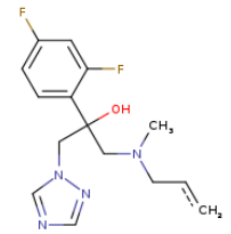
Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-6.63 cm/s

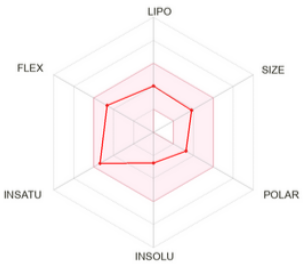
Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	No; 1 violation: Rotors>10
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	1 alert: quaternary_nitrogen_1
Leadlikeness	No; 2 violations: MW>350, Rotors>7
Synthetic accessibility	3.59

Figura 46 – Anexo B - Centroide *cluster* 7 - Análise completa realizada no SwissADME

Centroide Cluster 7





SMILES [CH3]=[CH2]CN(CC(c1ccc(cc1F)F)(Cn1cncn1)O)C

Physicochemical Properties	
Formula	C15H18F2N4O
Molecular weight	308.33 g/mol
Num. heavy atoms	22
Num. arom. heavy atoms	11
Fraction Csp3	0.33
Num. rotatable bonds	7
Num. H-bond acceptors	6
Num. H-bond donors	1
Molar Refractivity	78.00
TPSA	54.18 Å²

Lipophilicity	
Log $P_{o/w}$ (iLOGP)	-4.22
Log $P_{o/w}$ (XLOGP3)	1.57
Log $P_{o/w}$ (WLOGP)	2.29
Log $P_{o/w}$ (MLOGP)	2.09
Log $P_{o/w}$ (SILICOS-IT)	2.13
Consensus Log $P_{o/w}$	0.77

Water Solubility	
Log *S* (ESOL)	-2.65
Solubility	6.92e-01 mg/ml ; 2.25e-03 mol/l
Class	Soluble
Log *S* (Ali)	-2.32
Solubility	1.48e+00 mg/ml ; 4.81e-03 mol/l
Class	Soluble
Log *S* (SILICOS-IT)	-4.30
Solubility	1.54e-02 mg/ml ; 5.00e-05 mol/l
Class	Moderately soluble

Pharmacokinetics	
GI absorption	High
BBB permeant	Yes
P-gp substrate	Yes
CYP1A2 inhibitor	No
CYP2C19 inhibitor	No
CYP2C9 inhibitor	No
CYP2D6 inhibitor	No
CYP3A4 inhibitor	No
Log K_p (skin permeation)	-7.07 cm/s

Druglikeness	
Lipinski	Yes; 0 violation
Ghose	Yes
Veber	Yes
Egan	Yes
Muegge	Yes
Bioavailability Score	0.55

Medicinal Chemistry	
PAINS	0 alert
Brenk	1 alert: isolated_alkene
Leadlikeness	Yes
Synthetic accessibility	3.14