Michel Pires da Silva

Inteligência Artificial e Modelagem Molecular na Descoberta e Reposicionamento de Fármacos: Um Estudo de Caso Aplicado à Doença de Alzheimer para a Seleção de Inibidores da Acetilcolinesterase, Butirilcolinesterase e β-Secretase

São João del-Rei
Minas Gerais
25 de setembro de 2025

Michel Pires da Silva

Inteligência Artificial e Modelagem Molecular na Descoberta e Reposicionamento de Fármacos: Um Estudo de Caso Aplicado à Doença de Alzheimer para a Seleção de Inibidores da Acetilcolinesterase, Butirilcolinesterase e β-Secretase

Tese submetida ao Programa de Pós-Graduação em Bioengenharia da Universidade Federal de São João del-Rei, como parte dos requisitos para a obtenção do título de Scientiae Doctor (Sc.D.)

São João del-Rei
Minas Gerais
25 de setembro de 2025

Ao meu filho Pedro e minha esposa Fabrícia

Agradecimentos

Ao alcançar a conclusão desta tese, reconheço que este não é um feito individual, mas o resultado de uma trajetória permeada por apoio, inspiração e colaboração.

À minha esposa Fabrícia e ao meu filho Pedro, gostaria de registrar minha mais profunda gratidão. O apoio sincero e maravilhoso que sempre me dedicaram, a força que me transmitiram nos momentos mais desafiadores e a compreensão diante das longas horas de estudo e pesquisa foram fundamentais para que eu perseverasse nesta caminhada. Sem o amor e a presença de vocês, este momento não seria possível.

Aos meus pais, Vânia e Antônio Carlos, registro minha mais sincera e profunda gratidão pelas inúmeras oportunidades que me ofereceram ao longo da vida, pelo exemplo constante de dedicação e pelos valores que, com amor e cuidado, sempre me transmitiram. Esses ensinamentos foram fundamentais na formação da pessoa e do profissional que hoje me tornei. À minha irmã, Melina, expresso meu reconhecimento por ser uma fonte de força, resiliência e inspiração, cuja presença e apoio foram essenciais ao longo desta trajetória e para a concretização desta conquista.

Agradeço imensamente ao meu orientador, Professor Dr. Alex Gutterres Taranto, e ao meu coorientador, Professor Dr. Alisson Marques da Silva, pela competência, orientação segura, paciência e pelo constante estímulo intelectual. Suas valiosas contribuições foram determinantes para a qualidade deste trabalho, bem como para o meu amadurecimento acadêmico e científico. A ambos expresso minha mais sincera gratidão.

Aos amigos e colegas do CEFET-MG, manifesto minha sincera gratidão pelo apoio, seja por meio de gestos diretos ou indiretos, que muito contribuíram para a superação dos desafios e para a concretização desta trajetória. Ao CEFET-MG, instituição que sempre me acolheu e me proporcionou valiosas oportunidades de crescimento pessoal e profissional, registro meu reconhecimento e profundo agradecimento. À Universidade Federal de São João del-Rei (UFSJ), expresso minha gratidão pela oportunidade de realizar o doutoramento e pelo aprendizado adquirido ao longo deste percurso, bem como pelos inestimáveis ensinamentos transmitidos por diversos professores com os quais tive a honra de interagir. Ao Programa de Pós-Graduação em Bioengenharia (PPBE), dirijo meu especial agradecimento pela excelência acadêmica, pelo

profissionalismo e pela atenção constante. De modo particular, agradeço ao Prof. Antônio Márcio Rodrigues e à profissional Luciana Guimarães, cujos direcionamentos, dedicação e comprometimento foram determinantes para o desenvolvimento e êxito deste trabalho.

Ao meu estimado amigo Ari, um soteropolitano singular e admirável, cuja sabedoria, determinação e generosidade são inspiradoras, expresso minha profunda gratidão pelos valiosos ensinamentos que me proporcionou, tanto na área de atuação quanto na vida.

A Deus, expresso minha gratidão por conceder-me a resiliência necessária para prosseguir, mesmo diante das adversidades, e por renovar, a cada etapa, minhas forças, fortalecendo-me de maneira contínua ao longo desta jornada. A compreensão de que é no enfrentamento das dificuldades que se revelam as mais genuínas oportunidades permeou toda a minha trajetória acadêmica, inspirando-me a transformar cada desafio em aprendizado, cada obstáculo em superação e cada limitação em possibilidade concreta de crescimento. Permaneço, assim, convicto de que é na perseverança e na insistência que a transformação deixa de ser mera expectativa para tornar-se realidade manifesta.

Aos órgãos de fomento FAPEMIG, CNPq e CAPES, registro minha sincera gratidão pelo apoio, pelo direcionamento estratégico e pelas oportunidades concedidas ao longo desta trajetória acadêmica. O suporte proporcionado por essas instituições foi decisivo para a viabilização das diferentes etapas deste trabalho, refletindo seu compromisso permanente com o avanço científico e tecnológico do país e com a formação de recursos humanos altamente qualificados.

A todos, o meu mais sincero e profundo agradecimento.

"É no enfrentamento das adversidades e dificuldades que se revelam verdadeiras oportunidades de transformação e crescimento."

Nietzsche e Albert Einstein

Sumário

Lista de Figuras **iii**

Lista de Tabelas **xiv**

Lista de Abreviações e Siglas **xix**

1 Introdução **1**

2 Avanços no Tratamento do Alzheimer: Perspectivas Patológica, Molecular e Terapêuticas **5**

2.1 Considerações Iniciais 5
2.2 Características Patológicas Prevalentes 5
2.3 Avanços no Tratamento do Alzheimer 8
2.4 Considerações Finais 12

3 Design Racional de Fármacos: Evolução das Estratégias Computacionais para Descoberta e Reposicionamento Terapêutico **15**

3.1 Considerações Iniciais 15
3.2 Fundamentos do CADD 16
3.2.1 Definições e Tipos 17
3.3 Fontes e Preparação de Dados 19
3.3.1 Ferramentas de Exploração, Pré-processamento e Normalização 21
3.4 Triagem Virtual e Docking Molecular 25
3.4.1 Algoritmos e Modelos de Acoplamento 26
3.4.2 Abordagens Híbridas e Modelos Baseados em Similaridade 27
3.4.3 Refinamento Pós-Docking e Protocolos de Validação 28
3.5 Dinâmica Molecular 29
3.5.1 Ferramentas e Ambientes de Simulação 30
3.6 Inteligência Artificial 34

3.6.1 Preparação e Normalização de Dados 36
3.6.2 Avaliação de Desempenho: Métricas e Aplicabilidades 41
3.7 Considerações Finais 43

4 *DrugHunter*: Um Fluxo de Trabalho Integrado para Curadoria, Triagem Virtual de Alto Desempenho e Dinâmica Molecular 45
4.1 Considerações Iniciais 45
4.2 Da Curadoria à Integração de Bases Moleculares 46
4.2.1 Recuperação e Integração de Dados 48
4.2.2 Assinaturas Vetoriais e Análise de Similaridade 50
4.2.3 Construção e Análise de Redes de Interação Molecular 51
4.2.4 Design Modular, Escalabilidade e Generalização Funcional 53
4.3 Ancoragem Molecular por Aprendizado Profundo 54
4.3.1 Treinamento, Validação e Teste por Estratégia de Consenso 56
4.3.2 Otimização Autônoma de Hiperparâmetros para Modelos de IA 58
4.3.3 Eficiência Computacional e Flexibilidade Arquitetural 60
4.3.4 Predição em Larga Escala e Aplicação em Triagem Virtual 60
4.3.5 Características Estratégicas do *NeuroDock* como Ferramenta AIDD . . . 62
4.4 *DrugHunter*: Integração, Ampliação e Consolidação 62
4.4.1 Arquitetura Modular do DrugHunter 64
4.5 Considerações Finais 70

5 Aplicação do *DrugHunter* à Descoberta de Inibidores Multialvo para a Doença de Alzheimer 73
5.1 Considerações Iniciais 73
5.2 Aquisição e Curadoria de Dados Moleculares 74
5.2.1 Recuperação e Análise dos Complexos Biomoleculares 75
5.2.2 Recuperação de Compostos da ChEMBL e ZINC 77
5.2.3 Assinaturas Moleculares e Projeções para Análise Estrutural 81
5.3 Caracterização Topológica e Funcional das Bibliotecas Moleculares 81
5.3.1 Análise da Acetilcolinesterase 82
5.3.2 Análise da Butirilcolinesterase 86
5.3.3 Análise da Beta-Secretase 90
5.4 Predição de Ancoragem Molecular 94
5.5 Simulações e Dinâmica Molecular 102

6 Conclusões e Perspectivas Futuras 109
6.1 Considerações Finais 109
6.1.1 Perspectivas Futuras 111
6.1.2 Principais Contribuições 112

A Dados complementares: Avaliações de Dinâmica Molecular para Diferentes Compostos Selecionados no *NeuroDock* **115**

B Relação de Aminoácidos **129**

Lista de Figuras

1 Fluxograma representativo do paradigma tradicional para a descoberta de fármacos. O processo tem início com a recuperação de informações do domínio químico e biológico para a formulação da hipótese. Segue-se para a triagem primária (*in vitro*) e um ciclo iterativo de modelagem, síntese e caracterização molecular para otimização dos *hits*. Por fim, os compostos promissores avançam para os ensaios secundários (*in vivo*) para a validação do candidato a fármaco. xxvii

2.1 Esquema ilustrativo de algumas das principais alterações patológicas associadas à Doença de Alzheimer. À esquerda, observa-se uma região cerebral preservada, caracterizada por morfologia neuronal e organização sináptica típicas. À direita, evidencia-se uma área acometida pelos processos associados à doença. Os elementos destacados estão diretamente relacionados às temáticas desenvolvidas ao longo deste capítulo, compondo um panorama integrativo dos mecanismos clínicos, fisio– e neuropatológicos subjacentes à progressão da DA. 6

2.2 Representação esquemática comparativa das duas principais categorias etiológicas da Doença de Alzheimer e seus respectivos mecanismos fisiopatológicos predominantes. Na parte superior, destaca-se a forma familiar, de origem genética herdada e início precoce ($\leq$ 65 anos), associada a mutações com expressividade clínica elevada em genes como *APP*, *PSEN1* e *PSEN2*. Na parte inferior, apresenta-se a forma esporádica, multifatorial e de início tardio ($>$ 65 anos), envolvendo fatores genéticos de risco (e.g., *APOE* ϵ4, *TREM2*), alterações ambientais e processos celulares como estresse oxidativo, inflamação crônica e disfunção mitocondrial. A interseção ($\cap$) entre os grupos evidencia processos fisiopatológicos comuns, como a hiperfosforilação da proteína tau e formação de emaranhados neurofibrilares, a degeneração colinérgica (núcleo basal de Meynert), a deposição do peptídeo beta-amiloide (Aβ) e a atrofia cortical progressiva, embora mediados por mecanismos distintos entre os subtipos clínicos. 11

3.1 Esquemático típico utilizado na descoberta de medicamentos por auxílio computacional. **SBVS**: O processo inicia com a seleção e preparação dos alvos moleculares (1), seguida pela validação do protocolo de *redocking* e cálculo de RMSD (2). Em seguida, realiza-se a seleção de compostos candidatos (3) que são submetidos à triagem virtual (4), incluindo *docking* molecular e refinamento com dinâmica molecular. **LBVS**: O fluxo começa com a seleção de inibidores conhecidos (1) para a modelagem da atividade (2), que envolve a preparação dos dados, geração de assinaturas moleculares e/ou construção de modelos QSAR. Na sequência, realiza-se a coleta e curadoria de bibliotecas químicas (3), submetidas à triagem virtual (4) com base na similaridade molecular (e.g., Tanimoto), seguida da validação dos compostos identificados. 18

3.2 Representação esquemática do processo de geração de três tipos de *fingerprints* moleculares amplamente utilizados em aplicações de IA no contexto de CADD/AIDD: Morgan, farmacofóricos e MACCS. As impressões digitais de Morgan, baseadas em algoritmos de expansão radial centrados nos átomos, codificam a vizinhança química em torno de cada átomo até um determinado raio (geralmente $r = 2$), gerando comumente uma representação binária de 2.048 bits. Nessa codificação, características estruturais como tipos atômicos, hibridização, estados de carga e conectividade são consideradas como informações potenciais mapeáveis, enquanto relações de ligação não são explicitamente codificadas. As assinaturas farmacofóricas, por sua vez, descrevem os arranjos espaciais relativos entre grupos funcionais-chave (doadores e aceptores de hidrogênio, regiões hidrofóbicas, cargas positivas e negativas, entre outros), resultando em uma representação sensível ao potencial de interação molecular. Já os *fingerprints* MACCS consistem em um vetor binário de 166 bits, no qual cada posição corresponde à presença ou ausência de uma subestrutura química predefinida segundo um conjunto fixo de padrões estruturais. Essas diferentes abordagens oferecem descrições complementares das moléculas, variando quanto à especificidade estrutural, sensibilidade topológica e aplicabilidade em tarefas de triagem, classificação e predição molecular. 39

4.1 Fluxo de trabalho do *BioMolExplorer*, mostrando suas diversas etapas de recuperação e integração de dados. As linhas tracejadas representam as etapas manuais de pré-processamento fora da estrutura do *BioMolExplorer*, enquanto as linhas pontilhadas representam os subprocessos autônomos providos pela arquitetura desenvolvida para investigar a qualidade dos dados, as relações e as sobreposições entre as características moleculares e físico-químicas dos dados. . . 47

4.2 Arquitetura conceitual do *NeuroDock*, composta por quatro estágios principais: (a) leitura da base de moléculas e seus análogos, previamente identificados no processo de extração dos MCCs conduzido pelo *BioMolExplorer*; (b) execução do modelo de consenso, integrando os resultados de *docking* obtidos a partir dos algoritmos *AutoDock Vina* e *Dock6*, com vistas à geração de *scores* por alvo terapêutico de interesse; (c) composição dinâmica da arquitetura da rede neural e otimização dos hiperparâmetros, assegurando adequação ao espaço químico modelado; e (d) teste e aplicação do modelo treinado para predição em larga escala, viabilizando a TV de extensos bancos moleculares com elevada eficiência computacional. 54

4.3 Representação esquemática da arquitetura modular do *DrugHunter*. A solução proposta é estruturada em cinco etapas principais: (i) curadoria e pré-processamento de dados químicos e biológicos; (ii) triagem virtual com algoritmos de *docking* molecular; (iii) integração e análise de resultados de *docking/-redocking*; (iv) execução e avaliação de simulações de dinâmica molecular; e (v) geração e análise de trajetórias simuladas. Cada módulo foi desenvolvido para operar de forma independente ou integrada, conforme as necessidades específicas de cada estudo, garantindo flexibilidade, escalabilidade e reprodutibilidade. . . . 65

5.1 Diagramas de Venn representando as interseções entre os conjuntos de compostos obtidos para os três alvos terapêuticos investigados: AChE, BChE e BACE1. À esquerda (a), são ilustradas as sobreposições entre os compostos bioativos, com destaque para a interseção entre AChE e BChE (116 moléculas), e ausência de sobreposição com BACE1. Ao centro (b), tem-se a distribuição conjunta entre bioativos e análogos para cada alvo, evidenciando interseções mais relevantes, como entre AChE e BChE (1.166 compostos), entre AChE e BACE1 (3 compostos) e entre os três alvos simultaneamente (52 compostos). À direita (c), apresentam-se as interseções entre os análogos estruturais, destacando-se novamente a presença de 52 compostos compartilhados entre os três alvos, e a ausência de sobreposição exclusiva entre BChE e BACE1. 80

5.2 Análise comparativa das redes de interação molecular para o alvo terapêutico AChE. **(a)** Rede e gráficos associados para o conjunto de 57 compostos bioativos confirmados. **(b)** Rede e gráficos associados para o conjunto expandido de 473 análogos estruturais. Para ambas as redes, os nós são coloridos de acordo com seu grau (conectividade), e são apresentados os gráficos de *Ranking* de Graus, Histograma de Graus e a Relação de Graus entre os MCCs e as redes de relação completas. No canto inferior esquerdo de cada rede, encontra-se representado o maior fragmento comum identificado, o qual sintetiza a subestrutura recorrente de maior frequência observada entre os compostos analisados, servindo como marcador estrutural representativo das interações mapeadas. 83

5.3 Distribuição dos compostos da AChE no espaço químico reduzido via t-SNE, com agrupamentos definidos por KMeans, utilizando o método de *elbow* para definição do número adequado de *clusters* e PCA para a definição dos vetores de classificação: (a) compostos bioativos, (b) compostos análogos. 86

5.4 Análise comparativa das redes de interação molecular para o alvo terapêutico BChE. (a) Rede e gráficos associados para o conjunto de 85 compostos bioativos confirmados. (b) Rede e gráficos associados para o conjunto expandido de 306 análogos estruturais. Para ambas as redes, os nós são coloridos de acordo com seu grau (conectividade), e são apresentados os gráficos de *Ranking* de Graus, Histograma de Graus e a Relação de Graus entre os MCCs e as redes de relação completas. No canto inferior esquerdo de cada rede, encontra-se representado o maior fragmento comum identificado, o qual sintetiza a subestrutura recorrente de maior frequência observada entre os compostos analisados, servindo como marcador estrutural representativo das interações mapeadas. 88

5.5 Distribuição dos compostos da BChE no espaço químico reduzido via t-SNE, com agrupamentos definidos por KMeans, utilizando o método de *elbow* para definição do número adequado de *clusters* e PCA para a definição dos vetores de classificação: (a) compostos bioativos, (b) compostos análogos. 89

5.6 Análise comparativa das redes de interação molecular para o alvo terapêutico BACE1. (a) Rede e gráficos associados para o conjunto de 667 compostos bioativos confirmados. (b) Rede e gráficos associados para o conjunto expandido de 200 análogos estruturais. Em ambas as redes, os nós representam compostos moleculares e estão coloridos de acordo com seu grau de conectividade. São apresentados os gráficos de *Ranking* de Graus, Histograma de Graus e a Relação de Graus entre os MCCs e as respectivas redes completas. No canto inferior esquerdo de cada rede, encontra-se representado o maior fragmento comum identificado, o qual sintetiza a subestrutura recorrente de maior frequência observada entre os compostos analisados, servindo como marcador estrutural representativo das interações mapeadas. 91

5.7 Distribuição dos compostos da BACE1 no espaço químico reduzido via t-SNE, com agrupamentos definidos por KMeans, utilizando o método de *elbow* para definição do número adequado de *clusters* e PCA para a definição dos vetores de classificação: (a) compostos bioativos, (b) compostos análogos. 93

5.8 Comparação da evolução das métricas de desempenho durante o treinamento de duas arquiteturas de redes neurais aplicadas à predição de propriedades de ancoragem moleculares: (a) rede MLP e (b) rede ResNet. Cada linha representa a média dos valores obtidos ao longo de múltiplas execuções, enquanto as faixas sombreadas indicam o desvio padrão. As curvas de treino e validação são apresentadas em azul e laranja, respectivamente, enquanto os valores de teste estão representados por linhas tracejadas vermelhas. 97

5.9 Análise de contribuição energética residual para o composto 16399049 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 100

5.10 Análise de contribuição energética residual para o composto 16399049 em complexo formado com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 101

5.11 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC 16399049, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE. 104

5.12 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante 16399049, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE. 106

5.13 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante 16399049, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1. 106

A.1 Análise de contribuição energética residual para o composto 95467590 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 116

A.2 Análise de contribuição energética residual para o composto 95467590 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 116

A.3 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC 95467590, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE. 117

A.4 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante 95467590, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE. 117

A.5 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante 95467590, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1. 118

A.6 Análise de contribuição energética residual para o composto 1888911932 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 118

A.7 Análise de contribuição energética residual para o composto 1888911932 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 119

A.8 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC `1888911932`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE. 119

A.9 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `1888911932`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE. . . . 120

A.10 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `1888911932`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1. . . . 120

A.11 Análise de contribuição energética residual para o composto `1342121` em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 121

A.12 Análise de contribuição energética residual para o composto `1342121` em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 121

A.13 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC `1342121`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE. 122

A.14 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `1342121`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE. 122

A.15 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `1342121`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1. 123

A.16 Análise de contribuição energética residual para o composto `16429338` em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 123

A.17 Análise de contribuição energética residual para o composto `16429338` em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 124

A.18 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC `16429338`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE. 124

A.19 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `16429338`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE. 125

A.20 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `16429338`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1. 125

A.21 Análise de contribuição energética residual para o composto `16523915` em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 126

A.22 Análise de contribuição energética residual para o composto `16523915` em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*. 126

A.23 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC `16523915`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE. 127

A.24 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `16523915`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE. 127

A.25 Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `16523915`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1. 128

B.1 Descrição dos vinte aminoácidos canônicos utilizados na síntese proteica, incluindo suas denominações completas, abreviações padrão (três letras e uma letra) e suas representações estruturais no formato SMILES. 129

Lista de Tabelas

3.1 Síntese dos principais avanços promovidos por técnicas de Inteligência Artificial (IA), Aprendizado de Máquina (ML), Aprendizado Profundo (DL) e abordagens híbridas (AIDD) ao longo das distintas etapas do *workflow* computacional de descoberta e desenvolvimento de fármacos (CADD). A tabela destaca, de forma estruturada, contribuições metodológicas, impactos diretos na triagem virtual convencional e de alto desempenho (TV/HTVS), bem como perspectivas integrativas que viabilizam a transição para abordagens multiescalares, preditivas e centradas em dados. 37

3.3 Comparação entre as principais abordagens de representação molecular utilizadas em CADD/AIDD. As representações são avaliadas quanto à natureza dos dados, expressividade estrutural/farmacofórica, compatibilidade com modelos de aprendizado e limitações computacionais. 40

3.5 Principais métricas de avaliação utilizadas em modelos de IA aplicados a tarefas de classificação e regressão. A tabela descreve a aplicabilidade de cada métrica conforme o tipo de tarefa, bem como suas principais vantagens e limitações. Métricas como Acurácia, Precisão, Revocação, F1-Score e AUC-ROC são amplamente utilizadas na avaliação de classificadores, especialmente em contextos biomédicos e farmacológicos. Por sua vez, R^2, RMSE e MAE são comumente empregados na análise de desempenho de modelos de regressão, permitindo avaliar a qualidade preditiva sobre variáveis contínuas. 42

4.1 Procedimentos adotados no UCSF Chimera para a preparação do complexo, receptor e ligante a partir da estrutura cristalográfica original. 48

4.4 Configuração inicial utilizada na molelagem do *NeuroDock*, detalhando os principais parâmetros de configuração da arquitetura, a estratégia de otimização e o processo de avaliação do modelo. A tabela inclui: (i) parâmetros estruturais da rede, como limites de unidades por camada e funções de ativação; (ii) hiperparâmetros relacionados à regularização, otimização e inicialização dos pesos; (iii) métricas de avaliação; e (iv) aspectos relativos à divisão dos dados para treinamento, validação e teste. 55

4.7 Fluxo de preparação das melhores conformações obtidas a partir do *AutoDock Vina* no UCSF Chimera, após a conversão dos arquivos PDBQT para PDB via *OpenBabel*. O processo resulta em arquivos no formato MOL2, devidamente parametrizados e prontos para execução no *Dock6*. 57

4.9 Apresentação e resumo comparativo entre os métodos de normalização Min-Max e Z-Score, utilizados na padronização dos resultados de *docking* por consenso no *NeuroDock*. 57

4.11 Hiperparâmetros empregados no processo de otimização do *NeuroDock*, incluindo suas descrições funcionais, benefícios para o ajuste do modelo e os respectivos intervalos ou conjuntos de valores considerados durante a busca. 59

4.13 Descrição dos parâmetros utilizados na função `execute_md_simulation`, responsável por orquestrar a execução das simulações de DM. A tabela especifica os nomes dos parâmetros, seus respectivos valores padrão e uma descrição funcional, incluindo aspectos relacionados à preparação do sistema, à escolha dos campos de força, à configuração do ambiente termodinâmico, ao ajuste de propriedades do integrador e à definição das condições de saída. 68

5.1 Parâmetros empregados na configuração da função `load_pdb` para a recuperação automatizada das estruturas cristalográficas das enzimas-alvo. As consultas foram restringidas exclusivamente a estruturas de proteínas determinadas por difração de raios X, com resolução máxima de 2,0 Å, e que apresentam, em sua composição estrutural, ligantes cocristalizados como parte de sua estrutura. . . . 76

5.3 Resultados de *redocking* molecular para os complexos proteína-ligante correspondentes aos alvos terapêuticos AChE, BChE e BACE1. A análise considera as estruturas cristalográficas utilizadas como referência, incluindo o código PDB, o ligante ancorado, o número e a cadeia do resíduo chave, e a resolução experimental da estrutura. A métrica de avaliação principal foi o RMSD entre a conformação obtida do *AutoDock Vina* e a cristalográfica, sendo o menor valor de RMSD destacado em verde para evidenciar a melhor correspondência estrutural obtida. 76

5.6 Parâmetros aplicados na filtragem dos compostos bioativos extraídos da base ChEMBL para cada alvo terapêutico de interesse. Os critérios apresentados foram definidos com o objetivo de restringir o conjunto de dados a moléculas com maior relevância farmacológica, assegurando consistência estrutural, qualidade informacional e comparabilidade entre os registros. Tais parâmetros encontram-se especificados nos arquivos `src/crawlers/bioactivity.json` e `src/crawlers/molecules.json`, os quais integram o núcleo automatizado de curadoria da plataforma *DrugHunter*. 78

5.8 Parâmetros utilizados na recuperação dos análogos estruturais associados aos compostos bioativos previamente extraídos da base ChEMBL. Os filtros foram definidos com o objetivo de priorizar compostos estruturalmente relevantes, quimicamente viáveis e compatíveis com os critérios farmacocinéticos clássicos, assegurando a coerência do domínio químico. Os parâmetros encontram-se especificados no arquivo `src/crawlers/analogs.json`, utilizado pela plataforma *DrugHunter* para condução automatizada desta etapa. 79

5.10 Distribuição das moléculas bioativas e de seus análogos estruturais recuperadas para cada alvo terapêutico, após a aplicação dos filtros descritos no texto. Os totais referem-se ao número bruto de representações obtidas para cada classe (bioativo × análogo) e não contabilizam eventuais sobreposições entre compostos, sendo apresentados exclusivamente para ilustrar a amplitude do espaço químico reunido. 79

5.12 Comparação estrutural e topológica entre as redes de compostos bioativos e de análogos estruturais associados à AChE. As métricas incluem o número de compostos e de relações no MCC (MaxComp), bem como características topológicas e da distribuição de grau. 85

5.14 Comparação detalhada entre os sítios ativos das enzimas AChE e BChE, destacando as principais diferenças estruturais, topológicas e funcionais. As distinções observadas influenciam diretamente a seletividade, o espectro de substratos reconhecidos e a natureza das interações moleculares. Tais características são determinantes para o planejamento de inibidores seletivos ou multialvo, especialmente em abordagens computacionais de reposicionamento de fármacos para contextos polifarmacológicos. 89

5.16 Comparação estruturada entre os conjuntos de compostos bioativos e análogos estruturais para BACE1, considerando aspectos de diversidade química, topologia da rede de interação molecular e implicações de agrupamento no contexto de estratégias de descoberta e otimização de fármacos. 93

5.19 Resultados de *docking* para os cinco compostos com maior afinidade frente aos alvos AChE, BChE e BACE1 avaliados por *AutoDock Vina* e *Dock6* sob o modelo de consenso. São apresentados os *scores* individuais, o *z-score* do composto e o intervalo min-max de normalização. 95

5.21 Hiperparâmetros utilizados na configuração dos modelos de DL empregados nos experimentos de regressão. Os valores apresentados foram previamente otimizados a partir de testes com a arquitetura MLP e utilizados como base para a avaliação comparativa com a rede residual (ResNet). 96
5.23 Predições de afinidade de ligação para os principais candidatos moleculares às enzimas AChE, BChE e BACE1. A tabela apresenta os 20 compostos mais bem ranqueados com base em uma abordagem de consenso orientada ao contexto multi-alvo. Para cada composto, são fornecidos o identificador ZINC, a representação SMILES da estrutura química e os respectivos *scores* normalizados de afinidade preditiva frente a cada uma das três enzimas-alvo. Valores próximos de 1 indicam elevada afinidade estimada de interação. O critério de ranqueamento adotado considera o produto entre os valores de ancoragem preditos, de modo a favorecer compostos com desempenho simultaneamente elevado em todos os alvos moleculares analisados. 98
5.25 Parâmetros físico-químicos dos compostos selecionados extraídos da ferramenta *DataWarrior*, identificados por seus códigos ZINC, incluindo peso molecular, coeficiente de partição (LogP), número de doadores (HBD) e aceitadores (HBA) de hidrogênio, área polar de superfície (TPSA), número de átomos pesados e quantidade de anéis aromáticos. Atributos estruturais essenciais para a avaliação do potencial de permeabilidade à barreira hematoencefálica e para a otimização farmacológica de moléculas com atividade no sistema nervoso central. 101
5.28 Parâmetros utilizados para a configuração das simulações de dinâmica molecular conduzidas com o OpenMM por meio da função `execute_md_simulation()`. Os valores refletem a execução padrão para os compostos priorizados pelo *NeuroDock*, considerando equilíbrio e produção sob condições fisiológicas e ambiente solvatado. 102

Lista de Abreviações e Siglas

AChE Acetilcolinesterase

ADMET Absorption, Distribution, Metabolism, Excretion and Tolerable Toxicity

AIDD *Artificial Intelligence in Drug Discovery*

AMBER *Assisted Model Building with Energy Refinement*

API Interfaces de Programação de Aplicações

*APOE*4 Apolipoproteína E

APP *Amyloid Precursor Protein*

*BACE*1 β-secretase 1

BChE Butirilcolinesterase

BioBB *BioExcel Building Blocks*

CADD *Computational Aided Drug Design*

ChEMBLWSC *ChEMBL web services client*

DA Doença de Alzheimer

DL *Deep Learning*

DM *Dinâmica Molecular*

DSV *Discovery Studio Visualizer*

DTI *Drug-Target Interactions*

FDA *Food and Drug Administration*

GaMD *Gaussian Accelerated Molecular Dynamics*

GNN *Graph Neural Network*

GROMACS *GROningen MAchine for Chemical Simulations*

HTMD *High-Throughput Molecular Dynamics*

HTVS *High-Throughput Virtual Screening*

IA Inteligência Artificial

InChI *International Chemical Identifier*

LBVS *Ligand-Based Virtual Screening*

MAIA *Molecular Artificial Intelligence for Analysis*

MCS *Maximum Common Substructure*

ML *Machine Learning*

MLP *Multilayer Perceptron*

MTD *Multi-Target-Directed Ligands*

NAMD *Nanoscale Molecular Dynamics*

NCBI *National Center for Biotechnology Information*

NLP *Natural Language Processing*

PCA *Principal Component Analysis*

PDB *Protein Data Bank*

PSEN − 1 Presenilina-1

PSEN − 2 Presenilina-2

QSAR *Quantitative Structure-Activity Relationships*

RF *Random Forests*

RMSD *Root Mean Square Deviation*

RNA Redes Neurais Artificiais

RNA *High-Throughput Screening*

RNN *Recurrent Neural Network*

SBVS *Structure-Based Virtual Screening*

SDF *Structure Data File*

SMILES *Simplified Molecular Input Line Entry System*

SNC Sistema Nervoso Central

SNP Sistema Nervoso Periférico

SVM *Support Vector Machines*

TSD *Target-Specific Drug Ligands*

TV *Triagem Virtual*

VMD *Visual Molecular Dynamics*

Abstract

PIRES, M. S. *Artificial Intelligence and Molecular Modeling in Drug Discovery and Repurposing: A Case Study Applied to Alzheimer's Disease for the Acetylcholinesterase, Butyrylcholinesterase, and β-Secretase Inhibitors Screening.* Thesis presented to the Graduate Program in Bioengineering at the Federal University of São João del-Rei, as part of the requirements for obtaining the title of Scientiae Doctor (Sc.D.), 2025.

Recent advances in drug discovery and repurposing have substantially contributed to improving population health and quality of life. Within this context, the investigation of multi-target inhibitors has emerged as a promising therapeutic strategy for neurodegenerative disorders associated with dementia, particularly Alzheimer's disease. The high costs and inherent complexity of traditional drug development have accelerated the adoption of computational approaches to support the identification and evaluation of novel therapeutic candidates. Among these approaches, virtual screening stands out for its efficiency in prioritizing bioactive compounds by analyzing their structural and physicochemical properties, thereby anticipating experimental stages typically associated with phase I clinical trials. In this work, we introduce a high-throughput virtual screening pipeline for drug discovery and repurposing, applied to a case study aimed at identifying inhibitors of acetylcholinesterase, butyrylcholinesterase, and β-secretase, key targets in the pathophysiology of Alzheimer's disease. To address the multifactorial and intricate nature of the disease, we developed an exploratory model driven by the extraction, curation, and analysis of biological data to identify compounds with desirable multi-target profiles. The proposed approach adopts a modular and extensible architecture, enabling the flexible composition of analysis workflows focused on exploring interactions between therapeutic targets, bioactive compounds, and analogous molecular scaffolds. In this sense, artificial intelligence techniques and advanced data visualization methods are integrated to enhance inference and decision-making during the process. Results show the proposed strategy's efficacy in recognizing patterns of structural and functional overlap among compounds, facilitating the identification of candidates with potential anchoring to multiple binding sites. These discoveries evidence the extensive applicability of the proposal workflow for rational virtual screening of therapeutic agents, particularly in the context of complex neurodegenerative disorders.

Keywords: Drug Discovery, Virtual Screening, Molecular Modeling, Alzheimer's Disease.

Resumo

PIRES, M. S. *Inteligência Artificial e Modelagem Molecular na Descoberta e Reposicionamento de Fármacos: Um Estudo de Caso Aplicado à Doença de Alzheimer para a Seleção de Inibidores da Acetilcolinesterase, Butirilcolinesterase e β-Secretase.* Tese apresentada ao Programa de Pós-Graduação em Bioengenharia da Universidade Federal de São João del-Rei, como parte dos requisitos para a obtenção do título de *Scientiae Doctor* (Sc.D.), 2025.

Os avanços recentes na descoberta e no reposicionamento de fármacos têm contribuído significativamente para a melhoria da qualidade de vida da população. Nesse contexto, a investigação de agentes inibidores multialvo emerge como uma abordagem promissora no tratamento de desordens neurodegenerativas associadas à demência, com destaque para a doença de Alzheimer. Nesse contexto, os elevados custos e a complexidade inerente ao desenvolvimento farmacológico tradicional têm impulsionado a adoção de métodos computacionais como suporte à identificação e avaliação de novos candidatos terapêuticos. Entre essas estratégias, a triagem virtual destaca-se por sua eficácia na priorização de compostos bioativos, a partir da análise de propriedades estruturais e físico-químicas, antecipando etapas experimentais típicas da fase I de ensaios clínicos. Neste trabalho, introduzimos um fluxo de descoberta e reposicionamento de fármacos, fundamentado em triagem virtual de alto desempenho, aplicado a um estudo de caso voltado à identificação de inibidores das enzimas acetilcolinesterase, butirilcolinesterase e β-secretase, alvos-chave na fisiopatologia da doença de Alzheimer. Para enfrentar os desafios inerentes à natureza complexa e multifatorial dessa doença, foi desenvolvido um modelo exploratório orientado à extração, curadoria e análise de dados biológicos, com o objetivo de identificar compostos com perfis multialvo desejáveis. A abordagem proposta adota uma arquitetura modular e extensível, permitindo a composição flexível de fluxos de análise orientados à exploração de interações entre alvos terapêuticos, compostos bioativos e estruturas moleculares análogas. Diferentes técnicas de inteligência artificial e visualização de dados são integradas ao modelo, proporcionando suporte à inferência e à tomada de decisão. Os resultados obtidos indicam que a estratégia desenvolvida possui abstrações robustas para o reconhecimento de padrões de sobreposição estrutural e funcional entre compostos, favorecendo a identificação de candidatos com potencial de ancoragem em múltiplos sítios de ligação, o que reforça sua aplicabilidade na triagem racional de agentes terapêuticos para doenças neurodegenerativas complexas.

Palavras-chave: Descoberta de Fármacos, Triagem Virtual, Modelagem Molecular, Doença de Alzheimer.

Resumo Expandido

Introdução

A descoberta e o reposicionamento de fármacos constituem desafios relevantes para a ciência farmacêutica, marcados pela elevada complexidade, pelos altos custos e pelos longos prazos de execução, com impactos diretos sobre a saúde pública. Parte dessas dificuldades decorre da baixa taxa de sucesso das abordagens tradicionais, já que apenas uma pequena fração dos candidatos em ensaios clínicos alcança aprovação regulatória e chega ao mercado (DOWDEN; MUNRO, 2019). A Figura 1 ilustra esse modelo, estruturado em duas etapas principais: (a) triagens primárias *in vitro*, geralmente conduzidas por ensaios de alto rendimento, voltadas à identificação de moléculas iniciais promissoras (*hits*); e (b) ensaios secundários *in vivo*, destinados à validação da eficácia, à caracterização de perfis farmacocinéticos e toxicológicos e à seleção de candidatos para o desenvolvimento pré-clínico. Embora essenciais, essas etapas apresentam limitações expressivas de escalabilidade, sobretudo em razão da elevada demanda por insumos, da dependência de infraestrutura especializada e da complexa cronologia que condiciona sua execução.

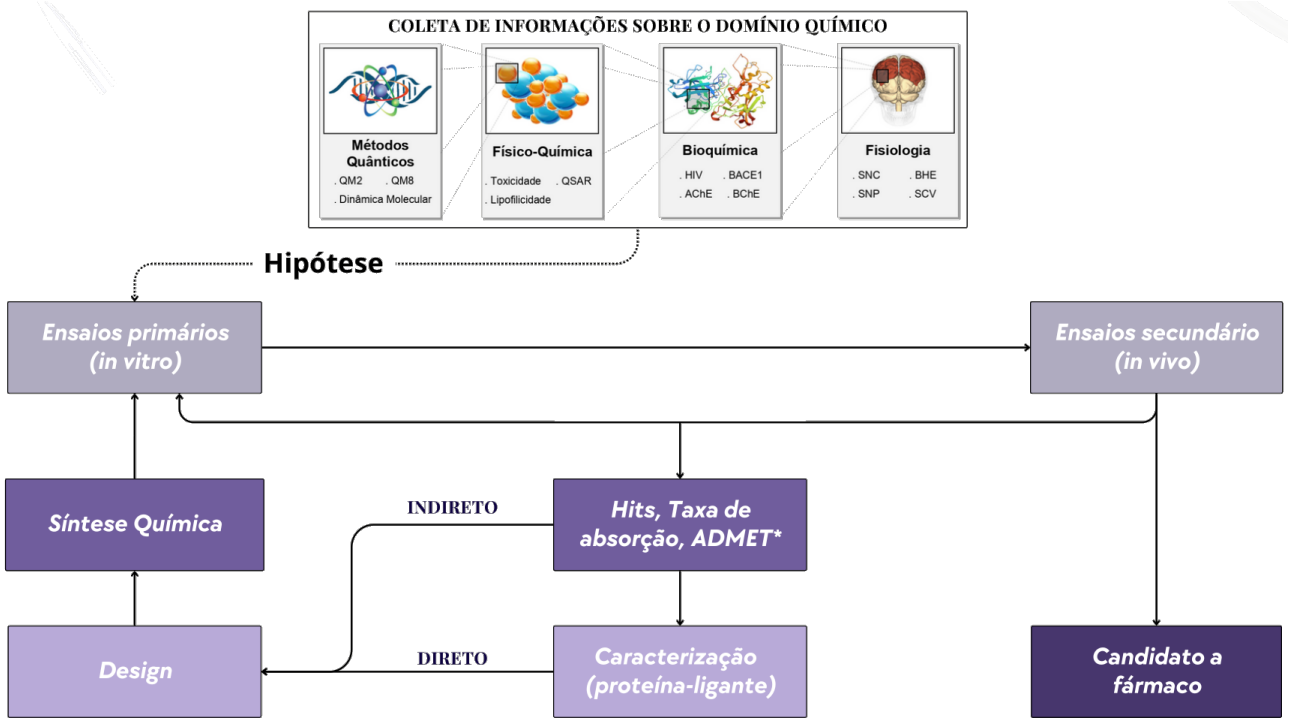

Figura 1: Fluxograma representativo do paradigma tradicional para a descoberta de fármacos. O processo tem início com a recuperação de informações do domínio químico e biológico para a formulação da hipótese. Segue-se para a triagem primária (*in vitro*) e um ciclo iterativo de modelagem, síntese e caracterização molecular para otimização dos *hits*. Por fim, os compostos promissores avançam para os ensaios secundários (*in vivo*) para a validação do candidato a fármaco.

Frente aos desafios de custo, tempo e baixa escalabilidade inerentes ao modelo tradicional, os avanços em computação de alto desempenho têm se consolidado como alternativas promissoras para acelerar etapas críticas, antecipar informações farmacológicas antes dos ensaios experimentais e otimizar a seleção de compostos, ampliando, assim, a eficiência de todo o processo. Nesse cenário, destacam-se as estratégias de modelagem molecular assistida por computador, as quais se inserem como etapa preliminar e complementar às abordagens convencionais anteriormente descritas. Por meio de simulações *in silico*, os modelos computacionais de modelagem molecular possibilitam a exploração de extensos conjuntos de compostos, favorecendo a identificação de fatores determinantes, como toxicidade, atividade biológica e biodisponibilidade. Além disso, esses resultados contribuem para a redução de incertezas na seleção de candidatos, oferecendo subsídios mais consistentes e precisos para a etapa de exploração prévia à realização de experimentos *in vitro* e *in vivo*.

Entre as estratégias computacionais emergentes, a triagem virtual de alto desempenho destaca-se por possibilitar a análise de extensas bibliotecas de compostos em curto prazo, considerando propriedades estruturais e físico-químicas para priorizar candidatos a fármacos. Quando a estrutura do alvo é conhecida, essa abordagem, denominada triagem virtual baseada em estrutura, pode ser associada a técnicas de ancoragem molecular (*docking*) para estimar a afinidade e o modo de interação ligante–receptor, ainda que apresente limitações em alvos pouco caracterizados (MAIA et al., 2020). De forma complementar, a triagem virtual baseada em ligantes utiliza descritores moleculares, como forma, carga e grupos farmacofóricos, para identificar compostos promissores a partir de relações de similaridade, servindo como etapa preliminar à validação experimental e computacional. Embora eficazes, modelos baseados em ligantes são fortemente dependentes da similaridade estrutural, o que pode levar à geração de falsos positivos ou à incapacidade de detectar moléculas inovadoras, ainda pouco exploradas (GIMENO et al., 2019; VÁZQUEZ et al., 2020). Para contornar essas limitações, abordagens híbridas que integram características estruturais tanto do receptor quanto do ligante têm sido desenvolvidas, combinando informações de similaridade molecular com dados estruturais do receptor. Essa integração amplia o alcance da triagem virtual, favorecendo a identificação de candidatos com maior diversidade estrutural e potencial biológico para o desenvolvimento de novos fármacos. Os detalhes metodológicos das estratégias de triagem virtual, suas variantes LBVS, SBVS e híbridas, bem como a ampliação da discussão sobre suas vantagens e limitações, são apresentados de forma aprofundada no capítulo 3.

Curadoria dos Dados. Independentemente da estratégia adotada, seja baseada em estrutura, em ligante ou em abordagens híbridas, a qualidade e a abrangência do domínio químico explorado configuram fatores decisivos para a efetividade das análises *in silico*. Nesse cenário, a composição e a disponibilidade das bases de dados assumem papel essencial, podendo ser categorizadas, em termos gerais, sob duas vertentes principais: (a) aquelas fundamentadas em dados previamente publicados, que possibilitam a ampliação do escopo de investigação por meio de reanálises, integrações e combinações; e (b) repositórios privados, frequentemente de acesso restrito e com baixa reprodutibilidade, o que compromete a transparência científica e

dificulta a validação experimental independente. Todavia, em ambos os contextos, a presença de informações redundantes, inconsistentes ou carentes de padronização pode comprometer a acurácia do processo, reduzindo seu potencial e sua aplicabilidade prática. Assim, a implementação de procedimentos sistemáticos de limpeza, padronização e integração de dados torna-se imprescindível para assegurar robustez metodológica e confiabilidade nas inferências geradas.

No presente trabalho, essa necessidade é suprida pelo *BioMolExplorer*, uma ferramenta de curadoria de dados químicos e biológicos que integra assinaturas moleculares, cálculos de similaridade, detecção de redundâncias e a construção de redes de relações físico-químicas para identificação de padrões estruturais (*scaffolds*), detalhada na seção 4.2. Os resultados obtidos, apresentados na seção 5.2, evidenciam a eficácia desse processo e reforçam a importância de sua adoção em fluxos de trabalho computacionais baseados em estratégias *in silico*.

Ancoragem Molecular. A etapa de curadoria de dados, ao eliminar inconsistências e redundâncias, constitui um pré-requisito importante para o emprego eficiente de estratégias de *docking* molecular. Isso porque a qualidade e a representatividade das bibliotecas químicas diretamente influenciam a precisão e a confiabilidade das interações previstas. As abordagens de *docking* permitem posicionar regiões específicas do ligante em sítios predeterminados do receptor, aumentando a acurácia das previsões e restringindo o espaço conformacional a ser explorado. Tal estratégia é particularmente útil no refinamento de modelos de interação em sistemas complexos, proporcionando uma orientação mais precisa dos ligantes em relação ao sítio ativo. Todavia, quando aplicadas a domínios químicos extensos, nos quais milhares de ligantes podem ser avaliados frente a um ou múltiplos receptores, tais abordagens podem demandar considerável poder computacional. Essa elevada necessidade de recursos compromete, em muitos casos, a escalabilidade, a eficiência e a reprodutibilidade dos estudos, sobretudo em cenários que envolvem patologias multifatoriais e múltiplos alvos terapêuticos.

Estratégias baseadas em inteligência artificial aplicadas à descoberta de fármacos têm se mostrado particularmente promissoras para mitigar as limitações intrínsecas ao *docking molecular* tradicional. Ao empregar modelos preditivos capazes de priorizar ligantes com maior probabilidade de interação relevante, viabilizam a exploração eficiente de amplos domínios químicos e múltiplos receptores, reduzindo a dependência de cálculos conformacionais extensivos e, consequentemente, o custo computacional associado. Nesse cenário, este trabalho apresenta, na seção 4.3, a solução *NeuroDock*, uma rede neural desenvolvida para predizer valores de *score* em modelos de ancoragem molecular por consenso. A ferramenta integra distintas técnicas de *docking* em uma plataforma unificada, favorecendo não apenas a priorização de compostos promissores, mas também o incremento da robustez e da reprodutibilidade no processo de triagem virtual. Resultados preliminares, com coeficiente de determinação (r^2) em torno de 80%, detalhados na seção 5.4, demonstram o potencial da estratégia como complemento ao *docking* tradicional, sobretudo em contextos que envolvem a exploração de grandes bibliotecas químicas.

Dinâmica Molecular. Uma vez priorizados os compostos mais promissores por meio de estratégias de ancoragem molecular e da abordagem preditiva do *NeuroDock*, a etapa subsequente consiste na validação estrutural e funcional por simulações de dinâmica molecular. Esse re-

finamento configura-se como passo relevante para superar as limitações do *docking* estático, possibilitando a avaliação, em escala temporal, da estabilidade dos complexos ligante–receptor, de sua flexibilidade conformacional e dos rearranjos estruturais envolvidos. Além disso, tais simulações possibilitam a caracterização detalhada de redes de ligações, interações moleculares específicas e movimentos dinâmicos críticos, fornecendo evidências adicionais sobre a viabilidade e a consistência dos candidatos selecionados.

Para consolidar essa etapa dentro de um fluxo computacional de descoberta e reposicionamento de fármacos, este trabalho utiliza o OpenMM como plataforma para simulações de dinâmica molecular, integrando-o ao *DrugHunter*, uma ferramenta de alto desempenho desenvolvida como um modelo de fluxo de trabalho dinâmico e modular. O *DrugHunter* reúne, em uma única solução, a curadoria de dados, a modelagem molecular e simulações de alta performance, padronizando as etapas *in silico* em um contexto coeso, flexível e escalável. Essa integração elimina a necessidade da utilização de múltiplas ferramentas de terceiros ou de processos fragmentados, assegurando consistência metodológica, rastreabilidade das análises e adaptabilidade a diferentes domínios químicos e múltiplos alvos terapêuticos. A implementação, funcionalidades e potencial aplicabilidade do *DrugHunter* são discutidos em detalhes no capítulo 4.

Neste trabalho, a operacionalização e validação da solução apresentada foram realizadas utilizando a doença de Alzheimer como estudo de caso, uma patologia neurodegenerativa de alta complexidade, caracterizada por múltiplos mecanismos patológicos e diversos alvos terapêuticos, detalhados no capítulo 2. Para esse propósito, foram selecionadas três enzimas de relevância consolidada nesse contexto: a acetilcolinesterase e a butirilcolinesterase, responsáveis pela hidrólise da acetilcolina e pela modulação da neurotransmissão colinérgica, e a beta-secretase 1, implicada na formação de placas beta-amiloides e emaranhados neurofibrilares, marcadores patognomônicos da doença.

A seleção dos alvos terapêuticos mencionados permitiu avaliar de forma abrangente a capacidade da solução proposta na identificação e caracterização de ligantes para múltiplos sítios funcionais, refletindo a complexidade fisiopatológica da doença de Alzheimer e demonstrando a eficácia da ferramenta na aplicação de estratégias polifarmacológicas em cenários multifatoriais. Os resultados obtidos, detalhados no capítulo 5, indicam que o fluxo de trabalho proposto é eficiente na detecção, priorização e análise de candidatos terapêuticos, consolidando o *DrugHunter* como uma plataforma robusta, flexível e generalizável para a descoberta acelerada de fármacos.

No estudo de caso realizado, os compostos mais promissores apresentaram perfis de ação terapêutica ampla, modulando simultaneamente múltiplos alvos, uma característica que potencialmente reduz a carga farmacológica necessária para intervenção direta sobre a patologia e favorece abordagens terapêuticas integradas. As interações moleculares e suas implicações potenciais foram examinadas em profundidade no capítulo 5, enquanto análises complementares de dinâmica molecular e discussões adicionais, incluindo refinamentos estruturais e avaliação de estabilidade ligante-receptor, são detalhadas no apêndice A, fornecendo suporte abrangente à interpretação dos resultados. Assim, os achados apresentados não apenas validam a capacidade

da solução *in silico* proposta neste trabalho de lidar com sistemas biológicos complexos e múltiplos alvos, como também destacam seu potencial para orientar estratégias polifarmacológicas de maneira eficiente, promovendo um avanço significativo na descoberta racional de fármacos e no desenvolvimento de intervenções terapêuticas mais integradas e eficazes para doenças com características multifatoriais.

Capítulo

1

Introdução

A compreensão do funcionamento do cérebro humano é essencial para a percepção de uma série de condições neurológicas que se desenvolvem ao longo da vida. Estruturalmente, o encéfalo é composto por diferentes regiões especializadas, denominadas lobos cerebrais, cada qual envolvido em funções cognitivas, sensoriais e motoras específicas. A integração dessas funções é viabilizada pela atuação coordenada de três classes principais de neurônios: os aferentes (ou sensoriais), responsáveis pela condução de estímulos dos receptores periféricos ao sistema nervoso central (SNC); os eferentes (ou motores), que transmitem impulsos do SNC através do sistema nervoso periférico (SNP) aos órgãos efetores, possibilitando desde movimentos voluntários até o controle de funções autônomas; e os interneurônios, que estabelecem conexões locais e de longa distância entre neurônios sensoriais e motores, formando circuitos e redes neurais complexas responsáveis pela modulação e integração da atividade encefálica (BEAR; CONNORS; PARADISO, 2017; IAIZZO, 2020; MACHADO; HAERTEL, 2022).

Com o envelhecimento, alterações estruturais e funcionais em circuitos neuronais interconectados tornam-se progressivamente mais evidentes. Essas alterações, resultantes tanto de mecanismos compensatórios quanto de processos degenerativos graduais, estão frequentemente associadas ao desenvolvimento de diferentes formas de demência. Uma condição clínica de elevada complexidade, caracterizada pela deterioração progressiva da memória, das capacidades cognitivas e das habilidades funcionais, impactando significativamente a autonomia e a qualidade de vida (LIVINGSTON et al., 2024). Estima-se que mais de 50 milhões de pessoas em todo o mundo sejam atualmente afetadas por algum tipo de demência, com projeções indicando que esse número poderá alcançar aproximadamente 131 milhões de casos até 2050, impulsionado pela transição demográfica e pelo aumento da expectativa de vida da população global (MOTEBENNUR; NANDESHWARAPPA; KATAGI, 2023). Entre os subtipos de demência mais prevalentes, destaca-se a Doença de Alzheimer (DA), responsável por cerca de um terço

dos diagnósticos.

Descrita inicialmente por Alois Alzheimer em 1907, a DA é reconhecida atualmente como uma doença neurodegenerativa de etiologia multifatorial, envolvendo interações complexas entre fatores genéticos, moleculares e ambientais. Essa diversidade etiológica contribui para a complexidade de sua fisiopatologia, dificultando a identificação abrangente de seus mecanismos patogênicos e limitando o desenvolvimento de terapias eficazes. Ademais, a DA representa um desafio não apenas clínico, mas também socioeconômico, gerando custos globais superiores a 1 trilhão de dólares anuais, principalmente em função das demandas associadas ao tratamento e ao cuidado prolongado dos pacientes (World Health Organization, 2021).

Considerando a complexidade fisiopatológica da DA e as limitações das estratégias terapêuticas atualmente disponíveis que, em sua maioria, promovem apenas alívio sintomático sem interromper a progressão da doença, diferentes abordagens têm sido exploradas com o intuito de ampliar o arsenal farmacológico. Nesse contexto, destacam-se as estratégias baseadas em modelagem molecular assistida por computador (CADD, do inglês, *Computer-Aided Drug Design*), que têm se apresentado promissoras tanto na identificação quanto na otimização de compostos bioativos para diferentes objetos de pesquisa. Essas abordagens oferecem uma alternativa racional e eficiente à experimentação tradicional, permitindo a simulação de interações moleculares, o refinamento de estruturas químicas e a priorização de candidatos com maior potencial terapêutico. Nesse contexto, o CADD viabiliza a análise *in silico* de grandes bibliotecas químicas, integrando ferramentas que permitem a triagem sistemática e a seleção de compostos com base em propriedades estruturais, físico-químicas e biológicas. Além de acelerar significativamente o processo de descoberta e reposicionamento de fármacos, essa abordagem contribui para a redução de custos e riscos associados às fases iniciais do desenvolvimento farmacêutico, ao antecipar características críticas como afinidade de ligação, seletividade, toxicidade e perfil farmacocinético.

No âmbito das abordagens de CADD, a triagem virtual de alto desempenho (HTVS, do inglês, *High Throughput Virtual Screening*) merece especial destaque, pois permite a avaliação automatizada e em larga escala de milhares de compostos em um curto intervalo de tempo. Essa estratégia pode ser conduzida por diferentes metodologias, entre as quais se destacam a triagem virtual baseada na estrutura do alvo (SBVS, do inglês, *Structure-Based Virtual Screening*) — que depende da estrutura tridimensional do receptor para estimar a afinidade de ligação — e a triagem virtual baseada em ligantes (LBVS, do inglês, *Ligand-Based Virtual Screening*), que se fundamenta na similaridade entre compostos bioativos conhecidos e candidatos a fármacos.

Ambas as abordagens apresentam vantagens distintas, mas também enfrentam limitações importantes. A SBVS, por exemplo, é fortemente dependente da disponibilidade e da qualidade estrutural do receptor-alvo, o que pode restringir sua aplicabilidade em contextos nos quais tais dados são ausentes ou imprecisos (MAIA et al., 2020). Por outro lado, a LBVS baseia-se em critérios de similaridade estrutural, o que pode limitar a identificação de novas entidades químicas quando estas diferem significativamente dos compostos de referência (GIMENO et al., 2019; VÁZQUEZ et al., 2020).

Para contornar as limitações inerentes às abordagens SBVS e LBVS, estratégias híbridas que integram os pontos fortes de ambas as metodologias têm sido avaliadas. Essa combinação permite expandir o escopo da triagem virtual, promovendo maior diversidade estrutural entre os compostos selecionados e, consequentemente, elevando as chances de identificar moléculas com potencial terapêutico significativo. Tal abordagem tem se revelado particularmente eficaz em cenários polifarmacológicos, nos quais múltiplos alvos moleculares participam simultaneamente da fisiopatologia da doença (VÁZQUEZ et al., 2020).

Entretanto, apesar dos avanços na concepção dessas estratégias híbridas, sua implementação prática ainda enfrenta obstáculos consideráveis. A fragmentação do ecossistema de ferramentas, muitas vezes voltadas apenas a etapas específicas do processo, aliada à ausência de padronização e à integração limitada entre diferentes fontes e formatos de dados, compromete a reprodutibilidade e dificulta sua aplicação em fluxos de trabalho consolidados. Nesse cenário, torna-se necessário o desenvolvimento de soluções integradas, que articulem essas diferentes etapas de forma coordenada, eficiente e adaptável.

Com esse objetivo, propomos uma abordagem híbrida e multiestágio para TV/HTVS, estruturada em um fluxo de trabalho unificado e flexível, que abrange desde a recuperação automatizada de informações químicas até a condução de simulações de dinâmica molecular. Ao lidar com os desafios associados à manipulação de grandes volumes de dados químicos e biológicos, essa proposta visa mitigar gargalos evidentes nos processos de descoberta e reposicionamento de fármacos, promovendo maior robustez analítica e escalabilidade operacional.

Para validar a aplicabilidade da estratégia proposta, conduzimos um estudo de caso voltado à investigação de fatores etiológicos relacionados à DA, com foco em três alvos moleculares de comprovada relevância terapêutica: a acetilcolinesterase (AChE), a butirilcolinesterase (BChE) e a β-secretase 1 (BACE1). Nesse contexto, buscamos compor as bases de ligantes analisados com compostos bioativos previamente descritos para essas enzimas, além de moléculas estruturalmente similares extraídas das bases de dados CHEMBL[1] e ZINC[2].

Como parte dos resultados, tem-se apresentado neste trabalho a ferramenta *DrugHunter*, um sistema computacional modular, flexível e extensível que automatiza o fluxo de HTVS para a descoberta e reposicionamento de fármacos. Esse fluxo abrange etapas de recuperação de informação sobre compostos, pré-processamento, agrupamento (clusterização), ancoragem molecular (*docking*), *redocking* e simulações de dinâmica molecular, incorporando ainda estratégias preditivas baseadas em redes neurais profundas. O *DrugHunter* foi pensado como uma arquitetura modular e multinível, composta por três camadas logicamente integradas, as quais asseguram flexibilidade, reprodutibilidade e extensibilidade ao fluxo de trabalho. A primeira delas, a **camada de execução e análise**, é responsável por simplificar e viabilizar a realização automatizada e reprodutível dos experimentos computacionais, oferecendo uma interface direta para usuários aplicarem os métodos integrados ao sistema. A segunda, denominada **camada de configuração e adaptação de fluxo**, permite a personalização e adaptação dinâmica das etapas do processo, possibilitando a construção de pipelines específicos e direcionados conforme os

[1] `https://www.ebi.ac.uk/chembl/`
[2] `https://zinc20.docking.org/`

objetivos da pesquisa em curso. Por fim, a **camada de desenvolvimento e expansão** proporciona um ambiente propício à incorporação de novas estratégias computacionais, viabilizando a expansão contínua do sistema por meio da integração de métodos, modelos ou heurísticas inovadoras. Tal organização não apenas amplia a aplicabilidade do *DrugHunter* em diferentes contextos científicos, como também estabelece uma base adequada para sua evolução contínua em consonância com os avanços metodológicos na área de descoberta racional de fármacos.

Capítulo

2

Avanços no Tratamento do Alzheimer: Perspectivas Patológica, Molecular e Terapêuticas

2.1 Considerações Iniciais

Como introduzido brevemente no Capítulo anterior (capítulo 1), a enfermidade descrita por Alois Alzheimer em 1907 integra o grupo das doenças neurodegenerativas de etiologia multifatorial. A literatura científica tem convergido ao caracterizá-la como uma condição de elevada complexidade fisiopatológica, cujo pleno entendimento permanece desafiador. Essa limitação decorre da multiplicidade de fatores envolvidos em sua manifestação clínica, incluindo determinantes genéticos, alterações bioquímicas e influências ambientais, que interagem de forma dinâmica e ainda não plenamente compreendida. Neste capítulo, tem-se a discussão de alguns dos principais processos biológicos associados à progressão da DA, evidenciando as alterações e características clínicas, fisio– e neuropatológicas, bem como os fatores de risco que contribuem para a manifestação e evolução da doença.

2.2 Características Patológicas Prevalentes

A transição demográfica global, marcada por um aumento expressivo na expectativa de vida e, consequentemente, da ampliação da população idosa, tem contribuído significativamente para o crescimento da prevalência de doenças crônicas associadas ao envelhecimento. Dentre essas condições, destacam-se os quadros demenciais — síndromes neurodegenerativas caracterizadas por declínio cognitivo progressivo, comprometimento funcional e alterações comportamentais relevantes (BEAR; CONNORS; PARADISO, 2017). Nesse espectro, a DA representa a forma

mais prevalente de demência, sendo responsável por mais de um terço dos casos diagnosticados (LIU; ZHANG; WANG, 2024). Sua relevância no cenário biomédico emerge não apenas de sua alta incidência, mas também dos desafios impostos ao cuidado, à pesquisa, aos custos e a formulação de políticas públicas em saúde.

Clinicamente, a DA manifesta-se por meio de um conjunto clássico de sintomas, cuja progressão compromete múltiplas dimensões da cognição. Inicialmente, observa-se deterioração da memória episódica recente, seguida por dificuldades linguísticas, prejuízos nas funções executivas, alterações de orientação espaço-temporal e comprometimento da capacidade de julgamento. Nos estágios mais avançados, o quadro evolui para dependência funcional completa e perda da autonomia, frequentemente acompanhada de sintomas neuropsiquiátricos, como agitação, apatia e depressão (LIU; ZHANG; WANG, 2024).

Sob a perspectiva fisiopatológica, o quadro clínico decorre de uma complexa rede de alterações funcionais e estruturais interdependentes. Entre os principais eventos envolvidos, destacam-se o acúmulo extracelular de peptídeos β-amiloides — responsáveis pela formação de placas senis, a deposição intracelular de emaranhados neurofibrilares formados por proteína tau hiperfosforilada, disfunção sináptica, neuroinflamação crônica e morte neuronal progressiva, frequentemente associada à ativação de vias autofágicas (ONYANGO et al., 2021; BANDYOPADHYAY, 2021; BOON et al., 2022; CHEN; YU, 2023). Ademais, a resposta neuroinflamatória é amplificada pela ativação reativa de astrócitos e micróglias, células gliais que, ao adotarem um fenótipo disfuncional, passam a liberar níveis elevados de citocinas pró-inflamatórias, o que leva à redução da capacidade fagocítica[1]. Essas alterações contribuem para a cronificação da lesão neural e o consequente agravamento do quadro clínico (SINGH, 2022; BANDYOPADHYAY, 2021).

A Figura 2.1 ilustra uma secção encefálica, contrastando, à esquerda, uma região cerebral preservada, com morfologia neuronal e arquitetura sináptica típicas e, à direita, uma área comprometida pela progressão patológica da DA.

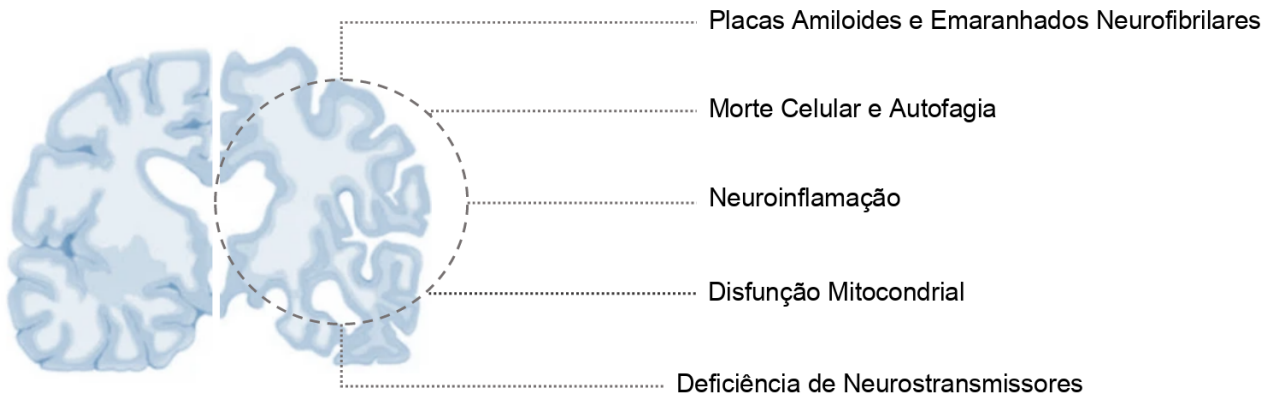

Figura 2.1: Esquema ilustrativo de algumas das principais alterações patológicas associadas à Doença de Alzheimer. À esquerda, observa-se uma região cerebral preservada, caracterizada por morfologia neuronal e organização sináptica típicas. À direita, evidencia-se uma área acometida pelos processos associados à doença. Os elementos destacados estão diretamente relacionados às temáticas desenvolvidas ao longo deste capítulo, compondo um panorama integrativo dos mecanismos clínicos, fisio– e neuropatológicos subjacentes à progressão da DA.

[1]Processo pelo qual certas células, como as do sistema imune, englobam e degradam partículas sólidas

Ao observar a Figura 2.1 do ponto de vista neuropatológico, as alterações acima citadas resultam em um processo de atrofia cerebral progressiva, que se inicia preferencialmente em regiões do lobo temporal medial, como o hipocampo e o córtex entorrinal — áreas fundamentais para a consolidação da memória episódica e a orientação espacial. Com a progressão da doença, o comprometimento estende-se a outras regiões corticais, como os lobos parietal e frontal, levando a déficits adicionais em funções executivas, linguagem, atenção e comportamento. A topografia dessas lesões mostra correlação direta com o avanço clínico progressivo da doença, o que reforça a importância de abordagens multidimensionais que integrem aspectos anatômicos, moleculares e neuropsicológicos em sua caracterização.

Embora avanços significativos nas esferas fisio- e neuropatológicas tenham permitido detalhar distintas condições e manifestações associadas à progressão da DA, autores como Wong et al. (2019), Athar, Balushi e Khan (2021), Hoogmartens, Cacace e Broeckhoven (2021) e Zhang et al. (2024) estendem essa discussão ao defenderem que a compreensão etiológica exige uma abordagem de maior amplitude, que transcenda a análise isolada de sintomas clínicos ou de alterações físicas e neurofuncionais específicas. Tal perspectiva ressalta a necessidade de uma compreensão aprofundada das inter-relações entre seus mecanismos patológicos subjacentes. Essa demanda tem fomentado múltiplas frentes de investigação, com destaque para aquelas centradas na elucidação do sistema colinérgico, dada sua reconhecida correlação com os déficits cognitivos observados nos estágios iniciais da doença (BENUSSI et al., 2022).

A hipótese colinérgica, uma das principais teorias propostas para explicar a etiologia da DA, estabelece que a progressão do quadro clínico está diretamente associada à degeneração de neurônios colinérgicos, resultando na redução da atividade da acetilcolina (ACh), neurotransmissor fundamental para funções cognitivas como memória, aprendizagem e comportamento (CHEN et al., 2022; XU et al., 2021). A homeostase desse sistema depende, em grande parte, da atuação coordenada das enzimas acetilcolinesterase (AChE) e butirilcolinesterase (BChE), as quais são responsáveis pela hidrólise da ACh na fenda sináptica, processo necessário para a regulação adequada da neurotransmissão.

No contexto da DA, o sistema colinérgico apresenta uma diminuição progressiva da atividade da AChE, concomitante à manutenção ou elevação da atividade da BChE — alteração enzimática amplamente interpretada como um mecanismo compensatório frente à perda da homeostase. Com o objetivo de restaurar a disponibilidade de ACh e mitigar os déficits cognitivos decorrentes, diversos inibidores de colinesterase, como Donepezila, Rivastigmina e Galantamina, foram propostos. Contudo, esses fármacos têm por característica apenas prover melhora clínica transitória nos sintomas cognitivos, especialmente durante os estágios iniciais e moderados da doença. Sua eficácia permanece restrita ao alívio sintomático, sem impacto comprovado na regressão do processo neurodegenerativo, além de estarem frequentemente associados a efeitos adversos relevantes (SON et al., 2019a; DAVID et al., 2021a; JASIECKI; TARGOŃSKA; WASĄG, 2021; ZHOU; HUANG, 2022).

Diante das limitações terapêuticas associadas aos inibidores de colinesterase, tem-se intensificado o interesse por alvos moleculares adicionais implicados na cascata patológica da DA,

com destaque para a enzima beta-secretase 1 (BACE1). Responsável pela clivagem inicial da proteína precursora amiloide (APP, do inglês, *Amyloid Precursor Protein*), a BACE1 desencadeia a formação dos peptídeos β-amiloides (Aβ), cuja agregação em placas senis extracelulares constitui uma das principais características neuropatológicas da doença (JEREMIC; JIMÉNEZ-DÍAZ; NAVARRO-LÓPEZ, 2021; TELEANU et al., 2022). Esses agregados estão intimamente associados à disfunção sináptica, à ativação de respostas neuroinflamatórias e ao aumento do estresse oxidativo. Evidências recentes reportam uma interação bidirecional entre a disfunção colinérgica e a deposição de Aβ, configurando um ciclo patológico de retroalimentação em que o acúmulo de Aβ compromete a neurotransmissão colinérgica, ao passo que a redução da atividade colinérgica favorece a produção e agregação de Aβ, o que agrava a neurodegeneração por meio da formação de agregados cada vez mais extensos e conformacionalmente complexos (ZHANG et al., 2023; HAMPEL et al., 2021; ZHANG et al., 2019).

Nesse cenário, estratégias terapêuticas voltadas à inibição da BACE1 têm despertado interesse, com dados preliminares sugerindo que uma inibição parcial e sustentada, na ordem de 20% a 30%, pode ser suficiente para atenuar esse ciclo de retroalimentação e, possivelmente, retardar o surgimento de manifestações clínicas em populações com risco elevado (MCDADE et al., 2021). No entanto, os resultados clínicos observados até o momento têm se mostrado inconclusivos. Ensaios com inibidores como o *atabecestat* não apenas falharam em demonstrar benefícios consistentes na preservação da função cognitiva, especialmente em estágios avançados, como também revelaram efeitos adversos relevantes, incluindo elevações significativas nas enzimas hepáticas (ALT e AST) e declínio cognitivo dose-dependente (NOVAK et al., 2020). Outros eventos adversos frequentemente relatados incluíram distúrbios do sono, perda de peso, confusão mental e aumento da suscetibilidade a infecções (MCDADE et al., 2021; EGAN et al., 2019). Embora tais efeitos adversos não invalidem a relevância terapêutica da BACE1, fundamentada por evidências substanciais provenientes de estudos pré-clínicos, eles ressaltam os desafios ainda persistentes no desenvolvimento de intervenções farmacológicas que aliem segurança, eficácia e viabilidade clínica.

Por conseguinte, a estreita interdependência entre a neurotransmissão colinérgica e a cascata amiloide reforça a limitação de abordagens terapêuticas unidimensionais diante da complexidade multifatorial da DA. Assim, estratégias integrativas que busquem à modulação simultânea das enzimas AChE, BChE e BACE1 configuram alternativas terapêuticas emergentes de considerável potencial. Ao atuar de forma coordenada sobre distintos eixos patogênicos, essas intervenções podem ampliar a eficácia no controle sintomático, como também oferecer perspectivas mais adequadas para o retardo da progressão neurodegenerativa, superando os efeitos paliativos das terapias atualmente disponíveis.

2.3 Avanços no Tratamento do Alzheimer

Conforme exposto, a compreensão aprofundada dos mecanismos fisio– e neuropatológicos subjacentes à DA, bem como de seus impactos sistêmicos, revela-se não apenas necessária, mas de importância crítica e inadiável, sobretudo diante do crescente custo que essa doença impõe

à saúde pública global, uma preocupação amplamente destacada por autores como Cummings et al. (2024), Dokholyan, Mohs e Bateman (2022), Motebennur, Nandeshwarappa e Katagi (2023). Nesse contexto, diversas investigações têm se dedicado à análise de sua progressão e causas subjacentes, entre as quais se destacam os estudos conduzidos por Benek, Korabecny e Soukup (2020) e Knopman et al. (2021), que propõem uma abordagem exploratória estruturada a partir de dois grupos populacionais: (i) indivíduos com predisposição genética hereditária e (ii) indivíduos pertencentes ao grupo idiopático[2], cuja manifestação não está associada a mutações reconhecidas.

No grupo de indivíduos com genética herdada, os casos são consideravelmente mais raros, representando cerca de 1 a 5% dos diagnósticos, e apresentam início precoce, frequentemente antes dos 65 anos de idade. As principais causas associadas a este subtipo incluem mutações nos genes presenilina-1 (PSEN1) e presenilina-2 (PSEN2), que resultam em disfunções na clivagem da APP e na subsequente produção desordenada do peptídeo Aβ. Como mencionado, o acúmulo de Aβ resulta na formação precoce das placas senis, configurando um dos eventos centrais da "cascata amiloide" (ZHANG et al., 2023; BOON et al., 2022).

Em contraste, a forma idiopática ou esporádica é substancialmente mais prevalente, com início geralmente após os 65 anos, sendo influenciada por uma combinação complexa de fatores genéticos de menor incidência, envelhecimento, estilo de vida e exposições ambientais. O principal fator genético associado a essa forma é o alelo ϵ4 da apolipoproteína E (APOE4), cuja presença tem sido correlacionada ao aumento da deposição de Aβ, à disfunção sináptica, ao comprometimento da depuração amiloide e ao aumento do risco global de desenvolvimento da DA. A esse quadro somam-se evidências de que mecanismos adicionais, como o estresse oxidativo, a neuroinflamação persistente e a disfunção mitocondrial, exercem papéis colaborativos na instalação e progressão do conjunto de traços clínicos observados (YAMAZAKI et al., 2019).

Segundo Wegmann, Biernat e Mandelkow (2021) e d'Errico e Meyer-Luehmann (2020), independentemente do grupo envolvido, a hiperfosforilação da proteína tau e a subsequente formação de emaranhados neurofibrilares, eventos que caracterizam coletivamente as tauopatias, estão presentes, embora resultem de vias patológicas distintas. Na variante de origem genética, a disfunção da tau tende a ocorrer como consequência secundária à cascata amiloide, desencadeada por mutações nos genes APP, PSEN1 ou PSEN2, que promovem o acúmulo anômalo do peptídeo Aβ. Em contraste, na forma esporádica da doença, a indução da tauopatia parece resultar da convergência de múltiplos fatores, incluindo a inflamação crônica do SNC, o aumento da vulnerabilidade neuronal associada ao envelhecimento e distúrbios metabólicos e mitocondriais que comprometem a homeostase celular.

Conforme relatado por Chen e Yu (2023), Boon et al. (2022) e d'Errico e Meyer-Luehmann (2020), a hiperfosforilação da proteína tau compromete sua função fisiológica de estabilização dos microtúbulos, favorecendo sua dissociação do citoesqueleto axonal e sua subsequente agregação no citoplasma neuronal. Esse processo culmina na formação de filamentos helicoidais emparelhados (PHFs, do inglês *paired helical filaments*), os quais se organizam em emara-

[2]Também referido na literatura como grupo esporádico.

nhados neurofibrilares intracelulares. A presença desses agregados provoca o colapso da rede microtubular, comprometendo o transporte axonal de organelas, vesículas sinápticas e fatores tróficos essenciais à manutenção da viabilidade neuronal. Adicionalmente, segundo (TOPOL, 2025), a proteína tau fosforilada, especialmente na posição da treonina 217 (p-tau217), constitui um biomarcador sanguíneo promissor, capaz de diferenciar com elevada precisão a doença de Alzheimer de outras formas de demência. Tal potencial diagnóstico se mostra eficaz pelo fato de que o aumento nos níveis plasmáticos de p-tau217 ocorre anos antes do surgimento dos sintomas clínicos, posicionando-o como um dos marcadores mais precoces detectáveis no curso prolongado da doença. Essas evidências reforçam que a carga de emaranhados neurofibrilares, conjuntamente com as recentes descobertas sobre o biomarcador p-tau217, correlaciona-se de forma mais precisa e consistente com o grau de declínio cognitivo do que a deposição isolada de placas senis, evidenciando o papel central da tauopatia na progressão clínica da DA.

Em paralelo à elucidação dos mecanismos celulares e estruturais associados à disfunção neuronal, avanços genéticos têm ampliado a compreensão sobre a DA, especialmente em sua forma idiopática. Conforme demonstrado por Hoogmartens, Cacace e Broeckhoven (2021), variantes genéticas raras com efeito de impacto moderado, envolvendo genes como SORL1, ABCA7, TREM2, CLU, PLCG2, ABI3, BIN1, UNC5C, AKAP9 e NOTCH3, bem como mutações somáticas adquiridas, contribuem de certa forma para a predisposição individual à doença. Essas descobertas evidenciam que, mesmo na ausência de herança genética, esses fatores podem desempenhar papel de atenção na modulação da vulnerabilidade e progressão do fenótipo clínico, particularmente no contexto esporádico.

Complementando esse cenário multifatorial, Shafiee et al. (2024) evidencia que o comprometimento precoce do sistema colinérgico, especialmente a degeneração do núcleo basal de Meynert, tem sido fortemente implicado nos déficits cognitivos iniciais. Essa disfunção colinérgica, presente em ambas as formas da doença mas particularmente acentuada nos casos esporádicos, parece resultar da interação entre a deposição de Aβ, processos inflamatórios persistentes e estresse oxidativo. Esse conjunto de alterações configura um eixo patológico adicional, que se soma à cascata amiloide-tau tradicional, contribuindo para a heterogeneidade fenotípica e a complexidade fisiopatológica observadas.

Dada a multiplicidade de fatores envolvidos e a sobreposição parcial entre as formas genética e esporádica da doença, tem-se na Figura 2.2 uma representação esquemática que sintetiza os principais elementos genéticos, moleculares e ambientais associados a cada uma dessas classes.

Conforme ilustrado na Figura 2.2, o esquema delineia as especificidades de cada subtipo da doença, destacando os principais marcadores genéticos, os mecanismos moleculares envolvidos e os processos celulares que se sobrepõem entre as formas genética e esporádica da Doença de Alzheimer (DA). No entanto, como argumentado por Athar, Balushi e Khan (2021), a complexa heterogeneidade da DA ultrapassa os limites de tal categorização, exigindo uma abordagem mais integrada e sistêmica para a compreensão de suas múltiplas vias fisiopatológicas e neuropatológicas.

Ao expandir essa perspectiva, observa-se que, para além das alterações canônicas no sistema

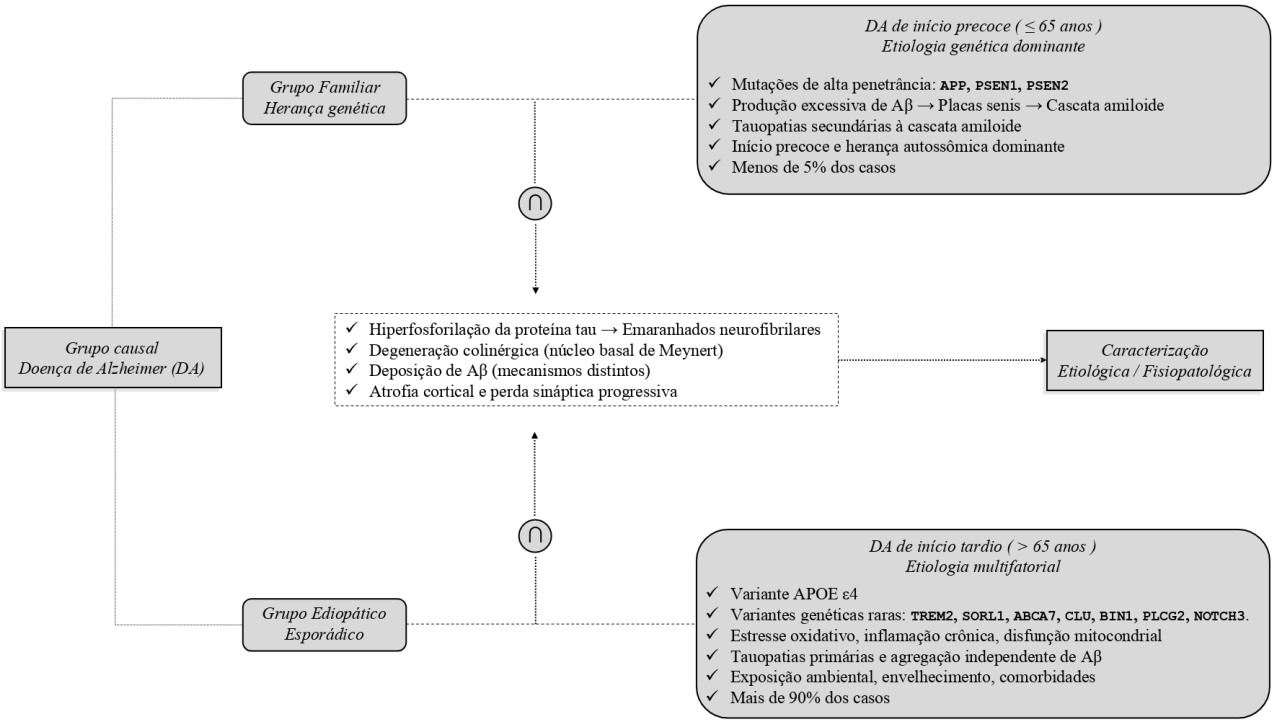

Figura 2.2: Representação esquemática comparativa das duas principais categorias etiológicas da Doença de Alzheimer e seus respectivos mecanismos fisiopatológicos predominantes. Na parte superior, destaca-se a forma familiar, de origem genética herdada e início precoce ($\leq$ 65 anos), associada a mutações com expressividade clínica elevada em genes como *APP*, *PSEN1* e *PSEN2*. Na parte inferior, apresenta-se a forma esporádica, multifatorial e de início tardio ($>$ 65 anos), envolvendo fatores genéticos de risco (e.g., *APOE* ϵ4, *TREM2*), alterações ambientais e processos celulares como estresse oxidativo, inflamação crônica e disfunção mitocondrial. A interseção ($\cap$) entre os grupos evidencia processos fisiopatológicos comuns, como a hiperfosforilação da proteína tau e formação de emaranhados neurofibrilares, a degeneração colinérgica (núcleo basal de Meynert), a deposição do peptídeo beta-amiloide (Aβ) e a atrofia cortical progressiva, embora mediados por mecanismos distintos entre os subtipos clínicos.

colinérgico e na cascata amiloide, estudos como os de Athar, Balushi e Khan (2021) e Cho et al. (2020) evidenciam a contribuição de metais de transição como ferro, cobre e zinco na intensificação do estresse oxidativo, o que agrava a disfunção celular e o dano neuronal. A esse panorama soma-se a ativação crônica da microglia, cuja transição de um fenótipo inicialmente neuroprotetor para um estado pró-inflamatório tem sido amplamente implicada na perpetuação da neuroinflamação e na progressão da degeneração neuronal. Segundo Adeniyi et al. (2023), tal ativação tem suas origens na liberação de citocinas pró-inflamatórias como IL-1β, TNF-α e IL-6, bem como de espécies reativas de oxigênio.

Apesar dos avanços substanciais na compreensão dos mecanismos fisio– e neuropatológicos subjacentes à DA, os obstáculos que persistem no desenvolvimento de terapias eficazes continuam a representar uma preocupação. De acordo com Dowden e Munro (2019), menos de 3% dos compostos candidatos ao tratamento de distúrbios neurodegenerativos alcançam aprovação por órgãos regulatórios como a *Food and Drug Administration*[3] (FDA). Essa incidência baixa é atribuída a uma combinação de fatores, entre os quais tem-se a complexidade multifatorial das doenças neurodegenerativas; a escassez de biomarcadores validados para o monitoramento precoce da eficácia terapêutica; a limitada transposição de resultados promissores obtidos em modelos pré-clínicos para contextos clínicos humanos; os custos elevados inerentes a todas as fases do desenvolvimento farmacológico; e, de forma particular, as barreiras fisiológicas — com

[3] `https://www.fda.gov/`

destaque para a barreira hematoencefálica — que restringem significativamente a biodisponibilidade e a eficácia dos fármacos no tecido neural. Nesse cenário, a maioria dos medicamentos atualmente aprovados é projetada para interagir com alvos moleculares únicos, os chamados *target-specific drug ligands* (TSDs), o que demanda a administração concomitante de múltiplos agentes terapêuticos, elevando substancialmente o risco de interações medicamentosas não desejadas, como hipersecreção, bradicardia, miose, náuseas e vômitos.

Diante dessas limitações, tem ganhado destaque o desenvolvimento de estratégias terapêuticas multi-alvo, denominadas *multi-target-directed ligands* (MTD), que visam à modulação simultânea de múltiplas vias patológicas envolvidas na DA. Conforme introduzido por Mesiti et al. (2019), Iraji et al. (2020) e Benek, Korabecny e Soukup (2020), essa abordagem busca ampliar a eficácia clínica ao mesmo tempo em que reduz a dependência de tratamentos combinatórios e os efeitos colaterais associados. Em consonância com essa perspectiva, estudos como os apresentados por Mendes et al. (2023b) investigam compostos com características MTD voltados à inibição da AChE, BChE, BACE1. Pertinência reforçada por Zhang et al. (2019), que ressaltam a importância de explorar a AChE juntamente com outros alvos terapêuticos, dada sua relevância e envolvimento com diversos processos fisiopatológicos da DA, frequentemente interligados com os mecanismos mediados por outros alvos moleculares.

2.4 Considerações Finais

Apesar dos avanços substanciais alcançados nas últimas décadas em neurociência e no aprimoramento de ferramentas diagnósticas e analíticas, persistem lacunas críticas na compreensão dos eventos moleculares e celulares iniciais que desencadeiam a cascata patológica da DA. A significativa heterogeneidade clínico-biológica que caracteriza essa enfermidade, aliada às limitações dos modelos experimentais atualmente disponíveis, que não reproduzem ou não observam a complexidade multifatorial do processo neurodegenerativo, compromete a elucidação das inter-relações de seus mecanismos etiopatológicos mais evidentes (CUMMINGS et al., 2024).

Esse cenário impõe obstáculos relevantes ao desenvolvimento de intervenções terapêuticas eficazes, especialmente considerando os altos custos, os riscos clínicos e o tempo demandado para a realização de ensaios clínicos. A imprevisibilidade dos resultados, associada às exigências regulatórias rigorosas, tem contribuído para o retraimento de investimentos por parte da indústria farmacêutica, resultando na estagnação terapêutica observada nas últimas décadas (DOKHOLYAN; MOHS; BATEMAN, 2022). Em consequência, os tratamentos atualmente disponíveis mantêm-se majoritariamente paliativos, voltados à mitigação dos sintomas clínicos, sem alterar de forma significativa o curso da neurodegeneração. Essa limitação, intensificada pelo envelhecimento populacional, reforça o impacto socioeconômico da DA em escala global.

Dessa forma, é evidente a necessidade de abordagens terapêuticas inovadoras, baseadas em mecanismos etiológicos, capazes de explorar grandes quantidades de informação na tentativa de modificar a história natural da doença. Assim, torna-se essencial desenvolver estratégias que otimizem o uso de recursos nas fases de pesquisa, desenvolvimento e validação de novos fármacos, promovendo intervenções não apenas eficazes, mas também acessíveis e sustentáveis

diante das crescentes demandas de saúde pública. Nesse contexto, observa-se um papel cada vez mais relevante das metodologias computacionais na investigação de alvos biomoleculares e vias patológicas. Abordagens *in silico* têm demonstrado potencial significativo ao viabilizar análises sistemáticas e integradas de múltiplos fatores etiológicos em ambientes controlados, com menor custo e maior escalabilidade. Tais estratégias vêm impulsionando novas perspectivas para o desenho racional de fármacos, a triagem e o reposicionamento de compostos bioativos.

Com base nos avanços computacionais acima mencionados, o próximo capítulo apresenta uma análise abrangente sobre CADD, com ênfase em suas aplicações na bioengenharia, no desenvolvimento de terapias de precisão e no emprego de técnicas de inteligência artificial para a otimização de tempo e custo nos processos de descoberta e reposicionamento de fármacos.

Capítulo

3

Design Racional de Fármacos: Evolução das Estratégias Computacionais para Descoberta e Reposicionamento Terapêutico

3.1 Considerações Iniciais

O desenvolvimento racional de fármacos configura-se como um processo altamente complexo e oneroso, frequentemente associado a altos investimentos e décadas de pesquisa contínua. Nos últimos anos, sua estrutura metodológica tem passado por uma série de transformações significativas, muitas das quais impulsionadas pela incorporação de estratégias capazes de acelerar, ampliar e refinar etapas críticas envolvidas na identificação, avaliação e otimização de compostos bioativos. Como reportado nos capítulos 1 e 2, as limitações dos métodos convencionais de descoberta e reposicionamento terapêutico evidenciam a necessidade de abordagens mais eficientes, escaláveis e integradas, tanto do ponto de vista técnico quanto sob a perspectiva da viabilidade econômica e mercadológica. Nesse cenário, as abordagens *in silico*, fundamentadas em algoritmos computacionais especializados, despontam como alternativas promissoras por oferecerem suporte preditivo e analítico de alto desempenho, contribuindo diretamente para a racionalização dos processos e a promoção de um desenvolvimento farmacêutico mais sustentável e eficiente. De acordo com Sabe et al. (2021), mais de 70 medicamentos já foram aprovados nos últimos anos com o auxílio dessas estratégias, o que confirma seu caráter de relevância para o cenário farmacêutico emergente.

Dentre as abordagens *in silico* mais consolidadas, destaca-se o CADD, um campo de natu-

reza interdisciplinar que integra fundamentos de química medicinal, biologia estrutural, ciência da computação e inteligência artificial (IA). Nesse amplo espectro, sua principal finalidade é identificar e aprimorar candidatos terapêuticos, buscando maior precisão, larga escala de exploração e redução substancial de tempo e custo, quando comparado aos métodos experimentais tradicionais.

A aplicabilidade do CADD estende-se por múltiplas etapas do processo de descoberta e reposicionamento de fármacos, abrangendo desde a curadoria e o pré-processamento de grandes bases de dados moleculares até a modelagem detalhada das interações entre ligantes e alvos biológicos, por meio de simulações de dinâmica molecular (SABE et al., 2021). De forma complementar, a inteligência artificial aplicada à descoberta de fármacos (AIDD, do inglês, *Artificial Intelligence-Driven Drug Discovery/Design*) tem ganhado destaque com a incorporação de técnicas de aprendizado de máquina (ML, do inglês, *Machine Learning*) e redes neurais artificiais (RNAs), especialmente em aplicações de triagem virtual (TV) e reposicionamento racional (VATANSEVER et al., 2021). Esse domínio emergente caracteriza-se pela capacidade de reconhecer padrões complexos em grandes volumes de dados multidimensionais — como assinaturas moleculares [1], ampliando de forma significativa o poder preditivo dos modelos computacionais. A integração entre CADD e AIDD tem-se revelado particularmente promissora no desenvolvimento de terapias personalizadas, com destaque para doenças complexas e multifatoriais, como as neurodegenerativas (CHENG et al., 2024; GAUTAM et al., 2023; SALMAN et al., 2021).

Este capítulo tem por objetivo revisar as principais estratégias computacionais que compõem o escopo do CADD/AIDD, com ênfase em suas aplicações no contexto da bioengenharia. Inicialmente, são discutidos os métodos de seleção, curadoria e pré-processamento de dados moleculares, que constituem a base informacional sobre a qual os modelos computacionais operam. Em seguida, são abordadas as estratégias de geração e triagem de compostos, com destaque para os métodos de acoplamento molecular (i.e., *docking*) e suas variantes. Na sequência, é discutido o papel das simulações de dinâmica molecular no refinamento estrutural, na análise da estabilidade de complexos biomoleculares e na caracterização da flexibilidade conformacional dos alvos terapêuticos. Nesse amplo cenário de soluções, são apresentadas as contribuições da IA para a modelagem preditiva de propriedades moleculares de candidatos terapêuticos. Por fim, discute-se a relevância da reprodutibilidade computacional e da automação de fluxos de trabalho (*workflows*), destacando as perspectivas para a integração dessas abordagens no desenvolvimento de terapias eficazes, reprodutíveis e em larga escala.

3.2 Fundamentos do CADD

Na Bioengenharia, a adoção de estratégias *in silico* tem promovido avanços significativos no desenvolvimento de fármacos, destacando-se pelos benefícios associados à simulação computacional nas etapas de descoberta, projeto e otimização de candidatos terapêuticos. Entre essas vantagens, a redução substancial de tempo e custos operacionais tem sido particularmente

[1] Comumente referidas na literatura como *fingerprints*, estas podem ser geradas por diferentes métodos/algoritmos, incluindo, por exemplo, Morgan, MACCS e os baseados em farmacóforo.

relevante para a superação das limitações impostas pelos métodos tradicionais (CHANG et al., 2023; CHOUDHURY; SAIKIA, 2018). De acordo com Sabe et al. (2021), as estratégias baseadas em CADD envolvem um conjunto de modelos computacionais aplicados majoritariamente à fase pré-clínica do desenvolvimento farmacêutico, com resultados expressivos na mitigação de gargalos relacionados ao investimento financeiro e à morosidade do processo.

Esses modelos permitem a triagem sistemática de bibliotecas moleculares em grande escala, favorecendo a identificação precoce de propriedades críticas, como toxicidade, atividade biológica e biodisponibilidade. Por possibilitarem análises preditivas que antecedem os experimentos *in vitro* e *in vivo*, tais abordagens contribuem para a redução de incertezas no processo de seleção e priorização de compostos com maior probabilidade de sucesso nas etapas subsequentes.

Dentre os recursos amplamente consolidados no âmbito do CADD, a TV destaca-se como uma estratégia eficiente, econômica e escalável para a identificação de potenciais interações de afinidade entre pequenas moléculas bioativas e alvos moleculares específicos. Essa técnica tem-se firmado como uma alternativa eficaz e frequentemente complementar às triagens experimentais de alto rendimento (i.e., HTS, do inglês, *High-Throughput Screening*), contribuindo não apenas para a descoberta de novos compostos, mas também para o refinamento de *hits* previamente selecionados e já posicionados em diferentes estágios de pesquisa e avaliação (OLIVEIRA et al., 2023a).

Nos últimos anos, tem-se observado uma evolução significativa nas metodologias de TV, em especial no contexto de alto desempenho com as soluções de HTVS. Esses avanços têm contribuído de maneira significativa para o aumento da precisão e eficiência dos processos de docagem molecular, consolidando o CADD como uma ferramenta estratégica para a descoberta racional de fármacos. Tais melhorias têm-se mostrado particularmente promissoras em estudos demenciais, como a doença DA, nas quais a triagem computacional viabiliza a exploração simultânea de múltiplos alvos terapêuticos, a rápida exclusão de espaços químicos irrelevantes e a priorização de compostos com perfis de ação multi-alvo (SON et al., 2019b; ZERROUG et al., 2019; MESITI et al., 2019; IRAJI et al., 2020; DAVID et al., 2021b; SALMAN et al., 2021; MENDES et al., 2023a; MENDES et al., 2023b). Nesse contexto, essas estratégias são observadas a partir de duas frentes metodológicas principais: aquelas centradas na análise estrutural dos alvos e as que exploram a similaridade entre ligantes.

3.2.1 Definições e Tipos

Na literatura, frequentemente observam-se associações das estratégias de HTVS com conceitos de triagem virtual baseada em estrutura ou triagem virtual baseada em alvo (SBVS, do inglês, *Structure-Based Virtual Screening*), termos que são sinônimos. Como brevemente apresentado no Capítulo 1, o propósito dessa abordagem consiste na identificação de moléculas candidatas com elevada afinidade e especificidade de ligação ao receptor de interesse. Essa abordagem é particularmente valiosa quando a estrutura tridimensional do receptor é conhecida. Isso permite a análise das moléculas candidatas em termos de sua capacidade de se ancorar no sítio de ligação de interesse. O alinhamento preciso entre alvo e ligante é uma etapa relevante nessa abordagem, requerendo o uso de técnicas computacionais de modelagem molecular para

a representação das estruturas tridimensionais (MAIA et al., 2020).

Uma vez preparadas as estruturas tridimensionais, são empregadas ferramentas de ancoragem, comumente referidas como *docking*, para avaliar as características de interação da molécula candidata com o sítio de ligação do receptor. Essas ferramentas simulam a interação ligante-receptor ao observar parâmetros físico-químicos, como energia de ligação, geometria de interação e interações intermoleculares. No entanto, apesar de serem amplamente abordadas e se mostrarem parte do estado da arte, existem casos em que a estrutura do receptor não está adequadamente detalhada, o que limita sua utilização como modelo prevalente de exploração e avaliação (VÁZQUEZ et al., 2020).

Por outro lado, na triagem virtual baseada no ligante (LBVS, do inglês, *Ligand-Based Virtual Screening*), também conhecida como triagem virtual baseada em similaridade, não é necessário o conhecimento prévio da estrutura tridimensional do receptor para identificar moléculas candidatas com potencial atividade biológica. Nessa abordagem, parte-se do princípio de que moléculas com estruturas químicas semelhantes possuem atividades biológicas similares, sugerindo que há compartilhamento de características físico-químicas dessas no domínio de investigação. No LBVS, algoritmos de similaridade molecular, como o coeficiente de Tanimoto (RÁCZ; BAJUSZ; HÉBERGER, 2018), exploram moléculas candidatas utilizando para isso características de compostos conhecidos com atividade biológica comprovada. Nesse cenário, são considerados durante a análise diferentes descritores moleculares, como tamanho, forma, carga, lipofilicidade, grupos farmacofóricos, entre outros (CHISHOLM; MACKEY; HUNTER, 2023). Assim, as moléculas candidatas mais promissoras, ou seja, aquelas com maior grau de sobreposição de descritores, são enviadas para ensaios de atividade biológica específicos, propriedades farmacocinéticas e toxicidade, os quais também podem ser simulados por modelos computacionais. A Figura 3.1 detalha os fluxos metodológicos típicos empregados pelos diferentes tipos de CADD, destacando as ações realizadas pelas abordagens SBVS e LBVS.

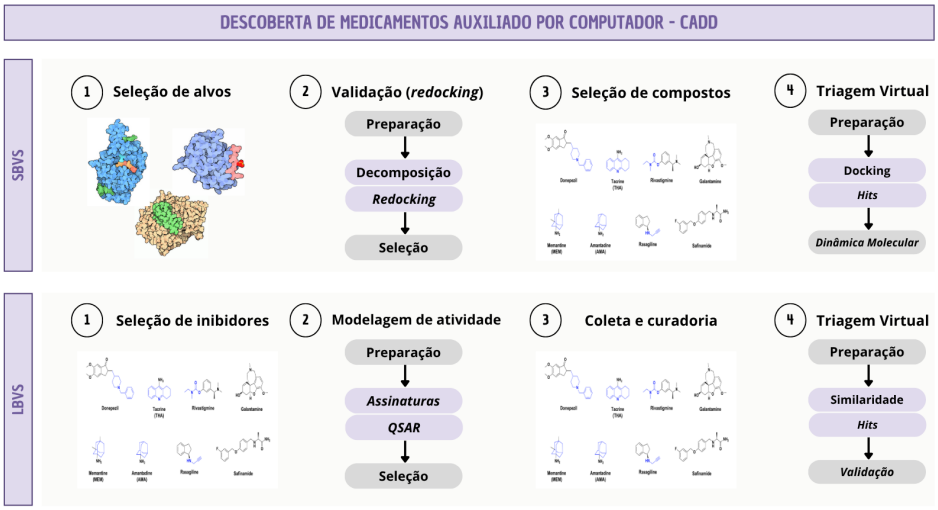

Figura 3.1: Esquemático típico utilizado na descoberta de medicamentos por auxílio computacional. **SBVS**: O processo inicia com a seleção e preparação dos alvos moleculares (1), seguida pela validação do protocolo de *redocking* e cálculo de RMSD (2). Em seguida, realiza-se a seleção de compostos candidatos (3) que são submetidos à triagem virtual (4), incluindo *docking* molecular e refinamento com dinâmica molecular. **LBVS**: O fluxo começa com a seleção de inibidores conhecidos (1) para a modelagem da atividade (2), que envolve a preparação dos dados, geração de assinaturas moleculares e/ou construção de modelos QSAR. Na sequência, realiza-se a coleta e curadoria de bibliotecas químicas (3), submetidas à triagem virtual (4) com base na similaridade molecular (e.g., Tanimoto), seguida da validação dos compostos identificados.

É importante ressaltar que, embora a LBVS seja uma abordagem eficaz na identificação de novos compostos, essa estratégia enfrenta limitações na detecção de moléculas candidatas quando a estrutura físico-química dessas diverge significativamente das encontradas nos compostos com atividade biológica comprovada. Essas limitações decorrem da dependência da similaridade estrutural, que pode resultar em falsos positivos ou falhas em identificar moléculas com propriedades inovadoras. Essa questão é um desafio importante no campo do HTVS baseado em ligante e/ou similaridade (GIMENO et al., 2019; VÁZQUEZ et al., 2020).

Em cenários em que a LBVS apresenta limitações, pode-se recorrer a modelos híbridos que integram elementos da LBVS com a SBVS. Essa abordagem combinada explora as vantagens complementares de cada estratégia, utilizando a estrutura tridimensional do receptor sempre que disponível, e incorporando análises baseadas em similaridade molecular nos casos em que informações estruturais são escassas ou imprecisas. A utilização mútua dessas metodologias aprimora a capacidade de identificar moléculas com arquiteturas distintas e atividade biológica promissora, ampliando o alcance da HTVS e aumentando as chances de descoberta de compostos viáveis para o desenvolvimento farmacológico. Além disso, por operarem simultaneamente sobre duas frentes estratégicas, os modelos híbridos favorecem uma exploração mais abrangente do espaço químico-biológico, possibilitando a identificação de padrões de interação ligante-receptor ainda não descritos, e, consequentemente, expandindo as fronteiras da descoberta e reposicionamento racional de fármacos.

3.3 Fontes e Preparação de Dados

Para que as estratégias previamente mencionadas sejam eficazes nos processos de descoberta e reposicionamento racional de fármacos, é essencial a construção de conjuntos de dados químico-biológicos adequados, representativos e de alta qualidade, compatíveis com os objetivos de cada investigação. Nesse contexto, o acesso a informações químicas e biológicas adequadamente fundamentadas, bem curadas e interoperáveis constitui a base fundamental para o desenvolvimento de abordagens preditivas e analíticas em bioengenharia farmacêutica.

Esses repositórios armazenam, organizam e disponibilizam informações estruturais, bioativas e funcionais de compostos químicos, biomoléculas e complexos moleculares, sendo amplamente utilizados como fontes primárias em tarefas como modelagem molecular (SHI et al., 2021), triagem virtual (PRAJAPAT, 2021), predição de propriedades (RODRIGUEZ et al., 2021), desenvolvimento de modelos baseados em ML (LI et al., 2021) e validação experimental (AJALA et al., 2023). Dentre as bases de dados comumente empregadas em projetos de design racional de fármacos, destacam-se aquelas cuja confiabilidade, escopo e interoperabilidade as tornam especialmente relevantes para aplicações de TV e HTVS, sendo essas:

- **ChEMBL**: Desenvolvida pelo *European Bioinformatics Institute* (EMBL-EBI), a ChEMBL é uma base de dados relacional que armazena informações sobre a bioatividade de compostos químicos frente a alvos biológicos, extraídas de literatura científica e ensaios experimentais padronizados. Em sua versão 35, lançada em dezembro de 2024, sua base contempla 2.496.335 compostos distintos, 3.185.505 registros de compostos (incluindo du-

plicatas), 21.123.501 atividades bioquímicas, 1.740.546 ensaios e 16.003 alvos biológicos, além de 92.121 documentos científicos associados (ZDRAZIL et al., 2024). A base oferece dados estruturais em múltiplos formatos (e.g., SMILES[2], InChI[3], SDF[4]) e metadados relacionados a IC_{50}, EC_{50}, K_i, e K_d, entre outros, tornando-se referência para modelagem de relações estrutura-atividade de forma quantitativa (QSAR, do inglês, *Quantitative Structure-Activity Relationship*) e aprendizado supervisionado (MAO et al., 2021). Suas informações podem ser acessadas através de uma série de interfaces web interativas ou via interfaces de programação de aplicações (APIs), como o ChEMBL *web services client* (ChEMBL WSC) (ChEMBL Team, 2024), facilitando sua integração com *workflows* de bioinformática e ML.

- **ZINC**: Desenvolvida pela Universidade da Califórnia em San Francisco, a ZINC é uma base de dados pública que reúne compostos comercialmente disponíveis, preparados especialmente para SBVS. Os compostos armazenados estão disponíveis em conformações bi– e tridimensionais otimizadas para docagem molecular, considerando diferentes estados de protonação, estereoquímica e tautomeria. Além disso, a ZINC oferece diversos formatos de arquivo para download, incluindo SMILES, mol2, SDF 3D e o formato DOCK flexibase, facilitando a integração com uma variedade de ferramentas de modelagem molecular. Em sua versão ZINC–22, publicada em 15 de fevereiro de 2023 por Tingle et al. (2023), sua estrutura é organizada em "*tranches*", agrupamentos de até 5.000 moléculas, categorizadas por características como número de átomos pesados, lipofilicidade, carga molecular entre outros.

- **PubChem**: Mantida pelo Centro Nacional de Informações sobre Biotecnologia (NCBI, do inglês, *National Center for Biotechnology Information*), a PubChem é uma das maiores bases de dados públicas de compostos químicos da atualidade. Até setembro de 2024, ela armazenava mais de 322 milhões de descrições de substâncias fornecidas por depositantes, 119 milhões de estruturas químicas únicas e aproximadamente 295 milhões de dados de bioatividade provenientes de mais de 1.2 milhão de ensaios biológicos (KIM et al., 2025). A base é altamente interoperável com outras plataformas do NCBI, como Gene, Protein e BioAssay. Os dados podem ser acessados e baixados em diversos formatos, incluindo SDF, CSV, XML e JSON, por meio de interfaces web interativas ou via APIs, como o PubChem *Power User Gateway* (PUG) e o PubChemRDF (KIM et al., 2021b).

- **Protein Data Bank (PDB)**: O PDB é o principal repositório de estruturas tridimensionais de macromoléculas biológicas, como proteínas, ácidos nucleicos e complexos proteína-ligante. As estruturas depositadas são obtidas principalmente por cristalografia de raios X, espectroscopia de ressonância magnética nuclear (RMN) e, mais recentemente, por microscopia crioeletrônica. Desde 2014, o formato PDBx/mmCIF tornou-se o padrão oficial para depósito e distribuição de dados no PDB, substituindo o formato legado PDB,

[2] *Simplified Molecular Input Line Entry System*
[3] *International Chemical Identifier*
[4] *Structure Data File*

que apresentava limitações quanto ao número de átomos e cadeias que podiam ser representados. O formato PDBx/mmCIF é altamente extensível e permite a representação de estruturas macromoleculares complexas, além de ser compatível com diversas ferramentas de visualização e análise estrutural, como PyMOL[5], UCSF Chimera[6] e VMD[7]. Os dados também estão disponíveis em formatos como PDBML (XML) e BinaryCIF, facilitando a integração com diferentes *workflows* computacionais (CHOUDHARY et al., 2024; ZHANG, 2023).

- **DrugBank**: O DrugBank é um banco de dados bio– e quimioinformático que integra informações químicas, farmacológicas e farmacocinéticas de medicamentos aprovados e em investigação clínica. Na versão 6.0, lançada em 2024, o DrugBank expandiu significativamente seu conteúdo, incluindo 4.563 medicamentos aprovados pela FDA, 6.231 em fase de investigação, totalizando 11.891 fármacos, além de mais de 1,4 milhão de interações fármaco-fármaco e 2.475 interações fármaco-alimento. A base combina dados experimentais e computacionais, abrangendo interações fármaco-alvo, mecanismos de ação, vias metabólicas, espectros experimentais e preditivos (MS/MS, RMN 1D/2D), além de informações regulatórias. Os dados estão disponíveis em diversos formatos, como SDF para estruturas químicas, XML e JSON para informações estruturadas, facilitando a integração com *workflows* de bioinformática e ML. O acesso ao conteúdo disponível é possível via APIs RESTful[8], mediante autenticação, permitindo consultas e *downloads* automatizados (KNOX et al., 2024).

Além da expressiva riqueza de informação, essas bases de dados destacam-se por sua rigorosa auditoria contínua, aderência a padrões internacionais de anotação e suporte a múltiplos formatos de exportação, tais como SDF, MOL2, PDB, FASTA, CSV e JSON, o que viabiliza sua integração direta com ferramentas computacionais e linguagens de programação voltadas à ciência de dados. A interoperabilidade entre repositórios, facilitada pelo uso de identificadores padronizados e APIs abertas, contribui significativamente para a automação de fluxos analíticos e para a reprodutibilidade dos experimentos computacionais. Nesse contexto, a seleção criteriosa das bases de dados, em conjunto com bibliotecas especializadas para extração e pré-processamento, configura uma etapa fundamental para assegurar a qualidade e consistência dos dados coletados e empregados em modelos preditivos e simulações *in silico*.

3.3.1 Ferramentas de Exploração, Pré-processamento e Normalização

A exploração de grandes conjuntos de dados químicos em busca de compostos com potencial bioativo impõe desafios substanciais, sobretudo devido à heterogeneidade estrutural, semântica e metodológica das representações químicas e biológicas neles contidas. Ainda que essas bases estejam organizadas segundo padrões internacionais já consolidados como SMILES, InChI e

[5]https://pymol.org/
[6]https://www.cgl.ucsf.edu/chimera/
[7]https://www.ks.uiuc.edu/Research/vmd/
[8]https://www.ebi.ac.uk/chembl/ws

PDBx/mmCIF, os dados recuperados de seus respectivos repositórios geralmente requerem etapas adicionais de curadoria, filtragem, conversão e normalização, a fim de atender aos requisitos específicos de diferentes modelos computacionais ou objetivos de pesquisa.

Frente a essa complexidade, torna-se essencial não apenas o pré-processamento criterioso dos dados, mas também a ampliação sistemática do domínio informacional analisado. Nesse sentido, a construção de domínios de busca amplos e ricos em informação demanda a integração coerente de múltiplas fontes especializadas — como ChEMBL, ZINC e PDB, permitindo a expansão controlada do espaço químico e bioativo considerado. Tal integração é indispensável para a geração de representações moleculares mais abrangentes, adaptadas aos desafios impostos por cenários terapêuticos complexos e frequentemente caracterizados por etiologias multifatoriais.

Para viabilizar essa abordagem integrativa de maneira eficiente e automatizada, tornam-se necessárias ferramentas computacionais capazes de realizar, de forma adequada e segura, a recuperação, harmonização sintática e semântica, e transformação dos dados provenientes de repositórios heterogêneos. Nesse contexto, destacam-se os seguintes recursos empregados na preparação, análise e modelagem de dados moleculares:

- **Biopython**: O *Biopython* constitui uma das principais bibliotecas de código aberto voltadas ao desenvolvimento de aplicações computacionais em bioinformática, tendo como base a linguagem de programação Python[9]. Desenvolvida e mantida por uma comunidade internacional coordenada pela *Open Bioinformatics Foundation*, essa biblioteca tem sido continuamente expandida desde o final da década de 1990, com o objetivo de oferecer uma infraestrutura modular e extensível para a manipulação e análise de dados biológicos. Entre suas funcionalidades, é possível destacar os módulos para leitura, escrita e manipulação de sequências nucleotídicas e proteicas em múltiplos formatos padronizados (e.g., FASTA, GenBank), execução de alinhamentos múltiplos, análise filogenética, interpretação de estruturas tridimensionais de proteínas no formato PDB, além de suporte à genética de populações e modelagem evolutiva (COCK et al., 2009). Um diferencial estratégico do *Biopython* é sua capacidade de integração com serviços remotos por meio de APIs de bancos de dados amplamente utilizados, como NCBI Entrez, UniProt, BLAST, DrugBank e Expasy. Essa funcionalidade permite automatizar tarefas rotineiras de consulta, recuperação de anotações funcionais, identificação de domínios conservados e comparação de sequências diretamente em ambientes computacionais Python. Por sua arquitetura colaborativa, extensível e interoperável, o *Biopython* é amplamente considerado como um dos pilares do ecossistema de ferramentas bioinformáticas, sendo amplamente utilizado para integração entre dados ómicos, anotações funcionais e modelagem estrutural (SÁ; NOGUEIRA, 2024).

- **ChEMBL *Web Service***: O ChEMBL *Web Service* constitui um conjunto de APIs do tipo RESTful desenvolvidas pelo *European Bioinformatics Institute* (EMBL-EBI) com o propósito de viabilizar o acesso remoto, eficiente e estruturado ao banco de dados

[9]https://docs.python.org/pt-br/3/tutorial/index.html

ChEMBL, um dos mais abrangentes repositórios públicos de informações sobre bioatividade de compostos químicos frente a alvos moleculares de interesse farmacológico (CHEMBL, 2023). Essas APIs oferecem uma ampla variedade de funcionalidades para consulta, filtragem e extração de dados relacionados a compostos, alvos biológicos, bioensaios, interações ligante-receptor e atividades experimentais, por meio de requisições HTTP padronizadas e respostas em formatos interoperáveis como JSON ou XML. Sua arquitetura permite uma integração direta a *workflows* automatizados de TV/HTVS, análise de QSAR, extração de conjuntos de dados para treinamento de modelos de ML, bem como para o desenvolvimento de *dashboards* interativos e sistemas de apoio à decisão. Adicionalmente, os serviços oferecidos incluem mecanismos para paginação, ordenação e filtragem paramétrica, facilitando a construção de consultas complexas de forma escalável (ChEMBL, 2023).

- **RDKit**: O *RDKit* é uma biblioteca de código aberto abrangente e consolidada para manipulação computacional de estruturas químicas, sendo amplamente adotada nos domínios de modelagem molecular, química medicinal computacional, bioengenharia e ciência de dados aplicados à química. Desenvolvida com interfaces em Python, essa biblioteca oferece um conjunto extenso de funcionalidades para representação, transformação e análise de compostos químicos em múltiplos formatos (e.g., SMILES, Mol, SDF, InChI), além de ferramentas avançadas para visualização 2D e 3D de moléculas. Entre suas funcionalidades, destacam-se: cálculo de descritores moleculares (físico-químicos, topológicos, eletrônicos), geração de assinaturas moleculares (como Morgan, MACCS e AtomPairs), calculo de similaridade entre moléculas (como coeficiente de Tanimoto), detecção de subestruturas, reações químicas programáticas, normalização canônica de estruturas, além de suportar o particionamento e alinhamento conformacional com métodos baseados em UFF[10], MMFF94[11] e ETKDG[12]. O *RDKit* também dispõe de integração nativa com *frameworks* de ML e bancos de dados relacionais, como PostgreSQL, sendo particularmente eficiente na construção de aplicações para TV, LBVS, *clustering* químico e modelagem preditiva (SCALFANI; PATEL; FERNANDEZ, 2022; RÁCZ; BAJUSZ; HÉBERGER, 2018; LANDRUM, 2006).

- **Mordred**: O *Mordred* é uma biblioteca de código aberto especializada no cálculo extensivo de descritores moleculares, sendo amplamente utilizada em tarefas de modelagem preditiva, desenvolvimento de modelos QSAR/QSPR (*Quantitative Structure–Activity/Property Relationship*) e análise multivariada de dados químicos. Desenvolvido em Python, o *Mordred* oferece uma interface que permite a extração automática de mais de 1800 descritores distintos, organizados em categorias que incluem propriedades topológicas, fisicoquímicas, eletrostáticas, geométricas, baseadas em grafos e baseadas em teoria da informação. Entre seus diferenciais, destacam-se a padronização na nomenclatura dos descritores, o

[10] *Universal Force Field*
[11] *Merck Molecular Force Field 94*
[12] *Experimental-Torsion Knowledge Distance Geometry*

suporte à validação automática de entradas moleculares, o tratamento de exceções numéricas e a possibilidade de geração seletiva de subconjuntos de descritores conforme critérios definidos pelo usuário. Segundo Moriwaki et al. (2018), sua arquitetura é projetada para trabalhar em conjunto com bibliotecas como o *RDKit*, que fornece as representações moleculares subjacentes, mas estende suas funcionalidades ao oferecer um repositório abrangente e especializado de características moleculares derivadas. Assim, enquanto o *RDKit* enfatiza a manipulação estrutural, geração de conformações, visualização, transformações químicas e integração com *workflows*, o *Mordred* concentra-se na extração de características descritivas em larga escala e com alta confiabilidade, sendo particularmente valioso em contextos onde a ampla descrição é essencial para a performance de modelos computacionais.

- **BioPandas**: O *BioPandas* é uma biblioteca também de código aberto que estende a funcionalidade da conhecida biblioteca *pandas*[13] para o domínio da bioinformática estrutural e da química. Seu principal objetivo é viabilizar a manipulação eficiente de dados moleculares e estruturais por meio de estruturas de dados compatíveis com a análise estatística e o ML. O *BioPandas* fornece classes específicas para leitura, escrita e manipulação de arquivos nos formatos PDB, MOL2 e SDF, encapsulando informações moleculares em objetos *DataFrame* otimizados para filtragem, agregação e transformação vetorial. Essa abordagem permite que pesquisadores apliquem métodos avançados de análise de dados diretamente sobre representações moleculares, favorecendo a integração com bibliotecas como *scikit-learn*, *seaborn* ou *xgboost* (RASCHKA, 2017). Além disso, sua interoperabilidade com ferramentas como *RDKit* e *Mordred* potencializa a construção de *workflows* consistentes e reproduzíveis para tarefas como modelagem preditiva, avaliação de similaridade química e extração de padrões estruturais em larga escala.

- **Open Babel**: O *Open Babel* é um dos mais versáteis conversores de formatos químicos disponíveis, sendo amplamente adotado em *workflows* de preparação e processamento de dados moleculares. Projetado como uma ferramenta multiplataforma e de código aberto, o *Open Babel* oferece suporte nativo a mais de 100 formatos de arquivo, incluindo SMILES, InChI, SDF, MOL2, PDB. Além de sua função principal de conversão entre representações químicas, a biblioteca disponibiliza funcionalidades essenciais como geração de coordenadas tridimensionais a partir de representações 2D, adição e otimização de hidrogênios, detecção de subestruturas, limpeza topológica de moléculas, análise de tautômeros e cálculo de propriedades físico-químicas básicas. Em sua versão mais recente, o *Open Babel* pode ser executado via linha de comando ou integrado ao Python, conferindo-lhe alta flexibilidade em ambientes de TV (O'BOYLE et al., 2011).

- **PyMOL**: O *PyMOL* é uma ferramenta popular utilizada para visualização tridimensional de estruturas moleculares, com aplicação extensa na análise estrutural de proteínas, ácidos nucleicos, ligantes e complexos biomoleculares. Desenvolvido inicialmente por DeLano et

[13] https://pandas.pydata.org/docs

al. (2002), o *PyMOL* combina uma interface gráfica intuitiva com um poderoso mecanismo de renderização e suporte a comandos através do Python, o que o torna particularmente útil em fluxos automatizados de análise estrutural e geração de figuras de alta qualidade para publicações científicas. Entre suas funcionalidades destacam-se a renderização realista de superfícies moleculares, detecção de interações não covalentes (como ligações de hidrogênio e interações hidrofóbicas), alinhamento estrutural entre modelos, visualização de trajetórias de dinâmica molecular, marcação de resíduos específicos, e a capacidade de gerar animações e cenas interativas. O *PyMOL* também se integra com bibliotecas e ferramentas de bioinformática como BioPython, MDTraj[14] e MDAnalysis[15], tornando-se um componente extremamente útil em análises de *docking* molecular, simulações de dinâmica e validação estrutural de modelos preditivos (YUAN; CHAN; HU, 2017).

As ferramentas acima elucidadas sustentam a construção de soluções computacionais diversas e abrangentes para análise de compostos bioativos, cobrindo desde a recuperação e preparação dos dados até a geração de matrizes de atributos para modelagem preditiva. Quando integradas a bancos de dados especializados, como ChEMBL, ZINC, PubChem e PDB, permitem a automatização de processos e a transformação de dados heterogêneos em representações estruturadas e compatíveis com diferentes objetivos de pesquisa. Essa integração eficaz é essencial para consolidar conjuntos moleculares consistentes, além de viabilizar a aplicação de estratégias modernas de TV/HTVS, incluindo métodos baseados em LBVS, *docking* e IA, componentes necessários em cenários emergentes da descoberta e reposicionamento racional de fármacos.

3.4 Triagem Virtual e Docking Molecular

Como evidenciado em momentos anteriores deste capítulo, a identificação eficiente de compostos bioativos com afinidade por alvos terapêuticos específicos representa um dos principais desafios no processo de exploração de novos fármacos. Nesse contexto, a TV, abordagem computacional voltada à avaliação das interações entre pequenas moléculas e macromoléculas biológicas, tem-se estabelecido como um dos passos essenciais das estratégias *in silico*, tanto para a descoberta quanto para o reposicionamento racional. Fundamentada em modelos de análise sistemática de propriedades moleculares, afinidades de ligação e padrões estruturais relevantes, sua utilização tem-se mostrado crucial para a racionalização do processo de triagem, promovendo a redução efetiva do espaço químico a ser explorado. Como consequência, observa-se um ganho significativo em eficiência preditiva, aliado à diminuição do tempo e dos custos envolvidos nas fases iniciais do desenvolvimento pré-clínico (VÁZQUEZ et al., 2020).

De acordo com Sadybekov e Katritch (2023), nos últimos anos, com o avanço da capacidade computacional e a expansão de bancos de dados químicos e estruturais, é possível observar uma consolidação progressiva das abordagens de TV em larga escala, comumente abordadas como TV de alto desempenho – HTVS. Essa variante tem se mostrado particularmente eficaz na análise de grandes bibliotecas moleculares, permitindo a filtragem, priorização e ranqueamento

[14] https://www.mdtraj.org/1.9.8.dev0/index.html
[15] https://www.mdanalysis.org/

de compostos candidatos com base em critérios estruturais, energéticos ou estatísticos.

Entre as técnicas que compõem essa etapa do processo de triagem, a ancoragem molecular (*docking*) destaca-se como uma das ferramentas mais relevantes. Sua aplicação possibilita estimar, com base em critérios energéticos, estatísticos ou empíricos, a orientação espacial (pose) de pequenas moléculas no sítio de ligação de alvos biológicos, bem como a afinidade associada a essas interações. Em razão de sua importância crescente nas estratégias computacionais de descoberta e reposicionamento de fármacos, diversos modelos de acoplamento, funções de pontuação e protocolos de refinamento pós-*docking* foram sendo desenvolvidos ao longo dos anos, com o objetivo de aprimorar a precisão preditiva e a robustez estrutural das soluções produzidas.

3.4.1 Algoritmos e Modelos de Acoplamento

Os métodos de *docking* são sustentados por dois componentes centrais: (i) a exploração do espaço conformacional do ligante em relação ao sítio de ligação do receptor e (ii) a estimativa da afinidade de interação por meio de funções de pontuação (*scoring*). A eficácia preditiva dessa abordagem decorre da integração entre essas etapas, permitindo a geração de poses de ligação plausíveis e seu subsequente ranqueamento com base em critérios físico-químicos, estatísticos ou empíricos (MUHAMMED; AKI-YALCIN, 2024; STANZIONE; GIANGRECO; COLE, 2021; PAGADALA; SYED; TUSZYNSKI, 2017).

Para viabilizar essa amostragem conformacional de forma eficiente e confiável, diferentes algoritmos computacionais têm sido desenvolvidos e refinados nos últimos anos (PAGGI; PANDIT; DROR, 2024; AHMAD et al., 2021). Entre as principais estratégias de busca, destacam-se os métodos *estocásticos*, que empregam heurísticas como algoritmos genéticos, *Monte Carlo* e *simulated annealing* para explorar amplamente o espaço de conformações possíveis. Em contrapartida, abordagens *determinísticas*, como a busca sistemática e técnicas baseadas em gradiente local, são comumente utilizadas para otimização localizada de poses previamente identificadas, ainda que com maior custo computacional. Alternativamente, modelos híbridos que combinam a abrangência da amostragem estocástica com a precisão da otimização determinística têm demonstrado resultados promissores na identificação de conformações favoráveis, ao mesmo tempo em que minimizam redundâncias estruturais.

No que se refere à avaliação da afinidade, as funções de pontuação podem ser classificadas em diferentes categorias. Modelos baseados em campos de força (*force-field based*) utilizam equações clássicas da mecânica molecular para estimar interações do tipo Van der Waals, eletrostáticas e de ligação de hidrogênio (SHIRALI et al., 2025). Funções empíricas, por sua vez, agregam diferentes contribuições energéticas ponderadas por coeficientes ajustados empiricamente com base em dados experimentais de afinidade (YANG; ZHANG, 2021). Abordagens baseadas em conhecimento utilizam informações estatísticas derivadas de estruturas conhecidas de complexos proteína-ligante para inferir preferências espaciais de interação (ZHAO et al., 2023). Mais recentemente, funções de pontuação baseadas em ML têm sido desenvolvidas com o intuito de incorporar múltiplas características moleculares e contextuais de maneira não linear e orientada a dados (GUEDES et al., 2021). Além disso, modelos de energia livre aproxi-

mada, como MM/PBSA e MM/GBSA, são empregados em etapas de refinamento pós-*docking*, visando estimativas mais acuradas da energia de ligação (SAHAKYAN, 2021).

Diversas ferramentas computacionais implementam essas estratégias segundo diferentes níveis de sofisticação e propósito. O *AutoDock Vina* utiliza algoritmos genéticos combinados a uma função de energia semiempírica, sendo amplamente adotado por sua flexibilidade e acessibilidade (EBERHARDT et al., 2021). O *DOCK6* realiza uma busca geométrica por correspondência de esferas, complementada por funções de energia de ligação baseadas em mecânica molecular (PRENTIS et al., 2022). O *Glide* (Schrödinger) emprega uma abordagem incremental sobre um grid pré-computado do sítio ativo, combinada a etapas de refinamento orientadas por função de *scoring* empírica (HALGREN et al., 2004). Já o *GOLD* (*Genetic Optimization for Ligand Docking*) adota um algoritmo genético com suporte a diferentes funções de pontuação configuráveis, permitindo sua aplicação em protocolos personalizados de triagem (JONES et al., 1997).

Mais recentemente, soluções baseadas em aprendizado profundo (DL, do inglês, *Deep Learning*), como o *GNina*, fazem uso de redes neurais convolucionais para estimar diretamente a afinidade de ligação entre ligantes e proteínas, a partir de representações tridimensionais densas do complexo molecular. Essa abordagem permite incorporar informações espaciais de forma mais rica e não linear, superando limitações de funções de pontuação tradicionais e oferecendo desempenho competitivo tanto na predição da pose quanto na classificação de afinidade (MCNUTT et al., 2021).

A escolha dos algoritmos de busca e dos modelos de pontuação deve, portanto, ser cuidadosamente orientada pelas características específicas do sistema biológico em estudo, pelos requisitos de acurácia e desempenho computacional, bem como pelos objetivos da análise — seja ela voltada à triagem virtual em larga escala ou ao refinamento estrutural de candidatos bioativos. Essas decisões metodológicas exercem influência direta sobre a capacidade preditiva do processo de *docking*, afetando, em última instância, sua utilidade na priorização racional de compostos com potencial terapêutico. Nesse contexto, modelos baseados em funções de consenso, conforme discutido por Maia et al. (2020), emergem como alternativas promissoras, ao combinarem *scoring* de diferentes abordagens para a obtenção de estimativas mais realistas da afinidade de ligação observada.

3.4.2 Abordagens Híbridas e Modelos Baseados em Similaridade

Em cenários nos quais a estrutura tridimensional do alvo molecular é inexistente, incompleta ou de baixa qualidade, os métodos baseados em similaridade molecular configuram uma alternativa viável para a triagem de compostos. No entanto, conforme discutido, tais abordagens tendem a restringir-se a regiões do espaço químico previamente exploradas, limitando-se a compostos bioativos conhecidos. Essa limitação pode conduzir a processos de TV enviesados ou com baixo potencial inovador. Como forma de mitigar essas restrições, abordagens híbridas têm emergido como alternativas promissoras e, em muitos casos, complementares aos métodos tradicionais de *docking*. Em particular, estratégias que integram princípios tanto da SBVS quanto da LBVS têm demonstrado efetividade na expansão do espaço químico e bioativo aces-

sado, promovendo ganhos em flexibilidade metodológica e capacidade preditiva (VÁZQUEZ et al., 2020).

Tais abordagens são frequentemente sustentadas por modelos computacionais que exploram representações moleculares variadas, incluindo *fingerprints*, descritores topológicos e vetores latentes gerados por arquiteturas de RNAs, como *autoencoders* ou modelos baseados em grafos moleculares (ZHANG et al., 2022; PAN et al., 2021; MUEGGE; MUKHERJEE, 2016). Complementarmente, técnicas como triagem baseada em forma (*shape-based screening*) (MICHINO et al., 2023), alinhamento farmacofórico e algoritmos supervisionados de ML, como máquinas de vetores de suporte (SVM, do inglês *Support Vector Machine*) (WAN; WANG; LEE, 2021), florestas aleatórias (RF, do inglês *Random Forest*) (FENG et al., 2023) e redes neurais por grafos (GNN, do inglês *Graph Neural Network*) (JIANG et al., 2022), têm demonstrado resultados promissores, especialmente quando aplicadas a grandes bancos de dados químicos.

A incorporação desses modelos aos protocolos de *docking* contribui para uma triagem inicial mais precisa, permitindo reduzir substancialmente o número de candidatos submetidos ao acoplamento molecular e priorizar compostos com maior probabilidade de sucesso experimental. Além disso, a utilização de abordagens híbridas favorece a identificação de padrões estruturais latentes e relações complexas entre a estrutura química e a atividade biológica, viabilizando a construção de soluções eficientes e alinhadas aos princípios do planejamento racional de fármacos.

3.4.3 Refinamento Pós-Docking e Protocolos de Validação

Uma vez identificados os candidatos mais promissores a *hits*, torna-se essencial refinar e validar suas interações moleculares antes de avançar para etapas experimentais mais elaboradas de bancada *in vitro* e *in vivo*. Nesse contexto, a fase de refinamento pós-*docking* representa um componente fundamental na filtragem e priorização das poses geradas pelos algoritmos de acoplamento molecular. Essa etapa visa mitigar limitações intrínsecas aos métodos de *docking*, como simplificações na representação do receptor, rigidez estrutural e o uso de funções de pontuação aproximadas, as quais podem resultar em conformações energeticamente desfavoráveis ou quimicamente implausíveis (STANZIONE; GIANGRECO; COLE, 2021).

Para superar essas limitações e aprimorar os resultados computacionais obtidos, diversas estratégias vêm sendo incorporadas ao estágio de pós-*docking*. Dentre elas, destacam-se métricas quantitativas de avaliação, abordagens baseadas em mecânica molecular, técnicas de IA e simulações de dinâmica molecular, todas com o objetivo de aumentar a confiabilidade na seleção e priorização de complexos com potencial bioativo. Para avaliar a acurácia das poses geradas, métricas quantitativas como a raiz do erro quadrático médio (RMSD, do inglês, *Root Mean Square Deviation*) são amplamente empregadas, permitindo a comparação entre conformações previstas e estruturas de referência cristalográficas. Essa análise é particularmente útil para aferir a fidelidade da pose em protocolos de *re-docking* ou *docking* cruzado.

Em um contexto mais amplo, métricas de desempenho classificatório como as curvas ROC (*Receiver Operating Characteristic*), a área sob a curva (AUC, do inglês, *Area Under the Curve*) e indicadores de enriquecimento, como o EF (*Enrichment Factor*) e o BEDROC (*Boltzmann-*

Enhanced Discrimination of Receiver Operating Characteristic), são utilizadas para quantificar a capacidade do modelo em distinguir compostos ativos de inativos, contribuindo assim para a validação da estratégia computacional adotada.

Além das métricas quantitativas, técnicas de minimização de energia são aplicadas para ajustar as geometrias dos complexos, utilizando algoritmos baseados em campos de força que reavaliam a estabilidade conformacional. Métodos mais rigorosos, como os cálculos de energia livre utilizando MM/GBSA (*Molecular Mechanics Generalized Born Surface Area*) e MM/PBSA (*Molecular Mechanics Poisson–Boltzmann Surface Area*), são frequentemente empregados como reprocessamento posterior, proporcionando estimativas eficazes da afinidade de ligação (SAHAKYAN, 2021). Esses métodos têm demonstrado eficiência na reclassificação de poses de *docking* e na melhoria da correlação com dados experimentais (JIANG et al., 2024).

Adicionalmente, simulações de dinâmica molecular oferecem uma abordagem abrangente para explorar a estabilidade das interações ao longo do tempo e sob flutuações térmicas. Essas simulações são particularmente úteis na análise de sítios de ligação flexíveis ou de interações mediadas por solvente, permitindo a consideração explícita da flexibilidade conformacional tanto do ligante quanto do receptor (JIANG et al., 2024). Estudos recentes demonstraram que protocolos de refinamento baseados em dinâmica molecular podem melhorar significativamente a precisão das poses de *docking*, especialmente em casos mais complexos envolvendo peptídeos flexíveis ou doenças multifatoriais (SAHU et al., 2024; BORAH et al., 2023).

3.5 Dinâmica Molecular

A dinâmica molecular (DM) é uma técnica computacional amplamente empregada na simulação do comportamento de sistemas atômico-moleculares ao longo do tempo, fundamentada na integração das equações do movimento de Newton. A partir da aplicação de campos de força previamente parametrizados, que descrevem as interações interatômicas, torna-se possível calcular as forças atuantes sobre cada átomo e, consequentemente, prever suas posições e velocidades futuras. Essa abordagem permite estimar trajetórias conformacionais detalhadas, refletindo a evolução estrutural e energética de biomoléculas em resposta a distintas condições físico-químicas, como variações de temperatura, pressão ou composição do meio (WEINBERG et al., 2022).

Os campos de força clássicos utilizados em DM descrevem a energia potencial total do sistema como uma soma de componentes associados a interações ligadas (ligações covalentes, ângulos e torções) e não ligadas (interações eletrostáticas e de van der Waals). Modelos amplamente utilizados, como *AMBER*, *CHARMM*, *OPLS-AA* e *GROMOS*, fornecem parametrizações específicas para proteínas, ácidos nucleicos, lipídios e pequenas moléculas, viabilizando a simulação de sistemas biológicos com elevado grau de precisão (KASHEFOLGHETA et al., 2021).

A evolução temporal do sistema em DM é obtida por meio de métodos numéricos de integração das equações do movimento, destacando-se algoritmos clássicos como Verlet (BADAR et al., 2022), Leap-Frog (MANDAL et al., 2022) e Velocity-Verlet (MolSSI Education, 2021). Além disso, integradores estocásticos baseados na equação de Langevin, que incorporam termos

de fricção e ruído térmico, permitem simultaneamente a atualização das coordenadas atômicas e o controle da temperatura do sistema, funcionando como um termostato implícito (EASTMAN et al., 2023; GARRIGA-ALONSO; FORTUIN, 2021). Nesse contexto, as simulações são geralmente conduzidas sob condições de contorno periódicas, empregando algoritmos específicos para controle termodinâmico, tais como os termostatos de Berendsen e Andersen, além dos barostatos de Parrinello–Rahman e Nosé–Hoover (TOXVAERD, 2024; KE et al., 2022). Esses métodos asseguram a conservação adequada das propriedades termodinâmicas do sistema ao longo da simulação, conforme os pressupostos de diferentes conjuntos estatísticos (*ensembles*) da biomecânica, tais como o *ensemble* microcanônico (NVE[16]), o *ensemble* canônico (NVT[17]) e o *ensemble* isobárico-isotérmico (NPT[18]) (KE et al., 2022; ZHOU; LIU, 2022).

Já o intervalo de tempo entre os passos de integração (tipicamente 1 a 2 femtossegundos) e a duração total das simulações (variando de nanosegundos a microssegundos, ou mais) determinam a resolução temporal e a capacidade de captura de eventos conformacionais de interesse, como reorganizações locais de sítios ativos, formação ou quebra de interações moleculares, e transições conformacionais globais. A DM, portanto, se destaca por sua habilidade de incorporar explicitamente a flexibilidade estrutural das biomoléculas e os efeitos dinâmicos do solvente, aspectos frequentemente negligenciados em métodos estáticos como o *docking* convencional (HOLLINGSWORTH; DROR, 2018).

3.5.1 Ferramentas e Ambientes de Simulação

A realização de simulações de DM requer ambientes computacionais especializados, que integram rotinas de preparação de sistemas, definição de parâmetros físico-químicos, integração numérica das equações de movimento e análise posterior dos dados gerados. Ao longo das últimas décadas, diversas ferramentas de alto desempenho foram desenvolvidas para esse fim, oferecendo implementações otimizadas para diferentes arquiteturas de *hardware*, compatibilidade com campos de força e ampla flexibilidade na configuração de experimentos computacionais (HOLLINGSWORTH; DROR, 2018).

Entre os pacotes bem consolidados no domínio da DM, tem-se o *GROMACS* (*GROningen MAchine for Chemical Simulations*), amplamente reconhecido por sua notável eficiência computacional, sobretudo em simulações de grande escala. Sua arquitetura suporta paralelização intensiva e incorpora otimizações específicas para CPU e GPU, o que o torna especialmente indicado para estudos envolvendo milhões de átomos em extensos períodos simulados. Sua estrutura modular, aliada a uma documentação detalhada e a uma comunidade ativa, favorece sua adoção por usuários com diferentes níveis de experiência. Além disso, apresenta elevada robustez e acurácia na modelagem de sistemas biomoleculares complexos, como proteínas, bicamadas lipídicas e complexos proteína-ligante, sendo amplamente empregado em investigações

[16]Mantém constante o número de partículas (N), o volume (V) e a energia total (E); representa um sistema isolado, sem trocas de energia com o ambiente.

[17]Mantém constante o número de partículas (N), o volume (V) e a temperatura (T); a energia pode flutuar, sendo a temperatura controlada por um termostato.

[18]Mantém constante o número de partículas (N), a pressão (P) e a temperatura (T); o volume do sistema é variável e controlado por um barostato.

que exigem desempenho elevado e rigor metodológico (REDKAR; RAMAKRISHNAN, 2023; PÁLL et al., 2020).

O *AMBER* (*Assisted Model Building with Energy Refinement*), por sua vez, constitui uma suíte abrangente de programas voltados à preparação, simulação e análise de sistemas moleculares, com ênfase em biomoléculas. Uma de suas principais características é a integração com campos de força altamente parametrizados e validados para proteínas, ácidos nucleicos e ligantes, o que o torna particularmente eficaz na modelagem precisa de interações moleculares. Sua utilização é amplamente reconhecida em estimativas de energia livre por meio de métodos como MM/GBSA e MM/PBSA, além de oferecer suporte avançado para parametrização de pequenas moléculas e sistemas híbridos, incluindo ambientes explícitos e implícitos de solvatação (CASE et al., 2023a; CASE et al., 2023b).

Outro destaque entre os pacotes de simulação molecular é o *NAMD* (*Nanoscale Molecular Dynamics*), desenvolvido com foco em desempenho escalável em ambientes de computação de alto desempenho. Projetado para simulações paralelas em arquiteturas distribuídas, o *NAMD* apresenta excelente eficiência em sistemas biomoleculares de grande porte, como proteínas de membrana, complexos supramoleculares e até vírus completos. Sua arquitetura paralela, baseada no modelo de programação *Charm++*[19], permite que simulações sejam executadas eficientemente em milhares de núcleos de processamento, com alto grau de escalabilidade. Um de seus diferenciais é sua integração nativa com o *VMD* (*Visual Molecular Dynamics*), o que possibilita a visualização interativa, em tempo real, das simulações em execução. Essa funcionalidade favorece a análise qualitativa de fenômenos dinâmicos complexos e contribui para a exploração visual de eventos raros ou transientes, como processos de reconhecimento molecular e translocação em membranas (PANT et al., 2025; PHILLIPS et al., 2020).

Em um cenário complementar às ferramentas voltadas à computação de alto desempenho, o *OpenMM* destaca-se como uma biblioteca de simulação molecular de código aberto, projetada com ênfase em flexibilidade, extensibilidade e desempenho em arquiteturas CPU e GPU. Desenvolvido para ser altamente programável, o *OpenMM* oferece uma interface em Python que permite a customização de protocolos de simulação, bem como a criação de forças personalizadas e a implementação de novos algoritmos de integração, tornando-se uma plataforma atrativa tanto para usuários finais quanto para desenvolvedores de métodos. Embora seja compatível com simulações tradicionais nos *ensembles NVE*, *NVT* e *NPT*, sua arquitetura orientada a GPU permite ganhos expressivos de desempenho mesmo em estações de trabalho convencionais, tornando-o especialmente útil em etapas de triagem, refinamento e prototipagem rápida de experimentos computacionais. Além disso, sua integração com campos de força amplamente utilizados (como *AMBER*, *CHARMM* e *OpenFF*) facilita a preparação e execução de simulações em sistemas biológicos diversos, incluindo proteínas, ligantes e complexos supramoleculares (EASTMAN et al., 2023).

Entre os avanços recentes que ampliam o potencial de análise do *OpenMM*, tem-se a incorporação de metodologias avançadas de amostragem, com destaque para o *GaMD* (*Gaussian*

[19]https://charmplusplus.org/

Accelerated Molecular Dynamics). Essa técnica, recentemente implementada na plataforma, permite expandir de forma eficiente a cobertura do espaço conformacional de sistemas biomoleculares, dispensando a aplicação de coordenadas coletivas previamente definidas para o direcionamento da amostragem. Ao suavizar a superfície de energia potencial por meio de um potencial gaussiano adaptativo, o *GaMD* viabiliza a observação de eventos raros e transições conformacionais que seriam inacessíveis em escalas de tempo convencionais, constituindo-se como uma alternativa para o estudo de processos cinéticos e de mecanismos moleculares complexos (COPELAND et al., 2022; WANG et al., 2021b).

A crescente sofisticação desses métodos tem impulsionado o desenvolvimento de ferramentas voltadas à integração e automação de *workflows* em DM. Nesse contexto, o *BioSimSpace* (BARIAMI et al., 2023) surge como uma solução promissora, ao oferecer uma abordagem interoperável que abstrai a complexidade técnica envolvida na orquestração de múltiplos pacotes de simulação. Desenvolvido com o objetivo de facilitar a prototipagem de *workflows* personalizáveis, o *BioSimSpace* provê uma interface unificada, escrita em Python, que permite combinar rotinas de preparação, parametrização, simulação e análise provenientes de ferramentas consagradas, como *GROMACS*, *AMBER* e o próprio *OpenMM*. Com foco na reprodutibilidade científica e na modularidade, essa plataforma tem se mostrado particularmente útil em estudos que demandam a integração de simulações biomoleculares com estratégias de triagem virtual, geração de farmacóforos e cálculo de afinidades de ligação (HEDGES et al., 2019).

Outro ambiente computacional de destaque é o *HTMD* (*High-Throughput Molecular Dynamics*), que se diferencia por sua capacidade de orquestrar simulações de forma massiva e automatizada, com ênfase em aplicações de descoberta de fármacos baseadas em DM. O *HTMD* provê ferramentas para preparação sistemática de sistemas, amostragem extensiva de estados conformacionais e análise automatizada baseada em métodos de modelagem markoviana. Sua arquitetura favorece a execução de simulações paralelas em larga escala, sendo especialmente adequada para estudos de reconhecimento molecular, mapeamento de sítios de ligação e análise cinética de processos bioquímicos (DOERR et al., 2017).

Complementando essa abordagem orientada à automação, o *BioBB* (*BioExcel Building Blocks*) oferece uma coleção modular de blocos computacionais reutilizáveis, projetados para compor *workflows* em bioinformática estrutural e simulações moleculares. Desenvolvido no contexto da infraestrutura europeia *BioExcel* (BAYARRI et al., 2022), o *BioBB* adota uma filosofia de interoperabilidade baseada em contêineres e linguagens de descrição de *workflow* (como CWL[20] e Nextflow[21]), permitindo que diferentes ferramentas de simulação, preparação de topologias, minimização e análise sejam integradas de forma transparente. Essa estrutura facilita a execução padronizada e reprodutível de experimentos computacionais em plataformas locais ou na nuvem, promovendo boas práticas científicas e rastreabilidade (ANDRIO et al., 2019).

Apesar dos avanços expressivos nas ferramentas de DM, bem como na automação das etapas de preparação e execução das simulações, a fase subsequente, centrada na análise quantitativa

[20] https://www.commonwl.org/
[21] https://www.nextflow.io/

e interpretativa das trajetórias geradas, permanece frequentemente subexplorada e, em muitos casos, negligenciada nos *workflows* computacionais propostos. A elevada complexidade dos dados envolvidos, associada à heterogeneidade de formatos, protocolos e representações estruturais, impõe desafios consideráveis à extração sistemática de informações biofísicas relevantes. Nesse contexto, torna-se necessário o uso de bibliotecas especializadas que possibilitem uma análise adequada, contemplando desde o processamento inicial dos dados até a geração de representações interpretáveis dos resultados.

Entre essas ferramentas, tem-se a *MDAnalysis* e a *MDTraj*, amplamente adotadas na comunidade científica em razão de sua versatilidade, desempenho e compatibilidade com os principais pacotes de simulação. Ambas oferecem interfaces programáveis em Python que permitem o desenvolvimento de rotinas analíticas personalizadas, abrangendo o cálculo de propriedades estruturais (como RMSD, RMSF, ligações de hidrogênio e raio de giro), a caracterização de flutuações conformacionais, a identificação de interações intermoleculares e a construção de *workflows* escaláveis, modulares e reprodutíveis, integráveis a diversos contextos de pesquisa em bioengenharia computacional.

O *MDAnalysis*, em particular, distingue-se por sua arquitetura orientada a objetos, que permite a manipulação eficiente de entidades moleculares — como átomos, resíduos e cadeias e a definição de seleções espaciais sofisticadas. A biblioteca é compatível com uma ampla gama de formatos de entrada, incluindo arquivos provenientes de softwares como *GROMACS*, *AMBER*, *NAMD*, *CHARMM* e *OpenMM*. Seu conjunto abrangente de funcionalidades permite a realização de análises automatizadas de propriedades estruturais e dinâmicas, incluindo funções de distribuição radial (RDF), além das métricas convencionais. Ademais, a integração nativa com bibliotecas do ecossistema científico em Python como *NumPy*[22], *Matplotlib*[23] e *Pandas* favorece a criação de *workflows* de análise amplos, interativos e facilmente reproduzíveis, configurando o MDAnalysis como uma alternativa eficaz para a análise pós-simulação (NAUGHTON et al., 2022).

De forma complementar, o *MDTraj* propõe uma abordagem leve e altamente otimizada para o processamento de trajetórias moleculares em larga escala. Desenvolvido com foco em desempenho e simplicidade, permite o carregamento e a manipulação eficientes de simulações extensas por meio de uma interface clara e expressiva. A biblioteca implementa diversos algoritmos para o cálculo de métricas estruturais, como distâncias interatômicas, ângulos, torções, RMSD e análise de componentes principais (PCA, do inglês *Principal Component Analysis*) para identificação de conformações dominantes. Adicionalmente, oferece suporte à conversão entre diferentes formatos e à visualização de trajetórias em múltiplas resoluções temporais. Sua interoperabilidade com bibliotecas como *scikit-learn* e *Matplotlib* potencializa sua aplicação em análises exploratórias, agrupamento conformacional (*clustering*) e avaliação da convergência de simulações (MCGIBBON et al., 2015).

Quando utilizadas de forma integrada e complementar, essas ferramentas constituem um amplo arcabouço para a execução e análise de simulações de DM, ampliando substancialmente

[22]https://numpy.org/
[23]https://matplotlib.org/

o escopo exploratório desses experimentos. Essa infraestrutura não apenas viabiliza análises descritivas e inferências quantitativas de alto nível, como também fornece as bases para abordagens preditivas fundamentadas em aprendizado de máquina. Ao possibilitar a extração sistemática e criteriosa de representações estruturais e dinâmicas, tornam-se adequadas para a geração de conjuntos de dados de alta qualidade, frequentemente indispensáveis para o treinamento, validação e avaliação de modelos de IA com aplicações classificatórias e preditivas no domínio da bioengenharia.

3.6 Inteligência Artificial

A incorporação progressiva de técnicas de IA, especialmente aquelas fundamentadas em ML, RNA e DL, tem promovido uma transformação substancial nos paradigmas clássicos da bioengenharia computacional. No âmbito da descoberta e reposicionamento de fármacos mediados por abordagens *in silico*, tais avanços vêm ampliando significativamente as capacidades preditivas, classificatórias e exploratórias das soluções computacionais empregadas na CADD, com impactos diretos na acurácia, escalabilidade e eficiência de processos como TV e, de forma particularmente expressiva, na HTVS (NOOR et al., 2024; BOLDINI et al., 2024). Entre os fatores que mais contribuem para isso, destacam-se três pilares interdependentes: (i) a crescente disponibilidade de dados biológicos, estruturais e químicos em larga escala; (ii) o avanço das infraestruturas computacionais, que permite o processamento paralelo de extensas bibliotecas moleculares; e (iii) o desenvolvimento de algoritmos avançados, capazes de identificar correlações não triviais, inferir relações latentes e generalizar padrões complexos em conjuntos de dados de alta dimensionalidade (HELLECKES et al., 2023; RONG et al., 2020).

Para contextualizar o impacto e relevância dessas transformações, é necessário revisitar os fundamentos tradicionais do CADD. Conforme discutido neste capítulo, métodos clássicos de *docking* molecular e simulações de DM exemplificam abordagens mecanicistas baseadas em princípios físico-químicos fundamentais. O *docking*, por exemplo, busca predizer modos de ligação por meio da amostragem sistemática de conformações e posições do ligante no sítio ativo do receptor, com avaliação por funções de pontuação baseadas em critérios empíricos, semiempíricos, estatísticos ou baseados em campos de força. Já as simulações de DM resolvem numericamente as equações do movimento de Newton, permitindo uma análise temporal detalhada da estabilidade conformacional de complexos ligante-receptor (WAN; SINCLAIR; COVENEY, 2021; NUNES-ALVES; KOKH; WADE, 2020; RYCKER et al., 2018; SALMASO; MORO, 2018).

Embora amplamente empregados, esses métodos determinísticos vêm sendo progressivamente complementados, e em alguns casos reconfigurados, por abordagens orientadas por dados, impulsionadas pela IA. Diferentemente das estratégias mecanicistas, modelos baseados em IA não exigem conhecimento explícito sobre os mecanismos moleculares subjacentes, operando de forma não determinística e aprendendo representações abstratas a partir dos dados. Essas abordagens têm se mostrado eficazes em tarefas como pré-processamento e filtragem de bibliotecas químicas, priorização automatizada de compostos bioativos e predição de propriedades farmacocinéticas e toxicológicas, otimizando etapas essenciais da TV/HTVS. Nesse contexto,

ainda é possível observar a consolidação de uma abordagem híbrida e emergente, que integra os fundamentos físico-químicos dos métodos clássicos com o poder classificatório e preditivo de modelos baseados em dados, por IA. Essa convergência dá origem ao paradigma conhecido como AIDD, caracterizado pela capacidade de explorar o espaço químico-biológico de forma ampla e integrativa, promovendo avanços substanciais na descoberta racional de novos fármacos em múltiplos níveis e escalas (VEMULA et al., 2023; LEE et al., 2022; KIM et al., 2020).

Em cenários de HTVS, nos quais milhões de compostos são avaliados frente a alvos biomoleculares específicos, a AIDD tem se consolidado como um componente estratégico fundamental. Sua adoção viabiliza a filtragem inteligente de bibliotecas moleculares, a redução eficiente do espaço químico e a identificação de *hits* promissores com maior precisão, aliando a isso menor custo computacional e tempo de exploração e processamento. Para isso, diferentes *workflows* incorporam, de forma recorrente, modelos preditivos treinados com dados experimentais, representações moleculares aprendidas por RNAs, DL e estratégias de aprendizado ativo, otimizando adaptativamente cada etapa do processo de triagem em larga escala.

Além das contribuições substanciais observadas nas fases iniciais da TV/HTVS, avanços mais recentes em IA têm expandido significativamente seu escopo de aplicação para as etapas finais e mais desafiadoras da modelagem biomolecular, incluindo as simulações de DM. Nesse contexto ampliado, modelos baseados em RNAs, DL e representações latentes de alta dimensionalidade têm possibilitado tarefas avançadas, como a predição da estabilidade conformacional de complexos proteína-ligante, a identificação automatizada de estados metaestáveis e a análise quantitativa de trajetórias moleculares (NOVELLI et al., 2022; DOERR et al., 2021; SIDKY; CHEN; FERGUSON, 2020).

Esse novo espectro de capacidades, introduzido pela integração de estratégias baseadas em IA nos *workflows* de CADD/AIDD, agrega uma nova perspectiva à exploração do espaço conformacional, promovendo não apenas a redução significativa do custo computacional, mas também um aprofundamento analítico na caracterização das propriedades dinâmicas de sistemas biológicos simulados. Tais abordagens assumem particular relevância em cenários biomoleculares de elevada complexidade, como nos estudos voltados às doenças neurodegenerativas, em especial para contextos como o da DA, em que múltiplas vias patológicas interagem de forma interdependente. Nesses casos, estratégias computacionais multiescalares e integrativas, que conciliem predições estatísticas baseadas em IA com inferências físico-químicas bem fundamentadas, constituem uma contribuição substancial para o avanço do entendimento dos mecanismos etiológicos subjacentes e para o delineamento racional de novas intervenções terapêuticas.

Sob esse panorama de inovações metodológicas, a Tabela 3.1 apresenta uma síntese estruturada das principais classes de algoritmos de IA atualmente empregados nas diferentes fases do *workflow* computacional de CADD/AIDD. As etapas foram organizadas segundo uma lógica sequencial que reflete o fluxo típico de trabalho: desde o pré-processamento e a representação molecular inicial até a geração de novos compostos, análise dinâmica, validação preditiva e integração híbrida por meio de abordagens orientadas a dados. Tal organização elucida não apenas a diversidade das estratégias existentes, mas também o amadurecimento progressivo

dessas técnicas, que têm promovido avanços significativos em acurácia, eficiência computacional e, sobretudo, na viabilidade de sua aplicação em contextos clínicos e experimentais, muitas vezes promovidos pela redução dos custos e do tempo envolvidos.

A diversidade e sofisticação das contribuições sintetizadas na Tabela 3.1 evidenciam a profunda transformação promovida pela IA e suas vertentes (como, ML, RNA e DL) no aprimoramento contínuo dos *workflows* computacionais voltados à descoberta, otimização e reposicionamento de fármacos. Entretanto, a eficácia dessas abordagens está intrinsecamente vinculada à qualidade, consistência e representatividade dos dados empregados nas fases de treinamento, validação e inferência dos modelos. Nesse sentido, a preparação de dados se apresenta como um componente estruturante e estratégico, influenciando de forma considerável a acurácia preditiva, a interpretabilidade algorítmica e a reprodutibilidade científica dos resultados.

3.6.1 Preparação e Normalização de Dados

A preparação e normalização de dados constituem etapas importantes para o sucesso de modelos baseados em IA, especialmente no contexto de aplicações em CADD/AIDD. Aspectos como a integridade, a padronização e a diversidade informacional dos dados influenciam diretamente a capacidade preditiva, a generalização e a eficácia dos modelos desenvolvidos. Nesse cenário, é comum a adoção de processos de preparação e normalização organizados em múltiplos estágios, que se estendem desde a curadoria inicial de compostos químicos e biomoleculares até etapas subsequentes de vetorização, anotação e balanceamento dos conjuntos de dados, sendo esses requisitos indispensáveis para o desenvolvimento de estratégias computacionais eficazes e cientificamente reprodutíveis (LEE et al., 2022).

A curadoria de bibliotecas químicas constitui o primeiro passo no desenvolvimento de modelos computacionais eficazes em bioinformática e descoberta de fármacos. Nesse processo, são conduzidas ações criteriosas para a remoção de compostos redundantes, sais, contraíons, além de estruturas incompletas, instáveis ou incompatíveis com o contexto bioquímico investigado. De forma complementar, filtros baseados em propriedades físico-químicas relevantes como massa molecular, número de rotâmeros, presença de grupos reativos e instabilidades eletrônicas podem ser utilizados com o propósito de assegurar a integridade, consistência e representatividade das entradas moleculares. Procedimentos adicionais de normalização estrutural, incluindo o ajuste de estados de protonação, tautomerização e estereoquímica (como centros quirais), contribuem para a padronização conformacional sob condições simuladas específicas. Essas práticas minimizam a introdução de ruídos sistemáticos e favorecem a performance de métricas avaliativas aplicadas a modelos classificatórios e preditivos (KING, 2025; LAWLESS et al., 2016).

Para além da qualidade estrutural, a robustez estatística dos conjuntos de dados é igualmente essencial. Em muitos casos, observa-se um desbalanceamento significativo entre classes, como entre compostos ativos e inativos, o que pode comprometer o desempenho preditivo de certos modelos de IA. Para contornar esse problema, são amplamente adotadas técnicas de reamostragem, incluindo subamostragem e superamostragem, sendo esta última frequentemente implementada com algoritmos avançados, como o SMOTE (*Synthetic Minority Over-sampling*

Tabela 3.1: Síntese dos principais avanços promovidos por técnicas de Inteligência Artificial (IA), Aprendizado de Máquina (ML), Aprendizado Profundo (DL) e abordagens híbridas (AIDD) ao longo das distintas etapas do *workflow* computacional de descoberta e desenvolvimento de fármacos (CADD). A tabela destaca, de forma estruturada, contribuições metodológicas, impactos diretos na triagem virtual convencional e de alto desempenho (TV/HTVS), bem como perspectivas integrativas que viabilizam a transição para abordagens multiescalares, preditivas e centradas em dados.

Etapa do *workflow*	**Avanços com IA/ML/DL/AIDD**	**Impacto na TV/HTVS**	**Referências**
Pré-processamento	Técnicas de clustering (e.g., K-means, DBSCAN), redução de dimensionalidade (PCA, t-SNE), filtragem automatizada, análise de similaridade molecular	Otimização do espaço químico com eliminação de redundâncias e compostos irrelevantes, promovendo escalabilidade e eficiência computacional nas etapas posteriores.	(TRIPATHI; BANDYOPADHYAY, 2022; GANDINI et al., 2022; YANG et al., 2021; GOH et al., 2017; GALLY et al., 2017)
Representação molecular	Representações vetoriais via redes neurais gráficas (GNNs), autoencoders, *fingerprints*, *embeddings* inspirados em NLP (e.g., Mol2Vec, SMILES2Vec)	Aumento da expressividade molecular e da acurácia em tarefas de regressão e classificação, facilitando a generalização dos modelos	(WANG; LI; FARIMANI, 2023; NASSER et al., 2022; SUN et al., 2021; DING et al., 2021; SUN et al., 2020; CAPECCHI; PROBST; REYMOND, 2020; ZANG; WANG, 2020; HAGBERG; SWART; SCHULT, 2008)
Predição de propriedades	Modelos supervisionados (RF, SVM, XGBoost), redes profundas (DNNs, CNNs) para estimativas de solubilidade, permeabilidade, toxicidade e ADMET	Antecipação de falhas em fases tardias do desenvolvimento farmacológico, priorizando compostos com perfis favoráveis	(YANG et al., 2023; CAI et al., 2022; AHN; LEE; KIM, 2022; ISHFAQ et al., 2022; SHAN et al., 2021; LIANG et al., 2020)
Triagem virtual ativa	Modelos QSAR baseados em aprendizado profundo, arquiteturas Siamese, GraphDTA, e sistemas de recomendação molecular	Redução do tempo de triagem com aumento da taxa de acerto (hit rate) e priorização mais precisa de compostos candidatos	(CAO; SCIABOLA; WANG, 2024; ZENG et al., 2024; OLIVEIRA et al., 2023a; GRAFF; SHAKHNOVICH; COLEY, 2021)
Docking* e pós-*docking	Aprimoramento de funções de pontuação com DL (e.g., AtomNet, DeepDock), refinamento por aprendizado reforçado e redes generativas	Maior fidelidade preditiva nas interações ligante-receptor e melhor correlação com resultados experimentais	(MCNUTT et al., 2025; HONG et al., 2024; WANG; WEI; XI, 2022; SHEN et al., 2020)
Validação preditiva *in silico*	Curvas ROC-AUC, precisão média, métricas de generalização cruzada; uso de ensembles e validação externa com bancos de dados independentes	Aumento da robustez e da confiabilidade dos modelos aplicados à TV/HTVS em cenários realistas	(HAN et al., 2025; KC et al., 2021; GÖLLER et al., 2020; ABRAHAMSSON et al., 2020)
Geração de novos compostos (*de novo design*)	Redes adversariais generativas (GANs), modelos autoregressivos e transformers (e.g., ChemGPT), RL para otimização de propriedades	Expansão racional do espaço químico com foco em moléculas sinteticamente viáveis e farmacologicamente relevantes	(ALAKHDAR; POCZOS; WASHBURN, 2024; SCHNEUING et al., 2024; LIN; LIN; LANE, 2022; ANISHCHENKO et al., 2021; TONG et al., 2021; JOO et al., 2020)
Dinâmica/simulação molecular	Predição de estabilidade conformacional e análise de trajetórias com GNNs, clustering de estados conformacionais com ML não supervisionado	Complementação de TV/HTVS com análises dinâmicas de flexibilidade, acessibilidade e persistência de interações	(BAI et al., 2022; KANG; SHANG; LIU, 2020; GKEKA et al., 2020; WANG et al., 2020)
Integração híbrida AIDD	Integração de múltiplas etapas com pipelines orientados por dados (e.g., DeepChem, DrugEx, TorchDrug), sistemas autônomos de descoberta	Sinergia entre etapas, promovendo otimização fim-a-fim com melhor balanceamento entre explorabilidade e explotabilidade do espaço químico	(SHAH et al., 2025; CATACUTAN et al., 2024; FLORES-HERNANDEZ; MARTINEZ-LEDESMA, 2024; JAYATUNGA et al., 2024; CATACUTAN et al., 2024; SADYBEKOV; KATRITCH, 2023; GUO, 2023)

Technique) (NITESH, 2002; MANSOURIFAR; SHI, 2020). Estratégias adicionais, como a ponderação de classes no processo de treinamento, também são empregadas para atenuar vieses induzidos pela distribuição desigual dos dados (BENKENDORF et al., 2023).

A correta divisão dos dados em conjuntos de treinamento, validação e teste representa outro ponto fundamental da curadoria estatística. Nesse contexto, métodos como o *scaffold splitting* têm ganhado destaque por basearem a separação dos dados na diversidade das subestruturas moleculares (*scaffolds*), promovendo uma avaliação mais realista da capacidade de generalização dos modelos, sobretudo frente a estruturas químicas ainda não observadas durante o aprendizado (GUO; HERNANDEZ-HERNANDEZ; BALLESTER, 2024; DENG et al., 2023; LIM et al., 2020). Já para cenários caracterizados pela escassez de informação rotulada, a aplicação de estratégias de ampliação dos dados (*data augmentation*[24]) tem-se mostrado promissora. Técnicas como a geração de diferentes representações sintáticas de uma mesma molécula (e.g., permutações em notações SMILES), rotações aleatórias em representações tridimensionais e a introdução controlada de ruídos em grafos moleculares constituem abordagens eficazes para aumentar a diversidade do conjunto de dados sem comprometer sua validade estrutural ou biológica. Essas estratégias não apenas ampliam a cobertura do espaço químico, como também contribuem para a robustez e generalização dos modelos preditivos treinados sobre tais condições restritivas (JIANG et al., 2023; KIM et al., 2021a).

Uma vez concluída a curadoria, tem-se como etapa subsequente a conversão das estruturas químicas em representações matemáticas compatíveis com algoritmos de IA. Essa etapa, denominada vetorização molecular, constitui um ponto de articulação entre a descrição estrutural das moléculas e os métodos computacionais de modelagem, viabilizando a aplicação eficaz de estratégias baseadas em IA no contexto do CADD/AIDD.

O propósito da vetorização molecular é viabilizar a transformação das representações químicas em vetores estruturados, de forma compatível com os algoritmos e paradigmas elucidados na Tabela 3.1. Dentre as abordagens comumente empregadas nesse processo, destacam-se as assinaturas moleculares (*fingerprints*) estruturais, que codificam informações topológicas e subestruturais das moléculas em vetores binários ou contínuos. Essas representações permitem a análise de padrões estruturais relevantes, funcionando como base computacional para tarefas supervisionadas ou não supervisionadas de predição, classificação ou agrupamento no domínio químico-farmacêutico (DAVID et al., 2020).

Diversas metodologias de vetorização podem ser utilizadas, a depender do grau de representatividade e do tipo de informação química desejada. Os *fingerprints* do tipo MACCS, por exemplo, fundamentam-se em um conjunto predefinido de padrões subestruturais, facilitando a identificação de relações recorrentes. Já em representações circulares, como Morgan (também conhecidas como ECFP), são empregados algoritmos de expansão radial centrados nos átomos para codificar vizinhanças atômicas com elevado poder descritivo (ZHOU; SKOLNICK, 2024; KUWAHARA; GAO, 2021). De forma complementar, tem-se observado crescente adoção de

[24]Data Augmentation (Aumento de Dados): É uma técnica essencial em IA, especialmente para ML, que visa expandir a quantidade e diversidade de um conjunto de dados de treinamento. Isso é feito criando novas amostras a partir das existentes através de transformações leves e controladas.

assinaturas farmacofóricas, que descrevem os compostos com base na presença e na disposição espacial de funcionalidades químicas à interação molecular, tais como doadores e aceptores de ligações de hidrogênio, grupos hidrofóbicos e centros aromáticos (YANG et al., 2022; MUEGGE; MUKHERJEE, 2016). Um exemplo ilustrativo de como essas representações são geradas pode ser observado na representação esquemática da Figura 3.2.

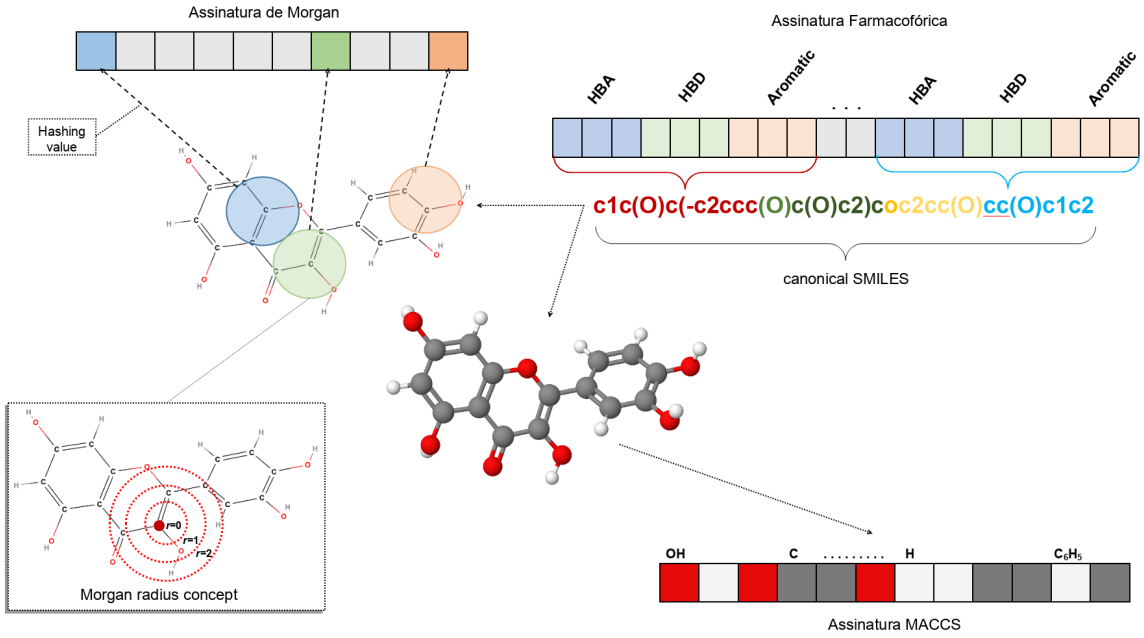

Figura 3.2: Representação esquemática do processo de geração de três tipos de *fingerprints* moleculares amplamente utilizados em aplicações de IA no contexto de CADD/AIDD: Morgan, farmacofóricos e MACCS. As impressões digitais de Morgan, baseadas em algoritmos de expansão radial centrados nos átomos, codificam a vizinhança química em torno de cada átomo até um determinado raio (geralmente $r = 2$), gerando comumente uma representação binária de 2.048 bits. Nessa codificação, características estruturais como tipos atômicos, hibridização, estados de carga e conectividade são consideradas como informações potenciais mapeáveis, enquanto relações de ligação não são explicitamente codificadas. As assinaturas farmacofóricas, por sua vez, descrevem os arranjos espaciais relativos entre grupos funcionais-chave (doadores e aceptores de hidrogênio, regiões hidrofóbicas, cargas positivas e negativas, entre outros), resultando em uma representação sensível ao potencial de interação molecular. Já os *fingerprints* MACCS consistem em um vetor binário de 166 bits, no qual cada posição corresponde à presença ou ausência de uma subestrutura química predefinida segundo um conjunto fixo de padrões estruturais. Essas diferentes abordagens oferecem descrições complementares das moléculas, variando quanto à especificidade estrutural, sensibilidade topológica e aplicabilidade em tarefas de triagem, classificação e predição molecular.

Conforme elucidado no modelo esquemático da Figura 3.2, entre as diversas estratégias para a vetorização molecular atualmente disponíveis, aquelas baseadas na notação SMILES, especialmente em sua forma canônica, figuram como o padrão mais utilizado. Fundamentada em uma codificação linear e compacta em formato ASCII[25], a notação SMILES permite descrever de maneira precisa a estrutura molecular, conciliando simplicidade sintática com elevado grau de expressividade estrutural (DAVID et al., 2020).

De acordo com Kikuchi et al. (2025) e Chandrasekhar et al. (2023), a adoção do SMILES canônico como entrada padronizada para algoritmos de vetorização fundamenta-se em diferentes aspectos técnicos e computacionais. Primeiramente, sua natureza determinística assegura representações consistentes e reprodutíveis para uma mesma entidade química, minimizando redundâncias e inconsistências durante as etapas de curadoria e pré-processamento. Em segundo lugar, sua padronização descritiva apresenta elevada interoperabilidade com ambientes

[25]O padrão ASCII (*American Standard Code for Information Interchange*) define uma codificação textual baseada em valores numéricos entre 0 e 127, permitindo a representação de caracteres alfanuméricos e símbolos com ampla compatibilidade entre sistemas computacionais.

computacionais amplamente utilizados, como RDKit, Open Babel, DeepChem e outros, atuando como elo facilitador entre a química estrutural tradicional e os métodos computacionais. Adicionalmente, sua estrutura tem favorecido a aplicação de modelos inspirados em Processamento de Linguagem Natural (NLP, do inglês, *Natural Language Processing*), tais como redes neurais recorrentes (RNNs, do inglês, *Recurrent Neural Network*), transformadores e autoencoders, que tratam SMILES como uma linguagem formal dotada de sintaxe e semântica química (LUONG; SINGH, 2024; CHEN et al., 2023; WANG et al., 2021a). A partir dessa abordagem, é possível extrair representações vetoriais, discretas ou contínuas, que capturam regularidades estruturais e funcionais relevantes para tarefas como predição de atividade biológica, TV, modelagem QSAR e classificação de compostos. A Tabela 3.3 apresenta uma comparação entre as principais abordagens de representação molecular empregadas em contextos CADD/AIDD, detalhando suas características, vantagens e limitações.

Tabela 3.3: Comparação entre as principais abordagens de representação molecular utilizadas em CADD/AIDD. As representações são avaliadas quanto à natureza dos dados, expressividade estrutural/farmacofórica, compatibilidade com modelos de aprendizado e limitações computacionais.

Representação	Descrição	Vantagens	Limitações
MACCS	Vetor binário de 166 bits baseado em subestruturas químicas pré-definidas	Simples, interpretável, amplamente suportado por diversas ferramentas	Pouco expressivo; baixa capacidade de diferenciação entre estruturas similares
Morgan (ECFP)	Codifica vizinhanças atômicas com raio definido utilizando hashing circular	Alta especificidade estrutural; eficaz em tarefas de similaridade e QSAR	Vetores esparsos e de alta dimensionalidade; sensível a pequenas alterações na estrutura
Assinaturas farmacofóricas	Vetores que codificam padrões farmacofóricos com base em distâncias topológicas entre grupos funcionais (doadores, aceptores, cargas, hidrofobicidade, etc.)	Captura propriedades funcionais relevantes para reconhecimento molecular; aproxima modelagem 2D e 3D implícita	Requer conhecimento farmacofórico prévio; sensível à ausência de dados conformacionais
SMILES + DL	Cadeia textual usada como entrada em modelos sequenciais (RNNs, CNNs, Transformers)	Permite aprendizado direto da sequência; compatível com técnicas de NLP e pré-treinamento	Ambiguidades sintáticas; sensível à ordem dos átomos; não explícita em topologia
GNNs	Modela a molécula como grafo atômico com agregação de vizinhança entre nós (átomos) e arestas (ligações)	Captura estrutura química de forma adaptativa; invariância a permutações atômicas	Elevado custo computacional; difícil interpretabilidade; sensível à qualidade do grafo
3D coordenadas + CNN 3D	Matrizes tridimensionais (voxels) contendo densidades atômicas utilizadas como entrada para redes convolucionais tridimensionais	Preserva conformação espacial realista; útil para modelagem de interações espaciais e afinidade ligante-receptor	Requer estruturas 3D otimizadas; alto custo de memória e processamento

Conforme introduzido na Tabela 3.3, diferentes mecanismos de vetorização molecular podem ser empregados para a geração de *fingerprints* no contexto de modelos de IA aplicados ao planejamento racional de fármacos - CADD/AIDD. A escolha da representação mais apropriada está, muitas vezes, relacionada à sua capacidade de capturar padrões estruturais, eletrônicos e topológicos relevantes ao sistema químico-biológico em análise. Contudo, para que essas representações possam ser devidamente validadas e suas propriedades discriminativas efetivamente quantificadas, torna-se essencial a utilização de métricas de desempenho adequadas, capazes de mensurar a eficácia dos modelos computacionais na caracterização do espaço químico explorado.

3.6.2 Avaliação de Desempenho: Métricas e Aplicabilidades

A avaliação quantitativa de desempenho de modelos de IA representa uma etapa indispensável na construção de soluções computacionais eficientes e cientificamente replicáveis, especialmente em domínios de elevada complexidade, como o planejamento racional de fármacos em CADD/AIDD. Segundo Oliveira (2025) e Maleki et al. (2022) , esse processo não apenas orienta a seleção e o ajuste de estratégias computacionais adequadas, como também permite a comparação sistemática entre diferentes abordagens e modelos, promovendo critérios objetivos para validação metodológica.

Em contextos como a bioengenharia computacional, onde pequenas variações preditivas podem impactar significativamente a priorização de candidatos bioativos ou a interpretação de interações moleculares, a definição de métricas de avaliação apropriadas torna-se necessária para assegurar tanto a eficácia de análise quanto a capacidade de generalização dos modelos frente a diferentes conjuntos de dados. Essas métricas exercem um papel estratégico ao longo de todo o ciclo de modelagem, influenciando diretamente múltiplas decisões técnicas fundamentais. Entre elas, destacam-se: (i) a escolha do algoritmo ou arquitetura de rede mais compatível com o problema em estudo; (ii) o ajuste sistemático de hiperparâmetros, com vistas à otimização do desempenho; (iii) a definição de estratégias para lidar com conjuntos de dados desbalanceados, como reamostragem ou penalizações direcionadas; e (iv) a identificação e seleção de atributos com maior contribuição informacional, favorecendo a construção de modelos mais eficientes, com melhor desempenho e menor complexidade computacional. Esse processo possibilita a avaliação não apenas da efetividade preditiva de um modelo frente a um determinado problema, mas também de sua sensibilidade a erros classificatórios, como falsos positivos e falsos negativos, de sua estabilidade estatística ao longo de diferentes particionamentos dos dados e de sua capacidade de generalização a cenários variados e conjuntos externos (OLIVEIRA et al., 2023a).

Para além da função de validação dos modelos, as métricas de avaliação podem ser classificadas conforme o tipo de tarefa preditiva a que se aplicam, como classificação binária, multiclasse ou regressão, e devem ser interpretadas em consonância com os objetivos específicos da modelagem, as propriedades estatísticas do conjunto de dados (e.g., presença de ruído, *outliers* ou desbalanceamento) e as implicações práticas decorrentes dos diferentes tipos de erro preditivo. A Tabela 3.5 apresenta uma síntese das principais métricas discutidas na literatura (TERVEN et al., 2025; NASER; ALAVI, 2023; ZHOU et al., 2021; NASER; ALAVI, 2020; HUDSON; COHEN, 1999), destacando suas aplicações, vantagens e limitações no contexto da modelagem voltada à bioengenharia computacional.

De acordo com Miller et al. (2024) e Adeshina, Deeds e Karanicolas (2020), a escolha das métricas de avaliação deve levar em consideração não apenas a natureza da tarefa preditiva como classificação ou regressão, mas também as implicações práticas associadas aos diferentes tipos de erro cometidos pelo modelo. Em aplicações de bioinformática e descoberta racional de fármacos, por exemplo, a ocorrência de falsos negativos pode resultar na exclusão inadvertida de compostos com potencial terapêutico, enquanto falsos positivos podem direcionar recursos a validações experimentais ineficazes ou dispendiosas.

Tabela 3.5: Principais métricas de avaliação utilizadas em modelos de IA aplicados a tarefas de classificação e regressão. A tabela descreve a aplicabilidade de cada métrica conforme o tipo de tarefa, bem como suas principais vantagens e limitações. Métricas como Acurácia, Precisão, Revocação, F1-Score e AUC-ROC são amplamente utilizadas na avaliação de classificadores, especialmente em contextos biomédicos e farmacológicos. Por sua vez, R^2, RMSE e MAE são comumente empregados na análise de desempenho de modelos de regressão, permitindo avaliar a qualidade preditiva sobre variáveis contínuas.

Métrica	**Aplicação**	**Vantagens**	**Limitações**
Acurácia	Classificação binária e multiclasse	Simples de interpretar; eficaz quando as classes estão balanceadas	Pode induzir erro em conjuntos desbalanceados
Precisão balanceada	Classificação binária e multiclasse	Considera equilíbrio entre classes; útil para dados desbalanceados	Menos intuitiva que acurácia
Precisão	Classificação binária	Útil quando falsos positivos são críticos	Ignora falsos negativos
Revocação (*Recall*)	Classificação binária	Importante quando falsos negativos são críticos (e.g., detecção de compostos ativos)	Pode gerar muitos falsos positivos
F1-Score	Classificação binária	Equilíbrio entre precisão e revocação	Pode ser insensível em distribuições assimétricas
AUC-ROC*	Classificação binária	Avalia desempenho global de classificação; independente de *threshold*	Pode ser ambíguo em bases com classes fortemente desbalanceadas
R^2 (Coef. de Determinação)	Regressão	Mede a proporção da variância explicada pelo modelo	Pode ser enganoso se usado isoladamente
MSE*	Regressão	Penaliza grandes erros; base para outras métricas como RMSE	Sensível a *outliers*
RMSE*	Regressão	Penaliza fortemente grandes erros; sensível a outliers	Menos robusto a distribuições não normais
MAE*	Regressão	Interpretação direta; menos sensível a outliers	Não distingue amplitude dos erros

* AUC: Área sob a curva ROC (*Area Under the Curve*)

* ROC: Curva que representa a relação entre a taxa de verdadeiros positivos e falsos positivos(*Receiver Operating Characteristic*)

* MSE: Erro Quadrático Médio (*Mean Squared Error*)

* RMSE: Raiz do erro quadrático médio (*Root Mean Squared Error*)

* MAE: Erro absoluto médio (*Mean Absolute Error*)

Diante desses desafios, é comum a utilização de um conjunto complementar de métricas, capaz de capturar diferentes aspectos do desempenho do modelo, sobretudo em cenários caracterizados por desbalanceamento de classes, presença de ruído ou alta heterogeneidade estrutural nos dados. A adoção de técnicas de validação cruzada, a análise de curvas de desempenho (como ROC e PRC[26]) e o uso de métricas robustas a exemplo do coeficiente de correlação de Matthews são estratégias adequadas para garantir avaliações estatisticamente sólidas, interpretáveis e alinhadas ao contexto da aplicação. Essa abordagem multifacetada de avaliação favorece a construção de modelos preditivos generalizáveis e confiáveis, além de reforçar a transparência metodológica, condição necessária para a reprodutibilidade científica e para a efetividade aplicada em estudos computacionais direcionados à inovação terapêutica.

[26]Precision-Recall Curve (Curva de Precisão vs. Revocação)

3.7 Considerações Finais

O avanço das estratégias computacionais aplicadas ao planejamento racional de fármacos tem transformado profundamente o panorama da descoberta e do reposicionamento terapêutico. Ao longo deste capítulo, foram apresentados os fundamentos, ferramentas e abordagens contemporâneas que sustentam o desenvolvimento de soluções preditivas, escaláveis e reprodutíveis, as quais têm respondido de forma eficiente aos desafios impostos pela complexidade biológica e pelas limitações dos métodos experimentais tradicionais e mecanicistas.

O fortalecimento do campo do CADD/AIDD, impulsionado por algoritmos de TV, *docking* molecular, IA e simulações de DM, tem promovido uma convergência inédita entre a inteligência computacional e o conhecimento biomolecular. Essa integração tem viabilizado avanços significativos tanto na identificação de novos candidatos bioativos quanto na reinterpretação racional de compostos previamente aprovados, ampliando as possibilidades terapêuticas frente a doenças multifatoriais e de elevada heterogeneidade, como as de natureza neurodegenerativa. Além disso, a eficácia dos *workflows* computacionais emergentes, aliada à disponibilidade de bancos de dados altamente curados e ferramentas interoperáveis, configura um novo paradigma de pesquisa em bioinformática, orientado pela eficiência analítica, pela automação de processos e pela rastreabilidade metodológica. Nesse contexto, a adoção de abordagens híbridas e o uso crescente de IA despontam como elementos-chave na superação de gargalos preditivos e na proposição de soluções terapêuticas personalizadas.

É nesse cenário dinâmico e de diversidade computacional que se insere a proposta deste trabalho. No capítulo seguinte, apresentamos os fundamentos teóricos, as motivações e os objetivos que orientaram o desenvolvimento de um novo fluxo computacional, voltado à descoberta racional de fármacos. Essa proposta enfatiza a integração entre TV, acoplamento molecular, DL e simulações moleculares de alta precisão, sendo pensada como uma arquitetura modular e multinível, composta por diferentes camadas logicamente integradas, que conferem ao fluxo de trabalho proposto atributos como flexibilidade, reprodutibilidade e extensibilidade.

Capítulo

4

DrugHunter: Um Fluxo de Trabalho Integrado para Curadoria, Triagem Virtual de Alto Desempenho e Dinâmica Molecular

4.1 Considerações Iniciais

Ao longo do desenvolvimento desta tese, foram concebidas e implementadas diversas soluções computacionais destinadas a otimizar etapas essenciais no âmbito da descoberta e do reposicionamento racional de fármacos. Este capítulo descreve a trajetória metodológica que resultou na criação do *DrugHunter*, um fluxo de trabalho integrativo e flexível, projetado para automatizar, interoperar e escalar as principais etapas do processo de CADD/AIDD, incluindo curadoria de dados, HTVS e simulações de DM.

A arquitetura do *DrugHunter* foi projetada para viabilizar a análise sistemática de extensos repositórios de dados biomoleculares, contribuindo computacionalmente para o enfrentamento da complexidade inerente às doenças emergentes, especialmente aquelas de natureza multifatorial, cujos elevados custos e prolongados prazos de desenvolvimento terapêutico impõem desafios substanciais à pesquisa biomédica. Nesse contexto, tal solução busca integrar de forma colaborativa distintas estratégias computacionais no campo da modelagem molecular, superando limitações estruturais e operacionais típicas de fluxos de análise tradicionais e mecanicistas. Essa integração resulta, entre outras vantagens, em avanços significativos em termos de eficiência, reprodutibilidade e adaptabilidade ao longo de todo o processo de exploração e triagem farmacológica.

A trajetória metodológica que fundamentou o desenvolvimento do *DrugHunter* estruturou-se a partir da concepção de duas soluções computacionais complementares, projetadas para atuar em etapas distintas, embora interdependentes, do planejamento racional de fármacos. A primeira dessas soluções, denominada *BioMolExplorer*, foi projetada como uma aplicação especializada na curadoria e preparação de bases de dados biomoleculares, permitindo a recuperação automatizada, sistemática e reprodutível de informações provenientes de repositórios amplamente reconhecidos, tais como *ChEMBL*, *PDB* e *ZINC*. Adicionalmente, incorpora um conjunto abrangente de funcionalidades que incluem: (i) a vetorização molecular, por meio de abordagens como *fingerprints* de Morgan, descritores *MACCS* e representações farmacofóricas; (ii) o cálculo de similaridade molecular, com destaque para métricas como o coeficiente de Tanimoto; e (iii) a modelagem de redes de interação molecular fundamentadas em grafos, possibilitando análises estruturais e relacionais avançadas.

A segunda solução, nomeada como *NeuroDock*, atua especificamente no processo de *docking*, viabilizando a execução eficiente e em larga escala de procedimentos de ancoragem molecular por predição. Sua arquitetura é desenvolvida para maximizar o desempenho ao longo de todo o fluxo de ancoragem, permitindo a análise de milhões de compostos, com significativa redução no tempo de processamento e nos custos computacionais associados. Para isso, fundamenta-se em um modelo de DL, implementado por meio de redes neurais multicamadas (MLP, do inglês, *Multilayer Perceptron*) ou residuais (ResNet, do inglês, *Residual Network*), treinadas com dados moleculares previamente recuperados e preparados pelo *BioMolExplorer*, assegurando, assim, uma integração eficiente entre ambas as soluções. Além disso, incorpora como parte de sua arquitetura processos automatizados de configuração e hiperparametrização, que lhe conferem elevada capacidade de adaptação à distintos domínios biomoleculares, sejam eles orientados a um alvo terapêutico específico ou a múltiplos alvos de interesse.

É precisamente nesse espectro de adaptabilidade e generalização que o *DrugHunter* se consolida como uma plataforma integrativa, articulando de forma eficiente o *BioMolExplorer*, o *NeuroDock*, os processos tradicionais de *docking* e *redocking*, bem como as etapas de simulação de DM. Para elucidar de maneira aprofundada o potencial e a relevância de sua arquitetura, as seções subsequentes apresentam, em detalhe, cada uma dessas soluções, destacando suas motivações, arquiteturas, principais funcionalidades e respectivas contribuições para a composição do fluxo integrado proposto nesta tese.

4.2 Da Curadoria à Integração de Bases Moleculares

O *BioMolExplorer* foi desenvolvido como uma plataforma (*framework*) computacional de caráter geral, orientado à automatização e sistematização de etapas essenciais à curadoria e integração de amplos domínios moleculares. Sua arquitetura responde à crescente demanda por soluções capazes de consolidar, de forma eficiente, escalável e reprodutível, bases de dados biomoleculares, adequando-se ao suporte de fluxos de trabalho em modelagem molecular, TV/HTVS e desenvolvimento racional de fármacos.

Em sua versão mais recente, o *BioMolExplorer* destaca-se, em especial, pela sua capaci-

dade de definir, expandir e refinar domínios exploratórios em larga escala, abrangendo uma diversidade substancial de dados químicos e estruturais. Essa abrangência assegura a coleta e a integração de informações essenciais acerca de diferentes mecanismos moleculares associados a alvos biológicos de interesse, em especial para aqueles relacionados a doenças de etiologia complexa e natureza multifatorial. Nesse contexto, a plataforma busca promover eficiência, consistência e rastreabilidade ao longo das investigações, posicionando-se como solução estratégica para assegurar a adequação dos domínios moleculares explorados e a reprodutibilidade das análises em bioinformática.

Sua capacidade de integrar dados provenientes de múltiplas fontes, incluindo compostos bioativos, alvos terapêuticos e descritores estruturais, potencializa a identificação de padrões latentes e recorrentes, de potenciais interações ligante-receptor e de oportunidades para reposicionamento terapêutico. Essa abordagem torna-se especialmente relevante no estudo de doenças associadas a múltiplos fatores de risco genéticos, metabólicos e ambientais, como as patologias neurodegenerativas e determinados tipos de câncer, nas quais a compreensão integrada dos mecanismos moleculares é essencial para a proposição de estratégias terapêuticas eficazes.

Desenvolvido com foco na flexibilidade e escalabilidade, o *BioMolExplorer* implementa um fluxo automatizado para integração de bases públicas de dados moleculares, com procedimentos sistemáticos de padronização, validação e enriquecimento informacional. Ademais, possibilita a geração de representações moleculares adequadas a distintas aplicações em modelagem computacional, como *docking*, predição de propriedades e análise de similaridade estrutural. A Figura 4.1 apresenta, de forma esquemática, as principais etapas desse fluxo de trabalho, evidenciando o processo integrado de recuperação, consolidação e curadoria de dados.

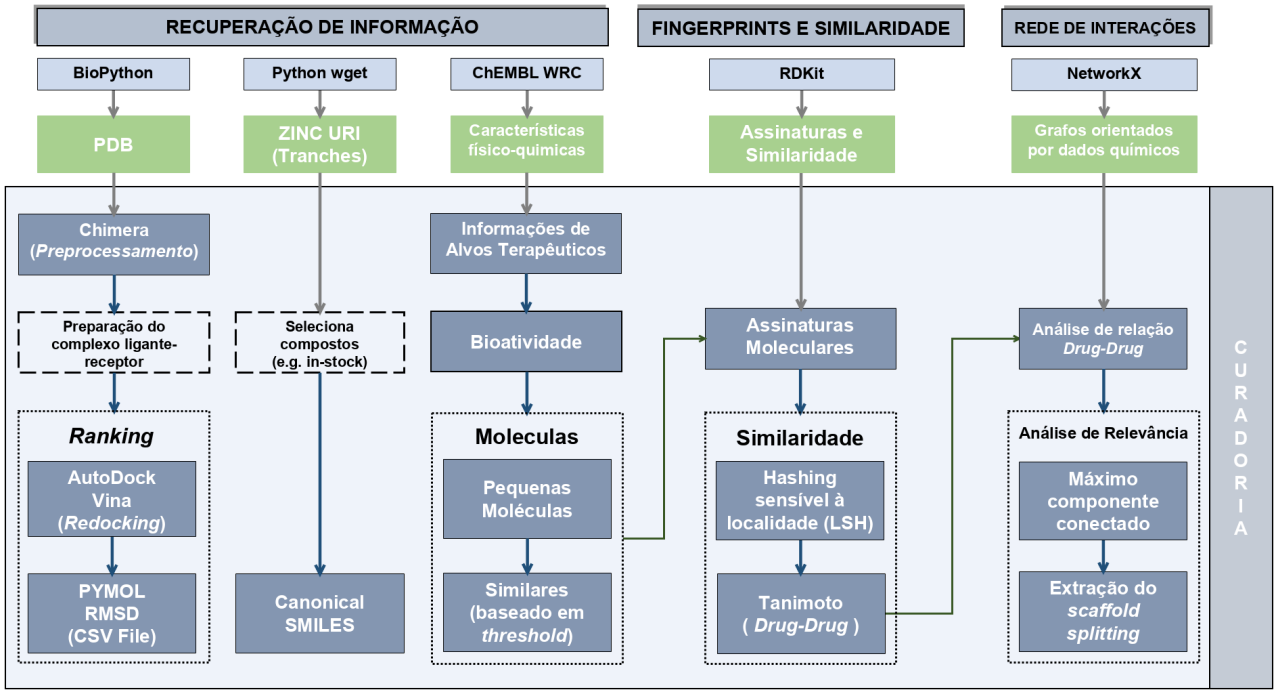

Figura 4.1: Fluxo de trabalho do *BioMolExplorer*, mostrando suas diversas etapas de recuperação e integração de dados. As linhas tracejadas representam as etapas manuais de pré-processamento fora da estrutura do *BioMolExplorer*, enquanto as linhas pontilhadas representam os subprocessos autônomos providos pela arquitetura desenvolvida para investigar a qualidade dos dados, as relações e as sobreposições entre as características moleculares e físico-químicas dos dados.

Conforme ilustrado na Figura 4.1, a proposta metodológica do *BioMolExplorer* estrutura-se em três etapas principais, organizadas de modo sequencial e interdependente: (i) recuperação e integração de dados; (ii) geração de *fingerprints* e análise de similaridade; e (iii) construção e análise de redes de interação.

4.2.1 Recuperação e Integração de Dados

Esta etapa concentra-se na extração, integração e unificação de informações moleculares provenientes de múltiplas bases públicas e especializadas. Para esse fim, são empregados módulos específicos, como o *BioPython*, para a obtenção automatizada de estruturas do PDB, e o *Python wget*, utilizado na recuperação em larga escala de compostos químicos a partir de URIs previamente extraídas da base de dados ZINC, abrangendo suas diversas *tranches*. De forma complementar, o ChEMBL WSC é empregado para a incorporação de descritores físico-químicos e dados de bioatividade relacionados a alvos terapêuticos de interesse.

Para as estruturas recuperadas do PDB, são gerados arquivos no formato CSV contendo informações relevantes para o rastreamento e o controle de qualidade dos dados, incluindo: os códigos PDB das estruturas baixadas, o código do ligante cocristalizado, o número de resíduo correspondente ao ligante identificado, a cadeia polipeptídica associada e a resolução cristalográfica do complexo. Essas informações são, então, utilizadas em procedimentos sistemáticos de pré-processamento, que incluem a preparação automatizada dos complexos ligante-receptor através do *software Chimera*, etapa necessária para a execução das análises subsequentes, especialmente o *redocking* realizado com o *AutoDock Vina*. A Tabela 4.1 detalha as configurações automatizadas, definidas em `src/scripts/chimera`, utilizadas pelo *DrugHunter* para manter a conformidade dessa ação.

Tabela 4.1: Procedimentos adotados no UCSF Chimera para a preparação do complexo, receptor e ligante a partir da estrutura cristalográfica original.

Entidade	Ação	Comandos (UCSF Chimera)

PDB	Remoção de solventes e hidrogênios, filtragem da cadeia de interesse e salvamento do complexo processado.	`open {input_complex}.pdb`
		`delete solvent`
		`delete element.H`
		`select #0:.{chain}`
		`select invert`
		`delete selected`
		`write format pdb #0 {output_complex}.complex.pdb`
		`close session`
		`close all`

PROTEINA	Isolamento da proteína, adição de hidrogênios e cargas, minimização e exportação nos formatos `mol2` e `pdb` sem hidrogênios.	`open {input_complex}.complex.pdb`
		`delete ligand`
		`select protein`
		`select invert`
		`delete selected`
		`addh`
		`addcharge all spec #0 chargeModel 14sb method gas`
		`minimize spec #0`
		`write format mol2 #0 {receptor}.dockprep.mol2`
		`close session`
		`open {receptor}.dockprep.mol2`
		`delete element.H`
		`write format pdb #0 {receptor}.noH.pdb`
		`close session`
		`close all`

LIGANTE	Isolamento do resíduo correspondente ao ligante, adição de hidrogênios e cargas, minimização e exportação nos formatos `pdb` e `mol2`.	`open {input_complex}.pdb`
		`select :{resnum}.{chain}`
		`select invert`
		`delete selected`
		`addh`
		`addcharge all spec #0 chargeModel 14sb method {charge_type}`
		`minimize spec #0`
		`write format pdb #0 {output_ligand}.lig.pdb`
		`close session`
		`open {output_ligand}.lig.pdb`
		`write format mol2 #0 {output_ligand}.lig.mol2`
		`close session`
		`close all`

Com o objetivo de assegurar a qualidade estrutural tanto dos dados extraídos quanto das poses geradas após o *redocking*, o módulo *BioMolExplorer* automatiza o processo de comparação entre as conformações de referência, obtidas do PDB, e aquelas resultantes do *redocking*, por meio do cálculo do desvio quadrático médio das posições atômicas (RMSD). Esse cálculo é realizado de forma automatizada pela plataforma, com o suporte de chamadas de subprocessos ao PyMOL. Os resultados dessa avaliação são então editados no CSV acima citado, fornecendo subsídios quantitativos para a análise da acurácia e confiabilidade das estruturas processadas, as quais servem de base para as etapas subsequentes de *docking* e modelagem molecular.

Em paralelo, os compostos selecionados da base ZINC, usualmente aqueles com disponibilidade comercial (*in-stock*), são extraídos em representações moleculares padronizadas, como SMILES canônicos, assegurando a interoperabilidade com os módulos subsequentes do fluxo de trabalho. Todos esses processos são conduzidos de forma automatizada, conferindo ao *BioMolExplorer* a capacidade de reduzir significativamente o tempo de execução, especialmente em cenários caracterizados por grandes volumes de dados e elevada complexidade informacional.

Por fim, os dados do ChEMBL, compreendendo moléculas bioativas e seus análogos estruturais, são extraídos com base em critérios pré-estabelecidos de similaridade molecular. Nesse processo, todas as entidades químicas que atendem a um limiar definido de similaridade são automaticamente recuperadas e integradas ao domínio molecular de interesse. Essa etapa de extração visa assegurar a abrangência e a representatividade do conjunto de dados, que será posteriormente empregado nas etapas subsequentes de modelagem e análise computacional.

Com o objetivo de ampliar a diversidade informacional do conjunto de dados moleculares extraídos, o *BioMolExplorer* disponibiliza um conjunto abrangente de filtros dinamicamente configuráveis que orientam a recuperação de dados tanto do PDB quanto do ChEMBL. Especificamente no contexto do PDB, os filtros implementados incluem: a classificação enzimática (número EC), o organismo de origem, o tipo de entidade biomolecular (e.g., DNA, proteína), o método experimental empregado na determinação estrutural (e.g., cristalografia de raios X), a resolução máxima permitida, bem como a presença ou ausência de ligantes ancorados ao receptor no complexo analisado.

Para o ChEMBL, os filtros são organizados em quatro categorias principais: *alvo*, *bioatividade*, *moléculas* e *análogos*. No âmbito do *alvo*, além do nome da proteína ou complexo, podem ser configurados parâmetros como organismo, tipo de proteína (e.g., proteína simples) e a natureza da relação entre filtros, incluindo operações como “relação direta” ou “está contido”

para extrações baseadas unicamente no nome. Em relação à *bioatividade*, os filtros contemplam a escolha do parâmetro padrão (e.g., K_i, IC_{50}, ID_{50}), o tipo molecular (e.g., pequena molécula), o valor máximo de referência e a unidade padrão correspondente. Para o estágio de seleção das *moléculas*, adota-se como critério específico a possibilidade de inclusão ou exclusão de produtos naturais do conjunto final recuperado. Por fim, a extração de moléculas *análogas* é realizada com base em parâmetros como o grau de similaridade (*threshold*), a presença ou não de produtos naturais, o tipo molecular e o peso molecular associado.

Esses filtros conferem elevada flexibilidade e precisão à definição do domínio molecular, permitindo que, para um mesmo alvo ou conjunto de alvos terapêuticos, sejam gerados distintos cenários avaliativos e exploratórios, ajustados conforme as especificidades e os objetivos de cada investigação. No *BioMolExplorer*, tais filtros podem ser configurados de forma parametrizável, seja diretamente nas chamadas de execução do código, usualmente realizadas com o suporte do ambiente de desenvolvimento *Visual Studio Code* (VSCode)[1], seja por meio de arquivos de configuração, organizados e armazenados de maneira sistemática na estrutura da pasta `src/scripts`, elemento integrante da implementação da plataforma.

4.2.2 Assinaturas Vetoriais e Análise de Similaridade

Nesta etapa, cada molécula do conjunto previamente recuperado é convertida para assinaturas vetoriais por meio da geração de *fingerprints* moleculares, utilizando-se, prioritariamente, as funcionalidades disponibilizadas pela biblioteca *RDKit*. Quando os dados são provenientes da base ChEMBL, esta é empregada de forma preferencial e automatizada. Caso contrário, é possível informar, via parametrização da função de execução, diretamente no VSCode, o caminho para a base de dados de escolha, a qual deve estar previamente padronizada em formato CSV, contendo obrigatoriamente os campos `molecule_chembl_id` e `canonical_smiles`.

As representações moleculares por *fingerprint* constituem abstrações estruturais densas e informativas, fundamentais para a quantificação formal da similaridade molecular. Esta quantificação orienta análises sistemáticas baseadas em critérios de proximidade estrutural, funcional e farmacofórica, viabilizando a identificação de relações químicas latentes e a inferência de padrões relevantes para as etapas subsequentes de modelagem computacional e TV/HTVS.

Conforme mencionado, o *BioMolExplorer* oferece suporte à geração de diferentes classes de assinaturas moleculares, entre elas: (i) as *Morgan fingerprints*, baseadas em subestruturas circulares e amplamente referenciadas em tarefas de ML e em estratégias de TV/HTVS; (ii) as *MACCS keys*, que consistem em um conjunto fixo e interpretável de fragmentos moleculares padronizados; e (iii) as *fingerprints* farmacofóricas, destinadas à captura de padrões tridimensionais críticos para a caracterização de interações moleculares. A escolha entre essas assinaturas é parametrizável, possibilitando sua definição e utilização de forma isolada, combinada ou integral, em consonância com os objetivos específicos e as particularidades metodológicas de cada estudo em desenvolvimento. Adicionalmente, para prover alto desempenho nesse processo, o *BioMolExplorer* incorpora, ainda, mecanismos de paralelização dessa tarefa, assegurando elevada eficiência computacional e escalabilidade, características indispensáveis para a análise de

[1] https://code.visualstudio.com/

conjuntos moleculares extensos.

Uma vez geradas as assinaturas moleculares, o passo subsequente consiste na aplicação de técnicas de agrupamento e comparação, com vistas à avaliação quantitativa do grau de similaridade entre os compostos. Para esse fim, o modelo de arquitetura proposto implementa uma abordagem em dois estágios. No primeiro, emprega-se a técnica de *Locality-Sensitive Hashing* (LSH), a qual promove uma redução significativa do espaço de busca ao realizar um agrupamento preliminar das assinaturas moleculares com base em limiares de similaridade (*thresholds*) previamente definidos. Considerando que estratégias baseadas em *hashing*, como o caso da LSH, operam mediante a estrutura de entrada no formato `<chave, valor>`, torna-se possível estabelecer as assinaturas moleculares como chaves de comparação, enquanto os identificadores `molecule_chembl_id` correspondentes são armazenados como os respectivos valores em cada grupo identificado. Esse processo, que pode ser interpretado como uma forma preliminar de obtenção de *scaffold splitting*, otimiza a identificação de pares de moléculas potencialmente similares, reduzindo substancialmente a necessidade de comparações exaustivas, aspecto particularmente relevante no contexto de bancos de dados moleculares de grandes amplitude.

Uma vez agrupadas as assinaturas, na etapa subsequente, é realizada a análise detalhada da similaridade intra-grupos, utilizando, como métrica padrão, o coeficiente de Tanimoto, amplamente reconhecido por sua robustez, simplicidade computacional e eficácia na comparação de vetores binários oriundos de *fingerprints* moleculares. Embora o coeficiente de Tanimoto seja extensivamente adotado na literatura, o *BioMolExplorer* possibilita a seleção de outras métricas, tais como o coeficiente de Dice, a similaridade do cosseno, entre outras funções de comparação. Essa flexibilidade permite a exploração de múltiplas perspectivas analíticas, favorecendo a detecção de relações estruturais complexas que, por vezes, não são evidenciadas por métricas convencionais. Em consonância com as demais funcionalidades do *BioMolExplorer*, a escolha da métrica de similaridade é totalmente parametrizável, assegurando ampla generalização conforme as necessidades específicas de cada análise.

Nesse contexto, o fluxo operacional do *BioMolExplorer* contempla, de forma integrada, a parametrização simultânea tanto do tipo de assinatura molecular quanto da métrica de similaridade a ser empregada. A partir dessas definições, procede-se à execução automatizada e paralela das análises, gerando como saída arquivos tabulares no formato CSV, os quais sintetizam os resultados de similaridade entre os pares de compostos agrupados. Tal saída configura-se como um recurso estratégico para etapas subsequentes do processo, tais como: (i) a priorização de candidatos; (ii) a seleção racional de sub-bibliotecas químicas; (iii) a identificação de compostos de referência; e (iv) a construção de modelos preditivos.

4.2.3 Construção e Análise de Redes de Interação Molecular

A etapa final, conduzida pelo *BioMolExplorer*, consiste na construção e análise de redes de interação molecular, elaboradas a partir dos dados químicos e estruturais gerados nas etapas precedentes. Para esse propósito, a versão mais recente da plataforma emprega a biblioteca *NetworkX*, amplamente reconhecida pela comunidade científica devido à sua robustez e versatilidade na modelagem, manipulação e análise de estruturas em grafos.

Com base nos arquivos CSV produzidos na etapa de análise de similaridade, o primeiro passo consiste na definição de um limiar (*threshold*) para a triagem dos pares moleculares que comporão as redes de interação. Assim como nos estágios anteriores, esse parâmetro é configurável e flexível, permitindo a exploração de diferentes combinações na composição dos resultados. A escolha do limiar é um fator essencial, uma vez que impacta diretamente a densidade, a conectividade e a topologia das redes geradas, podendo ser ajustada de acordo com os objetivos analíticos, seja para privilegiar relações mais restritivas, seja para captar associações mais permissivas.

A partir dos pares selecionados, o *BioMolExplorer* constrói grafos não direcionados, em que os vértices (nós) representam as moléculas e as relações de ligação entre nós (arestas) indicam a existência de uma relação de similaridade igual ou superior ao limiar previamente estabelecido. A modelagem das redes é organizada de forma sistemática por alvo molecular. Assim, para cada alvo em estudo, são geradas duas redes distintas: (i) uma composta exclusivamente pelas moléculas bioativas associadas ao referido alvo; e (ii) outra representando as relações de similaridade entre os análogos estruturais identificados. Adicionalmente, quando pertinente, é construído um grafo integrado, consolidando todas as moléculas (bioativos e análogos) e, consequentemente, representando a totalidade das interações potenciais relevantes no respectivo contexto biológico. Como nas demais etapas do fluxo, a base ChEMBL é utilizada de maneira preferencial, dada sua abrangência e curadoria sistemática. Todavia, o *BioMolExplorer* oferece flexibilidade para a modificação das parametrizações, possibilitando a aplicação do mesmo processo sobre bases de dados alternativas, incluindo aquelas previamente estruturadas ou modeladas externamente à plataforma.

Uma vez extraídas as redes de relação, a análise subsequente concentra-se na identificação do *máximo componente conexo* (MCC, do inglês, *Maximum Connected Component*), definido como o subconjunto de nós de maior inter-relação dentro do grafo. A detecção dessa sub-rede é particularmente relevante, uma vez que ela evidencia os agrupamentos estruturais mais densos[2] e com características recorrentes, sugerindo a presença de *scaffolds* centrais que podem desempenhar papel determinante na atividade biológica ou farmacológica sob investigação. A identificação e extração de componentes densos reforça a hipótese de que determinados núcleos estruturais comuns (*core scaffolds*) podem ser explorados como pontos de partida para a modelagem de novos candidatos terapêuticos, potencializando processos de descoberta e otimização de fármacos.

O *BioMolExplorer* automatiza integralmente a identificação e a extração dos MCCs, gerando, para cada rede modelada, um arquivo CSV estruturado com duas colunas principais: o identificador único da molécula (por exemplo, o código ChEMBL) e sua representação canônica no formato SMILES. Além disso, produz como resultado desse processo a base de moléculas utilizada para a composição de técnicas inteligentes de IA, utilizando para isso a interseção dos arquivos CSVs produzidos. Para garantir a integridade e a unicidade das informações, procede-se à eliminação rigorosa de duplicatas, assegurando que apenas uma instância por molécula seja

[2]A densidade é relacionada ao número de relações de ligação por nó

mantida, de modo que cada estrutura química esteja representada de forma única no conjunto a ser empregado na modelagem preditiva. Essa padronização promove a rastreabilidade e a interoperabilidade dos dados, viabilizando sua integração com sistemas computacionais distintos e fluxos analíticos complexos.

O conjunto molecular resultante da consolidação dos MCCs correspondentes às redes analisadas é designado como o núcleo mais representativo do espaço químico explorado, servindo como base para investigações subsequentes de maior sofisticação, incluindo modelagem preditiva, simulações de DM e planejamento racional de agrupamentos químicos. Em cenários envolvendo múltiplos alvos terapêuticos, essa abordagem favorece a identificação de compostos com características polifarmacológicas, com potencial para interagir simultaneamente com diferentes biomoléculas de interesse. Tal característica é particularmente desejável em estratégias emergentes de reposicionamento de fármacos e no desenvolvimento de agentes terapêuticos multifuncionais, capazes de modular de forma coordenada vias moleculares complexas associadas a doenças de etiologia multifatorial.

Complementarmente, o *BioMolExplorer* realiza a identificação do maior fragmento estrutural compartilhado entre as moléculas integrantes de cada MCC, extraindo e armazenando essa informação em um arquivo CSV adicional. Esta etapa é essencial para a elucidação de *scaffolds* centrais, potencialmente associados às atividades biológicas de interesse. Além disso, é gerada automaticamente uma representação bidimensional (2D) do fragmento estrutural comum, a qual compõe os relatórios e materiais visuais de apoio aos resultados, facilitando a comunicação científica dos achados.

As operações de mapeamento de *scaffolds* compartilhados, bem como a geração das correspondentes representações bidimensionais, também são conduzidas de forma individualizada para cada alvo. O arquivo CSV resultante organiza, de maneira sistemática, os diferentes fragmentos estruturais mais frequentes identificados nos MCCs, proporcionando uma visão integrada e informativa sobre os núcleos moleculares predominantes. Essa etapa integra de maneira transparente a análise baseada em similaridade com métodos avançados de modelagem de redes, proporcionando uma representação relacional rica e informativa do espaço químico investigado.

4.2.4 Design Modular, Escalabilidade e Generalização Funcional

Como demonstrado nas seções anteriores, uma das características essenciais do *BioMolExplorer* está em seu design generalista, que possibilita sua aplicação em uma ampla variedade de contextos e domínios químicos, independentemente do alvo molecular ou da classe terapêutica sob investigação. A modularidade de sua arquitetura, aliada à adoção de tecnologias abertas, padronizadas e interoperáveis, assegura elevada escalabilidade, permitindo a curadoria e a análise de conjuntos moleculares com distintas magnitudes e níveis de complexidade.

A capacidade de paralelização presente nos múltiplos estágios da plataforma amplia significativamente sua aplicabilidade em ambientes de análise em larga escala, tornando-o particularmente adequado para a composição de fluxos de trabalho automatizados e adaptativos. Tal configuração é especialmente eficaz para sustentar investigações que envolvem a exploração de extensos espaços químicos, mantendo elevados padrões de reprodutibilidade, robustez

metodológica e eficiência computacional.

Em consonância com as características acima apresentadas, o *BioMolExplorer* foi desenvolvido com foco na integração direta a fluxos emergentes de modelagem computacional, possibilitando que os domínios moleculares gerados sejam imediatamente incorporados em processos de TV/HTVS, modelagem preditiva ou refinamento estrutural. Essa integração favorece sua adoção como um componente estratégico em *workflows* mais abrangentes, como o *DrugHunter*, assegurando uma transição fluida, eficiente e consistente entre a etapa de curadoria molecular e os processos subsequentes de análise e modelagem computacional por AIDD.

4.3 Ancoragem Molecular por Aprendizado Profundo

Ao estabelecer domínios exploratórios de dados eficazes, por meio das etapas de extração, curadoria e preparação do *BioMolExplorer*, torna-se viável implementar estratégias de modelagem molecular baseadas em IADD, capazes de identificar padrões recorrentes, latentes e/ou de elevada complexidade no conjunto de dados, utilizando, para isso, soluções como as RNAs. Assim, como etapa subsequente às operações realizadas pelo *BioMolExplorer*, é introduzido o *NeuroDock*, uma rede MLP, estruturada segundo o paradigma de aprendizado profundo - DL. Esta arquitetura é concebida para predizer valores de *docking* (*scores*) a partir de representações vetoriais das moléculas, previamente associadas a referências de ancoragem obtidas via métodos de consenso. A Figura 4.2 ilustra, de forma esquemática, as principais etapas que compõem essa solução, evidenciando sua integração ao fluxo computacional e sua função estratégica na aceleração e aprimoramento das etapas de triagem molecular.

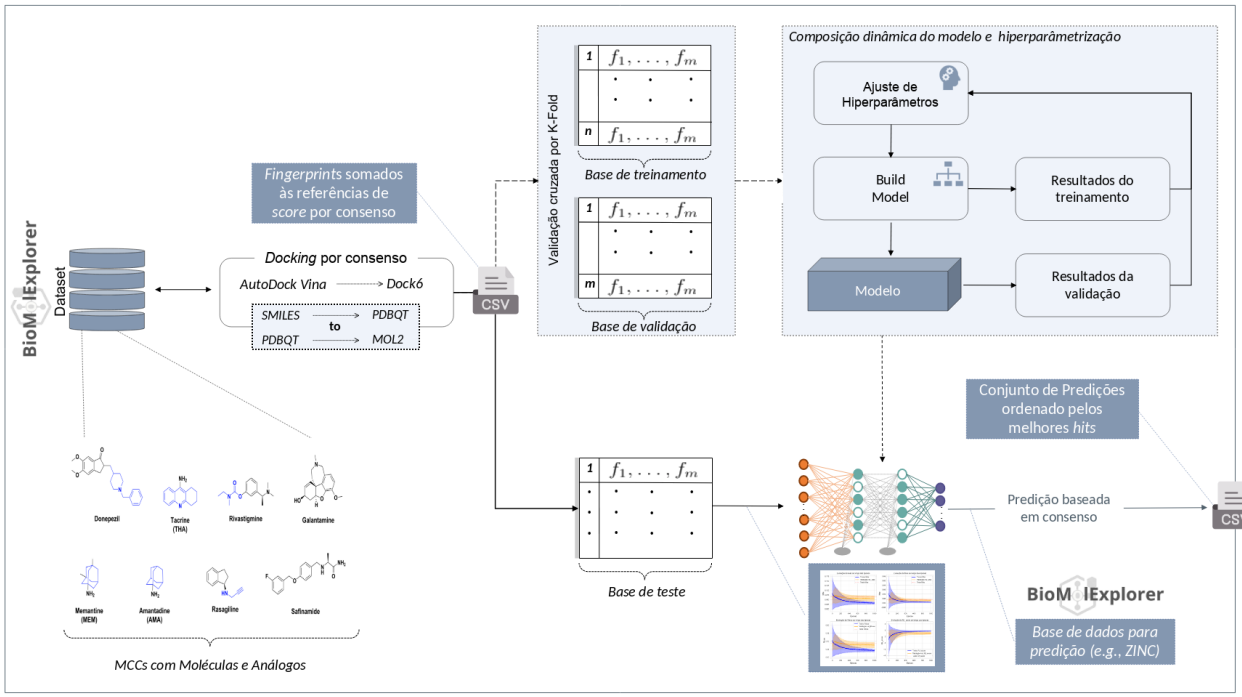

Figura 4.2: Arquitetura conceitual do *NeuroDock*, composta por quatro estágios principais: (a) leitura da base de moléculas e seus análogos, previamente identificados no processo de extração dos MCCs conduzido pelo *BioMolExplorer*; (b) execução do modelo de consenso, integrando os resultados de *docking* obtidos a partir dos algoritmos *AutoDock Vina* e *Dock6*, com vistas à geração de *scores* por alvo terapêutico de interesse; (c) composição dinâmica da arquitetura da rede neural e otimização dos hiperparâmetros, assegurando adequação ao espaço químico modelado; e (d) teste e aplicação do modelo treinado para predição em larga escala, viabilizando a TV de extensos bancos moleculares com elevada eficiência computacional.

Como elucidado na Figura 4.2, os dados modelados pelo *BioMolExplorer*, por meio da estratégia de extração e interseção dos MCCs, são utilizados como base para compor as entradas necessárias para a definição do *NeuroDock*. Para isso, a base molecular resultante desse processo de curadoria é submetida a avaliação de *docking* por consenso, sendo na sequência processada a partir das representações vetoriais obtidas via *fingerprints* moleculares.

Considerando que o *BioMolExplorer* é capaz de gerar distintos modelos de vetorização molecular, torna-se possível selecionar a representação que melhor favoreça o desempenho preditivo da RNA, a qual é utilizada como parte da composição dos dados aplicados às etapas de treinamento, validação e teste (Figura 4.2). Um modelo de configuração dedicado, disponível em `src/scripts`, permite a pré-definição das proporções adequadas para a formação de cada um desses subconjuntos, assegurando flexibilidade, padronização e reprodutibilidade ao processo. Para elucidar as diferentes possibilidades de configuração inicial disponíveis, a Tabela 4.4 apresenta o detalhamento de cada parâmetro associado a essa etapa.

Tabela 4.4: Configuração inicial utilizada na molelagem do *NeuroDock*, detalhando os principais parâmetros de configuração da arquitetura, a estratégia de otimização e o processo de avaliação do modelo. A tabela inclui: (i) parâmetros estruturais da rede, como limites de unidades por camada e funções de ativação; (ii) hiperparâmetros relacionados à regularização, otimização e inicialização dos pesos; (iii) métricas de avaliação; e (iv) aspectos relativos à divisão dos dados para treinamento, validação e teste.

Parâmetro	**Descrição**	**Exemplo/Valor**	**Vantagens/Considerações**
`model_type`	Tipo de arquitetura adotada	`mlp, resnet`	Estrutura de rede a ser utilizada no processo de predição. Na versão mais atual do *NeuroDock*, as redes MLP ou ResNet podem ser utilizadas
`layer_limits`	Intervalos definidos para o número de neurônios por camada oculta	`[[512, 1024], [512, 1024]]`	Permite ajuste fino da complexidade da rede conforme as características da base de dados, além da redução ou expansão das camadas ocultas adotadas
`max_dropout`	Taxa máxima de *dropout** para regularização	0.3	Reduz o risco de *overfitting* ao desligar aleatoriamente neurônios durante o treinamento
`l2_lambda`	Fator de regularização L2	0.0001	Penaliza pesos excessivos, promovendo generalização do modelo
`kernel_initializer`	Inicialização dos pesos	`he_uniform`	Adequada para funções de ativação `ReLU`; favorece inicialização eficiente
`hidden_activation`	Função de ativação das camadas ocultas	`relu`	Introduz não-linearidade; evita problemas de saturação

`output_activation`	Função de ativação da camada de saída	`sigmoid`	Apropriada para saídas contínuas normalizadas; garante valores entre 0 e 1
`batch_size`	Tamanho do lote de treinamento	32	Compromisso entre velocidade de processamento e estabilidade de gradiente
`epochs`	Número máximo de épocas de treinamento	1000	Permite treinamento prolongado; evita interrupções prematuras
`metrics`	Métricas de avaliação	`mae`, `mse`, `rmse`, `r2_score`	Fornece múltiplas perspectivas sobre o desempenho preditivo da rede
`loss_monitor`	Monitoramento explícito da função de perda	`False`	Foco na métrica de validação (`val_mse`) para monitoramento
`loss`	Função de perda utilizada	`Huber`, `delta`: 5.0	Combina vantagens de MSE e MAE; robusta a outliers
`callback_monitor`	Métrica para monitoramento de *callbacks**	`val_mse`	Foco no erro quadrático médio de validação para decisões de parada ou ajuste
`test_size`	Proporção de dados reservados para teste	0.1 (10%)	Garante conjunto independente para avaliação final do modelo
`validation_size`	Proporção de dados para validação	0.2 (20%)	Permite ajuste de hiperparâmetros e prevenção de *overfitting*
`random_state`	Semente para reprodutibilidade	73	Garante replicabilidade dos experimentos
`n_folds`	Número de divisões na validação cruzada	5	Estratégia de *K-Fold Cross Validation* para avaliação robusta

* Dropout: Função que desliga (zera) aleatoriamente uma porcentagem dos neurônios (e suas respectivas conexões) em uma ou mais camadas da rede.

* CallBacks: Funções monitoras utilizadas para finalizar o treinamento quando detectada estabilidade da rede.

Conforme evidenciado nas parametrizações da Tabela 4.4, a ampla gama de combinações confere ao *NeuroDock* elevada adaptabilidade, possibilitando sua eficiente adequação a distintos espaços químicos e variados cenários analíticos. Essa flexibilidade é acompanhada de uma robustez metodológica e de um rigoroso compromisso com a reprodutibilidade, aspectos fundamentais para assegurar a validade, a transparência e a confiabilidade dos processos de modelagem preditiva. Tais características derivam da capacidade de adaptação dinâmica da arquitetura a cada domínio molecular explorado, sendo tal ajuste realizado de maneira automatizada ao longo das etapas de treinamento, validação e teste propostos.

4.3.1 Treinamento, Validação e Teste por Estratégia de Consenso

Conforme previamente exposto, a estratégia de treinamento, validação e teste do *NeuroDock* fundamenta-se em um modelo de composição de dados por consenso, que integra, de forma totalmente automatizada, os resultados de *docking* de diferentes algoritmos, como o *AutoDock Vina* e o *Dock6*, com as *fingerprints* previamente selecionadas, compondo assim o conjunto representativo do domínio químico sob investigação.

Como ilustrado na Figura 4.2, o processo tem início com uma etapa automatizada de pré-

processamento, na qual as moléculas previamente selecionadas são avaliadas inicialmente pelo *AutoDock Vina*. Para isso, suas representações em SMILES canônicos são convertidas automaticamente em arquivos no formato PDBQT, utilizando o *OpenBabel*. Após a execução do *docking* e a obtenção dos respectivos *scores* conformacionais, a melhor pose é selecionada para cada molécula em observação.

As conformações selecionadas são então submetidas a uma segunda etapa de avaliação com o *Dock6*. Para isso, os arquivos PDBQT são reconvertidos para o formato PDB por meio do *OpenBabel*, sendo posteriormente processados conforme o *script* apresentado na Tabela 4.7, que gera arquivos MOL2 contendo a adição de hidrogênios e a parametrização com campo de força apropriado. Na versão mais recente do *NeuroDock*, essas cargas podem ser do tipo `am1` ou `gas`. Além disso, diversos outros parâmetros são aplicáveis a partir da chamada do método de execução, como `pH`, tipo de conformação de avaliação ("`flex`" ou "`rigid`"), entre outros. Esse refinamento conformacional garante uma representação estrutural mais fidedigna e informativa das interações intermoleculares, promovendo maior qualidade e consistência aos dados que alimentam a etapa subsequente de modelagem preditiva.

Tabela 4.7: Fluxo de preparação das melhores conformações obtidas a partir do *AutoDock Vina* no UCSF Chimera, após a conversão dos arquivos PDBQT para PDB via *OpenBabel*. O processo resulta em arquivos no formato MOL2, devidamente parametrizados e prontos para execução no *Dock6*.

Entidade	Ação	Comandos (UCSF Chimera)

PDB → MOL2	Remoção de hidrogênios que possam estar incorretos, remoção de resíduos fora da composição da molécula (possíveis solventes), adição de hidrogênios e cargas, minimização e exportação para o formato `mol2`.	`open {ligand}.pdb`
		`delete element.H`
		`delete solvent`
		`addh`
		`addcharge all spec #0 chargeModel 14sb method {charge_type}`
		`minimize spec #0`
		`write format mol2 #0 {ligand}.lig.mol2`
		`close session`
		`close all`

Na sequência, os resultados provenientes de ambas as ferramentas acima citadas são submetidos a um processo de normalização, aplicado segundo uma de duas estratégias matemáticas disponíveis: *min-max* ou *z-score*. A Tabela 4.9 consolida as principais propriedades, vantagens e limitações associadas a cada método, orientando a escolha conforme as especificidades dos dados e dos objetivos do estudo.

Tabela 4.9: Apresentação e resumo comparativo entre os métodos de normalização Min-Max e Z-Score, utilizados na padronização dos resultados de *docking* por consenso no *NeuroDock*.

Método	Função Matemática	Vantagens	Limitações
Min-Max	$x_{\text{norm}} = \dfrac{x - x_{\min}}{x_{\max} - x_{\min}}$	Simples de aplicar; mantém a proporcionalidade entre os valores; ideal para escalas conhecidas e limitadas	Sensível a *outliers*; pode comprimir excessivamente a escala se houver valores extremos
Z-Score	$x_{\text{std}} = \dfrac{x - \mu}{\sigma}$	Centraliza a distribuição em torno de zero; ajusta a variabilidade para desvio padrão unitário; útil para dados com variância heterogênea	Sensível a *outliers* na estimativa de μ e σ; menos intuitivo em termos de escala absoluta

Após a normalização, os resultados obtidos são integrados por meio do cálculo da média aritmética, constituindo, assim, a referência de *score* para cada assinatura molecular presente no conjunto de dados. Quando múltiplos alvos terapêuticos são avaliados simultaneamente, essa referência é representada na forma de vetores multidimensionais, cujos componentes correspondem aos respectivos *scores* de consenso atribuídos a cada alvo considerado. Como resultado, um CSV é gerado, sendo utilizado nas etapas subsequentes de validação cruzada (*K-Fold*) e teste do modelo preditivo. As proporções destinadas a cada uma dessas ações são definidas de acordo com os parâmetros `test_size` e `validation_size`, cujos valores e respectivas configurações encontram-se descritos na Tabela 4.4.

4.3.2 Otimização Autônoma de Hiperparâmetros para Modelos de IA

Considerando a sensibilidade das arquiteturas de RNA às características dos dados observados, o *NeuroDock* foi elaborado como um sistema autônomo de composição e ajuste de modelos. Esse sistema não apenas incorpora os refinamentos descritos na seção anterior, mas também viabiliza a execução automatizada de um processo sistemático de otimização de hiperparâmetros. Tal automatização possibilita ajustes finos, tanto das propriedades normalizadas da base de dados extraída pelo *BioMolExplorer*, quanto sobre os parâmetros iniciais de configuração, assegurando que a arquitetura resultante seja adequadamente dimensionada para capturar a complexidade e a variabilidade química do conjunto sob investigação.

Como elucidado no modelo esquemático da Figura 4.2, o fluxo de modelagem inicia-se com a elaboração de conjunto de dados de treinamento, validação e teste, a partir da estratégia de *docking* por consenso previamente descrita. Uma vez definidos os subconjuntos necessários à execução, esses dados são submetidos a uma etapa de avaliação sistemática por validação cruzada, a qual tem por objetivo ampliar o *stress* do modelo durante as etapas de treinamento e validação buscando produzir estimativas mais robustas, confiáveis e imparciais da sua capacidade de generalização sob o domínio químico explorado.

Nessa etapa, além dos parâmetros clássicos sintetizados na Tabela 4.4, são também configurados componentes funcionais para a avaliação. Destacam-se, nesse contexto, a escolha do tipo de vetorização molecular utilizada como entrada; a seleção do método de normalização aplicado na composição do *score* de consenso, com as alternativas *min-max* e *z-score*; e a atribuição de uma nomenclatura para a configuração e recuperação futura da arquitetura gerada. Todas essas operações são parametrizáveis por meio da função `build_model`, disponibilizada como parte da arquitetura do *NeuroDock*.

Ao adotar uma abordagem de parametrizações dinâmica, a arquitetura do *NeuroDock* amplia significativamente sua aplicabilidade e capacidade de generalização, podendo ser operacionalizado sob distintas perspectivas: (i) como **mecanismo de análise e exploração**, restrito à aplicação das funções e configurações previamente estabelecidas; (ii) como **arquitetura extensível**, apta à incorporação de novos modelos de RNA ainda não contemplados; e (iii) como **modelo exploratório adaptativo**, passível de integração ou adequação a *workflows* emergentes em modelagem molecular. Para compor essa flexibilidade, o processo de otimização contempla um conjunto de hiperparâmetros estratégicos, cujas definições, descrições e intervalos de valores

utilizados estão resumidos na Tabela 4.11.

Tabela 4.11: Hiperparâmetros empregados no processo de otimização do *NeuroDock*, incluindo suas descrições funcionais, benefícios para o ajuste do modelo e os respectivos intervalos ou conjuntos de valores considerados durante a busca.

Hiperparâmetro	**Descrição**	**Vantagens**	**Intervalo de Valores**
`hidden_units`	Quantidade de neurônios por camada oculta; o número de camadas varia conforme a complexidade do problema	Ajusta a capacidade de modelagem da rede ao problema, evitando subajuste ou sobreajuste	Inteiros entre 8 e 1024 unidades por camada
`max_dropout`	Fração máxima de *dropout* aplicada durante o treinamento para evitar *overfitting*	Reduz o risco de sobreajuste, promovendo melhor generalização do modelo	Contínuo entre 0.0 e 0.5
`l2_lambda`	Fator de regularização L2 que penaliza pesos excessivos	Favorece modelos mais simples e robustos, prevenindo overfitting	Contínuo entre 10^{-6} e 10^{-2}
`optimizer`	Algoritmo de otimização usado para atualização dos pesos da rede	Ajuste eficiente dos parâmetros; permite escolha entre diferentes métodos segundo o perfil da tarefa	*adam*, *rmsprop*, *sgd*, *nadam*
`learning_rate`	Taxa de aprendizado para atualização dos pesos	Controla a velocidade de convergência do modelo; evita oscilações ou estagnação	Contínuo entre 10^{-5} e 10^{-2}
`amsgrad`	Variante do otimizador *adam* com garantias teóricas de convergência	Estabiliza o treinamento, especialmente em cenários com ruído	*True* ou *False*
`rho`	Coeficiente de decaimento da média móvel no *rmsprop*	Ajusta a suavização do gradiente, impactando a estabilidade da otimização	Contínuo entre 0.8 e 0.99
`momentum`	Fator de *momentum* aplicado nos otimizadores *rmsprop* e *sgd*	Acelera a convergência, reduzindo flutuações no caminho do gradiente	Contínuo entre 0.0 e 0.9
`epsilon`	Termo de estabilidade numérica para *rmsprop* e *nadam*	Evita divisões por zero ou números muito pequenos, estabilizando a atualização dos pesos	Contínuo entre 10^{-8} e 10^{-6}
`beta_1`, `beta_2`	Coeficientes das médias móveis de primeira e segunda ordem no *nadam*	Controlam o decaimento do gradiente e o ajuste do momento, influenciando estabilidade e velocidade de aprendizado	Contínuo entre 0.8 e 0.999

Essa gama de ajustes, orientada por um conjunto de hiperparâmetros previamente configuráveis, assegura um equilíbrio adequado entre a capacidade de generalização e a especificidade do modelo, promovendo um desempenho preditivo robusto e eficaz para distintos espaços químicos. Ademais, tal abordagem viabiliza a exploração sistemática de múltiplas combinações parametrizáveis, ampliando substancialmente a adaptabilidade do modelo em consonância com as particularidades e a complexidade do domínio químico em análise.

Para otimizar esse processo de ajuste, o *NeuroDock* adota a ferramenta *Optuna*, uma biblioteca de otimização automática de hiperparâmetros baseada em técnicas de busca eficiente, como *Tree-structured Parzen Estimator* (TPE) e *pruning* assíncrono. A utilização do *Optuna*[3] não apenas automatiza e sistematiza a seleção das melhores configurações, mas também garante

[3]https://optuna.org/

a manutenção de um elevado desempenho computacional durante o processo de avaliação, mitigando o custo associado a buscas exaustivas e assegurando a escalabilidade do modelo.

4.3.3 Eficiência Computacional e Flexibilidade Arquitetural

Durante as fases de treinamento, validação e teste, o *NeuroDock* foi pensado de forma a operar de maneira otimizada, maximizando o aproveitamento dos recursos computacionais disponíveis e assegurando elevada eficiência funcional e operacional. Com o objetivo de garantir um desempenho superior e reduzir substancialmente o tempo de processamento, a execução do modelo prioriza, sempre que possível, a utilização de *Unidades de Processamento Gráfico* (GPUs). Tais unidades oferecem infraestrutura altamente paralelizada, especialmente adequada para cargas de trabalho intensivas, características dos processos de DL.

Em cenários nos quais a utilização de GPUs não é possível, o *NeuroDock* dispõe de mecanismos automáticos de adaptação, redirecionando suas operações para *Unidades Centrais de Processamento* (CPUs). Embora o desempenho computacional seja potencialmente inferior nesse contexto, a continuidade do fluxo de execução é garantida, assegurando a generalização, robustez e a portabilidade do sistema. Essa estratégia confere ao *NeuroDock* elevada flexibilidade, permitindo sua implantação e utilização em uma ampla gama de ambientes computacionais, desde servidores equipados com dispositivos de *hardware* especializados até estações de trabalho convencionais.

Adicionalmente, como parte integrante do processo de *docking* por consenso, múltiplas conversões de formatos moleculares são sistematicamente requeridas, configurando-se como uma etapa crítica para assegurar a interoperabilidade entre diferentes ferramentas de ancoragem. Especificamente, as análises realizadas com o *AutoDock Vina* demandam a conversão prévia dos dados de entrada, originalmente no formato SMILES, para o formato PDBQT. Posteriormente, a seleção e o reaproveitamento das melhores conformações obtidas requerem a conversão dessas estruturas para o formato MOL2, compatível e exigido pelo *Dock6*. Essas conversões são operacionalizadas por meio da ferramenta *OpenBabel*, integrada ao fluxo computacional via rotina `subprocess` do Python, a qual permite a parametrização de diversas opções, como, por exemplo, a definição do valor de `pH`, quando necessário.

Considerando que as conversões são aplicadas a um amplo conjunto de entradas, a fim de garantir a eficiência e mitigar o impacto dessas operações sobre o tempo total de execução, todas as tarefas são paralelizadas em CPU, empregando-se estratégias de processamento concorrente que asseguram a fluidez e o desempenho do fluxo de trabalho. Essa abordagem permite que as etapas de pré-processamento e de integração entre múltiplos sistemas sejam conduzidas de maneira eficiente, preservando a escalabilidade do *NeuroDock*, mesmo em cenários caracterizados por elevado volume de dados ou pela execução simultânea de múltiplos experimentos.

4.3.4 Predição em Larga Escala e Aplicação em Triagem Virtual

Uma vez concluídas as etapas de hiperparametrização e composição do modelo, este é submetido à fase de teste, a qual consiste em sua aplicação sobre uma fração previamente definida e estratificada dos dados oriundos do pré-processamento. A estratificação é realizada por meio

da função `train_test_split`, disponibilizada pela biblioteca `scikit-learn`[4] da linguagem Python, assegurando que a amostra preserve a representatividade estatística das distintas classes e padrões moleculares presentes no conjunto original.

Como parte dessa etapa, o *NeuroDock* executa a predição de ancoragem (*scores*) para as entradas do conjunto, permitindo a avaliação quantitativa do desempenho da rede sob diferentes métricas. Tais métricas, que incluem, por exemplo, erro absoluto médio (MAE), erro quadrático médio (MSE), raiz do erro quadrático médio (RMSE) e o coeficiente de determinação (R^2), são parametrizáveis e previamente configuradas, conforme detalhado na Tabela 4.4. Os resultados obtidos são sintetizados na forma de gráficos de desempenho, que ilustram o comportamento preditivo do modelo e oferecem suporte visual à análise crítica da sua eficácia.

Uma vez estabelecida a robustez e a confiabilidade do modelo por meio das etapas de validação e teste, o *NeuroDock* é aplicado em larga escala sobre extensos bancos de dados moleculares. Dentre esses, destaca-se a base *ZINC*, composta por milhões de compostos químicos e amplamente empregada em *workflows* emergentes de TV e descoberta e reposicionamento racional de fármacos. Nesse cenário, o modelo já validado realiza a predição automatizada dos *scores* para as moléculas da base, considerando para isso cada alvo molecular observado, gerando como saída um arquivo no formato `CSV`, estruturado em duas colunas principais: (i) o identificador único da molécula, por exemplo, o código *ZINC* e (ii) um vetor contendo os valores preditos de ancoragem, correspondentes a cada um dos alvos biológicos considerados.

Adicionalmente, o arquivo resultante é ordenado com base nos valores de *score* obtidos, estratégia que visa priorizar as moléculas com maior potencial de afinidade para o alvo observado. Em cenários envolvendo múltiplos alvos, a ordenação é realizada por meio do cálculo do produto dos valores individuais de *score* atribuídos a cada alvo, consolidando uma medida composta de desempenho. Esse procedimento assegura que os candidatos mais promissores (*hits*) sejam inseridos nas primeiras posições da listagem, facilitando sua identificação e seleção para as etapas subsequentes de análise, validação experimental e, potencialmente, desenvolvimento farmacológico.

Essa capacidade de predição em larga escala, aliada à possibilidade de investigação simultânea de múltiplos alvos, confere ao *NeuroDock* uma vantagem estratégica no contexto da TV, viabilizando a avaliação rápida e eficiente de extensos acervos moleculares, com um custo computacional significativamente reduzido em comparação às metodologias tradicionais baseadas exclusivamente em *docking* exaustivo. Ademais, a utilização de modelos preditivos fundamentados em técnicas de DL possibilita a identificação de padrões latentes e complexos nas interações molécula-alvo, potencializando a priorização de candidatos com maior probabilidade de sucesso nas etapas subsequentes de validação experimental e desenvolvimento farmacológico. Assim, o *NeuroDock* não apenas automatiza e acelera o processo de TV, mas também amplia substancialmente as capacidades analíticas na descoberta racional de fármacos, integrando-se de forma eficiente aos sistemas computacionais modernos voltados à inovação em bioengenharia e química medicinal.

[4] https://scikit-learn.org/stable/

4.3.5 Características Estratégicas do NeuroDock como Ferramenta AIDD

Conforme observado nas seções anteriores, o *NeuroDock* apresenta-se como uma ferramenta emergente no contexto da modelagem molecular assistida por IA - AIDD, reunindo um conjunto de características que o diferenciam e ampliam significativamente sua aplicabilidade e impacto nas etapas de TV/HTVS e descoberta racional de fármacos. Sua arquitetura flexível, aliada a mecanismos de otimização computacional e à capacidade de predição em larga escala o posiciona como uma solução robusta, eficiente e adaptável para diferentes cenários experimentais e computacionais. Dentre os principais benefícios proporcionados pelo *NeuroDock*, pode-se destacar:

- **Modelo de DL Dinamicamente Gerado**: a rede neural é customizada para cada base de dados, otimizando o desempenho preditivo em diferentes espaços químicos.
- **Otimização de Hiperparâmetros**: a configuração da rede é ajustada automaticamente para maximizar a eficácia na aprendizagem de interações moleculares.
- **Predição de *Docking* em Larga Escala**: elevada eficiência computacional permite a avaliação de milhões de compostos, acelerando processos de descoberta de fármacos.
- **Aprendizado Baseado em Consenso**: integração de múltiplas estratégias de *docking* (AutoDock Vina e Dock6) para aprimorar a confiabilidade e acurácia das predições.
- **Curadoria Otimizada de Dados**: utilização de conjuntos moleculares de alta qualidade, previamente processados e refinados pelo *BioMolExplorer*, assegurando a robustez do modelo de aprendizado.

Adicionalmente, destacam-se como benefícios definidos pela arquitetura do *NeuroDock*: (i) a integração eficiente de fluxos automatizados que englobam as etapas de pré-processamento, modelagem e predição, promovendo coesão e reprodutibilidade ao processo; (ii) a incorporação de técnicas avançadas de DL, as quais asseguram elevada acurácia preditiva e capacidade de generalização frente a distintos espaços químicos; (iii) a elevada portabilidade e escalabilidade, que viabilizam sua execução em ambientes computacionais heterogêneos, desde estações de trabalho convencionais até servidores especializados com GPU; e (iv) a implementação de estratégias sistemáticas de priorização de candidatos moleculares, fundamentadas na ordenação orientada ao desempenho multialvo, o que potencializa a eficiência dos processos de triagem e otimização molecular.

4.4 DrugHunter: Integração, Ampliação e Consolidação

No contexto atual da modelagem molecular computacional, a demanda por soluções integrativas, capazes de incorporar de maneira eficiente e harmoniosa todas as fases do processo de descoberta e reposicionamento racional de fármacos, permanece como um desafio ainda não plenamente superado. Tradicionalmente, os *workflows* empregados em TV/HTVS focam predominantemente na execução de etapas isoladas e independentes, dirigidas à resolução de

problemas específicos inerentes a determinados contextos terapêuticos. Embora essa abordagem fragmentada apresente eficácia em aplicações pontuais, sua utilização como solução geral é limitada, fato essencial para o progresso das abordagens *in silico*, sobretudo diante da complexidade multifatorial que caracteriza as patologias emergentes.

Avanços recentes, impulsionados pela crescente incorporação de estratégias baseadas em AIDD, têm promovido transformações substanciais nos paradigmas associados à descoberta e ao reposicionamento racional de compostos por meio de abordagens *in silico*. Tais estratégias têm proporcionado o desenvolvimento de ferramentas computacionais altamente especializadas e eficazes para cada uma das etapas envolvidas no processo de descoberta de fármacos. Entre os principais benefícios, destacam-se os avanços na curadoria sistemática e automatizada de dados, na predição de afinidades moleculares e perfis toxicológicos, bem como na avaliação da estabilidade conformacional de complexos biomoleculares, utilizando simulações de DM.

Entretanto, não obstante a eficácia comprovada das abordagens supracitadas, constata-se que muitas delas ainda negligenciam aspectos fundamentais relacionados à interoperabilidade entre as distintas etapas do fluxo de trabalho. Tal limitação compromete a integração eficiente dos modelos, restringindo sua aplicabilidade em contextos que demandam elevada escalabilidade, robustez e automação dos processos.

Neste contexto, destaca-se o *DrugHunter*, uma arquitetura projetada para a construção de *workflows* dinâmicos e semi-autônomos que integram, ampliam e consolidam as diferentes etapas da análise molecular. Essa plataforma supera o modelo fragmentado tradicional ao estabelecer um fluxo adaptativo e automatizado, que abrange desde a curadoria e pré-análise de dados, realizada com o apoio do *BioMolExplorer*, passando pela predição em larga escala de ancoragem molecular via *NeuroDock*, até a validação das interações mais relevantes por meio de simulações de DM de alto desempenho, executadas com o *OpenMM*.

Com o objetivo de assegurar elevada capacidade de generalização a distintos contextos analíticos, o *DrugHunter* foi desenvolvido para contemplar cinco fases estruturais da análise molecular: (i) curadoria de dados; (ii) pré-análise, que engloba a geração de assinaturas moleculares, o cálculo de similaridade e a análise assistida de toxicidade[5]; (iii) execução de procedimentos de *docking* e *redocking*; (iv) utilização de AIDD através do módulo `MAIA` (*Molecular Artificial Intelligence for Analysis*); e (v) validação das interações moleculares por simulações de DM.

Nesse cenário de múltiplas fases, a arquitetura do *DrugHunter* adota um modelo hierárquico de operacionalização e organização, estruturado em três camadas logicamente interconectadas. Essa concepção confere elevada flexibilidade, capacidade de generalização, reprodutibilidade e extensibilidade, possibilitando a definição personalizada de diferentes *workflows*.

A camada de mais alto nível, denominada **camada de execução e análise**, viabiliza a automatização simplificada e robusta de experimentos computacionais, fornecendo uma interface direta e intuitiva para a aplicação integrada dos métodos de exploração e avaliação de domínios moleculares sobre diferentes alvos terapêuticos. Essa camada é constituída por um conjunto

[5]A análise de toxicidade é realizada com o apoio da ferramenta *DataWarrior*, que fornece avaliações sobre *druglikeness*, mutagenicidade e tumorigenicidade. No *DrugHunter*, essas informações, exportadas em formato CSV, são utilizadas como filtros para compor o domínio molecular analisado.

abrangente de funções e rotinas pré-estabelecidas, cuidadosamente desenvolvidas para contemplar a maioria das análises *in silico* típicas na descoberta racional de fármacos. Dessa forma, o *DrugHunter* exige apenas a definição dos parâmetros experimentais e critérios de interesse, enquanto a arquitetura subjacente gerencia automaticamente a execução das tarefas, o processamento dos dados e a geração dos resultados esperados, sem a necessidade de ajustes finos ou programação adicional. Isso simplifica significativamente o fluxo de trabalho, reduzindo barreiras técnicas para pesquisadores e aumentando a reprodutibilidade e a eficiência das análises computacionais integradas.

Já na camada intermediária, denominada *camada de configuração e adaptação de fluxo*, reside o núcleo flexível responsável pela customização e composição de processos analíticos sob medida. Nessa camada, as diferentes funções e rotinas pré-estabelecidas, organizadas de forma estruturada em classes bem definidas, podem ser reconfiguradas, reparametrizadas e/ou combinadas, viabilizando a construção de fluxos de trabalho ajustados às particularidades e objetivos específicos de cada investigação. Tal modularização favorece a integração de novos métodos e algoritmos, assegurando ampla flexibilidade na modelagem e refinamento dos processos analíticos, sempre preservando a robustez e a coerência sistêmica. Assim, essa camada estabelece-se como um elo fundamental entre a simplicidade operativa da automação de alto nível e a sofisticação técnica das etapas subjacentes, promovendo a versatilidade, extensibilidade e escalabilidade do *DrugHunter* em diversos cenários de aplicação.

Por fim, a **camada de desenvolvimento e expansão** constitui um ambiente especializado, projetado para viabilizar a incorporação sistemática de novas estratégias computacionais, fomentando a evolução contínua e sustentável da arquitetura. Esta camada possibilita a integração eficiente de métodos emergentes, modelos preditivos avançados e abordagens analíticas inovadoras, assegurando que o *DrugHunter* permaneça alinhado às tendências mais recentes em ciência de dados, bioinformática e descoberta racional de fármacos. Sua estrutura modular e extensível facilita a experimentação e a validação de novos componentes, promovendo a adaptabilidade do sistema frente à rápida evolução tecnológica e às demandas específicas de contextos científicos diversos. Nesse contexto, tal camada se estabelece como um pilar essencial para a manutenção metodológica do *DrugHunter*, garantindo sua generalização, escalabilidade e relevância no ecossistema de ferramentas para TV/HTVS e modelagem computacional em bioengenharia e química medicinal.

4.4.1 Arquitetura Modular do DrugHunter

Para viabilizar uma solução amplamente adaptativa, capaz de operar em múltiplas fases e integrar distintas camadas de exploração e desenvolvimento, a arquitetura do *DrugHunter*, representada esquematicamente na Figura 4.3, foi concebida de forma modular e altamente flexível. Essa estrutura abrange de maneira sistemática as diferentes etapas inerentes aos processos de CADD/AIDD, assegurando não apenas a expansão e integração eficiente do sistema, mas também facilitando sua adaptação a variados contextos de análise e exploração molecular. Tal abordagem arquitetural permite a personalização e escalabilidade das operações, promovendo a interoperabilidade entre métodos e modelos diversos, de modo a atender às especificidades e

complexidades das investigações científicas emergentes em descoberta e desenvolvimento racional de fármacos.

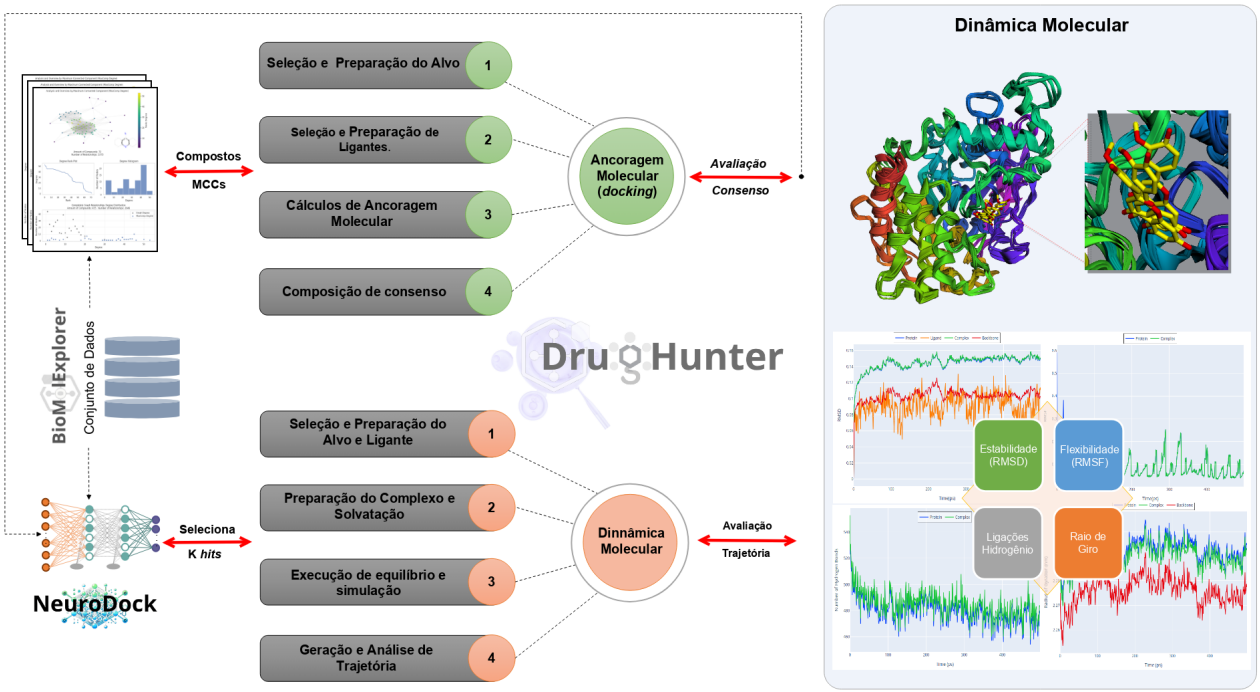

Figura 4.3: Representação esquemática da arquitetura modular do *DrugHunter*. A solução proposta é estruturada em cinco etapas principais: (i) curadoria e pré-processamento de dados químicos e biológicos; (ii) triagem virtual com algoritmos de *docking* molecular; (iii) integração e análise de resultados de *docking/redocking*; (iv) execução e avaliação de simulações de dinâmica molecular; e (v) geração e análise de trajetórias simuladas. Cada módulo foi desenvolvido para operar de forma independente ou integrada, conforme as necessidades específicas de cada estudo, garantindo flexibilidade, escalabilidade e reprodutibilidade.

Como observado na Figura 4.3, além de estabelecer condições adequadas para múltiplos níveis de customização, a modularidade da arquitetura do *DrugHunter* permite que cada etapa do *workflow* seja executada de forma independente ou integrada, conforme as demandas e objetivos específicos de cada estudo em desenvolvimento. Essa característica confere ao sistema uma elevada capacidade de generalização e adaptabilidade, tornando-o particularmente adequado para distintos cenários de TV/HTVS e estratégias de descoberta racional de fármacos.

Nesse contexto de flexibilidade e modularidade, com o propósito de maximizar a interoperabilidade entre os módulos e assegurar a eficiente reutilização de dados, cada etapa do fluxo foi projetada para padronizar sistematicamente seus resultados. Essa padronização permite a incorporação direta de saídas previamente geradas, inclusive por ferramentas ou plataformas externas, em quaisquer pontos do processo, desde que tais dados estejam em conformidade com os formatos e especificações preestabelecidos. Assim, evita-se a necessidade de adaptações adicionais onerosas, promovendo maior eficiência, escalabilidade e robustez na execução dos fluxos experimentais.

Na representação esquemática da Figura 4.3, o primeiro módulo do *DrugHunter*, responsável pela curadoria de dados, fundamenta-se nas especificações metodológicas previamente definidas pela plataforma *BioMolExplorer*. Esse componente foi concebido para viabilizar, de forma eficiente e sistemática, a coleta, organização e filtragem de extensos conjuntos de dados moleculares, assegurando sua qualidade e adequação para as etapas subsequentes de análise. É importante evidenciar que, conforme já apresentado, este módulo opera de maneira autônoma, podendo ser

executado de forma independente, sem a necessidade de ativação imediata das demais fases do fluxo, o que amplia a sua aplicabilidade e flexibilidade em diferentes contextos investigativos.

Adicionalmente, nos casos em que os compostos de interesse já se encontrem previamente disponíveis, esta etapa pode ser omitida, sendo suficiente proceder ao preparo dos dados em conformidade com os padrões de entrada exigidos pela plataforma. Complementarmente, no escopo do *BioMolExplorer*, integra-se o módulo de pré-processamento, cuja função central consiste na geração dos MCCs, definidos como subconjuntos de compostos com elevada similaridade estrutural ou funcional, que constituem a base de moléculas a serem submetidas à etapa de *docking*. É importante salientar que, embora esse procedimento seja altamente eficaz para a racionalização e a otimização do conjunto de compostos, sua execução é opcional, podendo ser suprimida quando não se revelar necessária aos objetivos específicos do estudo em desenvolvimento.

Na sequência, o terceiro módulo compreende as etapas de *docking* e *redocking* molecular, que desempenham um papel central na avaliação da afinidade e da orientação espacial das interações entre ligante e receptor. No contexto da preparação estrutural para a ancoragem, a conversão e adequação dos arquivos no formato PDB são realizadas com o suporte de ferramentas amplamente consolidadas na comunidade científica, como o *UCSF Chimera* e o *OpenBabel*.

O *Chimera* é responsável por operações estruturais fundamentais, incluindo a separação do ligante e do receptor, a adição de hidrogênios, bem como a atribuição de parâmetros adequados de campo de força, garantindo a conformidade e a integridade das estruturas para as etapas subsequentes. Essas funcionalidades são automatizadas no *DrugHunter* por meio de uma coleção de *scripts* parametrizáveis, localizados em `src/scripts/chimera`, cuja definição flexível permite a adaptação a diferentes cenários experimentais. Tal flexibilidade de parametrização possibilita, por exemplo, a inclusão de múltiplas cadeias na análise, a incorporação de cofatores ao receptor, entre outras operações essenciais para o preparo rigoroso do complexo molecular. Como as ações especificadas nos *scripts* correspondem a comandos e funções nativas do *Chimera*, sua composição pode contemplar quaisquer condições previstas na documentação oficial da ferramenta, assegurando assim a robustez, a reprodutibilidade e a escalabilidade do fluxo computacional. Em complemento, o *OpenBabel* é empregado para a conversão dos arquivos estruturais nos formatos exigidos.

Após a preparação dos complexos, é possível realizar a etapa de *redocking* com o auxílio do *AutoDock Vina*, seguida do cálculo sistemático do desvio quadrático médio (RMSD, do inglês *Root Mean Square Deviation*) para cada estrutura, com o objetivo de avaliar a fidelidade na reprodução da pose experimental original. Os resultados obtidos são então compilados em um arquivo CSV padronizado, que reúne informações estruturais essenciais, tais como o código PDB do complexo, a identificação do resíduo ligante, a cadeia, a posição do resíduo, a resolução estrutural e o valor de RMSD. Esse arquivo é inicialmente gerado pelo *BioMolExplorer*, responsável por automatizar a extração dos arquivos PDB dos alvos de interesse e sistematizar as informações estruturais conforme o padrão previamente estabelecido. Antes de sua utilização na etapa de *redocking*, é necessária a realização de uma curadoria manual, com o propósito de eliminar linhas irrelevantes e, assim, evitar cálculos redundantes ou desnecessários, assegurando

que apenas dados pertinentes sejam mantidos para as análises subsequentes. Por fim, o cálculo do RMSD é automatizado com o suporte da ferramenta *PyMOL*, integrada ao fluxo computacional do *DrugHunter* por meio de sua versão *open source*, disponibilizada como biblioteca em *Python*, o que garante maior eficiência, reprodutibilidade e escalabilidade ao processo.

De maneira análoga, a etapa de *docking* é conduzida com base no modelo de consenso previamente apresentado. Nesse contexto, as moléculas selecionadas, organizadas em um arquivo CSV contendo seus respectivos códigos e representações em SMILES canônico, são processadas para a obtenção do *score* de consenso. Para tal finalidade, é possível especificar, entre as parametrizações de execução, o receptor a ser utilizado, bem como o valor de `pH`, o campo de força aplicável e a necessidade de preparação do complexo. Adicionalmente, variáveis específicas, como densidade, distância e raio, parâmetros indispensáveis para simulações conduzidas com o *Dock6*, também podem ser ajustadas conforme as necessidades experimentais. Com o objetivo de maximizar a flexibilidade e a adaptabilidade do processo, o *DrugHunter* disponibiliza um conjunto abrangente de *scripts*, organizados nos diretórios `src/scripts/vina` e `src/scripts/dock6`, que permitem ampla configuração e personalização da execução, de acordo com as particularidades de cada experimento. Cabe ressaltar que, assim como as demais funções descritas até o momento, a etapa de *docking* pode ser operacionalizada de forma integrada ao fluxo completo ou de maneira independente, conferindo ampla aplicabilidade e versatilidade para processos personalizados de exploração.

Uma vez definido o *score* de consenso, inicia-se a execução das predições em larga escala por meio do *NeuroDock*. Nesse estágio, o arquivo CSV contendo os dados provenientes do *docking* por consenso é utilizado como base para a construção do modelo, conforme descrito anteriormente. Após a obtenção das predições, realiza-se uma parametrização adicional, mediante a definição do parâmetro `k_value`, que determina a seleção das K melhores predições identificadas no conjunto completo. Essas predições podem, então, ser utilizadas em avaliações subsequentes, particularmente em processos de simulação por DM. Adicionalmente, conforme mencionado, a operacionalização dos resultados de *docking* direciona a execução para o módulo `MAIA`, permitindo, além do emprego do *NeuroDock*, a aplicação de algoritmos de agrupamento (*clusterização*), com o objetivo de ampliar e aprofundar a exploração sobre o conjunto de compostos analisados.

No âmbito da DM, o *DrugHunter* incorpora como componente de apoio o *OpenMM*, uma biblioteca extensível e de alto desempenho, amplamente reconhecida por sua eficiência na execução de simulações que exploram arquiteturas paralelas, especialmente com suporte a GPUs. A adoção do *OpenMM* no fluxo computacional proposto fundamenta-se na sua capacidade de aliar precisão nas simulações com elevada escalabilidade, características indispensáveis para a condução de experimentos de larga escala e alta complexidade, como aqueles associados aos processos de triagem virtual e refinamento estrutural. Nesse contexto, a arquitetura do *DrugHunter* foi pensada de modo a abstrair as complexidades inerentes à execução de simulações de DM, disponibilizando uma interface simplificada por meio de uma única chamada funcional, a qual define toda parametrização necessária à execução. A Tabela 4.13 detalha os parâmetros disponíveis

para pré-configuração das simulações executadas no ambiente.

Tabela 4.13: Descrição dos parâmetros utilizados na função `execute_md_simulation`, responsável por orquestrar a execução das simulações de DM. A tabela especifica os nomes dos parâmetros, seus respectivos valores padrão e uma descrição funcional, incluindo aspectos relacionados à preparação do sistema, à escolha dos campos de força, à configuração do ambiente termodinâmico, ao ajuste de propriedades do integrador e à definição das condições de saída.

Parâmetro	Valor padrão	Descrição
`receptor_keepWater`	`False`	Define se moléculas de água cristalográfica devem ser mantidas. Pode preservar interações biológicas relevantes.
`ph_value`	7.4	Valor do pH a ser considerado na preparação da estrutura, influenciando a protonação dos resíduos.
`padding_value`	1.0	Margem adicional em torno da caixa de simulação, garantindo afastamento adequado entre a molécula e as bordas do sistema periódico. O tamanho da caixa é ajustado dinamicamente com base no volume ocupado pelo sistema biomolecular (complexo proteína-ligante, por exemplo), somando o valor do *padding* como margem;
`ionic_strength`	0.15	Força iônica da solução, empregada na adição de íons para mimetizar condições fisiológicas.
`neutralize`	`True`	Define se a carga total do sistema deve ser neutralizada mediante adição de contra-íon(s).
`solvatation`	`True`	Indica se o sistema será solvatado com moléculas de água explícitas.
`water_model`	`TIP3P`	Modelo de água utilizado. O TIP3P é amplamente validado e compatível com diversos campos de força. No *DrugHunter* o objeto `SolvationWaterModel` define os diferentes modelos aplicáveis.
`box_shape`	`dodecahedron`	Formato geométrico da caixa de simulação, sendo aceitos `cubic`, `orthorhombic`, `truncated_octahedron`, `rhombic_dodecahedron` e `custom` em conformidade com documentação do OpenMM.
`protein_forcefield_xml`	`AMBER_FF14SB`	Campo de força aplicado à proteína. No *DrugHunter* o objeto `ProteinForceField` define os diferentes modelos aplicáveis.
`solvent_forcefield_xml`	`TIP3P`	Campo de força para o solvente, coerente com o modelo de água escolhido. No *DrugHunter* o objeto `WaterForceField` define os diferentes modelos aplicáveis.
`ligand_forcefield`	`openff_2.0.0`	Campo de força aplicado ao ligante. No *DrugHunter* o objeto `LigandForceField` define os diferentes modelos aplicáveis.
`constraints`	`HBonds`	Restrições estruturais aplicadas para acelerar a simulação, sendo permitido também o uso de `AllBonds`.
`rigidWater`	`True`	Define se as moléculas de água devem ser mantidas rígidas durante a simulação.
`removeCMMotion`	`True`	Especifica a remoção do movimento do centro de massa, evitando translações globais do sistema.
`use_periodic_boundary`	`True`	Aplica condições de contorno periódicas. Essencial para simular um sistema em volume contínuo e evitar efeitos de borda.
`nonbondedCutoff`	1.0	Distância de corte para interações não-ligantes. Valor típico que equilibra precisão e desempenho computacional.
`ewaldErrorTolerance`	5×10^{-4}	Tolerância para o método PME (Ewald). Define a precisão na resolução de interações eletrostáticas de longo alcance via PME*.
`useDispersionCorrection`	`True`	Aplica correção para energia de dispersão. Relevante para representar corretamente a energia de van der Waals em simulações com PME.
`hydrogenMass`	None	Reatribuição da massa do hidrogênio (HMR). Não utilizada por padrão, mas pode permitir passos de integração maiores se aplicada.
`barostat_pressure`	1.0	Pressão de referência (bar) para o barostato, quando em ensemble NPT*.

`barostat_frequency`	25	Frequência de atualização da pressão. Define o intervalo de aplicação da correção de pressão no sistema.
`simulation_temperature`	310	Temperatura de simulação. Define a energia cinética média das partículas. Temperatura fisiológica padrão para estudos em humanos (300 a 310).
`friction_coeff`	1 ps^{-1}	Coeficiente de atrito para o integrador Langevin. Controla o acoplamento térmico do sistema com o ambiente. Valor informado como ponto flutuante (e.g., 1.0).
`integration_step`	1 fs	Passo de integração da simulação. Valor balanceado para precisão temporal e estabilidade numérica.
`integrator_tolerance`	10^{-5}	Tolerância de erro numérico do integrador. Define a precisão das integrações numéricas do sistema.
`equilibration_duration_steps`	10000	Número de passos destinados à etapa de equilíbrio do sistema.
`production_duration_ns`	10 ns	Duração da fase produtiva da simulação em nanosegundos (ns).
`use_HMR`	`False`	Indica a aplicação de HMR*.
`externalForce_constrain_kJ`	None	Valor de força aplicada (k) externamente para restrição (em kJ/mol/nm^2). Útil em protocolos com ancoragem ou simulações direcionadas. Também conhecida como função de harmonização ($k * ((x - x_0)^2 + (y - y_0)^2 + (y - y_0)^2)$).
`restraint_target_atoms`	['CA', 'N', 'C', 'O']	Átomos-alvo para aplicação de restrição. Foco no esqueleto da proteína (backbone) para minimizar desvios estruturais globais.
`restraint_axes`	['x','y','z']	Eixos de aplicação da força de restrição harmônica. Todos os eixos por padrão, podendo ser configurados para restrições direcionais.
`standard_amino_acids`	None	Lista de resíduos para os quais as restrições externas são válidas. Evita aplicação indevida em ligantes ou íons ao mesmo tempo que facilita a utilização das forças em co-fatores, quando aplicável.
`platform_name`	`CUDA`	Plataforma padrão de *hardware* utilizada para a simulação. Em caso de não existência, a CPU é automaticamente selecionada. No *DrugHunter* o objeto `MDPlatform` define os diferentes modelos aplicáveis.
`reporting_interval_steps`	1000	Intervalo de passos entre a geração de relatórios de simulação.
`checkpoint_interval_steps`	10000	Frequência de geração de arquivos de *checkpoint*.
`enforcePeriodicBox_dcd`	`True`	Define se a periodicidade deve ser imposta na escrita de trajetórias no formato DCD*.

*None: Parâmetros para os quais não há valores predefinidos, exigindo atribuição em conformidade com o objetivo do experimento.

*PME: Particle Mesh Ewald.

*HMR: Hydrogen Mass Repartitioning.

*NPT: Número de Partículas, Pressão, Temperatura constantes.

*DCD: Dynamics Coordinate Data.

Conforme apresentado na Tabela 4.13, observa-se a diversidade de parametrizações disponíveis e configuráveis no *DrugHunter*. Visando simplificar e padronizar diversas dessas atribuições, a arquitetura, em sua versão mais recente, estabelece um conjunto de classes específicas para ações como: seleção da plataforma computacional; definição dos campos de força para o solvente e para as macromoléculas; especificação do modelo de água para solvatação; determinação do campo de força aplicado ao receptor e ao ligante; além da configuração de modelos de forças implícitas de solvatação e dos tipos de interações consideradas durante a análise das relações ligante-receptor. Tal abordagem promove a padronização e a simplificação das chamadas para atribuições parametrizadas, como `platform_name`, `protein_forcefield_xml`, `ligand_forcefield_xml` e `water_model`, contribuindo para maior reprodutibilidade, legibilidade

e modularidade no fluxo de simulações implementado.

Dadas as parametrizações necessárias para a execução das simulações de dinâmica molecular (DM), obtém-se, como resultado desta etapa, um conjunto abrangente de representações gráficas, as quais auxiliam na análise detalhada do comportamento das interações moleculares ao longo do tempo. Entre essas representações, destacam-se: a análise da estabilidade do complexo por meio do cálculo do Desvio Quadrático Médio (RMSD); a avaliação da flexibilidade estrutural via o Fator de Flutuação Quadrática Média (RMSF); o monitoramento dinâmico das ligações de hidrogênio; e a evolução temporal do raio de giro (Rg, do inglês, *Radius of Gyration*) (Figura 4.3).

Adicionalmente, uma página interativa em formato HTML é gerada, contendo a descrição detalhada das conformações molecularmente relevantes, correspondentes ao primeiro *frame*, ao *frame* extraído do ponto médio da simulação, e ao último *frame* obtido. Essa visualização permite identificar os tipos de interações predominantes, bem como outras informações estruturais pertinentes à composição do sistema. Complementarmente, é apresentada uma sobreposição estrutural dos referidos estados conformacionais, favorecendo uma análise comparativa mais robusta e ampliando as possibilidades de interpretação dos resultados gerados pela simulação.

Tais recursos integrados à arquitetura do *DrugHunter* proporcionam uma maximização das capacidades de avaliação e de precisão na identificação de potenciais *hits*, que poderão ser posteriormente validados em etapas subsequentes, empregando estratégias experimentais *in vitro* e *in vivo*.

4.5 Considerações Finais

Neste capítulo foi apresentado, no máximo rigor de detalhes, à descrição da arquitetura computacional que compõe a solução denominada de *DrugHunter*, um fluxo de trabalho computacional integrado, concebido e desenvolvido com o objetivo de sistematizar e otimizar etapas cruciais nos processos contemporâneos de descoberta e reposicionamento de fármacos. Ao introduzir sua arquitetura, foram detalhadas suas funcionalidades e componentes primários: o *BioMolExplorer*, voltado à curadoria, preparação e análise de bases de dados biomoleculares; e o *NeuroDock*, uma ferramenta de ancoragem molecular baseada em modelos de DL, projetada para a predição eficiente e escalável de interações ligante-receptor.

Ao decorrer das discussões, evidenciou-se, por diversas vezes, a composição modular e flexível do *DrugHunter*, a qual permite a integração entre as soluções computacionais acima citadas com metodologias tradicionais de *docking*, *redocking* e simulações de DM, todas combinadas para a composição de uma solução de alto desempenho. Nesse cenário, foram discutidas as estratégias implementadas de paralelização e otimização, fundamentais para assegurar a escalabilidade, a eficiência computacional e a viabilidade do processamento de extensos repositórios de dados biomoleculares, um requisito indispensável frente à complexidade e à heterogeneidade das doenças emergentes, multifatoriais e de difícil conduta terapêutica. Adicionalmente, elucidou-se a robustez e a reprodutibilidade proporcionadas pela solução desenvolvida, que oferece um ambiente sistemático para a condução de estudos no contexto da CADD e da AIDD,

desde a recuperação e curadoria iniciais dos dados até a validação e refinamento das interações moleculares por simulações de DM.

A trajetória metodológica que resultou no *DrugHunter* foi orientada pela superação de limitações inerentes aos fluxos de análise tradicionais, promovendo avanços significativos em termos de eficiência operacional, reprodutibilidade experimental e adaptabilidade a distintos contextos exploratórios. A ênfase na interoperabilidade entre os módulos e na padronização dos formatos de entrada e saída visa não apenas facilitar a integração com outras ferramentas computacionais, mas também assegurar a reutilização e a rastreabilidade dos resultados. Tais atributos consolidam o *DrugHunter* como uma plataforma versátil, robusta e estrategicamente alinhada às demandas contemporâneas da pesquisa em modelagem molecular e no desenvolvimento racional de fármacos.

Concluída a apresentação detalhada da proposta de arquitetura modular do *DrugHunter*, suas funcionalidades e seus fundamentos metodológicos subjacentes, o próximo capítulo se dedicará à apresentação e discussão dos resultados obtidos mediante a aplicação deste fluxo de trabalho integrado, tendo como estudo de caso a DA. Serão demonstradas as potencialidades da plataforma na identificação e caracterização de moléculas com perfil terapêutico multialvo, evidenciando não apenas a relevância científica da abordagem, mas também sua aplicabilidade prática no contexto da descoberta racional e acelerada de novos fármacos.

Capítulo

5

Aplicação do DrugHunter à Descoberta de Inibidores Multialvo para a Doença de Alzheimer

5.1 Considerações Iniciais

Este capítulo tem como objetivo apresentar e analisar os resultados obtidos com a aplicação do *DrugHunter* na descoberta de inibidores multialvo, no contexto da TV/HTVS, destacando sua capacidade integrativa e automatizada em fluxos computacionais orientados para o CADD e para a AIDD. Para a validação do modelo proposto, foi conduzido um estudo de caso associado à DA, cuja escolha fundamenta-se tanto na elevada prevalência quanto na reconhecida complexidade etiopatológica associada a essa condição. Nesse contexto, foram investigados três alvos terapêuticos de reconhecida relevância: AChE, BChE e BACE1, em razão de sua importante participação nos processos fisiopatológicos que resultam no declínio cognitivo característico da doença, conforme discutido no Capítulo 2.

A aplicação do *DrugHunter*, cuja necessidade e relevância estão fundamentadas no Capítulo 3 e cuja metodologia é detalhada no Capítulo 4, foi estruturada como um fluxo computacional integrado e automatizado, que se inicia com a extração e curadoria sistemática de dados moleculares relacionados aos alvos terapêuticos selecionados, estendendo-se até a realização de simulações de DM, utilizadas como ferramenta para a validação e o refinamento na seleção de compostos multialvo promissores (*hits*).

Esse fluxo incorporou procedimentos de *docking*, *redocking* e análises baseadas em redes de interação molecular, configurando uma abordagem abrangente, orientada à ampliação das observações e à maximização do potencial preditivo das estratégias adotadas. Destaca-se, nesse

escopo, a utilização de análises topológicas e funcionais das redes de interação molecular, que permitiram a elucidação de características físico-químicas e estruturais relevantes do conjunto de compostos investigados, com especial ênfase na identificação de fragmentos comuns, por meio da investigação dos MCCs, detalhando subestruturas recorrentes (*scaffold splitting*), recuperadas da avaliação de similaridade molecular e detecção de padrões de sobreposição estrutural entre bioativos e seus análogos, ambos relacionados aos alvos terapêuticos em observação.

Complementarmente, a efetividade das predições geradas nas etapas de ancoragem molecular em larga escala, conduzidas pelo módulo `MAIA` com o suporte do *NeuroDock*, é validada por simulações de DM, conferindo maior robustez aos resultados e sustentação às inferências obtidas. No escopo das soluções de IA aplicadas à descoberta de fármacos (AIDD) implementadas no `MAIA`, tem-se algoritmos de clusterização para mapear e organizar topologicamente o espaço químico de alta dimensionalidade delineado pelas distintas estratégias de representação molecular por *fingerprints*. Esse mapeamento é viabilizado com o apoio de técnicas de redução de dimensionalidade, tanto lineares quanto não lineares, tais como a PCA[1] e o t-SNE[2], permitindo uma caracterização acurada da distribuição do domínio químico, especialmente daquele utilizado para o treinamento dos modelos de aprendizado profundo. Além disso, essas abordagens de projeção química ampliam a capacidade de exploração de famílias recorrentes de fragmentos moleculares, favorecendo a identificação de *scaffolds* dominantes e subsidiam análises de relações estrutura-atividade (SAR), ao agrupar compostos que compartilham padrões estruturais ou funcionais. Também permitem a detecção de potenciais *outliers* e anomalias, contribuindo significativamente para uma compreensão mais aprofundada da composição e do balanceamento do conjunto de dados utilizado ao longo do fluxo computacional.

Este capítulo, portanto, apresenta as etapas do fluxo de trabalho, em grande parte automatizadas pela plataforma *DrugHunter*, destinadas à aquisição, exploração, validação e refinamento de domínios químicos. Também são descritas as moléculas priorizadas pelo potencial bioativo (*hits*), com destaque para a estratégia de inibição multialvo, considerada promissora no tratamento da DA. Os experimentos apresentados foram realizados em ambiente Ubuntu 24.04, utilizando processador Intel i9, 64 GB de RAM e GPU Quadro 4000.

5.2 Aquisição e Curadoria de Dados Moleculares

A aquisição sistemática e a curadoria criteriosa de dados moleculares constituem etapas fundamentais para a construção, consolidação e validação do fluxo computacional proposto, evidenciando sua robustez, reprodutibilidade e desempenho no contexto do CADD, sendo igualmente indispensáveis para a caracterização dessas propriedades sob a ótica das soluções AIDD, as quais se encontram integradas como componentes estruturantes da plataforma *DrugHunter*.

Neste estudo, a delimitação e construção do domínio molecular para a DA fundamentaram-se na utilização de dados amplamente reconhecidos e explorados pela comunidade científica. A partir do PDB, principal repositório de estruturas tridimensionais de biomoléculas, foram extraídos os complexos macromoleculares empregados nas análises de *docking* e DM. Por sua

[1] *Principal Component Analysis* (GREENACRE et al., 2022)
[2] *t-distributed Stochastic Neighbor Embedding* (BALAMURALI, 2023)

vez, as bases ChEMBL e ZINC, comumente utilizadas na composição de bibliotecas moleculares para TV/HTVS, forneceram os compostos utilizados nas etapas de modelagem e exploração realizadas por meio do módulo `MAIA`.

A seleção dessas bases foi fundamentada não apenas em sua elevada representatividade e diversidade estrutural, mas também na disponibilidade de dados experimentais relacionados a interações proteína-ligante, parâmetros físico-químicos, perfis de bioatividade e caracterizações de compostos análogos. Elementos essenciais para o delineamento de domínios moleculares abrangentes e informativos, ampliando, assim, as probabilidades de identificação de compostos candidatos com potencial multialvo, característica particularmente relevante no contexto terapêutico da DA.

Para tanto, a etapa de curadoria levou em consideração procedimentos sistemáticos de refinamento, padronização e organização dos dados moleculares, com o objetivo de assegurar a integridade estrutural das moléculas, eliminar redundâncias e adequar o domínio químico aos objetivos do estudo. Entre as ações executadas, destacam-se: (i) a conversão entre diferentes formatos moleculares, (ii) a correção dos estados de protonação em `pH` fisiológico, (iii) a inclusão de hidrogênios explícitos, (iv) a atribuição de campos de força apropriados e (v) a remoção de moléculas de solvente não estruturais. Ações essas conduzidas de forma automatizada pela plataforma *DrugHunter*, a qual, sempre que possível, buscou utilizar como base a representação canônica das moléculas por meio de SMILES e/ou dados dos complexos biomoleculares, extraídos diretamente da base PDB.

5.2.1 Recuperação e Análise dos Complexos Biomoleculares

Neste trabalho, as estruturas tridimensionais das enzimas AChE, BChE e BACE1 foram selecionadas com base em critérios que assegurassem, de forma simultânea, a qualidade estrutural, a relevância funcional e a adequação conformacional dos complexos biomoleculares empregados nas etapas subsequentes de modelagem computacional. Para isso, foram consideradas como restrições: (i) a exigência de elevada resolução cristalográfica, garantindo precisão nas coordenadas atômicas; (ii) a presença obrigatória de ligantes co-cristalizados, imprescindíveis para a delimitação acurada do sítio ativo e para a avaliação das interações intermoleculares no contexto nativo; (iii) a ausência de mutações artificiais ou artefatos estruturais, assegurando a fidedignidade conformacional necessária aos procedimentos de ancoragem e simulação; e (iv) a anotação funcional consistente com a atividade enzimática de interesse, verificada por meio do código *Enzyme Commission* (EC), a fim de garantir que a conformação cristalográfica reflita adequadamente a função biológica da proteína-alvo.

Adicionalmente, foram priorizadas estruturas de origem humana, com o intuito de maximizar a aplicabilidade translacional dos resultados no contexto fisiopatológico da DA. Ao final desse processo, foram recuperados 10 complexos para a AChE, 4 para a BChE e 55 para a BACE1. A Tabela 5.1 apresenta as parametrizações utilizadas na função `load_pdb`, integrante do arcabouço computacional *DrugHunter*, responsável pela automatização das etapas de recuperação, filtragem e padronização das estruturas cristalográficas selecionadas.

Uma vez recuperadas, as estruturas identificadas foram submetidas a um processo de cu-

Tabela 5.1: Parâmetros empregados na configuração da função `load_pdb` para a recuperação automatizada das estruturas cristalográficas das enzimas-alvo. As consultas foram restringidas exclusivamente a estruturas de proteínas determinadas por difração de raios X, com resolução máxima de 2,0 Å, e que apresentam, em sua composição estrutural, ligantes cocristalizados como parte de sua estrutura.

Parâmetro	**Acetilcolinesterase**	**Butirilcolinesterase**	**Beta-secretase 1**
`target`	"`Acetylcholinesterase`"	"`Butyrylcholinesterase`"	"`Beta-secretase1`"
`pdb_ec`	3.1.1.7	3.1.1.8	3.4.23.46
`organism`	"`Homo sapiens`"	"`Homo sapiens`"	"`Homo sapiens`"
`PolymerEntityTypeID`	`PROTEIN`	`PROTEIN`	`PROTEIN`
`ExperimentalMethodID`	`X_RAY_DIFFRACTION`	`X_RAY_DIFFRACTION`	`X_RAY_DIFFRACTION`
`max_resolution`	2.0	2.0	2.0
`must_have_ligand`	`True`	`True`	`True`

radoria semi-autônomo para a sua preparação estrutural, composto pelas seguintes etapas: (i) verificação e correção das identificações automáticas empregadas para, ligantes, receptores, cadeias enzimáticas e resolução do complexo, com a edição ou remoção manual de entradas incorretas ou redundantes a partir da edição do arquivo de mapeamento em formato CSV, sempre que necessário; (ii) adição de hidrogênios com base em um `pH` fisiológico de 7.4, adotado uniformemente em todos os experimentos por sua representatividade em condições biológicas padrão, sendo amplamente referenciado na modelagem de sistemas *in vitro* e *in vivo*; (iii) definição dos estados de ionização e atribuição de cargas parciais, utilizando o modelo `ff14SB` para os receptores, com cargas de Gasteiger (`gas`), escolhidas por sua eficiência em processos automatizados e o parâmetro de carga AMBER (`am1`) para os ligantes, assegurando compatibilidade metodológica com as etapas subsequentes de *docking* e simulações de DM; e (iv) remoção seletiva de moléculas de água e solventes, mantendo-se apenas aquelas diretamente envolvidas na estabilização da conformação nativa ou na arquitetura funcional do sítio de ligação.

Concluídas as etapas de refinamento e preparação, os complexos biomoleculares foram submetidos a experimentos de *redocking* com o *AutoDock Vina*, com o objetivo de validar a integridade estrutural dos modelos e avaliar a capacidade de reprodutibilidade do modo de ligação observado nas estruturas cocristalizadas. A Tabela 5.3 apresenta um resumo dos principais resultados obtidos nessa etapa, destacando os valores de RMSD correspondentes ao melhor subconjunto de alvos terapêuticos identificado para cada uma das enzimas investigadas.

Tabela 5.3: Resultados de *redocking* molecular para os complexos proteína-ligante correspondentes aos alvos terapêuticos AChE, BChE e BACE1. A análise considera as estruturas cristalográficas utilizadas como referência, incluindo o código PDB, o ligante ancorado, o número e a cadeia do resíduo chave, e a resolução experimental da estrutura. A métrica de avaliação principal foi o RMSD entre a conformação obtida do *AutoDock Vina* e a cristalográfica, sendo o menor valor de RMSD destacado em verde para evidenciar a melhor correspondência estrutural obtida.

Target	**PDB**	**Ligante**	**RESNUM**	**Cadeia**	**Resolução**	**RMSD (Å)**
AChE	4M0E	1YL	604	A	2.00	0.15
	6EUE	1PE	701	A	2.00	5.10
	6H14	FW8	610	A	1.86	0.96
	7AIS	8UH	601	A	1.75	3.08
	7AIW	8U5	601	A	1.90	4.51
BChE	1P0I	BUA	606	A	2.00	1.77
	6QAA	HUN	613	A	1.90	4.65
	7AWG	S6Q	605	A	2.00	6.13

BACE1	2IQG	F2I	801	A	1.70	0.38
	2QMD	CS7	1	A	1.65	0.43
	3UDH	091	501	A	1.70	0.35
	3VF3	0GS	401	A	1.48	0.42
	4B72	2FB	1503	A	1.60	0.42
	4ZPE	4QA	501	A	1.70	0.25
	5HE5	60S	502	A	1.55	0.17
	5HE4	60T	501	A	1.53	0.22

Os resultados obtidos nos experimentos de *redocking* (Tabela 5.3) evidenciaram níveis satisfatórios de reprodutibilidade do modo de ligação observado nas estruturas co-cristalizadas para os complexos selecionados, com destaque para a AChE (`PDB ID`: 4M0E; `RMSD` = 0.15 Å) e a BACE1 (`PDB ID`: 5HE5; `RMSD` = 0.17 Å), cujos valores de RMSD se mostraram amplamente compatíveis com os critérios de validação estrutural estabelecidos na literatura. Embora o complexo adotado para a BChE (`PDB ID`: 1P0I) tenha apresentado um valor de `RMSD` relativamente mais elevado (1.77 Å), este ainda se manteve dentro de um intervalo aceitável para fins exploratórios, sendo considerado o modelo mais adequado entre as alternativas avaliadas.

Dessa forma, os três complexos biomoleculares validados foram adotados como estruturas de referência para as etapas subsequentes do fluxo computacional, aplicados sobre os conjuntos de dados ChEMBL e ZINC recuperados nas respectivas bases. A seção seguinte descreve os critérios e procedimentos utilizados na extração e preparação de pequenas moléculas a partir das bases ChEMBL e ZINC, que comporão as bibliotecas químicas empregadas na triagem *in silico* frente aos alvos estruturais aqui definidos.

5.2.2 Recuperação de Compostos da ChEMBL e ZINC

De forma análoga à estratégia adotada para a seleção das estruturas do PDB, a extração de compostos nas bases de dados ChEMBL e ZINC foi conduzida com base em critérios de refinamento específicos, de modo a alinhar o domínio químico recuperado às particularidades do presente estudo, especialmente no contexto da DA e dos alvos moleculares previamente definidos. No caso da base ZINC, conforme previamente descrito, adotou-se um processo semi-autônomo para a recuperação dos compostos de interesse. Inicialmente, os compostos são selecionados manualmente por meio da interface do ZINC, sendo extraídos os respectivos links de referência. Esses links são, então, utilizados como entrada nos scripts automatizados do *DrugHunter*, que realizam a coleta dos dados e a construção da base química. A partir desse processo, foram obtidos aproximadamente 14 milhões de compostos, considerando como critério de filtragem apenas aqueles disponíveis em estoque.

No *DrugHunter* a coleta de dados da ChEMBL foi realizada por meio da especificação das referências nominais "`Acetylcholinesterase`", "`Beta-secretase 1`" e "`Butyrylcholinesterase`", atribuídas ao parâmetro `target_name` da função `load_chembl`, integrada à plataforma *DrugHunter*. A definição desses nomes segue estritamente as nomenclaturas padronizadas utilizadas pela base ChEMBL, uma vez que a identificação correta dos alvos depende da correspondência exata entre o valor fornecido e o campo `target_name` dos registros oficiais.

Com o objetivo de assegurar a especificidade e a qualidade dos dados extraídos para cada alvo

terapêutico, foram aplicados filtros complementares, configuráveis no arquivo `src/scripts/-crawlers/target.json`, por meio da definição dos seguintes parâmetros: `organism` = "Homo sapiens", `type_in` = ["SINGLE PROTEIN"] e `relationship_type` = "DIRECT". Tais critérios garantiram a recuperação exclusiva de registros associados a proteínas humanas de natureza uniprotéica, cuja correspondência com o nome do alvo (`target_name`) ocorre de forma estrita e literal, ou seja, o nome pesquisado na base deve ser rigorosamente idêntico ao fornecido como referência. Como resultado da aplicação desses filtros, foram identificados e extraídos os seguintes códigos de alvos terapêuticos: **CHEMBL220**, **CHEMBL1914** e **CHEMBL4822**, correspondentes, respectivamente, às referências AChE, BChE e BACE1.

Uma vez recuperadas em arquivos estruturados no formato `JSON`, as referências dos alvos terapêuticos anteriormente citados foram submetidas a um processamento automatizado pela plataforma *DrugHunter*, com o objetivo de realizar a identificação sistemática e acurada das listas de compostos bioativos associados a cada alvo investigado. A partir dessa recuperação inicial, procedeu-se à etapa de filtragem refinada dos bioativos, com a aplicação de critérios adicionais de seleção voltados à restrição do conjunto de dados a compostos com maior potencial farmacológico e alinhamento direto com os objetivos desta pesquisa. A Tabela 5.6 detalha os filtros empregados no processo de recuperação das moléculas bioativas, as referências de valor adotadas e uma breve descrição sobre sua aplicabilidade sobre o domínio químico explorado.

Tabela 5.6: Parâmetros aplicados na filtragem dos compostos bioativos extraídos da base ChEMBL para cada alvo terapêutico de interesse. Os critérios apresentados foram definidos com o objetivo de restringir o conjunto de dados a moléculas com maior relevância farmacológica, assegurando consistência estrutural, qualidade informacional e comparabilidade entre os registros. Tais parâmetros encontram-se especificados nos arquivos `src/crawlers/bioactivity.json` e `src/crawlers/molecules.json`, os quais integram o núcleo automatizado de curadoria da plataforma *DrugHunter*.

Parâmetro	Valor	Descrição
`standard_type_in`	$[K_i]$	Restringe os registros a medidas padronizadas de afinidade molecular, garantindo valores consistentes e interpretáveis. O uso de listas entre colchetes indica possibilidade de expansão (ex.: ["K_i", "IC_{50}", "EC_{50}", ...]), conforme a natureza e disponibilidade dos dados.
`molecule_type`	`small molecule`	Limita a extração a compostos de baixa massa molecular, mais apropriados para triagem virtual e com maior viabilidade farmacológica.
`max_value_ref`	1000	Define o valor máximo de referência para medidas de inibição, restringindo o conjunto a compostos com maior afinidade potencial (e.g., $K_i \leq 1000$ nM).
`standard_units`	nM	Uniformiza a unidade de medida dos registros extraídos, assegurando coerência na comparação entre valores de afinidade.
`natural_product`	0	Filtragem de produtos naturais, por meio da definição do parâmetro 0 (onde 1 indicaria inclusão). Tal escolha teve por objetivo evitar a inserção de estruturas de origem natural, que, embora possuam reconhecida relevância farmacológica, poderiam aumentar a variabilidade química e comprometer a uniformidade estrutural requerida para as análises comparativas deste estudo.

Com base nos compostos previamente recuperados sob as restrições descritas na Tabela 5.6, a etapa subsequente consistiu na extração dos análogos estruturais, utilizando como referência os identificadores únicos associados a cada molécula bioativa. De forma equivalente ao processo de filtragem aplicado aos bioativos, a identificação e coleta dos análogos estruturais foram orientadas por um conjunto de critérios combinados, descritos na Tabela 5.8. Esses filtros visaram restringir o espaço químico a compostos estruturalmente relevantes, compatíveis com

os objetivos da análise de similaridade e modelagem multialvo adotada neste estudo.

Tabela 5.8: Parâmetros utilizados na recuperação dos análogos estruturais associados aos compostos bioativos previamente extraídos da base ChEMBL. Os filtros foram definidos com o objetivo de priorizar compostos estruturalmente relevantes, quimicamente viáveis e compatíveis com os critérios farmacocinéticos clássicos, assegurando a coerência do domínio químico. Os parâmetros encontram-se especificados no arquivo `src/crawlers/analogs.json`, utilizado pela plataforma *DrugHunter* para condução automatizada desta etapa.

Parâmetro	Valor	Descrição
`similarity`	`60%`	Define o limiar mínimo de similaridade estrutural entre a molécula de referência e seus análogos, com base nos critérios definidos pela própria base de dados ChEMBL.
`natural_product`	`0`	Exclui compostos naturais (como produtos naturais e alcaloides), com o intuito de manter consistência estrutural e evitar variabilidade excessiva.
`molecule_type`	`small molecule`	Restringe a busca a moléculas de baixo peso molecular, favorecendo a aplicabilidade em estratégias de TV.
`molecule_weight`	$\leq$ `500`	Limita o peso molecular dos análogos, em conformidade com a regra de Lipinski como tentativa de ampliar as características de boa absorção oral e biodisponibilidade.

Os resultados obtidos no processo de aquisição de bioativos e análogos estruturais, fundamentados nos critérios restritivos especificados nas Tabelas 5.6 e 5.8, resultaram na obtenção de um total de 6.304 moléculas, sendo 1.826 classificadas como bioativos e 4.478 como análogos estruturais, todas diretamente associadas aos alvos terapêuticos de interesse.

Com parte do processo sistemático de composição do domínio químico acima citado, critérios adicionais de refinamento foram empregados com o intuito de garantir a integridade estrutural e a consistência informacional do conjunto de moléculas selecionadas. Especificamente, foram excluídas as entradas que apresentavam representações inválidas no formato SMILES, bem como aquelas que apresentavam duplicidade ou inconsistências nas descrições físico-químicas. Esse processo foi integralmente automatizado pela plataforma *DrugHunter*, por meio da aplicação de funcionalidades da biblioteca `RDKit`. As duplicidades foram identificadas mediante análise cruzada das listas de compostos associadas a cada bioativo, considerando-se, como critérios para exclusão, a sobreposição entre os identificadores ChEMBL e as representações SMILES. Essa estratégia visou mitigar ruídos e a elevação da qualidade dos dados processados para as etapas subsequentes do fluxo computacional. A Tabela 5.10 detalha a quantidade de bioativos e análogos estruturais por alvo terapêutico, considerando as restrições e filtros descritos anteriormente.

Tabela 5.10: Distribuição das moléculas bioativas e de seus análogos estruturais recuperadas para cada alvo terapêutico, após a aplicação dos filtros descritos no texto. Os totais referem-se ao número bruto de representações obtidas para cada classe (bioativo $\times$ análogo) e não contabilizam eventuais sobreposições entre compostos, sendo apresentados exclusivamente para ilustrar a amplitude do espaço químico reunido.

Alvo terapêutico	**Bioativos (moléculas)**	**Análogos estruturais**	**Total de compostos**
AChE	450	2.292	2.742
BChE	252	1.473	1.725
BACE1	1.124	713	1.837

Os dados apresentados na Tabela 5.10 evidenciam a presença de um número expressivo de

análogos estruturais com elevada similaridade em relação aos bioativos identificados para cada alvo terapêutico, o que justifica sua inclusão como componente essencial do espaço químico explorado neste estudo. A Figura 5.1 apresenta diagramas de Venn que ilustram as interseções entre os diferentes conjuntos de compostos analisados. À esquerda (a), têm-se as sobreposições entre os bioativos identificados para os três alvos; à direita (c), são representadas as interseções entre os respectivos análogos estruturais. Já ao centro (b), observa-se a distribuição das sobreposições entre bioativos e análogos dentro de cada alvo terapêutico, evidenciando o grau de sobreposição entre os compostos diretamente extraídos e suas respectivas expansões estruturais.

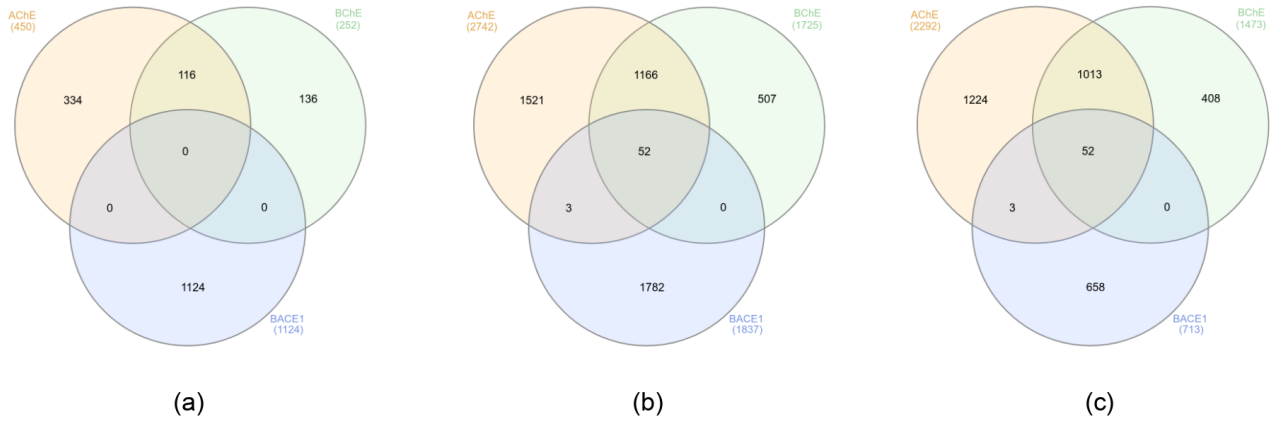

Figura 5.1: Diagramas de Venn representando as interseções entre os conjuntos de compostos obtidos para os três alvos terapêuticos investigados: AChE, BChE e BACE1. À esquerda (a), são ilustradas as sobreposições entre os compostos bioativos, com destaque para a interseção entre AChE e BChE (116 moléculas), e ausência de sobreposição com BACE1. Ao centro (b), tem-se a distribuição conjunta entre bioativos e análogos para cada alvo, evidenciando interseções mais relevantes, como entre AChE e BChE (1.166 compostos), entre AChE e BACE1 (3 compostos) e entre os três alvos simultaneamente (52 compostos). À direita (c), apresentam-se as interseções entre os análogos estruturais, destacando-se novamente a presença de 52 compostos compartilhados entre os três alvos, e a ausência de sobreposição exclusiva entre BChE e BACE1.

Conforme ilustrado na Figura 5.1, observa-se a existência de diferentes graus de sobreposição entre os compostos associados à AChE e aqueles vinculados às enzimas BChE e BACE1, o que reforça as evidências discutidas no Capítulo 2 quanto à essencialidade da AChE na compreensão das caracterizações envolvidas com a DA. Nesse contexto, destaca-se, em particular, a expressiva interseção entre AChE e BChE, delineada por 116 bioativos e 1.013 análogos estruturais compartilhados, sugerindo uma potencial convergência estrutural entre os sítios de ligação dessas enzimas. Esse achado fortalece a hipótese de que uma mesma molécula possa apresentar interações relevantes e comparáveis com ambas as proteínas-alvo, o que é particularmente promissor no contexto da identificação de inibidores multialvo com possível aplicação terapêutica. Por outro lado, a baixa sobreposição observada entre os compostos bioativos de BACE1 e os demais alvos evidencia os desafios inerentes à descoberta de moléculas capazes de atuar de forma simultânea sobre múltiplos sítios de ligação com perfis estruturais distintos. Essa constatação ressalta a complexidade do direcionamento terapêutico multialvo no contexto da DA, sobretudo no que se refere ao balanceamento entre eficácia farmacológica e minimização de efeitos adversos indesejados.

5.2.3 Assinaturas Moleculares e Projeções para Análise Estrutural

Conforme apresentado no Capítulo 4, o *Drug Hunter* foi pensado para comportar uma ampla quantidade de descritores, sendo, para este estudo, considerados aqueles que são capazes de caracterizar a individualidade de cada molécula no domínio, bem como os capazes de reportar os diferentes graus de similaridade existentes no conjunto. Nesse sentido, optou-se por explorar a utilização da assinatura de Morgan para a caracterização dos bioativos e análogos estruturais, enquanto o coeficiente de Tanimoto foi abordado para a definição dos graus de similaridade e identificação dos MCCs para os alvo terapêuticos observados.

Cabe ressaltar que as assinaturas de Morgan foram elaboradas com o tamanho de 2.048 bits, sendo essas empregadas como entrada para a composição das redes de interação, cálculos de similaridade e identificação de sobreposição máxima. A escolha da assinatura é fundamentada no estudo apresentado por Ucak, Ashyrmamatov e Lee (2023), em que o valor adequado para a descrição sem perda de generalização das características físico-químicas moleculares é discutido.

Diante da elevada dimensionalidade das assinaturas moleculares, tornou-se necessário incorporar ao presente estudo técnicas de redução de dimensionalidade, com destaque para a PCA e o t-SNE, ambas integradas à plataforma *DrugHunter*. Tais técnicas foram empregadas com o propósito de gerar representações vetoriais mais compactas, favorecendo tanto as estratégias de agrupamento (clusterização) dos compostos quanto a identificação de padrões estruturais recorrentes no espaço químico analisado. Para cada assinatura molecular, foram derivadas duas projeções distintas: uma utilizando PCA com 8 dimensões, empregada como entrada para os algoritmos de agrupamento, e outra com 2 dimensões por t-SNE, destinada à construção das visualizações bidimensionais apresentadas neste estudo.

A partir dessas representações, procedeu-se à análise relacional entre as moléculas, com base em estratégias de detecção de padrões frequentes em conformidade com trabalhos como (SCALFANI; PATEL; FERNANDEZ, 2022; SANTANA et al., 2020; FASSIO et al., 2019; MEDINA et al., 2017). Nesse contexto, foram construídas redes de inferência estrutural, utilizadas para descrever possíveis sobreposições entre bioativos, compostos análogos e conjuntos moleculares compartilhados entre alvos terapêuticos distintos.

A análise topológica das redes geradas permitiu a caracterização do comportamento dos agrupamentos formados, com ênfase no componente de maior conectividade, identificado como elemento central em cada cenário analisado. Para demonstrar a efetividade do *DrugHunter* em produzir diferentes meios para exploração dos domínios químicos em evidência, a seção seguinte apresenta a discussão detalhada dos alvos terapêuticos, destacando as características estruturais e funcionais relevantes evidenciadas por meio da aplicação desta estratégia analítica.

5.3 Caracterização Topológica e Funcional das Bibliotecas Moleculares

Nesta seção, tratamos em detalhes a análise dos alvos terapêuticos investigados neste estudo, com foco na avaliação da similaridade molecular e na organização topológica das bibliotecas

químicas associadas a cada enzima. Inicialmente, optou-se por examinar o comportamento de cada alvo de forma isolada, com o intuito de abstrair características estruturais e funcionais recorrentes que possam contribuir para a definição de métricas relevantes na identificação de compostos promissores. Na sequência, a análise foi estendida para os subconjuntos moleculares compartilhados entre pares de enzimas, com o objetivo de elucidar propriedades distintivas desses grupos sobrepostos que possam enriquecer o arcabouço preditivo voltado à identificação de inibidores multialvo, com ênfase na estratégia de tripla inibição proposta neste trabalho.

5.3.1 Análise da Acetilcolinesterase

A enzima AChE, conforme discutido anteriormente, é amplamente reconhecida na literatura como um alvo terapêutico fundamental na compreensão da etiopatogênese da DA. Ao investigar sua representatividade na base de dados ChEMBL, conforme ilustrado na Tabela 5.10, foram recuperadas 2.742 moléculas associadas ao alvo, das quais 450 correspondem a compostos bioativos diretamente relacionados à AChE, e os 2.292 restantes compõem o conjunto de análogos estruturais selecionados por similaridade.

Conforme indicado pelos dados da Tabela 5.10 e ilustrado pela Figura 5.1, o domínio químico associado à AChE concentra o maior número absoluto de compostos dentre os alvos terapêuticos analisados. Esse predomínio quantitativo destaca não apenas a robustez do espaço químico explorado para essa enzima, mas também sua centralidade nas sobreposições interalvo observadas. Tal expressividade sugere que a AChE exerce um papel estratégico na identificação de perfis de atividade cruzada, sendo um ponto essencial para o desenvolvimento de inibidores com potencial polifarmacológico.

A relevância da AChE nesse contexto se justifica pela sua participação direta na fisiopatologia da DA, onde sua inibição contribui para o aumento dos níveis sinápticos de acetilcolina, promovendo melhora cognitiva. No entanto, sua importância extrapola a monoterapia, ao demonstrar potencial sinérgico quando associada à inibição de outras enzimas-chave, como a BChE e a BACE1. Nesse contexto, a ampla representatividade do domínio químico da AChE reforça sua viabilidade como elemento estruturante na construção de candidatos terapêuticos multialvo, visando intervenções mais eficazes e duradouras no tratamento da DA.

Com o intuito de investigar a organização estrutural do domínio químico associado à AChE, foi conduzida uma análise relacional baseada em pares de compostos, utilizando como métrica de similaridade o coeficiente de Tanimoto. Esse coeficiente foi calculado por meio de uma função especializada integrada à plataforma *DrugHunter*, a partir das representações moleculares codificadas em *fingerprints*. A aplicação dessa abordagem permitiu a construção de redes de interação molecular, em que as arestas refletem o grau de sobreposição estrutural entre os compostos conectados.

Para uma análise detalhada das relações intra-domínio, foram modeladas duas redes independentes: (a) uma composta exclusivamente por moléculas bioativas; e (b) outra restrita ao conjunto de análogos estruturais. Essa separação visou explorar, de forma comparativa, os padrões de conectividade e redundância estrutural dentro de cada subconjunto, fornecendo subsídios para a identificação de regiões densamente conectadas, que podem representar núcleos

químicos (*scaffolds*) com alto potencial farmacológico.

Para tanto, cada rede de interação foi submetida a análises topológicas, com o intuito de identificar padrões recorrentes de conectividade e características estruturais dominantes, com vistas à definição de assinaturas representativas do espaço químico associado à AChE. Devido à natureza combinatória do problema e à necessidade de otimização computacional, a análise foi restrita a pares moleculares com similaridade $\geq 60\%$, conforme o limiar estabelecido na etapa de aquisição dos análogos. Tal restrição permitiu reduzir a densidade das redes, preservando as interações estruturalmente mais relevantes.

Após a filtragem, foram identificados os componentes de maior conectividade em cada rede (MCCs), os quais foram analisados quanto às características estruturais predominantes e à sua relevância para a identificação de candidatos promissores ao sítio de ligação da AChE. A análise foi conduzida em três etapas sequenciais: (i) caracterização topológica da rede composta por bioativos; (ii) avaliação da rede dos análogos estruturais; e (iii) análise integrada dos dois conjuntos, com base em um arquivo de saída no formato CSV, contendo a sobreposição dos MCCs extraídos nas etapas anteriores. As relações estruturais identificadas e os impactos da integração dos análogos na diversidade do domínio químico são sintetizados na Figura 5.2, a qual resume visualmente os principais resultados e sustenta as interpretações discutidas nesta subseção.

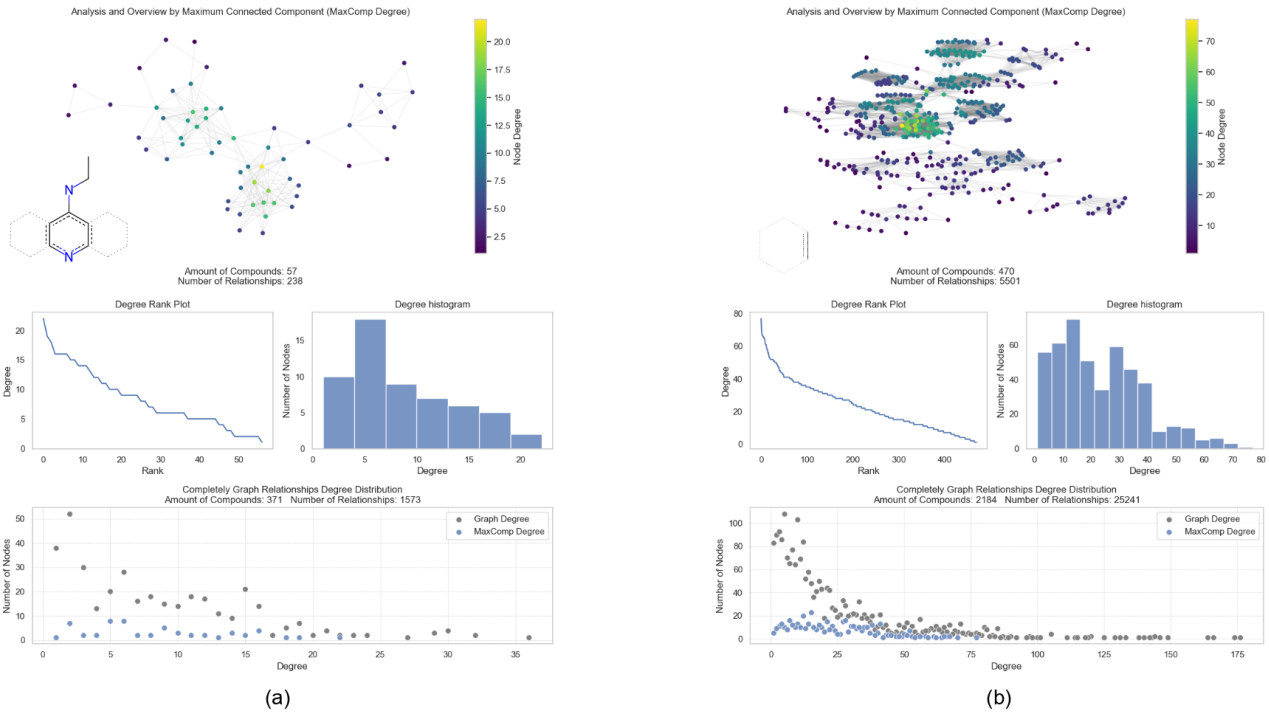

Figura 5.2: Análise comparativa das redes de interação molecular para o alvo terapêutico AChE. **(a)** Rede e gráficos associados para o conjunto de 57 compostos bioativos confirmados. **(b)** Rede e gráficos associados para o conjunto expandido de 473 análogos estruturais. Para ambas as redes, os nós são coloridos de acordo com seu grau (conectividade), e são apresentados os gráficos de *Ranking* de Graus, Histograma de Graus e a Relação de Graus entre os MCCs e as redes de relação completas. No canto inferior esquerdo de cada rede, encontra-se representado o maior fragmento comum identificado, o qual sintetiza a subestrutura recorrente de maior frequência observada entre os compostos analisados, servindo como marcador estrutural representativo das interações mapeadas.

A rede de interações correspondente aos compostos bioativos (Figura 5.2a) delineia um espaço químico predominantemente homogêneo. Constituída por 57 nós e 238 arestas em seu

MCC, a rede exibe uma topologia clássica do tipo *hub-and-spoke*. Essa configuração é caracterizada pela presença de um número restrito de nós centrais altamente conectados, denominados *hubs*, os quais representam os *scaffolds* moleculares mais recorrentes no conjunto analisado. Tais *hubs* funcionam como núcleos estruturais aos quais a maioria dos compostos periféricos está conectada, indicando uma organização centrada em arquiteturas químicas conservadas, possivelmente associadas a padrões robustos de atividade biológica. Nesse contexto, destacam-se como prováveis nós centrais os três compostos com maior grau de conectividade: **CHEMBL3235218**, com 22 interações; **CHEMBL3326704**, com 19; e **CHEMBL3326701**, com 18 conexões. A centralidade dessas estruturas sugere seu papel estratégico na definição da topologia da rede, bem como sua relevância potencial como núcleos estruturais para o desenvolvimento de novos inibidores da AChE.

A análise quantitativa da distribuição dos graus de conectividade reforça as observações qualitativas previamente discutidas. O gráfico de *ranking* para os graus de nós evidencia um padrão de decaimento acentuado, característico de redes dominadas por poucos nós altamente conectados, indicando que um número restrito de compostos concentra a maior parte das interações. Complementarmente, o histograma apresenta assimetria pronunciada, com a maioria dos nós exibindo baixa conectividade (grau ≤ 5), o que é típico de distribuições de cauda longa. Adicionalmente, a sobreposição entre os perfis de grau da rede completa e de seu MCC (MaxComp) revela que o espaço químico bioativo é notavelmente coeso, elucidando que os compostos formam um conjunto fortemente interconectado entre si, configurando-se como uma única e ampla família estrutural inter-relacionada. Isso sugere que os esforços de otimização de ligantes voltados à AChE tendem a convergir para um núcleo estrutural recorrente, refletindo possivelmente um *scaffold* relevante para a atividade inibitória sobre essa enzima.

Em contraste, a rede de análogos estruturais (Figura 5.2b) representa um espaço químico substancialmente mais amplo e diversificado. Seu componente conexo máximo MCC (MaxComp) é composto por 473 nós e 5.501 arestas, números que superam em múltiplas vezes, em especial no número de interações, os observados na rede de bioativos. Essa ampliação resulta em uma topologia mais complexa e distribuída, caracterizada pela presença de diversos agrupamentos locais (*clusters*) com alta conectividade interna, os quais estão pouco relacionados entre si. Embora ainda se observem alguns *hubs*, a conectividade geral é mais heterogênea, refletindo uma distribuição de similaridades mais ampla entre os compostos.

Sob uma perspectiva quantitativa, o histograma de graus exibe uma distribuição assimétrica, com concentração de frequência média em torno de 10 a 20 conexões por nó, mas com cauda longa que se estende até valores significativamente mais elevados. Esse padrão indica que, em média, os compostos análogos compartilham similaridade com um número substancialmente maior de moléculas, evidenciando a exploração de uma diversidade química mais abrangente e a presença de múltiplos *scaffolds* inter-relacionados.

Em termos funcionais, essa rede pode ser interpretada como um domínio exploratório a partir da qual os compostos bioativos foram selecionados e otimizados. Sua maior diversidade estrutural contribui para enriquecer o domínio químico, favorecendo abordagens computacio-

nais baseadas em IA. Ao ampliar a cobertura do espaço químico e reduzir a redundância, tal diversidade pode mitigar problemas como *overfitting*, causado por excesso de similaridade, e *underfitting* decorrente de baixa representatividade estrutural, promovendo maior robustez e capacidade de generalização para modelos preditivos. A Tabela 5.12 detalha um resumo dos dados comparativos entre bioativos e análogos estruturais discutidos.

Tabela 5.12: Comparação estrutural e topológica entre as redes de compostos bioativos e de análogos estruturais associados à AChE. As métricas incluem o número de compostos e de relações no MCC (MaxComp), bem como características topológicas e da distribuição de grau.

Métrica	**Compostos Bioativos (a)**	**Análogos Estruturais (b)**
Nº de Compostos (MaxComp)	57	473
Nº de Relações (MaxComp)	238	5.501
Topologia Principal	*Hub-and-spoke* (Homogênea)	Distribuída / Multi-*cluster* (Diversa)
Distribuição de Grau	Fortemente assimétrica à direita	Ampla e mais dispersa

Validação da Topologia via Análise de Agrupamento

Com o objetivo de aprofundar a caracterização do espaço químico ocupado pelos compostos da AChE e validar as inferências estruturais previamente derivadas da análise topológica das redes, foram aplicadas técnicas de agrupamento baseadas em aprendizado não supervisionado. Especificamente, utilizou-se o algoritmo *KMeans* sobre representações vetoriais previamente reduzidas via PCA, mantendo-se oito componentes principais. A determinação do número ótimo de agrupamentos foi conduzida por meio do método do cotovelo (*elbow method*), que estimou o ponto de inflexão da curva de inércia intra-cluster em função do número de grupos, otimizando a distribuição estrutural.

Todas essas etapas foram executadas de forma automatizada no módulo `MAIA`, pertencente à plataforma *DrugHunter*, exigindo apenas a parametrização inicial do número de componentes a ser preservado na redução dimensional e a seleção do tipo de *fingerprint* molecular. Para as análises aqui apresentadas, manteve-se o uso das *fingerprints* de Morgan.

Com o intuito de facilitar a interpretação visual dos agrupamentos gerados, os rótulos atribuídos pelo algoritmo KMeans, calculados a partir dos vetores projetados via PCA, foram posteriormente utilizados para compor uma representação bidimensional por meio do algoritmo t-SNE. Ainda que o agrupamento tenha sido realizado no espaço vetorial reduzido por PCA, a projeção em t-SNE foi empregada exclusivamente para fins de visualização, permitindo uma representação mais intuitiva e acessível da distribuição dos compostos no espaço químico. Essa abordagem possibilita evidenciar com maior clareza a separação entre os grupos identificados, bem como a dispersão relativa entre diferentes regiões químicas do conjunto analisado por lidar de forma mais adequada com espaços de domínio não lineares.

Os resultados obtidos (Figura 5.3) corroboram diretamente as topologias anteriormente discutidas. Para os compostos bioativos (Figura 5.3a), observa-se uma distribuição concentrada, com formação de poucos grupos bem definidos e espacialmente próximos, sugerindo uma ocupação de um domínio químico restrito e relativamente homogêneo. Este comportamento coeso

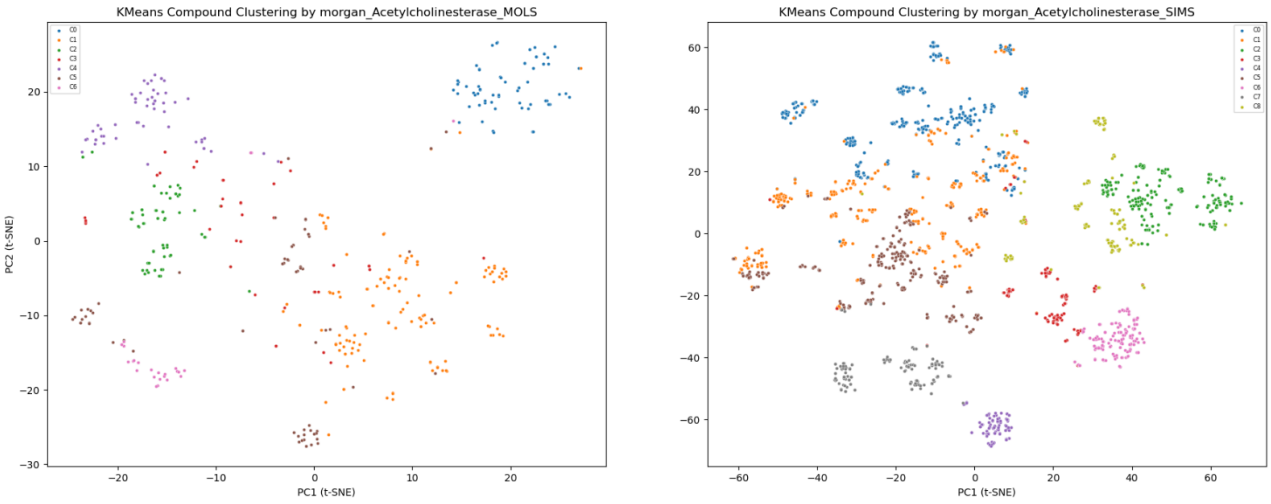

Figura 5.3: Distribuição dos compostos da AChE no espaço químico reduzido via t-SNE, com agrupamentos definidos por KMeans, utilizando o método de *elbow* para definição do número adequado de *clusters* e PCA para a definição dos vetores de classificação: (a) compostos bioativos, (b) compostos análogos.

reforça a estrutura do tipo *hub-and-spoke* observada na rede de interações, além de confirmar a baixa diversidade estrutural intrínseca ao conjunto.

Em contraste, a análise dos compostos análogos (Figura 5.3b) revela a formação de múltiplos agrupamentos dispersos em um espaço químico substancialmente mais amplo, aproximadamente três vezes superior à área ocupada pelos compostos bioativos. Essa maior amplitude é coerente com a topologia distribuída previamente observada na rede de interações, refletindo a coexistência de distintas famílias estruturais conectadas por relações de similaridade molecular. A acentuada heterogeneidade e o maior grau de dispersão entre os *clusters* indicam um espaço exploratório mais amplo e quimicamente diverso. Esses achados complementam e reforçam as evidências previamente discutidas, destacando a importância crítica da caracterização do domínio químico em estudo. Tal caracterização é essencial para orientar adequadamente condutas analíticas subsequentes, sobretudo aquelas fundamentadas em estratégias de IA, cuja eficácia depende fortemente da representatividade e diversidade do conjunto de dados.

5.3.2 Análise da Butirilcolinesterase

Assim como a AChE, a BChE é uma enzima de reconhecida relevância, sendo, de acordo com os achados apresentados no Capítulo 2, responsável pela regulação da neurotransmissão colinérgica por meio da hidrólise do éster butirilcolina, resultando na formação de colina e butirato. Além de sua função fisiológica clássica, a BChE tem despertado crescente interesse científico em virtude de seu envolvimento em processos patológicos relacionados à DA, notadamente pela sua interação com proteínas associadas à formação de placas de beta-amiloide. Além disso, alterações nos níveis de expressão ou atividade dessa enzima têm sido correlacionadas a variantes genéticas específicas, as quais podem influenciar o risco de desenvolvimento ou a progressão clínica da doença.

Dada sua importância terapêutica, a caracterização estrutural e funcional dos compostos que interagem com a BChE configura-se como uma estratégia essencial para o avanço de aborda-

gens em TV/HTVS e no reposicionamento racional de fármacos, especialmente em cenários que demandam intervenções de caráter polifarmacológico. Assim, parte-se da hipótese de que compostos estruturalmente similares tendem a compartilhar propriedades biológicas semelhantes, o que os qualifica como candidatos promissores à atuação multialvo. Nesse sentido, a Figura 5.1 evidencia um número expressivo de compostos presentes simultaneamente nos conjuntos associados à AChE e à BChE, sugerindo não apenas uma possível similaridade entre os respectivos sítios de ligação, mas também a recorrência de *scaffolds* com características estruturais sobrepostas. Tais elementos podem desempenhar papel funcional ao favorecer múltiplas interações moleculares, reforçando seu potencial como ponto estratégico para inibição multialvo.

Ao considerarmos as relevâncias acima citadas, a análise da rede de interações molecular dos compostos da BChE tem como objetivo não apenas revelar padrões estruturais recorrentes locais, mas também orientar a seleção racional de candidatos com propriedades desejáveis. Se confirmadas as hipóteses formuladas, tais compostos são potencialmente promissores a compor bibliotecas químicas com elevada diversidade estrutural e relevância bioativa, contribuindo para aplicações em modelagem preditiva, TV/HTVS e desenho racional de fármacos.

Considerando que o conjunto de moléculas investigadas no domínio químico da BChE apresenta uma quantidade relativamente inferior àquela observada para a AChE, e tendo em vista o expressivo grau de sobreposição entre os respectivos espaços químicos explorados por ambas as enzimas, é plausível inferir que os padrões estruturais e topológicos previamente caracterizados para a AChE também se manifestem, ao menos em parte, no contexto da BChE. Para sustentar essa hipótese, a Figura 5.4 detalha a representação das redes de interação molecular correspondentes aos compostos (a) bioativos e (b) análogos estruturais associados à BChE, permitindo evidenciar as principais propriedades de interação do domínio químico em questão.

A análise dos dados representados na Figura 5.4 revela que, embora o domínio químico associado à BChE seja quantitativamente inferior ao da AChE, os compostos bioativos dessa enzima exibem um número mais elevado de interações, sugerindo uma maior flexibilidade estrutural e diversidade de composição química, possivelmente sustentada por múltiplos *scaffolds*. A rede formada por 85 compostos bioativos e 465 arestas refuta a configuração clássica de topologia *hub-and-spoke*, pois apresenta um grau médio de conectividade superior ao observado para a AChE.

Tal comportamento é corroborado pelas distribuições de grau, tanto no gráfico de *ranking* quanto no histograma, que evidenciam, para os compostos bioativos, uma conectividade menos assimétrica e com maior densidade de nós de grau intermediário. Essa configuração indica uma distribuição mais uniforme de interações entre os compostos, favorecendo o compartilhamento de características estruturais em subgrupos conectados de maneira mais ampla. Além disso, a análise do subconjunto MaxComp, em comparação com a composição completa da rede, mostra a presença de múltiplos agrupamentos discretos, embora espacialmente próximos, em vez de uma nuvem de pontos mais simétrica como ocorre na AChE. Tal característica reforça a noção de que os inibidores bioativos da BChE são estruturalmente mais diversos, o que contribui para uma composição química mais heterogênea e potencialmente mais rica do ponto de vista

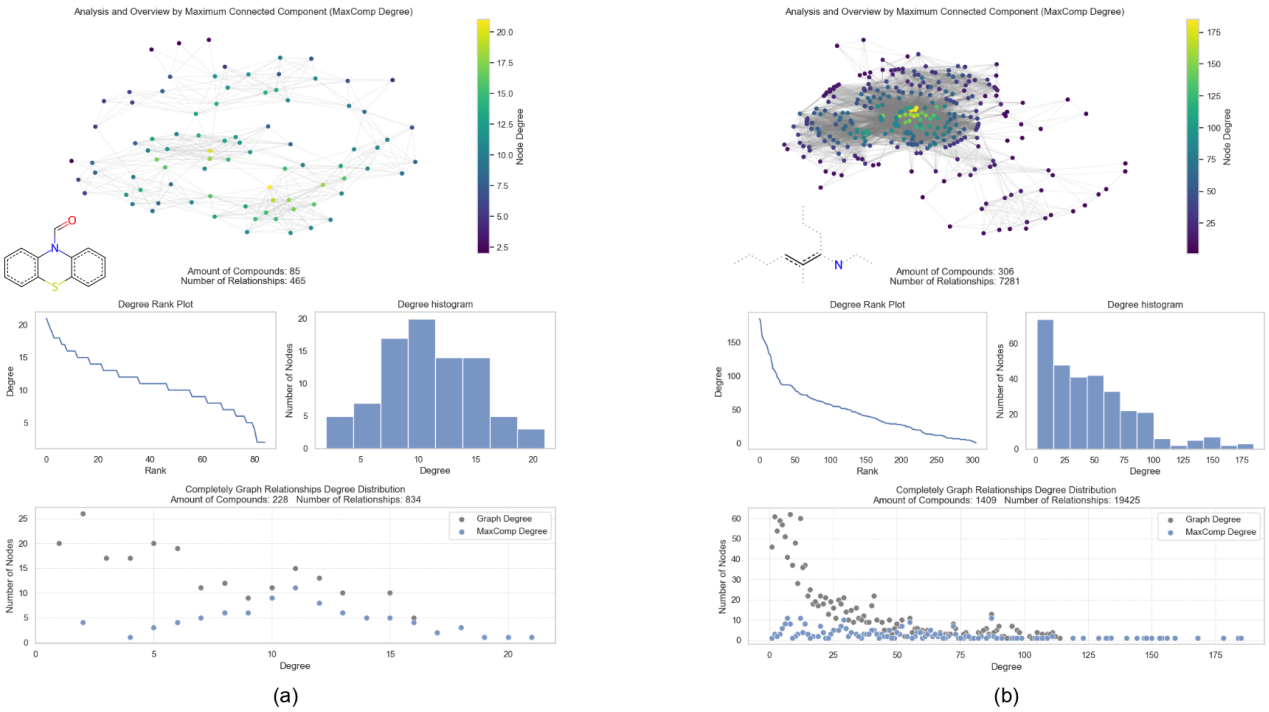

Figura 5.4: Análise comparativa das redes de interação molecular para o alvo terapêutico BChE. (a) Rede e gráficos associados para o conjunto de 85 compostos bioativos confirmados. (b) Rede e gráficos associados para o conjunto expandido de 306 análogos estruturais. Para ambas as redes, os nós são coloridos de acordo com seu grau (conectividade), e são apresentados os gráficos de *Ranking* de Graus, Histograma de Graus e a Relação de Graus entre os MCCs e as redes de relação completas. No canto inferior esquerdo de cada rede, encontra-se representado o maior fragmento comum identificado, o qual sintetiza a subestrutura recorrente de maior frequência observada entre os compostos analisados, servindo como marcador estrutural representativo das interações mapeadas.

farmacofórico e exploratório.

Contudo, assim como na AChE, a rede de análogos da BChE (306 compostos, 7281 relações) é ampla, densa e complexa, o que leva à mesma condição observada no conjunto da AChE, uma topologia definida por um "gigante componente conectado", indicando uma exploração química vasta e diversificada. Quanto aos gráficos de *ranking* e histograma, ambos apresentam uma distribuição ampla, com um número elevado de conexões por nó, o que é esperado para um conjunto de dados de análogos. Tais evidências são reforçadas ao observarmos os agrupamentos de compostos bioativos e análogos estruturais. A Figura 5.5 detalha as condições características desse comportamento.

Conforme evidenciado pelas distribuições apresentadas na Figura 5.5, os dados confirmam as análises anteriormente discutidas. Nota-se, especialmente na composição dos agrupamentos de compostos bioativos (Figura 5.5a), a formação de *clusters* mais definidos e bem delimitados dentro do espaço químico explorado, indicando maior diversidade e abrangência estrutural dos ligantes associados à BChE. Em contraste, os compostos classificados como análogos estruturais (Figura 5.5b) apresentam uma quantidade menor de agrupamentos, embora estes exibam melhor distribuição ao longo do domínio químico, em comparação ao observado para a AChE. Tal padrão sugere uma maior flexibilidade estrutural e uma dispersão topológica mais pronunciada, possivelmente decorrente da plasticidade conformacional superior do sítio ativo da BChE.

Essas diferenças nos padrões de agrupamento e distribuição entre os compostos bioativos de AChE e BChE podem ser explicadas, em grande parte, pelas características estruturais distintas

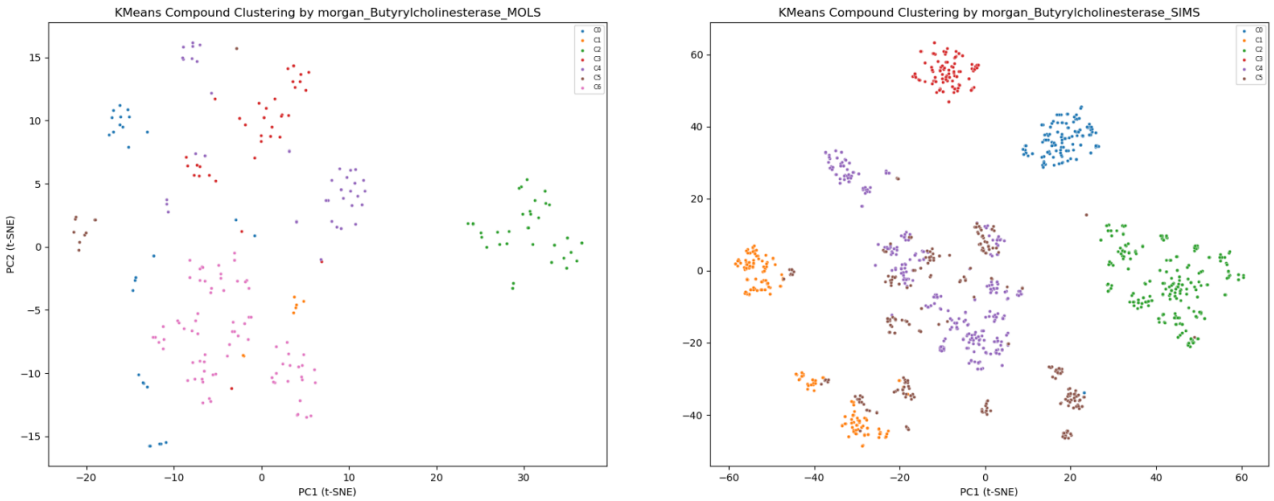

Figura 5.5: Distribuição dos compostos da BChE no espaço químico reduzido via t-SNE, com agrupamentos definidos por KMeans, utilizando o método de *elbow* para definição do número adequado de *clusters* e PCA para a definição dos vetores de classificação: (a) compostos bioativos, (b) compostos análogos.

dos sítios catalíticos dessas enzimas. O sítio ativo da AChE é definido por uma fenda estreita, predominantemente hidrofóbica e conformacionalmente rígida, composta por resíduos aromáticos altamente conservados, como a fenilalanina. Essa conformação impõe restrições estéricas e eletrônicas significativas, limitando a diversidade de *scaffolds* que podem ser acomodados. Por outro lado, o sítio da BChE apresenta uma cavidade mais ampla, flexível e menos restritiva, substituindo resíduos aromáticos por alifáticos (e.g., leucina ou valina), o que permite maior tolerância estrutural e contribui diretamente para a maior heterogeneidade observada nos agrupamentos moleculares associados a essa enzima. As principais distinções estruturais entre os sítios ativos dessas enzimas encontram-se sintetizadas na Tabela 5.14.

Tabela 5.14: Comparação detalhada entre os sítios ativos das enzimas AChE e BChE, destacando as principais diferenças estruturais, topológicas e funcionais. As distinções observadas influenciam diretamente a seletividade, o espectro de substratos reconhecidos e a natureza das interações moleculares. Tais características são determinantes para o planejamento de inibidores seletivos ou multialvo, especialmente em abordagens computacionais de reposicionamento de fármacos para contextos polifarmacológicos.

Característica	**AChE**	**BChE**
Resíduos predominantes	Presença marcante de resíduos aromáticos (ex: triptofano, tirosina). Altamente conservados entre espécies.	Substituição de resíduos aromáticos por alifáticos (ex: leucina, valina), conferindo menor especificidade.
Arquitetura do sítio	Desfiladeiro estreito e rigidamente conformado.	Sítio de ligação amplo, aberto e mais flexível.
Topologia e profundidade do desfiladeiro catalítico	Estrutura profunda ($\approx$ 20 Å), estreita e fortemente delimitada, o que favorece ligantes pequenos e específicos.	Desfiladeiro menos profundo, com acesso facilitado e menor restrição estérica.
Interação principal	Predomínio de interações cátion-π, críticas para o reconhecimento seletivo da acetilcolina.	Interações hidrofóbicas predominantes, com menor especificidade eletrônica.
Especificidade ao substrato	Alta especificidade para acetilcolina e análogos estruturais próximos.	Baixa especificidade. Atividade promiscua sobre diversos ésteres e substratos volumosos.
Função fisiológica	Principal enzima reguladora da neurotransmissão colinérgica em sinapses.	Regulação da neurotransmissão colinérgica por meio da hidrólise do éster butirilcolina, resultando na formação de colina e butirato.

Apesar das distinções estruturais entre os sítios ativos detalhados n Tabela 5.14, ambas as enzimas compartilham caracterizações de fragmentos estruturais recorrentes entre seus ligantes bioativos. Em particular, destaca-se a presença de um farmacóforo tricíclico comum nas redes moleculares associadas a ambas as enzimas, sugerindo a existência de um núcleo estrutural conservado com papel central no reconhecimento molecular multialvo. Estruturas como acridinas, fenotiazinas e carbazóis, amplamente reconhecidas na literatura como farmacóforos clássicos de inibidores de colinesterases, emergem de forma consistente nas análises computacionais realizadas, corroborando a relevância funcional do *scaffold* tricíclico como unidade estrutural chave. Essa convergência, evidenciada pelas relações de similaridade nas redes químicas analisadas, reforça o potencial para o desenvolvimento de inibidores de ação multialvo, estratégia promissora em contextos clínicos como a DA, em que AChE e BChE desempenham funções complementares. No entanto, conforme previamente discutido, as restrições estéricas e eletrostáticas impostas pelo sítio ativo da AChE, caracterizado por uma fenda mais estreita e rigidamente delimitada, impõem desafios adicionais à identificação de compostos que mantenham alta afinidade por ambas as enzimas, o que torna ainda mais significativa a detecção de estruturas com potencial de reconhecimento duplo.

5.3.3 Análise da Beta-Secretase

A BACE1, uma protease transmembrânica do tipo I, é de essencial relevância no processamento proteolítico da APP. Sua principal função está na clivagem inicial da APP em um ponto específico de seu domínio extracelular, sendo asse o primeiro passo da chamada *via amiloidogênica*, evento que resulta na liberação do fragmento amino-terminal solúvel (sAPPβ) e na geração de um fragmento C-terminal que, após subsequente processamento pela γ-secretase, dá origem aos peptídeos β-amiloides (Aβ), em especial os Aβ_{40} e Aβ_{42}. Esses peptídeos, particularmente o Aβ_{42}, apresentam elevada hidrofobicidade e forte tendência à autoagregação, favorecendo a formação de oligômeros neurotóxicos e, posteriormente, as placas senis β-amiloides.

Como discutido no Capítulo 2, o acúmulo progressivo dessas placas-amiloides representa uma das lesões histopatológicas mais características e amplamente documentadas na DA. A presença dessas estruturas está diretamente associada a processos de disfunção sináptica, neuroinflamação e degeneração neuronal, contribuindo de forma substancial para o comprometimento cognitivo observado nas fases iniciais e avançadas da patologia. Diante desse cenário, a BACE1 figura como um alvo terapêutico estratégico, sendo objeto de intensas investigações voltadas ao desenvolvimento de inibidores seletivos capazes de modular ou interromper a cascata amiloide.

Dada sua relevância biológica, a análise da representatividade da BACE1 no espaço químico disponível revelou um conjunto de 1.837 moléculas associadas a esse alvo terapêutico, das quais 1.124 são classificadas como compostos bioativos e 713 como análogos estruturais, conforme ilustrado na Tabela 5.10. Esse volume expressivo de dados, principalmente de bioativos, evidencia não apenas a ampla exploração da BACE1 em estratégias de modulação molecular, como também reforça sua centralidade nas análises desenvolvidas no estudo de caso apresentado neste trabalho. Para compreender sua relevância, tem-se na Figura 5.6 os modelos esquemáti-

cos das redes de interação molecular formadas pelos compostos bioativos (Figura 5.6a) e seus respectivos análogos estruturais (Figura 5.6b).

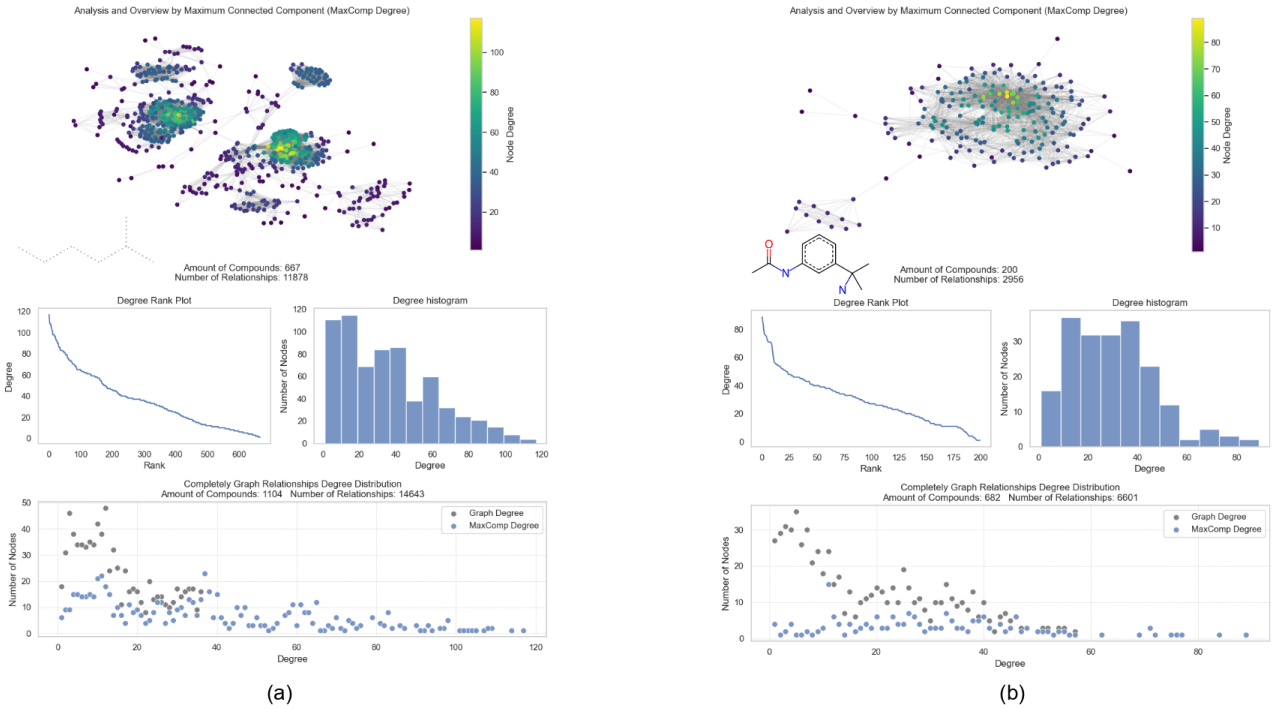

Figura 5.6: Análise comparativa das redes de interação molecular para o alvo terapêutico BACE1. (a) Rede e gráficos associados para o conjunto de 667 compostos bioativos confirmados. (b) Rede e gráficos associados para o conjunto expandido de 200 análogos estruturais. Em ambas as redes, os nós representam compostos moleculares e estão coloridos de acordo com seu grau de conectividade. São apresentados os gráficos de *Ranking* de Graus, Histograma de Graus e a Relação de Graus entre os MCCs e as respectivas redes completas. No canto inferior esquerdo de cada rede, encontra-se representado o maior fragmento comum identificado, o qual sintetiza a subestrutura recorrente de maior frequência observada entre os compostos analisados, servindo como marcador estrutural representativo das interações mapeadas.

Nota-se, na rede de compostos bioativos representada na Figura 5.6a, um elevado grau de fragmentação topológica, caracterizado pela presença de múltiplos subconjuntos conexos com baixa densidade e coesão relacional restrita. Essa configuração indica uma organização estrutural esparsa no espaço químico associado à BACE1.A formação de agrupamentos localizados e estruturalmente heterogêneos sugere a inexistência de um padrão molecular dominante, podendo ser interpretada sob a perspectiva de características do sítio catalítico desta enzima, cuja estrutura e composição favorecem a exploração de múltiplas estratégias de ancoragem por diferentes perfis moleculares.

Diferentemente das colinesterases, cuja arquitetura enzimática impõe restrições conformacionais e químicas mais rígidas, a BACE1 possui um sítio catalítico caracterizado por elevada plasticidade estrutural e permissividade química. Essas propriedades favorecem a diversidade conformacional e funcional de seus inibidores, permitindo maior variação na composição e no arranjo espacial dos grupos funcionais. Essa flexibilidade se reflete na estrutura comum mais predominante identificada, a qual corresponde a um fragmento com características gerais, desprovido de especificidade funcional ou atividade inibitória predominante quando isolado.

Entre os fatores estruturais que contribuem para essa diversidade molecular e inexistência de *scaffold* central, destaca-se um sítio catalítico profundo e conformacionalmente dinâmico, organizado em torno de uma cavidade ampla delimitada por regiões altamente flexíveis. Dentre

essas, sobressai-se a alça móvel, ou *flap*, que regula o acesso ao núcleo catalítico. Esta estrutura é composta por resíduos como Gln_{73} e Thr_{72}, cuja mobilidade contribui para a modulação estérica e dinâmica do sítio, viabilizando múltiplas orientações de ancoragem dos ligantes. Essa configuração possibilita a definição de múltiplos subsítios com capacidade de ancoragem diversificada. Além disso, a composição química do sítio é essencialmente híbrida, abrigando em seu núcleo uma díade catalítica polar (Asp_{32} e Asp_{228}), responsável pela atividade hidrolítica, enquanto seu entorno é constituído por bolsões hidrofóbicos formados por resíduos aromáticos, como Tyr_{71}, Phe_{108} e Trp_{115}. Essa organização alternada de regiões polares e apolares promove interações moleculares diversas, incluindo pontes de hidrogênio, empacotamento hidrofóbico e interações eletrostáticas, ampliando a tolerância química do sítio a diferentes arquiteturas de *scaffolds* e reforçando o padrão estruturalmente disperso observado entre os compostos bioativos.

Essa interpretação é reforçada pelas distribuições observadas nos gráficos de *ranking* e no histograma de graus, os quais evidenciam um número expressivo de nós com baixa conectividade, abaixo de 40 arestas, que, possivelmente, atuam como elementos de ligação entre subgrupos mais densos e localizados. Além disso, a comparação entre os graus na rede completa e o MaxComp revela um espalhamento considerável dos pontos, ainda que alinhados ao longo do eixo de grau. Tal padrão evidencia a ausência de centralidade estrutural dominante e confirma a elevada fragmentação topológica do espaço químico ocupado pelos ligantes da BACE1.

Em contraste com a configuração fragmentada observada entre os compostos bioativos, os análogos estruturais associados à BACE1 apresentam, tal como na AChE, uma rede de interações típica do tipo *hub-and-spoke*. A razão para essa topologia é a presença de um *scaffold* dominante, o qual apresenta como parte da sua composição a *N-fenilacetamida*. Quase todos os compostos nesse conjunto são variações sobre esse mesmo tema estrutural, compartilhando do mesmo núcleo, e as diferenças estão nas substituições periféricas. Como pode ser observado, além da *N-fenilacetamida*, há um grupo adicional (o grupo *1-amino-2,2-dimetilpropil*) no *scaffold* que pode potencializar a capacidade de ancoragem, introduzindo sob essa perspectiva duas características químicas que podem corroborar para tal caracterização de agrupamento da rede, que são:

- O grupo amino (NH_2) como âncora iônica: Em pH fisiológico, ele estará protonado, adquirindo uma carga positiva (NH_3^+). Essa carga positiva pode formar uma interação iônica (ou ponte salina) com um dos aspartatos de carga negativa (Asp_{32} ou Asp_{228}) do sítio ativo. Essa é a interação mais forte e mais clássica explorada no desenvolvimento de inibidores de BACE1. Além da ponte salina, o grupo NH_3^+ é um excelente doador de ligações de hidrogênio, podendo interagir com outros resíduos próximos, aumentando ainda mais a afinidade.

- O grupo terc-butila ($C(CH_3)_3$) como preenchedor do sítio catalítico: O grupo terc-butila é grande, volumoso e extremamente hidrofóbico (apolar). Este grupo pode se encaixar perfeitamente em um dos bolsões hidrofóbicos do sítio ativo da BACE1. Ao fazer isso, ele desloca moléculas de água que estavam nesse espaço, um processo que é energeticamente

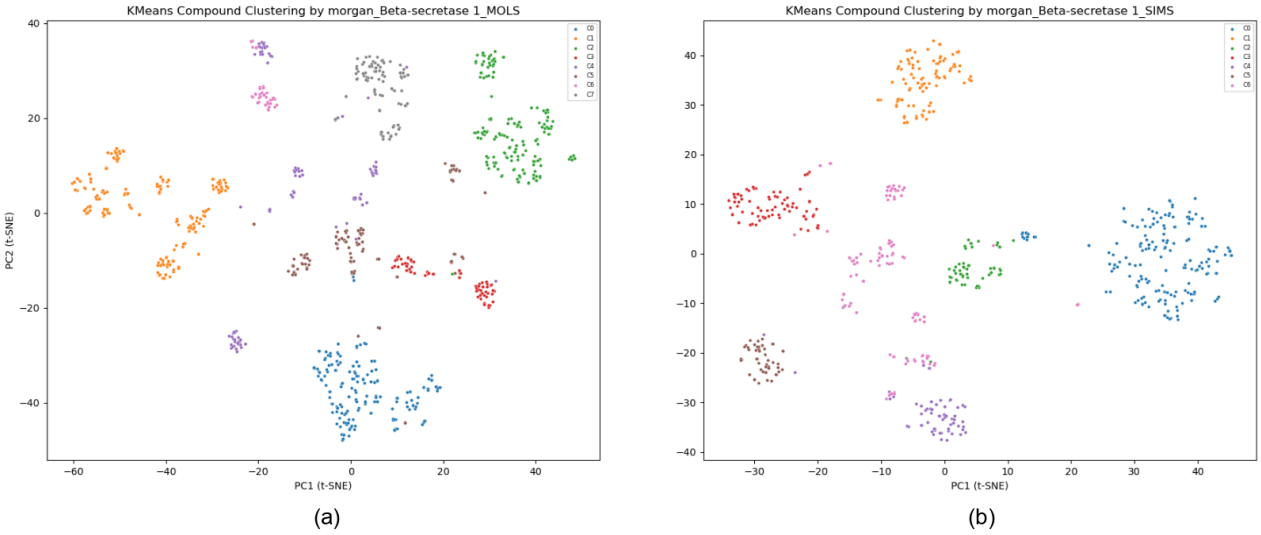

Figura 5.7: Distribuição dos compostos da BACE1 no espaço químico reduzido via t-SNE, com agrupamentos definidos por KMeans, utilizando o método de *elbow* para definição do número adequado de *clusters* e PCA para a definição dos vetores de classificação: (a) compostos bioativos, (b) compostos análogos.

favorável (ganho entrópico) e que contribui significativamente para a energia livre de ligação.

A análise dos agrupamentos formados pelos compostos bioativos e seus respectivos análogos estruturais permite identificar padrões adicionais que corroboram as observações previamente descritas. Como ilustrado na Figura 5.7, a representação (a) revela que os bioativos originam um número mais elevado de *clusters* e ocupam um espaço químico mais amplo em comparação aos análogos representados em (b). Essa maior dispersão evidencia uma diversidade estrutural acentuada entre os bioativos, implicando em uma variedade mais extensa de *scaffolds* e em distâncias estruturais mais pronunciadas entre as famílias químicas. Tal comportamento é coerente com a elevada plasticidade conformacional do sítio catalítico da BACE1, que acomoda múltiplas estratégias de ligação e reconhece ligantes estruturalmente distintos com afinidade comparável.

Por outro lado, a configuração observada para os análogos revela agrupamentos mais coesos e espacialmente compactos, indicando uma menor variabilidade estrutural. Essa homogeneidade é típica de séries de otimização racional, nas quais pequenas variações são introduzidas sistematicamente a partir de um número restrito de estruturas-base com potencial inibitório previamente identificado. A Tabela 5.16 sintetiza as discussões apresentadas, reportando os principais pontos de divergência entre os conjuntos de bioativos e análogos investigados.

Tabela 5.16: Comparação estruturada entre os conjuntos de compostos bioativos e análogos estruturais para BACE1, considerando aspectos de diversidade química, topologia da rede de interação molecular e implicações de agrupamento no contexto de estratégias de descoberta e otimização de fármacos.

Característica de Análise	**(a) - Bioativos**	**(b) - Análogos Estruturais**
Diversidade Estrutural	**Alta.** Composta por múltiplos *scaffolds* e famílias químicas distintas, sem um núcleo dominante.	**Baixa.** Variações sobre um ou poucos *scaffolds* centrais, resultando em alta redundância estrutural.
Topologia da Rede de Similaridade	**Fragmentada** e descentralizada. Múltiplos componentes de baixa densidade, sem um *hub* central.	**Coesa** e centralizada. Topologia clássica de **"Hub-and-Spoke"**, com um núcleo denso.

Número de Clusters (KMeans)	**Maior.** Indica a existência de um número superior de famílias químicas distintas.	**Menor.** Sugere um conjunto de compostos derivado de um número mais limitado de esqueletos-base.
Dispersão Espacial dos Clusters	**Alta dispersão**. Os clusters estão representados em espaço de dispersão amplo, indicando grande dissimilaridade química entre as famílias.	**Baixa dispersão**. Os clusters estão mais próximos no espaço de dispersão com espaço químico ocupado mais compacto, indicando maior similaridade geral.

5.4 Predição de Ancoragem Molecular

Após a caracterização do domínio químico e a evidência de sua relevância e heterogeneidade estrutural, conforme discutido nas seções anteriores, estruturou-se a base de compostos a ser utilizada pelo *NeuroDock*, em conformidade com o modelo metodológico descrito no Capítulo 4, particularmente conforme o fluxo esquemático representado na Figura 4.2.

Conforme ilustrado na Figura 4.2, os compostos selecionados da base ChEMBL, previamente extraídos por meio do *BioMolExplorer*, são submetidos a um protocolo de *docking* por consenso, com o objetivo de gerar os dados estruturais necessários à construção e ao treinamento do modelo preditivo. A seleção dos compostos pertencentes ao domínio químico em análise fundamentou-se na interseção entre os múltiplos MCCs, abrangendo tanto compostos bioativos quanto seus análogos estruturais. Essa abordagem, orientada pela análise topológica do espaço químico, assegurou elevada diversidade estrutural e representatividade dos conjuntos empregados.

Inicialmente, os compostos selecionados foram organizados em um conjunto contendo seus respectivos identificadores `CHEMBL` e representações canônicas no formato `SMILES`. Na sequência, aplicou-se uma etapa de filtragem voltada à eliminação de duplicidades, garantindo que cada entrada correspondesse a uma única entidade química. Para isso, foram removidos códigos redundantes e representações `SMILES` repetidas. Após esse refinamento, os compostos foram submetidos ao protocolo de *docking* por consenso, o qual atribuiu a cada molécula um valor de afinidade em relação a cada um dos três alvos moleculares de interesse. Dessa forma, cada entrada passou a ser representada por um vetor composto por três *scores*, refletindo sua propensão de interação com os respectivos receptores.

Os alvos moleculares adotados neste procedimento foram selecionados com base nos resultados consolidados na Tabela 5.3, tendo sido empregados os seguintes complexos cristalográficos de referência: 4M0E (AChE), 1P0I (BChE) e 5HE5 (BACE1). A Tabela 5.19 sintetiza, através de um pequeno exemplo, os compostos com melhor desempenho em termos de afinidade para cada alvo, enquanto a Tabela 4.9 apresenta os procedimentos de normalização aplicados para a composição das colunas Z-score e Min-Max. Essas transformações foram utilizadas para compor vetores classificatórios, posteriormente empregados com assinaturas de Morgan para compor o treinamento e o processo de avaliação de diferentes modelos preditivos.

Uma vez definido e devidamente pré-processado o conjunto de dados experimental, composto por assinaturas moleculares de Morgan como representação vetorial de entrada e os respectivos valores de afinidade obtidos por *docking* por consenso como alvos de regressão, procedeu-se à

Tabela 5.19: Resultados de *docking* para os cinco compostos com maior afinidade frente aos alvos AChE, BChE e BACE1 avaliados por *AutoDock Vina* e *Dock6* sob o modelo de consenso. São apresentados os *scores* individuais, o *z-score* do composto e o intervalo min-max de normalização.

Alvo	Molécula	Vina	Dock6	Z-score	Min-Max
4M0E	CHEMBL2336135	-12.24	-42.21	1.76	0.81
	CHEMBL4090413	-9.88	-68.81	1.74	0.77
	CHEMBL3978016	-11.00	-54.33	1.65	0.77
	CHEMBL3914118	-11.58	-47.12	1.62	0.78
	CHEMBL3670320	-11.04	-48.76	1.40	0.74
1P0I	CHEMBL3959263	-11.35	-54.88	1.59	0.77
	CHEMBL241115	-11.96	-46.68	1.55	0.78
	CHEMBL3948490	-11.23	-55.4	1.55	0.76
	CHEMBL4277644	-11.4	-53.07	1.53	0.76
	CHEMBL4129747	-10.97	-57.19	1.48	0.75
5HE5	CHEMBL3948490	-11.38	-53.31	1.95	0.95
	CHEMBL3984963	-11.27	-53.94	1.93	0.94
	CHEMBL4293298	-10.68	-54.0	1.62	0.89
	CHEMBL2178718	-11.25	-47.44	1.54	0.89
	CHEMBL3933481	-10.81	-51.48	1.53	0.88

avaliação do desempenho preditivo de diferentes arquiteturas de DL. O objetivo desta etapa consistiu em investigar a capacidade dos modelos de capturar padrões não lineares presentes no espaço químico representado, bem como em generalizar predições para compostos não observados. Nesse sentido, inicialmente, adotamos uma arquitetura clássica de RNA do tipo MLP, amplamente utilizada em tarefas de regressão e classificação sobre vetores fixos, especialmente em contextos envolvendo descritores químicos. A escolha por esse modelo baseia-se em sua simplicidade arquitetural, ampla disponibilidade em bibliotecas de ML e, sobretudo, por sua adequação à natureza tabular dos dados extraídos das *fingerprints*.

Em complemento à arquitetura MLP, avaliamos uma abordagem mais sofisticada baseada em redes residuais - ResNet. Originalmente proposta para o domínio da visão computacional, a ResNet introduz conexões residuais que resolvem o problema da degradação do gradiente em DL, facilitando o treinamento de arquiteturas com múltiplas camadas e permitindo a modelagem de funções altamente não lineares com maior estabilidade e eficiência. Tais características tornam essa arquitetura particularmente promissora em cenários que exigem a extração de padrões complexos a partir de representações vetoriais densas ou esparsas.

No contexto da química computacional, redes residuais vêm sendo cada vez mais exploradas como alternativa à modelagem convencional, sobretudo quando se trata de relacionar descritores moleculares, como as *fingerprints* de Morgan, a propriedades bioativas derivadas de experimentos ou predições *in silico*. Nesse sentido, a adoção da ResNet nesta investigação justifica-se pela expectativa de que sua capacidade de representação pode contribuir para a captura de relações sutis entre a estrutura molecular e os valores de afinidade obtidos via *docking* por consenso. A comparação entre as arquiteturas MLP e ResNet foi conduzida com o objetivo de avaliar o impacto da capacidade preditiva na convergência, no desempenho e na generalização dos modelos. Nesse contexto, ambas as redes foram treinadas e validadas sobre o mesmo conjunto de entrada, formado por assinaturas de Morgan, e utilizaram como variável dependente os vetores de *bin-*

ding scores obtidos para os três alvos moleculares. Essa padronização possibilitou uma análise comparativa direta e controlada dos modelos. A Tabela 5.21 apresenta os hiperparâmetros e configurações adotados nas arquiteturas avaliadas, os quais foram previamente otimizados com base em uma série de testes realizados com o modelo MLP.

Tabela 5.21: Hiperparâmetros utilizados na configuração dos modelos de DL empregados nos experimentos de regressão. Os valores apresentados foram previamente otimizados a partir de testes com a arquitetura MLP e utilizados como base para a avaliação comparativa com a rede residual (ResNet).

Parâmetro	**Valor**
Tipo de modelo	[mlp, resnet]
Otimizador	AdamW
Taxa de aprendizado	9.90×10^{-4}
Regularização L2 (λ)	4.26×10^{-4}
Taxa de dropout máxima	3.51×10^{-3}
Inicializador dos pesos	`he_uniform`
Ativação nas camadas ocultas	ReLU
Ativação da saída	Sigmoid
Uso de bias	Não
Normalização na entrada	Sim
Normalização nas camadas ocultas	Sim
Função de perda	Huber (delta = 0,533)
Monitoramento de perda durante o treinamento	Não
Métrica de monitoramento	`val_mse`
Épocas de treinamento	1000
Tamanho do lote (*batch size*)	8
Tamanho do conjunto de teste	10%
Tamanho do conjunto de validação	20%
Estado aleatório	73
Número de validações cruzadas (*K-Fold*)	5
Métricas utilizadas	MAE, MSE, RMSE, R^2
Unidades nas camadas ocultas	[829, 661, 282, 173, 220]

Após a definição dos parâmetros de configuração para a avaliação comparativa das duas arquiteturas de DL, procedeu-se à coleta das métricas descritas anteriormente (Tabela 5.21), com o objetivo de caracterizar o desempenho preditivo de cada modelo de regressão. Para garantir uma avaliação adequada e reduzir o viés associado à divisão dos dados, adotou-se a técnica de validação cruzada do tipo *K-Fold*. No que se refere à partição dos dados, 90% do conjunto total foi destinado à etapa de treinamento, sendo os 10% restantes mantidos como subconjunto de teste, utilizado ao final de cada interação de validação para avaliar a convergência, desempenho e capacidade de generalização dos modelos. A Figura 5.8 apresenta os resultados obtidos a partir dessa configuração, evidenciando o comportamento de ambas as arquiteturas (MLP e ResNet) ao longo das 1000 épocas de observação.

Os valores apresentados na Figura 5.8 definem os critérios comparativos de desempenho entre os modelos MLP (a) e ResNet (b), com base em diferentes métricas de regressão (MAE, MSE, RMSE e coeficiente de determinação R^2). No caso da MLP, observa-se uma convergência suave e progressiva das curvas de treino (em azul) e validação (em amarelo), indicando um processo de otimização estável e bem-comportado. Essa estabilidade é corroborada pela linha de desempenho no conjunto de teste (linha pontilhada vermelha), que permanece próxima aos

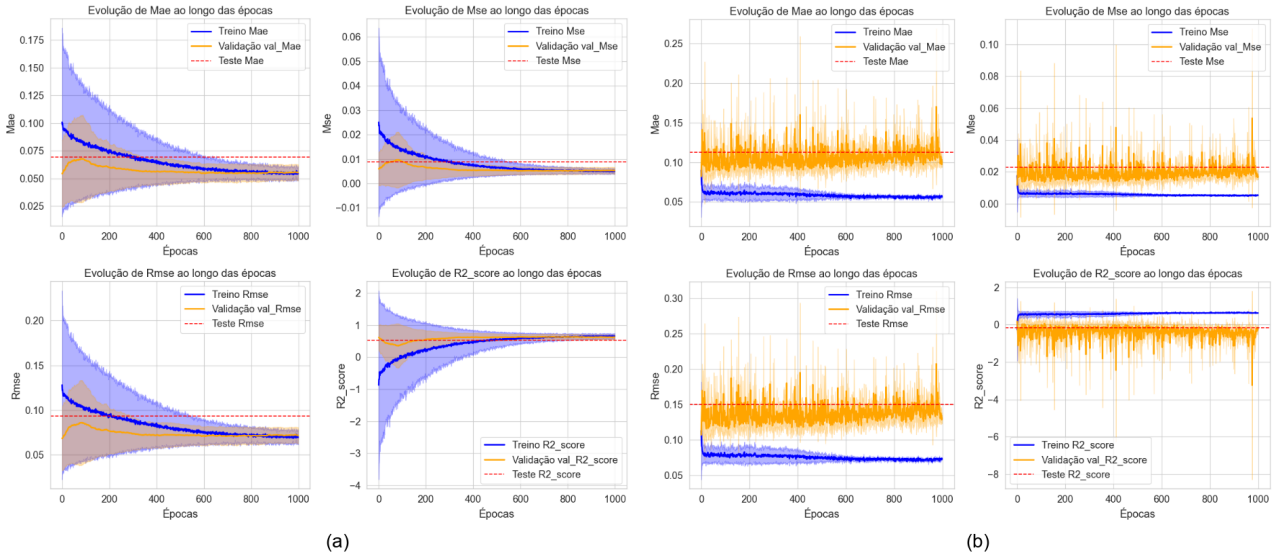

Figura 5.8: Comparação da evolução das métricas de desempenho durante o treinamento de duas arquiteturas de redes neurais aplicadas à predição de propriedades de ancoragem moleculares: (a) rede MLP e (b) rede ResNet. Cada linha representa a média dos valores obtidos ao longo de múltiplas execuções, enquanto as faixas sombreadas indicam o desvio padrão. As curvas de treino e validação são apresentadas em azul e laranja, respectivamente, enquanto os valores de teste estão representados por linhas tracejadas vermelhas.

valores de validação ao longo de todo o treinamento.

Do ponto de vista da generalização, o modelo MLP não apresenta indícios de sobreajuste (*overfitting*), uma vez que as curvas de treino e validação mantêm-se próximas durante as épocas, com baixa variância entre execuções. Essa proximidade evidencia que o modelo é capaz de generalizar adequadamente para dados não observados. Além disso, o desempenho no conjunto de teste é coerente com o comportamento final de validação, o que reforça a robustez da arquitetura. Métricas como MAE e RMSE assumem valores baixos, indicando erro médio de predição reduzido, enquanto o coeficiente de determinação R^2 no teste se mantém próximo de 0.8, o que é um resultado expressivo, sugerindo que o modelo MLP é capaz de explicar aproximadamente 80% da variabilidade associada aos valores de entrada, o que atesta sua eficácia preditiva no contexto avaliado.

Em contrapartida, a arquitetura ResNet não apresentou resultados adequados, apesar de frequentemente ser citada na literatura como uma abordagem promissora para mitigar limitações de desempenho em tarefas de CADD/AIDD. Conforme ilustrado na Figura 5.8b, observa-se que as curvas de validação apresentam elevada instabilidade e flutuações ao longo das épocas de treinamento, independentemente da métrica considerada (MAE, MSE, RMSE e R^2). Tal comportamento é indicativo de um processo de treinamento altamente irregular e não convergente.

Além disso, evidencia-se uma lacuna significativa entre as curvas de treinamento e validação, sugerindo um ajuste excessivo do modelo aos dados de treinamento. De fato, enquanto o erro de treinamento decresce e o coeficiente de determinação aumenta progressivamente nesse conjunto, o desempenho sobre os dados de validação permanece baixo e volátil, caracterizando um quadro clássico de *overfitting*. No que se refere às métricas quantitativas, os valores obtidos para MAE e RMSE são substancialmente superiores aos observados no modelo MLP, denotando maior erro

médio nas previsões. Ademais, o valor do coeficiente R^2 no conjunto de teste aproxima-se de zero, ou até mesmo assume valores ligeiramente negativos, indicando que o modelo ResNet não apresenta capacidade preditiva superior a uma simples média dos valores de entrada, falhando, portanto, em capturar a variabilidade subjacente às amostras avaliadas.

Após a definição da arquitetura final do *NeuroDock* por MLP, o modelo otimizado foi empregado para realizar a predição dos valores de *docking* em um extenso conjunto de compostos provenientes da base ZINC. Essa etapa envolveu a análise de aproximadamente 12.3 milhões de moléculas, conduzida em um tempo inferior a três horas, o que evidencia a eficiência computacional do modelo desenvolvido. A Tabela 5.23 apresenta os resultados correspondentes às 20 moléculas com os maiores valores preditos, destacando-se como candidatos prioritários para etapas subsequentes de TV/HTVS e validação experimental.

Tabela 5.23: Predições de afinidade de ligação para os principais candidatos moleculares às enzimas AChE, BChE e BACE1. A tabela apresenta os 20 compostos mais bem ranqueados com base em uma abordagem de consenso orientada ao contexto multi-alvo. Para cada composto, são fornecidos o identificador ZINC, a representação SMILES da estrutura química e os respectivos *scores* normalizados de afinidade preditiva frente a cada uma das três enzimas-alvo. Valores próximos de 1 indicam elevada afinidade estimada de interação. O critério de ranqueamento adotado considera o produto entre os valores de ancoragem preditos, de modo a favorecer compostos com desempenho simultaneamente elevado em todos os alvos moleculares analisados.

ZINC ID	**SMILES**	**Consensus**		
		AChE	**BChE**	**BACE1**
16429338	FC(F)(F)c1ccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccc(Cl)cc2)cc1	0.9185	0.8677	0.9688
16523915	Fc1ccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccccc2)c(F)c1	0.8960	0.8804	0.9760
13502523	Clc1ccc(-n2nnnc2CSc2nc(C3CCCCC3)nc3ccccc23)cc1	0.9290	0.8560	0.9653
89869386	Cn1c(C2CC2)nc2cc(NC(=O)c3ccccc3-n3cnnn3)ccc21	0.9165	0.8910	0.9395
95467590	c1ccc(-c2csc3nc(C4CC4)nc(N4CCC[C@@H]4c4ncc[nH]4)c23)cc1	0.9220	0.8574	0.9680
72337220	CCc1cc(N2CCOCC2)nc(C2CCN(C(=O)c3ccc(-n4cnnn4)cc3)CC2)n1	0.9053	0.8843	0.9550
14994933	O=C(c1cc(-c2cccc3cccnc23)cc(-n2cnnn2)c1)N1CCC[C@H](c2ccccc2)CC1	0.9150	0.8690	0.9590
16429848	Fc1ccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccc(Cl)cc2)c(F)c1	0.8906	0.8770	0.9740
16523923	Clc1cccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccccc2)c1	0.9116	0.8574	0.9707
16523930	Fc1cccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccccc2)c1	0.9116	0.8574	0.9707
16399177	Fc1cccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccc(Cl)cc2)c1	0.9116	0.8574	0.9707
16399049	Clc1ccc(-n2nnnc2-c2cnc(C3CC3)nc2-c2cccc(Cl)c2)cc1	0.9116	0.8574	0.9707
1342121	CCOc1cc(-n2cnnn2)c(OCC)cc1NC(=O)c1cc2ccc(N(CC)CC)cc2oc1=O	0.9453	0.8540	0.9375
16523909	Clc1ccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccccc2)cc1	0.9087	0.8540	0.9717
16523911	Fc1ccc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccccc2)cc1	0.9087	0.8540	0.9717
11880665	O=C(c1cc(-c2cccc3cccnc23)cc(-n2cnnn2)c1)N1CCC(c2ccccc2)CC1	0.9194	0.8520	0.9604
16523902	Fc1cc(F)cc(-c2nc(C3CC3)ncc2-c2nnnn2-c2ccccc2)c1	0.8965	0.8620	0.9730
16311575	Cc1ccc(-n2nnnc2-c2cnc(C3CC3)nc2-c2cccc(C(F)(F)F)c2)cc1	0.9185	0.8560	0.9560
72292302	O=C(CCCc1nc(C2CC2)no1)Nc1ccc(-n2cnnn2)cc1	0.9497	0.8380	0.9440
1888911932	Cc1nc(C2CC2)nc(N2CCN(c3nc4ccccc4o3)CC2)c1F	0.8853	0.8813	0.9624

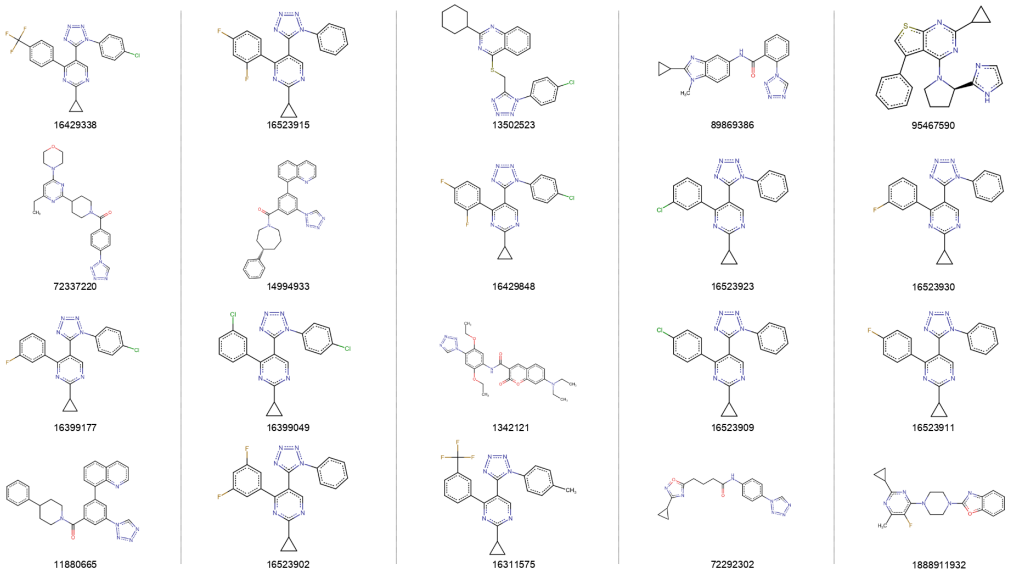

Como pode ser observado nas moléculas resultantes, parte integrante da Tabela 5.23, uma proporção significativa dos compostos selecionados compartilha, a exemplo dos identificadores `16429338`, `16523915`, `16399177`, `16523909`, um núcleo heterocíclico central de cinco membros densamente funcional com três ou mais anéis aromáticos, tais como grupos fenil e piridinil. Essa recorrência estrutural sugere a presença de um *scaffold* farmacofórico promissor, que possivelmente constitui o principal *hit* identificado na TV/HTVS conduzida. Nesse contexto, destaca-se também a presença de substituintes halógenos, como o átomo de cloro no composto `16399049` e o flúor no composto `16523915`, ou ainda de anéis aromáticos nitrogenados, como a piridina em `16523915`. Esses substituintes indicam que os sítios de ligação das enzimas-alvo toleram, ou até mesmo favorecem, esses grupos funcionais, os quais podem exercer papel relevante na modulação de propriedades eletrônicas e de solubilidade, contribuindo para uma melhor afinidade de ligação.

Segundo Boer et al. (2021), sob a perspectiva estrutural das colinesterases, o sítio ativo dessas enzimas compreende uma cavidade profunda com duas regiões principais: o sítio aniônico catalítico (CAS) e o sítio aniônico periférico (PAS). Este último, localizado na entrada da fenda catalítica, é caracterizado pela presença de resíduos aromáticos como triptofano e tirosina. A elevada densidade de anéis fenílicos nos compostos identificados favorece a formação de interações do tipo empilhamento π–π e interações hidrofóbicas com esses resíduos, mecanismos essenciais para o reconhecimento e a estabilidade do complexo enzima-ligante. Essa conformação estrutural é compatível com o perfil observado em diversos inibidores de AChE com mecanismo de dupla ligação, capazes de interagir simultaneamente com o CAS e o PAS, e cuja elevada aromaticidade contribui para uma ligação mais eficaz ao PAS.

Nesse sentido, embora a AChE e a BChE compartilhem uma arquitetura estrutural homóloga, incluindo resíduos catalíticos conservados, como Trp_{86} (AChE) e seu análogo Trp_{82} (BChE), diferem substancialmente quanto à composição da entrada da fenda catalítica. A BChE não possui um sítio aniônico periférico (PAS) bem definido, uma vez que resíduos aromáticos essenciais na AChE, como Trp_{278} e Tyr_{333}, são substituídos por resíduos alifáticos de menor volume. Essa substituição resulta em um sítio ativo mais amplo, hidrofílico e permissivo, conferindo à BChE maior plasticidade conformacional e tolerância a ligantes volumosos.

É precisamente essa característica que os compostos identificados, em sua maioria, parecem explorar. A presença de um *scaffold* aromático, com múltiplos pontos de interação e elevada flexibilidade conformacional, permite que tais ligantes contornem a ausência de um PAS funcional na BChE e se acomodem de modo eficaz no interior da cavidade catalítica, promovendo interações diretas e estabilizadoras com os resíduos do CAS. A Figura 5.9 ilustra a análise de contribuição energética residual (*footprint*), empregando como exemplo o composto `16399049`, para ambas as enzimas. São destacados, em cada caso, os cinquenta resíduos que mais contribuem energeticamente para a interação com o ligante. Nesse contexto, a análise detalha as componentes de energia de Van der Waals (*VDW Energy*) e eletrostática (*ES Energy*), oferecendo uma perspectiva detalhada dos fatores físico-químicos que sustentam o ancoramento do composto aos respectivos sítios ativos.

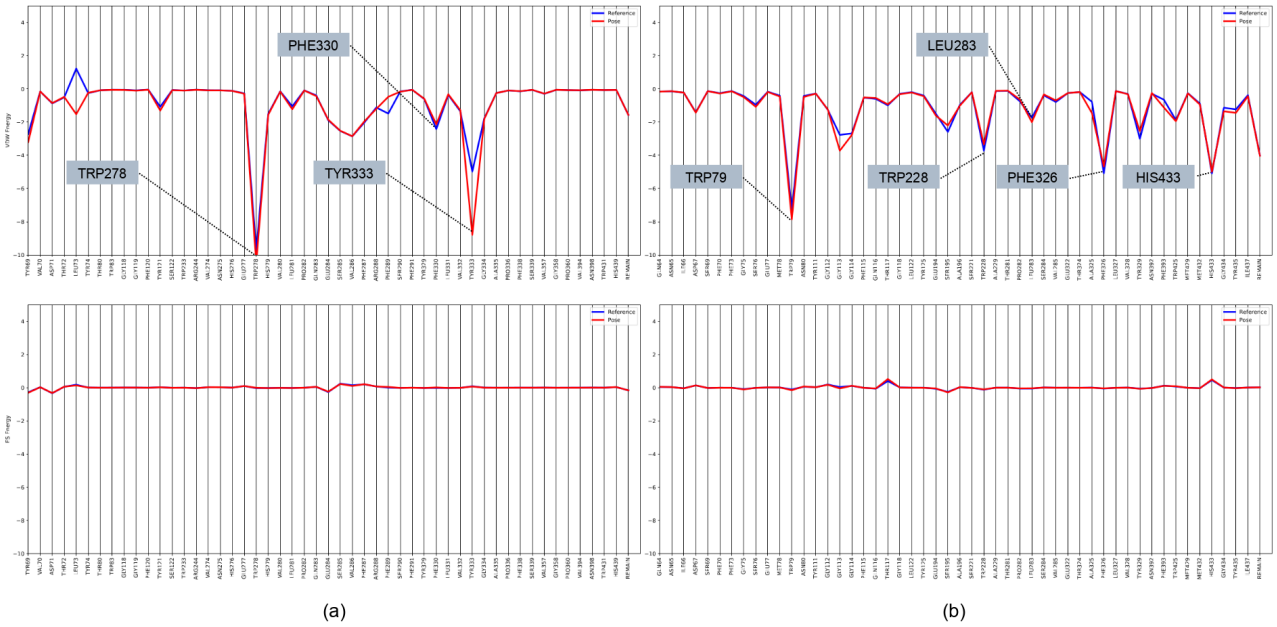

Figura 5.9: Análise de contribuição energética residual para o composto `16399049` em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

Em relação à BACE1, como previamente discutido, seu sítio ativo corresponde a uma fenda relativamente ampla e majoritariamente hidrofóbica, contendo uma díade catalítica composta pelos resíduos Asp_{32} e Asp_{228}. Esses resíduos ácidos podem atuar como doadores de ligação de hidrogênio, e os átomos de nitrogênio presentes no anel heterocíclico central dos compostos candidatos estão idealmente posicionados para atuar como aceptores, possibilitando a formação de interações hidrogênio-ligante oportunas com a díade catalítica. Tais interações são favoráveis para o ancoramento eficaz e seletivo ao sítio ativo da enzima. A Figura 5.10 detalha, sob as mesmas perspectivas de contribuição energética residual para o composto `16399049`, os resultados obtidos para BACE1.

Conforme observado na Figura 5.10, a interação predominante ocorre no resíduo TYR_{75}, que contribui sozinho com aproximadamente -10 unidades de energia VdW, sendo esse localizado na região de *flap* da enzima. Assim, ancorar-se a este resíduo é um mecanismo clássico de inibição da BACE1, pois contribui para o bloqueio do *flap* na conformação fechada, inviabilizando o acesso ao sítio catalítico.

Além das propriedades estruturais e das interações moleculares previamente discutidas, os compostos priorizados ainda apresentam características físico-químicas compatíveis com a permeação da BHE, fator determinante para a eficácia terapêutica em doenças neurodegenerativas. De acordo com Gupta et al. (2019) e Janicka, Sztanke e Sztanke (2024), parâmetros como número reduzido de doadores (HBD, entre 0 e 3) e alto número de aceptores (HBA, até 8) de hidrogênio, área de superfície polar topológica (TPSA) inferior a 100 $Å^2$, peso molecular ≤ 450 daltons e coeficiente de partição lipofílico ($\log P$ - lipofilicidade) entre 1 e 5 estão fortemente associados à capacidade de penetração no SNC.

Além disso, observa-se que a maioria dos compostos priorizados apresenta um número inferior a cinco de anéis aromáticos, bem como entre 20 e 35 átomos pesados (não hidrogênios).

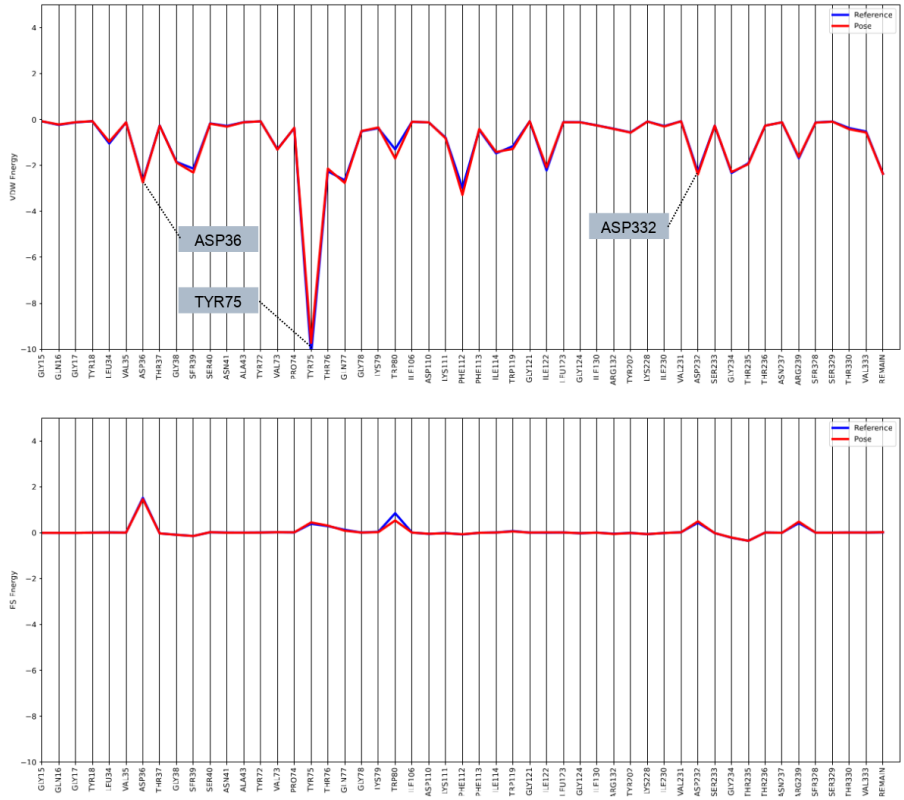

Figura 5.10: Análise de contribuição energética residual para o composto 16399049 em complexo formado com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

Esses atributos estruturais conferem rigidez conformacional, o que contribui para a estabilidade dos complexos enzima-ligante e potencializa as interações do tipo π–π com resíduos aromáticos presentes nos sítios ativos das enzimas-alvo. Tais características têm sido consistentemente correlacionadas com uma maior permeabilidade à BHE e com desempenho farmacológico otimizado em candidatos terapêuticos destinados ao tratamento de doenças neurodegenerativas. Os valores obtidos para cada uma dessas métricas encontram-se sumarizados na Tabela 5.25, possibilitando uma análise comparativa dos compostos investigados quanto ao seu potencial de atuação.

Tabela 5.25: Parâmetros físico-químicos dos compostos selecionados extraídos da ferramenta *DataWarrior*, identificados por seus códigos ZINC, incluindo peso molecular, coeficiente de partição (LogP), número de doadores (HBD) e aceitadores (HBA) de hidrogênio, área polar de superfície (TPSA), número de átomos pesados e quantidade de anéis aromáticos. Atributos estruturais essenciais para a avaliação do potencial de permeabilidade à barreira hematoencefálica e para a otimização farmacológica de moléculas com atividade no sistema nervoso central.

ZINC ID	Peso (Da)	LogP	HBA	HBD	TPSA (Å^2)	Átomos Pesados	Anéis Aromáticos
16429338	442.09	4.84	06	0	69.38	31	4
16523915	376.12	3.59	06	0	69.38	28	4
13502523	436.97	4.89	06	0	94.68	30	4
89869386	359.39	2.43	08	1	90.52	27	4
95467590	387.51	4.19	05	1	85.94	28	4
72337220	448.52	2.30	10	0	102.16	33	3
14994933	474.56	5.45	07	0	76.80	36	5
16429848	410.81	4.19	06	0	69.38	29	4
16523923	374.83	3.99	06	0	69.38	27	4
16523930	358.37	3.48	06	0	69.38	27	4
16399177	392.82	4.09	06	0	69.38	28	4
16399049	409.27	4.60	06	0	69.38	28	4
1342121	492.53	2.60	11	1	120.70	36	3

16523909	374.83	3.99	06	0	69.38	27	4
16523911	358.37	3.48	06	0	69.38	27	4
11880665	460.54	5.11	07	0	76.80	35	5
16523902	376.36	3.59	06	0	69.38	28	4
16311575	422.41	4.58	06	0	69.38	31	4
72292302	339.35	1.78	09	1	111.62	25	3
1888911932	353.40	3.60	06	0	58.29	26	3

Os parâmetros físico-químicos, estruturais e de interação apresentados na Tabela 5.25 sustentam a adequação dos compostos selecionados como candidatos promissores a inibidores multi-alvo, caracterizados por propriedades polifarmacológicas e elevado potencial de atuação no SNC. Nesse contexto, destaca-se que a convergência identificada pelo modelo preditivo baseado em MLP, implementado na plataforma *NeuroDock*, em uma família estruturalmente coesa, em detrimento de uma distribuição aleatória e quimicamente heterogênea, evidencia a capacidade do algoritmo de reconhecer padrões moleculares relevantes associados a altas pontuações de *docking*. Essa evidência reforça a robustez do modelo supervisionado adotado, validando sua eficácia no planejamento racional de fármacos com perfis multi-alvo.

5.5 Simulações e Dinâmica Molecular

Conforme discutido na seção anterior, o processo de predição por *docking* permitiu a priorização de compostos cujas propriedades físico-químicas são compatíveis com aquelas descritas na literatura para candidatos com potencial polifarmacológico, especialmente no contexto de doenças neurodegenerativas. Essa priorização está associada à presença de atributos estruturais considerados essenciais para a permeabilidade à BHE, o que amplia a probabilidade de eficácia terapêutica sob o SNC.

Neste estudo, foram selecionados alguns desses compostos, entre os quais o `16399049`, cuja conformação ancorada sugere um potencial promissor de ligação simultânea às diferentes enzimas-alvo (Figuras 5.9 e 5.10). Para a condução das simulações e a validação desses achados, os experimentos de DM foram preparados com base nos parâmetros descritos na Tabela 4.13, incorporando pequenas adaptações pontuais. As modificações aplicadas encontram-se detalhadas na Tabela 5.28, sendo essas utilizadas para a obtenção e interpretação dos resultados apresentados.

Tabela 5.28: Parâmetros utilizados para a configuração das simulações de dinâmica molecular conduzidas com o OpenMM por meio da função `execute_md_simulation()`. Os valores refletem a execução padrão para os compostos priorizados pelo *NeuroDock*, considerando equilíbrio e produção sob condições fisiológicas e ambiente solvatado.

Parâmetro	**Valor**
`production_duration_ns`	`50`
`integration_step`	`2.0 fs`
`equilibration_duration_steps`	`100000`
`reporting_interval_steps`	`1000`
`checkpoint_interval_steps`	`1000`

Para cada simulação de DM realizada, analisamos quatro métricas fundamentais: (i) o desvio quadrático médio das posições atômicas (RMSD), (ii) a flutuação quadrática média por

frame da simulação (RMSF), (iii) o número de ligações de hidrogênio formadas entre a proteína e o ligante ao longo do tempo e (iv) o raio de giro do sistema (Rg). A escolha dessas métricas se justifica por sua ampla aplicação na avaliação da estabilidade conformacional, da flexibilidade local, da robustez das interações intermoleculares e do grau de compactação estrutural.

Uma vez que o RMSD constitui um dos principais indicadores da estabilidade conformacional ao longo da simulação, utilizamos essa informação para observar três componentes: (i) o complexo proteína-ligante, (ii) a proteína isolada e (iii) os átomos do *backbone*. O objetivo foi distinguir entre alterações estruturais globais e variações locais ou periféricas. Nesse sentido, a principal evidência de interesse foi o comportamento dessa métrica para o complexo, cuja convergência para um platô estável ao longo do tempo foi interpretada como evidência de equilíbrio conformacional e manutenção da interação proteína-ligante. Embora o RMSD do *backbone* seja amplamente utilizado como referência para avaliar a conservação da estrutura proteica, com valores entre 0.2 e 0.4 `nm` (2–4 Å) frequentemente associados à estabilidade estrutural, tal observação foi empregada de modo complementar, com ênfase nas análises do complexo como um todo, dada a relevância funcional das interações intermoleculares para o desempenho bioativo do sistema.

Adicionalmente, foi analisada a dinâmica local das estruturas por meio do cálculo do RMSF, o qual quantifica as variações posicionais dos átomos de cada resíduo em relação à sua posição média ao longo da simulação. Essa abordagem permitiu distinguir entre estabilidade conformacional e mobilidade funcional localizada. De modo geral, regiões com elementos regulares de estrutura secundária, como hélices-α e folhas-β, tendem a exibir valores baixos de RMSF, evidenciando sua rigidez relativa. Em contrapartida, picos elevados nesta métrica concentram-se em alças expostas ao solvente e nas extremidades N- e C-terminais, regiões naturalmente flexíveis, cuja mobilidade não necessariamente implica instabilidade funcional, mas pode estar relacionada à interação com ligantes, regulação alostérica ou variações funcionais conformacionais (SHUKLA; TRIPATHI, 2020).

Paralelamente às análises estruturais citadas, a quantificação do número de ligações de hidrogênio ao longo da simulação foi empregada como métrica fundamental para a avaliação da estabilidade e especificidade das interações intermoleculares entre a proteína e o ligante. Em contraste com indicadores estruturais globais, como o RMSD e Rg, ou métricas locais, como o RMSF, a análise das ligações de hidrogênio proporciona uma perspectiva funcional diretamente ancorada na persistência dos contatos moleculares que sustentam a interação entre os parceiros. A dinâmica dessas ligações ao longo do tempo permite inferir o grau de eficácia da interface de ligação frente às flutuações conformacionais, contribuindo, portanto, para a compreensão da estabilidade do complexo sob condições simuladas próximas ao ambiente fisiológico.

Já o Rg foi monitorado como indicador da compactação estrutural global da proteína ao longo da trajetória simulada. A estabilidade dessa métrica durante as simulações, caracterizada pela ausência de tendências de expansão ou colapso, reforça a conservação da organização tridimensional do sistema, afastando a ocorrência de eventos de desnaturação ou desdobramento conformacional. O comportamento dessas métricas ao longo da simulação do composto

16399049 em interação com a enzima AChE é apresentado na Figura 5.11, a qual sintetiza as variações estruturais observadas e sustenta a interpretação de estabilidade conformacional do sistema.

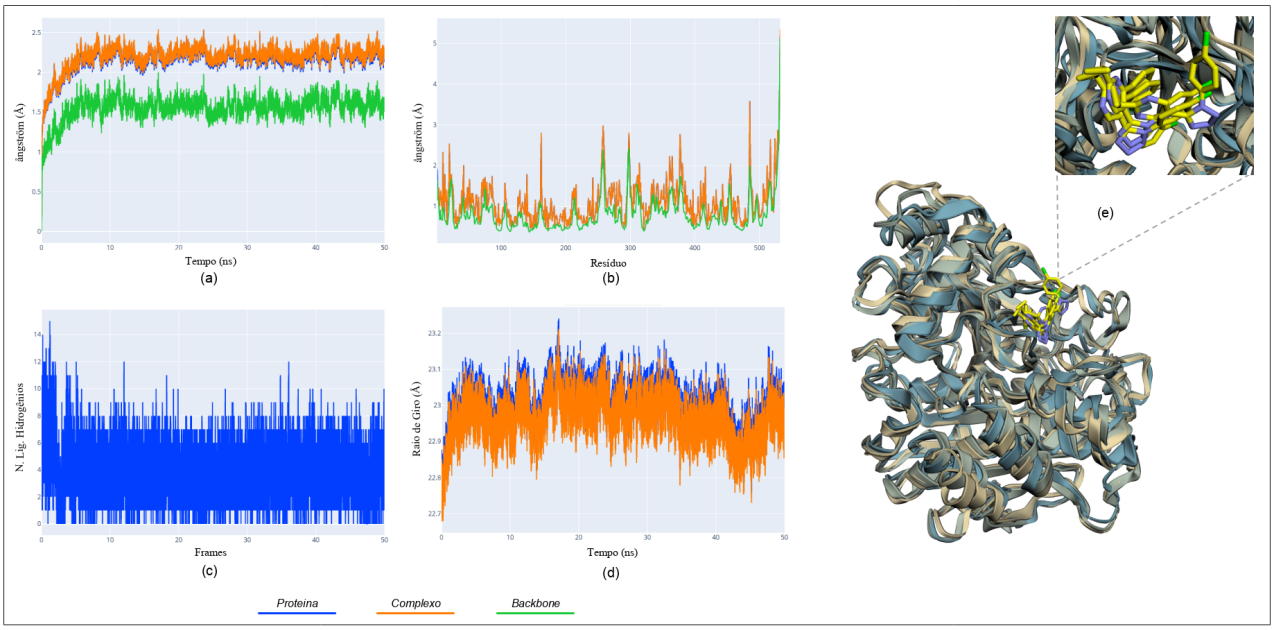

Figura 5.11: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC 16399049, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE.

A representatividade do RMSD na Figura 5.11a revela as variações estruturais ao longo de 50 ns de simulação, contemplando o complexo proteína-ligante (linha laranja), a proteína isolada (linha azul) e o *backbone* (linha verde). Conforme pode ser observado, os valores obtidos permaneceram consistentemente baixos e com flutuações mínimas, o que indica elevada estabilidade estrutural durante toda a trajetória simulada. A ausência de desvios expressivos ou picos abruptos sugere que não houve perturbações significativas na estrutura global do sistema. Além disso, a proximidade entre as curvas do complexo e do *backbone*, bem como deste em sobreposição com a proteína isolada, reforça a hipótese de que a ligação do composto 16399049 ao sítio ativo periférico da AChE não provocou alterações conformacionais relevantes na estrutura primária da enzima, mantendo sua integridade ao longo do tempo.

De forma complementar, o RMSF, apresentado na Figura 5.11b, evidencia baixos níveis de mobilidade para a maioria dos resíduos da cadeia polipeptídica, tanto para o *backbone* quanto para o complexo. Picos localizados foram identificados em regiões específicas, compatíveis com domínios mais flexíveis, bem como com resíduos do sítio ativo associados a interações de maior afinidade (Figura 5.9). Além disso, a predominância de valores semelhantes entre o complexo e o *backbone* ao longo da sequência reforça a manutenção da rigidez estrutural da proteína, indicando que a presença do ligante não comprometeu a estabilidade conformacional da enzima. A sobreposição das curvas nas duas condições analisadas torna evidente, portanto, a interpretação de que a interação proteína-ligante foi conformacionalmente compatível e não disruptiva.

A avaliação da evolução temporal do número de ligações de hidrogênio estabelecidas entre o ligante e a AChE (Figura 5.11c) revela um padrão elevado e estável de interações ao longo da simulação, evidenciando a formação de contatos moleculares persistentes e energeticamente favoráveis. Tal comportamento é indicativo de uma ancoragem eficaz, contribuindo tanto para a retenção do composto no sítio de ligação quanto para a estabilidade estrutural global do complexo.

Nesse contexto, a análise do Rg, ilustrada na Figura 5.11d para a proteína isolada e para o complexo, reforça essa interpretação ao demonstrar valores consistentes e com variações mínimas ao longo de toda a simulação. A manutenção desse parâmetro estrutural ao longo do tempo sugere a ausência de eventos de desdobramento, colapso conformacional ou alterações estruturais significativas, indicando a preservação da organização terciária da enzima tanto em sua forma livre quanto complexada.

Somando-se às evidências previamente discutidas, a Figura 5.11e revela que a ancoragem do composto `16399049` ocorreu predominantemente na região periférica da enzima, compatível com a localização do sítio periférico de ligação à acetilcolina (PAS). Tal observação está em consonância com análises anteriores sobre a arquitetura da fenda catalítica da AChE e reforça a hipótese de múltiplos modos de interação, incluindo contribuições estruturais e funcionais relevantes fora do sítio catalítico central (CAS).

De maneira geral, os resultados obtidos para a AChE indicam um perfil estrutural estável, com interações proteína-ligante bem definidas e compatíveis com os sítios de ligação previamente caracterizados. De forma similar, análises conduzidas para a BChE revelaram tendências semelhantes, tanto em termos de estabilidade conformacional quanto de persistência das interações intermoleculares ao longo das simulações. A seguir, tem-se na Figura 5.12 os principais achados para a BChE, os quais reforçam a consistência dos efeitos observados entre as duas colinesterases e sugerem potenciais mecanismos de ação compartilhados pelo composto `16399049`.

Conforme evidenciado no *footprint* da BChE (Figura 5.9b), o número de resíduos que interagem com o composto `16399049` é consideravelmente maior em comparação à AChE, resultando em um perfil de interações mais extenso e proeminente. Essa característica se reflete de forma coerente nas análises de RMSF, número de ligações de hidrogênio e Rg (Figura 5.12), cujos padrões reforçam a adequação das interações intermoleculares observadas. Adicionalmente, os valores de RMSD mantêm-se em patamar estável ao longo da simulação, caracterizando um platô que, assim como observado na AChE, indica estabilidade conformacional e favorece a interpretação de uma ancoragem eficiente do ligante. Por fim, a Figura 5.12e mostra que o composto se acomoda adequadamente no interior do sítio catalítico da BChE, conformação compatível com a formação de um complexo estável e funcionalmente relevante.

Em contraste com os resultados anteriormente descritos para as colinesterases, a análise das interações entre o composto `16399049` e a enzima BACE1 evidenciou um comportamento distinto. Aproximadamente aos 15 ns de simulação, foi observado o desligamento do ligante do sítio de ligação, fato que resultou em oscilações abruptas nos parâmetros estruturais monitorados, conforme previamente discutido. Tal comportamento indica uma ancoragem instável e

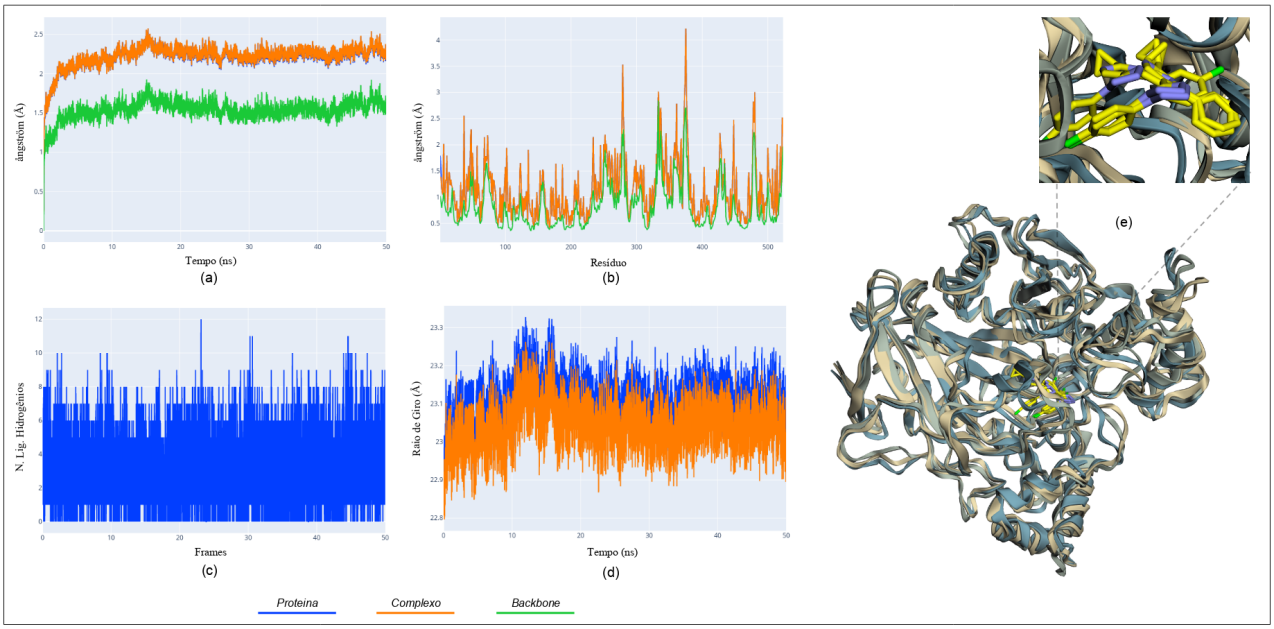

Figura 5.12: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante 16399049, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE.

sugere baixa afinidade conformacional entre o composto e a BACE1 ao longo da trajetória simulada. A Figura5.13 ilustra esse padrão dinâmico, destacando, inclusive, as diferentes posições ocupadas pelo ligante ao longo do experimento (Figura 5.13e).

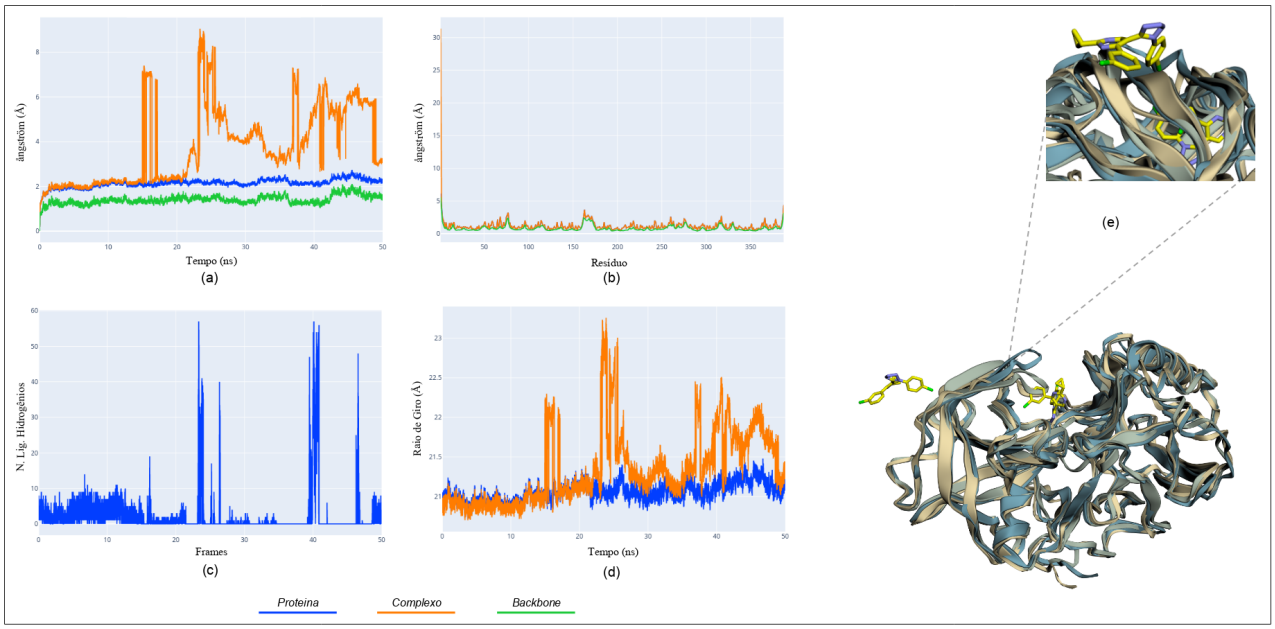

Figura 5.13: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante 16399049, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1.

Esse comportamento pode estar relacionado a uma combinação de fatores estruturais e estereoeletrônicos desfavoráveis, como a ausência de interações de ancoragem específicas (por exemplo, ligações de hidrogênio persistentes ou contatos hidrofóbicos profundos), bem como

a incompatibilidade do volume ou da polaridade do ligante com a topologia do sítio ativo da BACE1. Adicionalmente, a geometria do composto pode não favorecer o encaixe adequado nos bolsões catalíticos da enzima, limitando a formação de interações estáveis e favorecendo a sua dissociação ao longo do tempo. Tais evidências sugerem que a BACE1 não constitui um alvo preferencial para o composto `16399049`, em contraste com as colinesterases, para as quais se observou estabilidade e persistência nas interações. Avaliações complementares com outros compostos, realizadas segundo a mesma abordagem, encontram-se disponíveis no Apêndice A.

Capítulo

6

Conclusões e Perspectivas Futuras

6.1 Considerações Finais

A presente tese propôs e desenvolveu uma abordagem computacional integrada voltada à descoberta e ao reposicionamento racional de fármacos, com foco específico na DA e na identificação de inibidores direcionados às enzimas AChE, BChE e BACE1. Considerando a elevada complexidade inerente a essa patologia de natureza progressiva e etiologia multifatorial, foi concebido um fluxo de trabalho robusto, modular e adaptável, denominado *DrugHunter*, projetado como uma solução abrangente para os desafios recorrentes nos processos de TV/HTVS, curadoria de dados e modelagem molecular, com suporte em métodos emergentes de CADD e AIDD. Nesse sentido, apresentamos uma resposta inovadora às múltiplas demandas dos estudos *in silico*, ao integrar diferentes níveis de realização experimental, promovendo eficiência, reprodutibilidade e racionalidade nos processos de identificação de candidatos terapêuticos.

Entre os principais achados deste estudo, destaca-se a consolidação de um *workflow* computacional capaz de integrar, de forma coerente, múltiplas etapas do processo de *drug discovery*, desde a curadoria de compostos para formação de domínios químicos específicos até a realização de simulações de DM de complexos proteína-ligante, com base na seleção de *hits* promissores extraídos a partir da triagens em larga escala, utilizando para isso métodos computacionais preditivos. Inserida nesse contexto, a ferramenta *NeuroDock* demonstrou desempenho preditivo consistente ao empregar modelos de DL por MLP para ancoragem molecular, promovendo a priorização de subconjuntos de compostos bioativos com elevado potencial terapêutico. Sua capacidade de adaptação ao espaço químico analisado evidenciou, ainda, notável generalização no processo de *docking*, característica desejável em cenários computacionais emergentes. A validação do *NeuroDock*, fundamentada nos dados previamente curados pela plataforma *BioMolExplorer*, evidenciou: (a) a relevância da definição criteriosa de domínios químicos para o treinamento e aplicação de modelos de IA; e (b) a necessidade de uma curadoria refinada, inte-

grando múltiplas bases químicas, aspecto frequentemente negligenciado em soluções tradicionais de TV/HTVS.

Adicionalmente, a análise dos compostos selecionados revelou padrões estruturais interessantes nos bioativos e análogos priorizados para cada uma das enzimas-alvo. Verificou-se que os inibidores mais promissores para AChE e BChE compartilham fragmentos com elevada rigidez conformacional, formados principalmente por núcleos aromáticos condensados, baixa flexibilidade torsional e reduzido número de ligações rotacionais livres. Essas características são compatíveis com sítios de ligação rigidamente definidos, como os observados na AChE. Em contraste, os compostos com maior afinidade preditiva frente à BACE1 apresentaram cadeias laterais mais extensas, elevada diversidade topológica e maior liberdade conformacional, sugerindo a necessidade de flexibilidade estrutural para interação eficaz com o sítio catalítico dessa enzima.

As diferenças conformacionais observadas entre os compostos analisados evidenciam os desafios inerentes ao desenvolvimento de inibidores multialvo, especialmente quando se almeja eficácia simultânea sobre as enzimas AChE, BChE e BACE1. As análises de similaridade estrutural revelaram padrões de sobreposição seletiva entre fragmentos recorrentes nos compostos prioritários para cada enzima, indicando que os domínios químicos explorados apresentam, em sua maioria, interseções limitadas. Tal constatação impõe restrições significativas ao desenho de moléculas com perfil polifarmacológico, exigindo estratégias de modelagem que conciliem seletividade molecular, eficiência terapêutica e a minimização de efeitos adversos. Nesse contexto, a identificação e o refinamento de *scaffolds* com potencial para modular múltiplos alvos tornam-se componentes estratégicos no processo de descoberta racional de fármacos. Esses esforços demandam abordagens computacionais altamente precisas, fundamentadas em princípios de complementaridade estereoeletrônica, flexibilidade conformacional controlada e integração inteligente de dados estruturais e funcionais, a fim de maximizar a eficácia multialvo sem comprometer a especificidade farmacológica.

Os achados desta pesquisa indicam que a BChE apresenta maior permissividade estrutural, evidenciada por um sítio de ligação mais amplo, acessível e topologicamente flexível. Essa característica confere maior tolerância à ancoragem de compostos com estruturas híbridas e conformacionais mais diversas, o que a destaca como um alvo estratégico em abordagens terapêuticas multialvo. Nesse contexto, a BChE pode atuar como um elo de compatibilização estrutural entre AChE e BACE1, viabilizando o desenho racional de inibidores com ação simultânea sobre múltiplos alvos. Diante disso, acreditamos que futuras investigações devam se concentrar na identificação e otimização de moléculas capazes de promover interações sinérgicas entre a AChE e BACE1, ampliando o potencial terapêutico sem comprometer a seletividade farmacológica, um requisito essencial no desenvolvimento de candidatos clinicamente viáveis.

Assim, a avaliação do *DrugHunter* sobre a DA demonstrou não apenas sua aplicabilidade como ferramenta versátil e de arquitetura generalista, mas também sua capacidade de capturar sutilezas farmacológicas críticas, permitindo a exploração de diferentes perspectivas no processo de triagem. Observou-se que os compostos priorizados, em sua maioria, exibiram propriedades

fisicoquímicas compatíveis com a permeabilidade à BHE, um requisito essencial para agentes terapêuticos direcionados ao SNC. Isso reforça a validade das etapas de filtragem implementadas e atesta o potencial da abordagem desenvolvida.

Por fim, os resultados obtidos permitiram aprofundar a compreensão sobre a complexidade dos alvos investigados, em especial no que se refere aos desafios da seletividade molecular em contextos polifarmacológicos. A constatação de sobreposição seletiva entre os sítios ativos das enzimas e os perfis de similaridade química encontrados entre os compostos sugere uma tendência à promiscuidade molecular, que, embora vantajosa sob certas perspectivas terapêuticas, requer avaliação rigorosa quanto ao risco de efeitos adversos e à toxicidade associada. Além disso, foram observadas evidências de que o *footprint*, gerado pelo Dock6, pode desempenhar um papel relevante na seleção de alvos adequados para simulações de DM. As relações energéticas mais pronunciadas no *footprint*, quando correlacionadas aos resíduos críticos do sítio de ligação, parecem associar-se aos melhores desempenhos nas análises de DM, o que representa uma contribuição potencialmente valiosa para a identificação de compostos mais promissores a serem submetidos a essa etapa, possibilitando a otimização de recursos e a redução de custos e tempo na condução das análises.

6.1.1 Perspectivas Futuras

Tendo em vista os avanços obtidos, diversas direções promissoras podem ser exploradas para o aprimoramento e ampliação do *DrugHunter*. Em especial, destacam-se:

- Desenvolvimento de uma interface gráfica interativa, capaz de facilitar a configuração, execução e interpretação dos resultados por usuários não especialistas, promovendo maior acessibilidade ao sistema.

- Incorporação de modelos preditivos para toxicidade em larga escala, empregando arquiteturas de aprendizado profundo treinadas em bancos de dados específicos (e.g., Tox21, ToxCast), de forma a antecipar riscos associados ao perfil de segurança dos compostos selecionados.

- Adoção de abordagens baseadas em *scaffold hopping*, com ênfase na identificação de fragmentos estruturais privilegiados e no reposicionamento de esqueletos moleculares bioativos, como estratégia complementar à análise de similaridade.

- Integração com métodos de aprendizado ativo (*Active Learning*) para refinar o processo iterativo de seleção de compostos, otimizando recursos computacionais e laboratoriais com base no *feedback* contínuo dos modelos.

- Exploração de modelos generativos baseados em inteligência artificial, tais como *Variational Autoencoders* (VAEs) e *Generative Adversarial Networks* (GANs), com o objetivo de propor novas entidades moleculares derivadas de padrões estruturais e farmacofóricos extraídos de compostos previamente identificados como promissores. Ampliar esse

escopo para incluir abordagens de geração por alucinação, capazes de extrapolar o espaço químico conhecido e sugerir conformações inéditas, como apresentado no trabalho de Anishchenko et al. (2021), que emprega modelos de *deep learning* para a concepção de enzimas sintéticas com funcionalidades específicas.

6.1.2 Principais Contribuições

O presente trabalho resultou em um conjunto de contribuições científicas, tecnológicas e institucionais, que refletem tanto a solidez metodológica adotada quanto o elevado potencial de impacto das soluções desenvolvidas no contexto da descoberta e do reposicionamento de fármacos mediados por abordagens de CADD. A estratégia proposta permitiu integrar, de forma eficaz e flexível, diferentes etapas do processo de TV/HTVS com abordagens emergentes de AIDD, consolidando um fluxo computacional robusto e adaptável. Essa integração viabilizou, conforme apresentado no Capítulo 5, uma investigação aprofundada de múltiplos fatores essenciais à identificação de compostos promissores com potencial polifarmacológico, promovendo não apenas a priorização de *hits*, mas também a compreensão de seus modos de interação com diferentes alvos biomoleculares. Nesse sentido, detalhamos a seguir as principais contribuições:

- Apoio técnico e científico no processo de elaboração do artigo "*Virtual screening algorithms in drug discovery: a review focused on machine and deep learning methods*" - (OLIVEIRA et al., 2023b), sendo esse utilizado como parte do suporte necessário para a compreensão das estratégias adotadas no fluxo de trabalho do *DrugHunter*.

- Apoio técnico e científico, empregando o *DrugHunter*, no processo de seleção de inibidores empregados no estudo apresentado por Mendes et al. (2023b), contribuindo diretamente para o delineamento do conjunto de compostos avaliados. Esforços semelhantes foram empregados na elaboração do artigo *"Silodosin as a Novel Inhibitor of Acetylcholinesterase, Butyrylcholinesterase and Beta-Secretase 1: In Vitro and In Silico Studies"*, recentemente submetido à revista ACS Omega.

- Apoio técnico e científico, empregando o *DrugHunter*, no processo de identificação da quercetina como possível neuroprotetor para a doença de Alzheimer. Achados estão sendo compilados no artigo "*Neuroprotective Effects of Quercetin on the Nervous Tissue of Rats with Alzheimer's Disease*" para submissão.

- Apoio técnico e científico no processo de seleção de *hits*, por meio da utilização da ferramenta *DrugHunter*, no âmbito do estudo "Uma Abordagem Baseada em Triagem Virtual para o Combate à Candida auri", apresentado como Trabalho de Conclusão de Curso em Engenharia de Computação no CEFET-MG pelo discente *Victor Geraldo Faria Costa*. Essa contribuição foi importante para o delineamento do conjunto de compostos avaliados, bem como para a identificação dos hits mais promissores.

- Apoio técnico e científico, mediante a utilização da ferramenta *DrugHunter*, no processo de definição do domínio de exploração e na aplicação de estratégias de *docking* molecular por

consenso, no âmbito do mestrado em Bioengenharia da Universidade Federal de São João del-Rei (UFSJ), desenvolvido pela aluna Isabela Santos de Melo Wiermann, intitulado "Triagem Virtual para a Seleção de Inibidores da Enzima Quinona Redutase 2 para o Tratamento da Doença de Alzheimer".

- Colaboração no processo de solicitação e obtenção da patente número `BR1020240237625` para o uso da silodosina para o tratamento da doença de Alzheimer, bem como no processo de elaboração do artigo "*Silodosin as a novel inhibitor of acetylcholinesterase, butyrylcholinesterase and beta-secretase 1: in vitro and in silico studies*", em fase final de revisão.

- Estabelecimento de acordo internacional de cooperação tecnológica com a *Dublin City University* (DCU), Irlanda, visando à ampliação da aplicabilidade da ferramenta *DrugHunter* no contexto de TV/HTVS.

- Redação e submissão do manuscrito intitulado *BioMolExplorer: Enabling Multi-Source Data Integration for Structure- and Ligand-Based Virtual Screening* à revista *Cheminformatics* (grupo *Nature*), atualmente em processo de avaliação por pares.

- Obtenção de registro de três soluções tecnológicas junto ao Instituto Nacional da Propriedade Industrial (INPI): (a) *BioMolExplorer* - BR512025001092-3; (b) *NeuroDock* - BR512025001806-1; e (c) *DrugHunter* - BR512024005038-8.

- Desenvolvimento de dois artigos em fase final de preparação: um a ser submetido à *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, apresentando a arquitetura e os resultados do *NeuroDock*; e outro direcionado à *Nature Reviews Drug Discovery*, descrevendo as funcionalidades e inovações associadas ao *DrugHunter*.

- Elaboração e realização do 1^o *workshop* para *Drug Hunters*, sob financiamento da FAPEMIG/DBE (n^o 113230351/2025), realizado na Universidade Federal de São João del-Rei (UFSJ).

- Concepção e execução do projeto *Triagem Virtual por Estratégias de Classificação Postergada e Memoização para Reposicionamento e Descoberta de Fármacos* aprovado no Edital 001/2024 - Demanda Universal da FAPEMIG (APQ-03224-24).

Apêndice

A

Dados complementares: Avaliações de Dinâmica Molecular para Diferentes Compostos Selecionados no NeuroDock

Com o objetivo de aprofundar a exploração do domínio químico identificado ao longo das predições, além do composto 16399049, outras moléculas representativas foram submetidas às mesmas abordagens de DM e às métricas de avaliação descritas no Capítulo 5. Para além das caracterizações predominantes anteriormente discutidas, buscou-se evidenciar as variações estruturais entre os compostos analisados, ampliando tanto o escopo investigativo quanto a consistência das evidências geradas.

Essa estratégia permitiu não apenas a comparação detalhada entre diferentes perfis moleculares, mas também o reforço da importância de etapas de pré-análise, como a utilização de perfis de interação (*footprints*), os quais se mostraram úteis como mecanismos de triagem e orientação preliminar na seleção de candidatos promissores para os experimentos de DM. Acreditamos que essa integração metodológica pode contribuir para uma abordagem racional e eficiente no planejamento e execução de simulações, otimizando recursos computacionais e aumentando a probabilidade de identificação de interações biologicamente relevantes.

Nesse contexto, os compostos 95467590, 1888911932, 1342121, 16429338 e 16523915 foram selecionados com base na pertinência dos mesmos resíduos de interação previamente identificados no composto 16399049, com o objetivo de avaliar a recorrência e a relevância dessas interações ao longo das simulações de DM e dos respectivos processos de ancoragem. Essa análise comparativa busca não apenas reforçar a consistência dos sítios de interação observados, mas também identificar padrões estruturais recorrentes entre os compostos analisados, com ênfase nas interações de van der Waals e nos componentes de energia eletrostática envolvidos.

Objetivamos com isso deixar como parte das discussões desta tese o quanto tais parâmetros contribuem para a compreensão mais aprofundada da estabilidade dos complexos formados e da afinidade potencial dos ligantes pelos seus respectivos alvos moleculares.

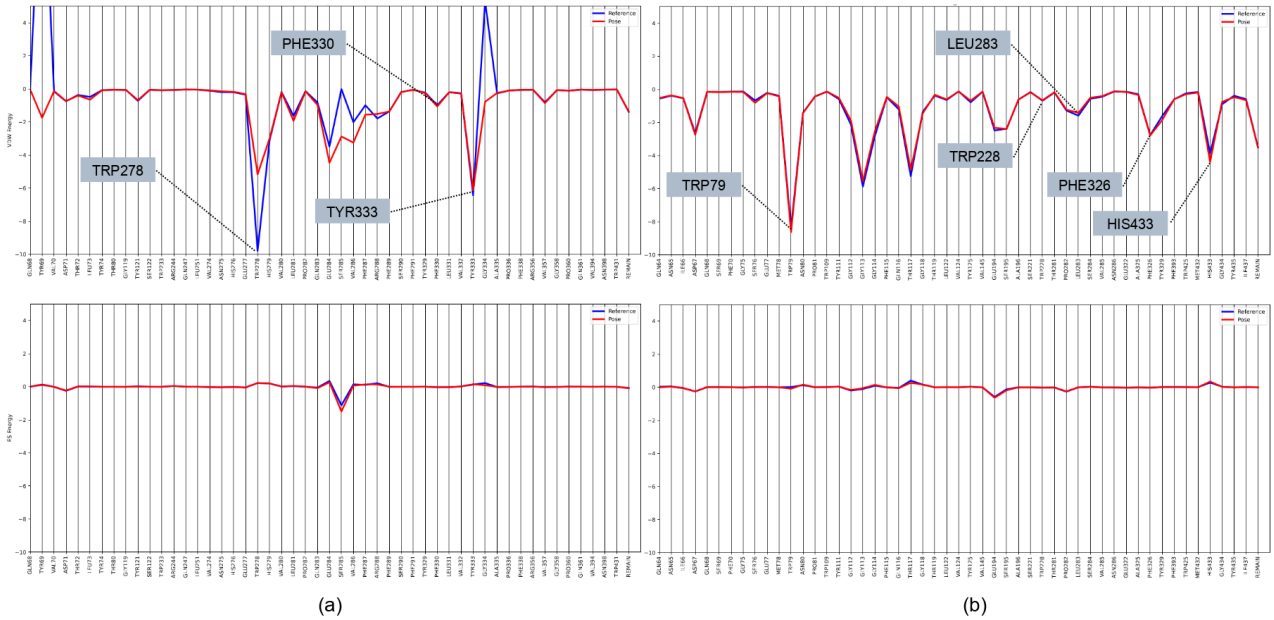

Figura A.1: Análise de contribuição energética residual para o composto 95467590 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

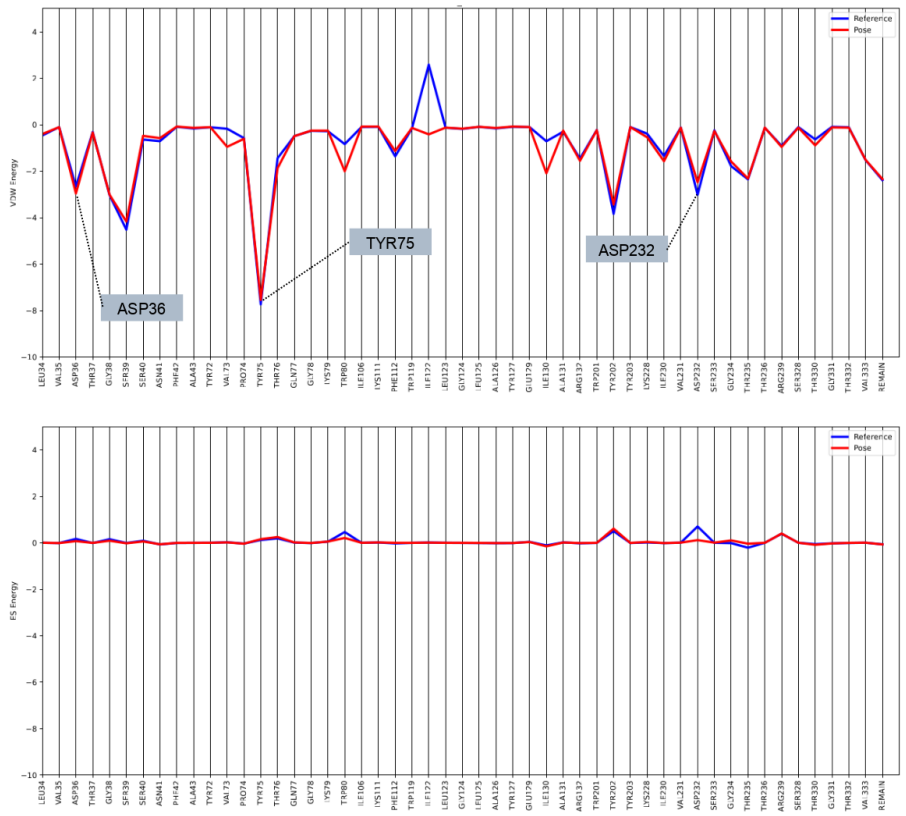

Figura A.2: Análise de contribuição energética residual para o composto 95467590 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

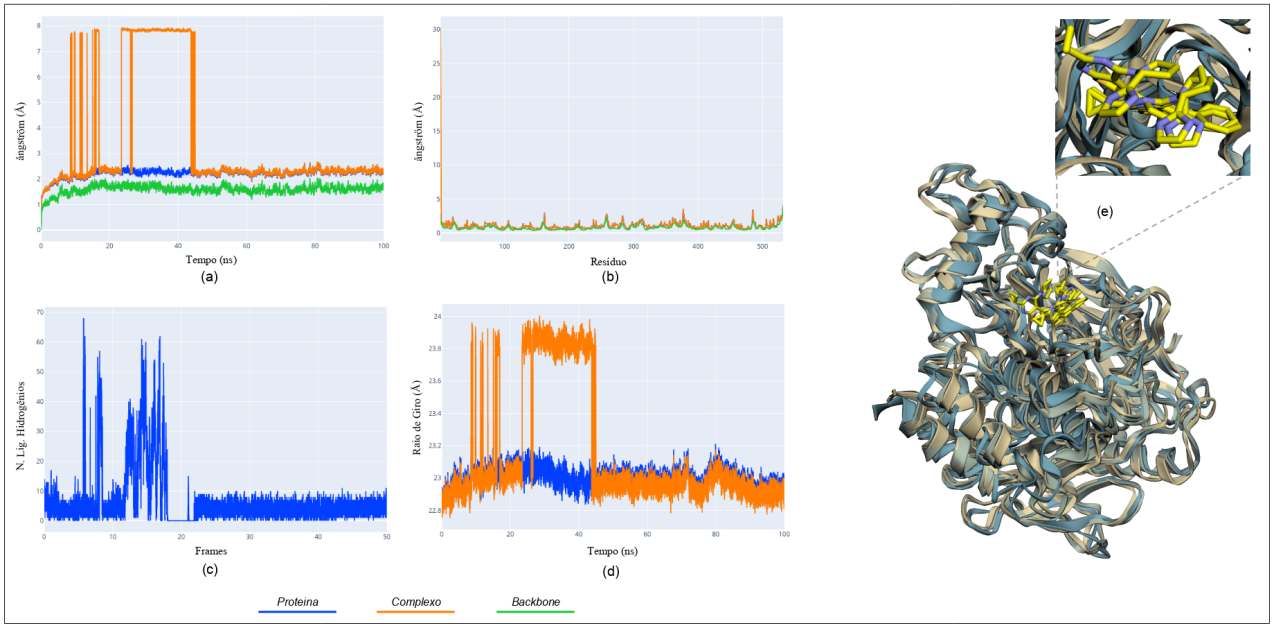

Figura A.3: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC 95467590, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE.

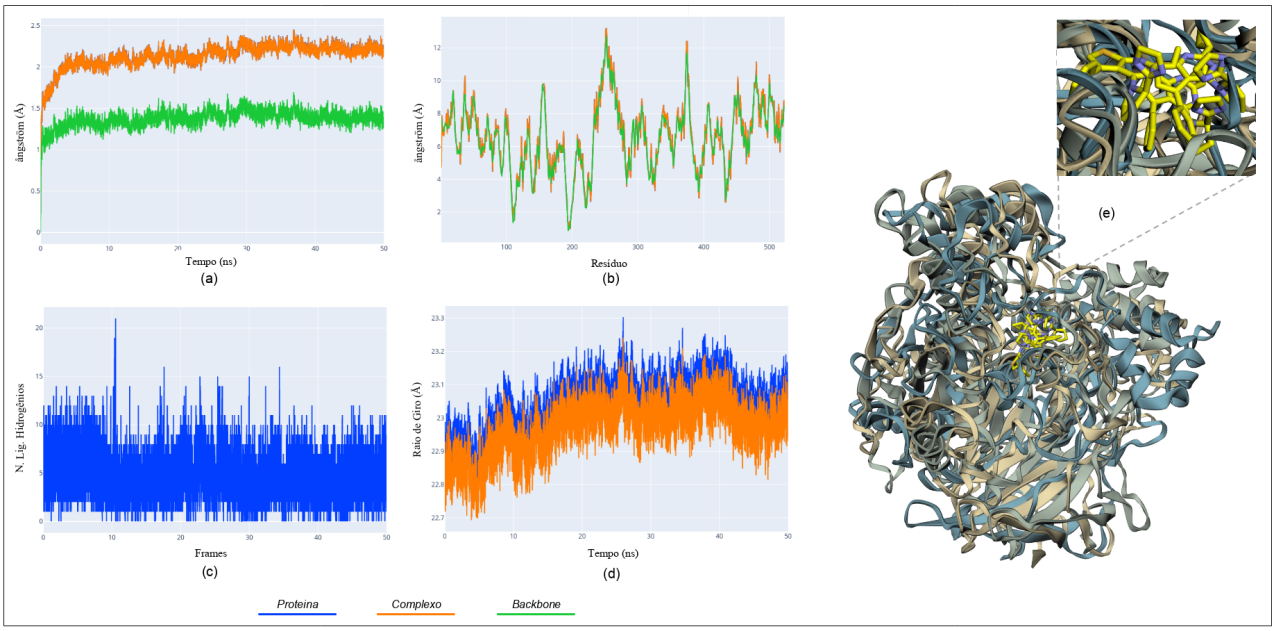

Figura A.4: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante 95467590, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE.

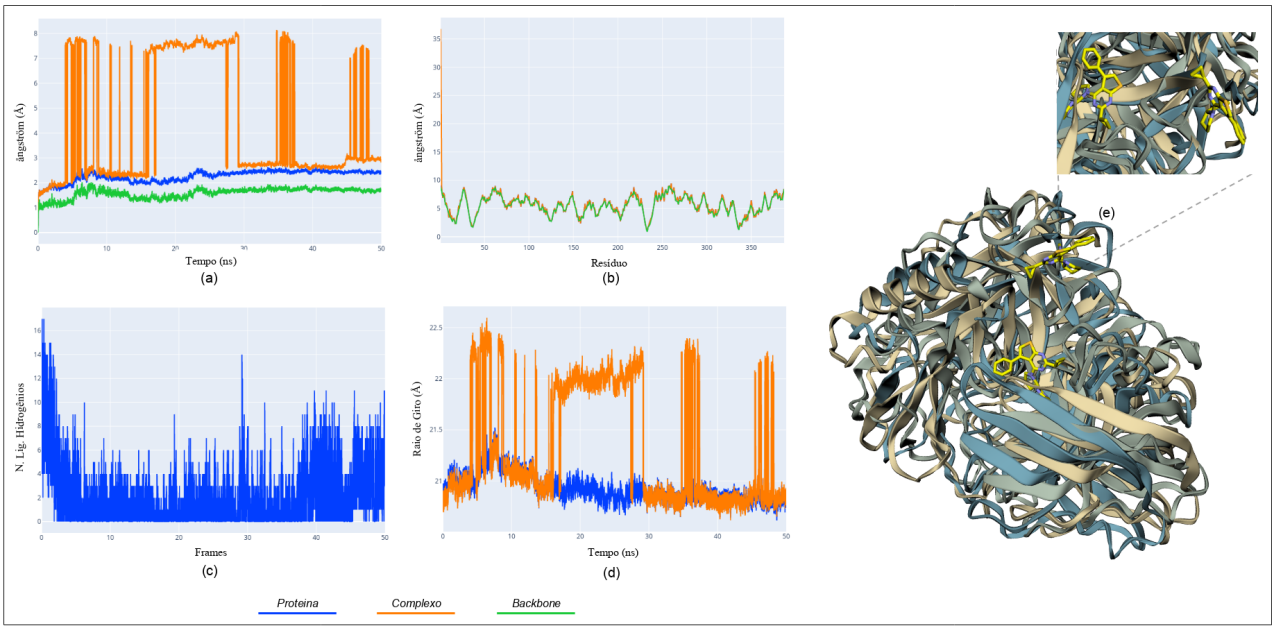

Figura A.5: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante 95467590, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1.

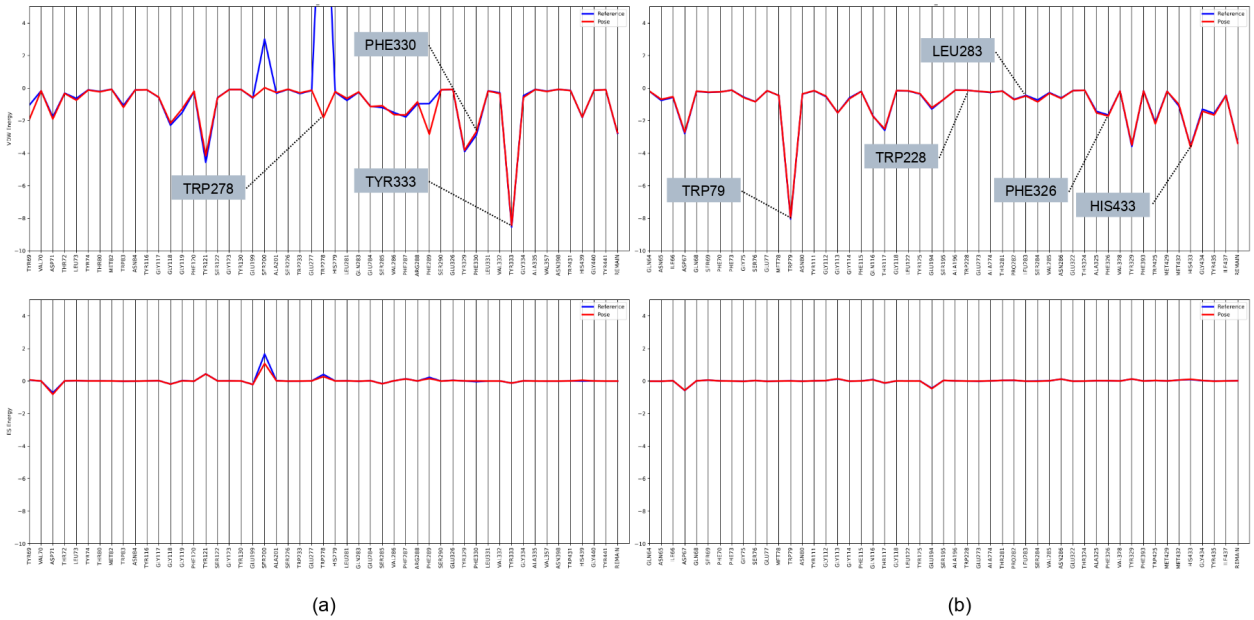

Figura A.6: Análise de contribuição energética residual para o composto 1888911932 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

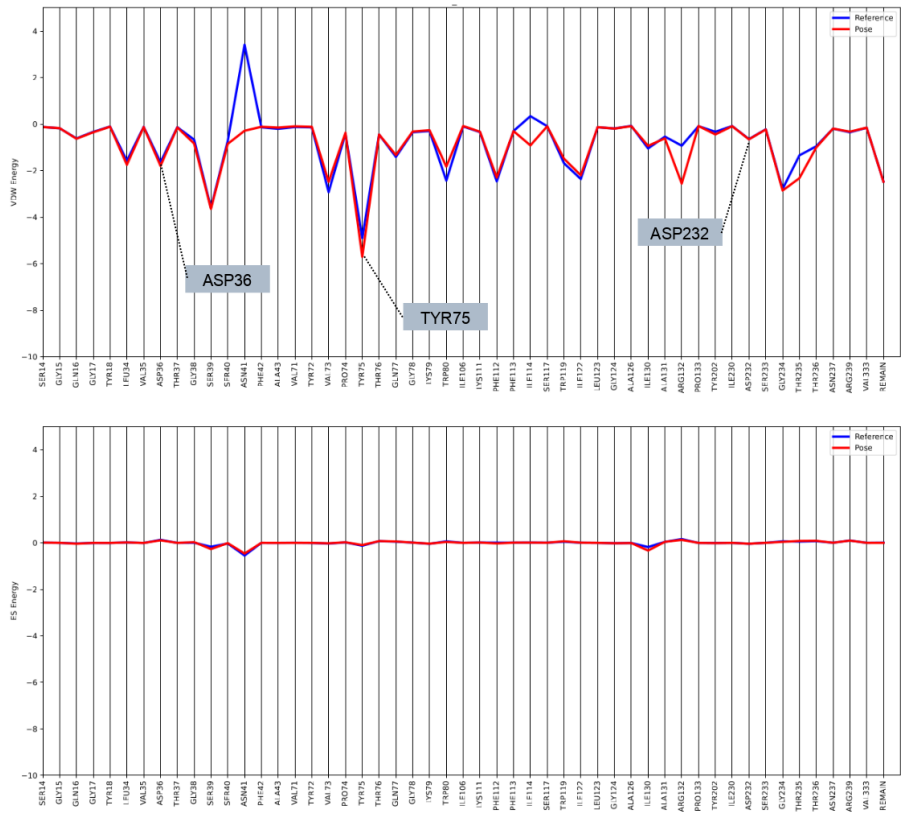

Figura A.7: Análise de contribuição energética residual para o composto 1888911932 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

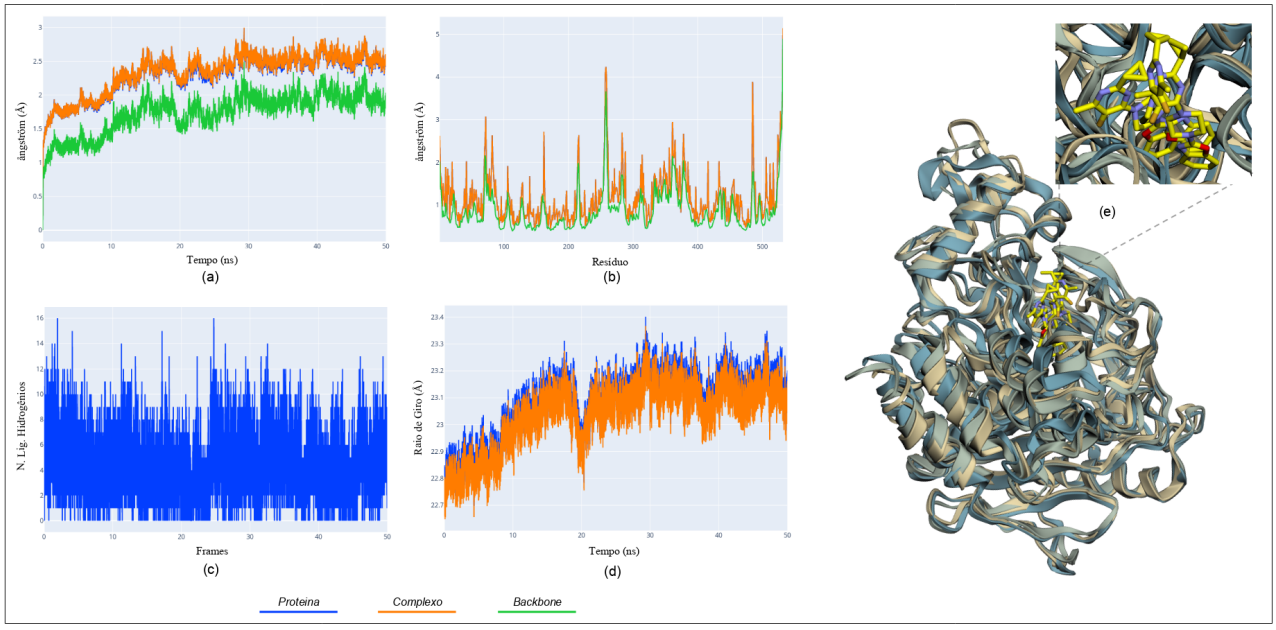

Figura A.8: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC 1888911932, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE.

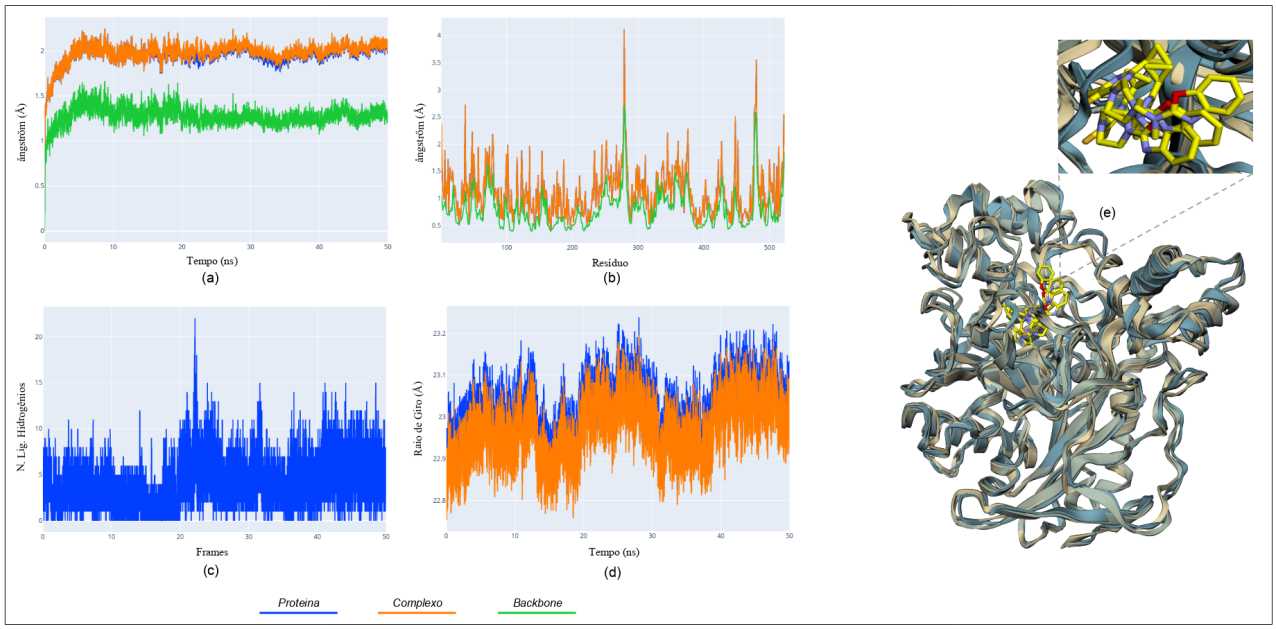

Figura A.9: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `1888911932`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE.

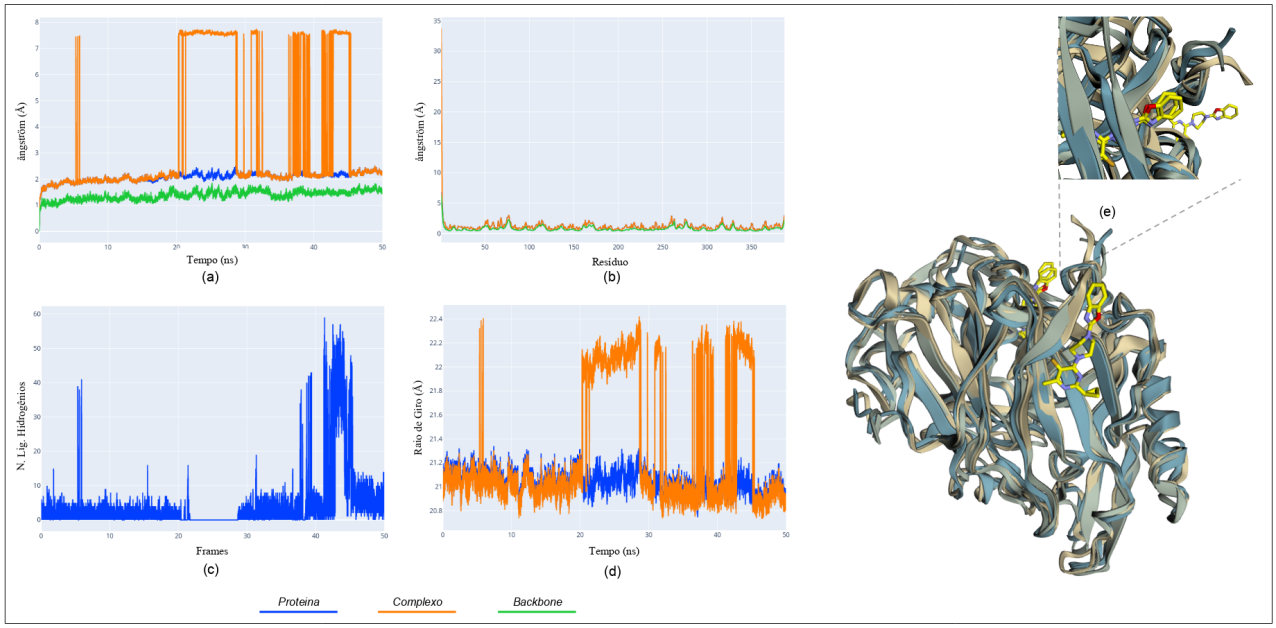

Figura A.10: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `1888911932`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1.

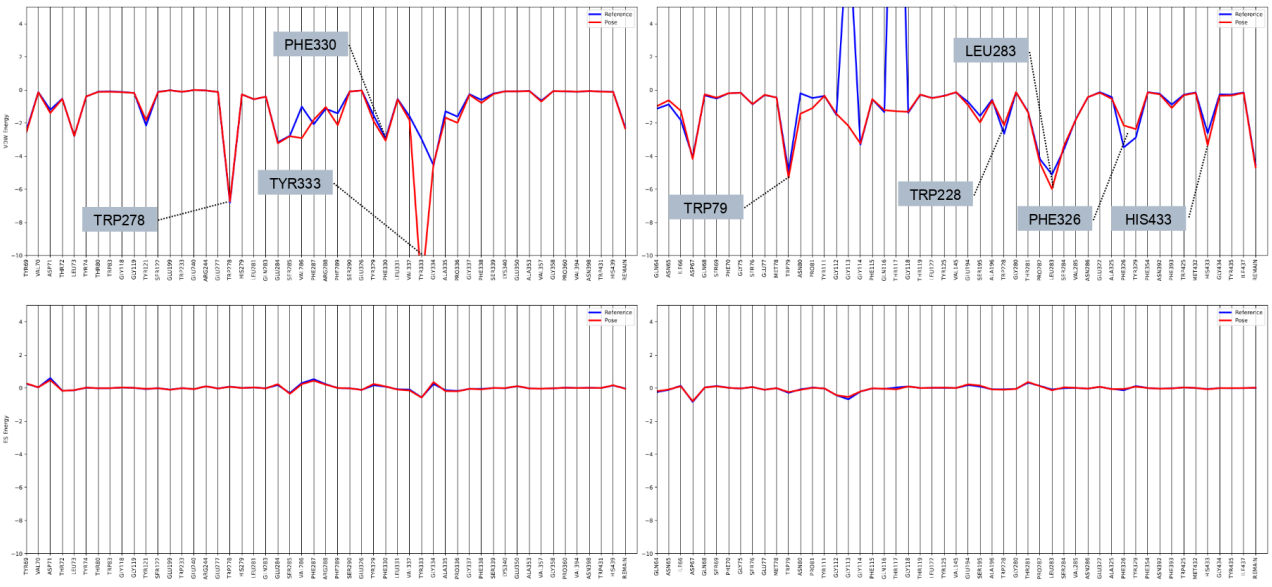

Figura A.11: Análise de contribuição energética residual para o composto 1342121 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

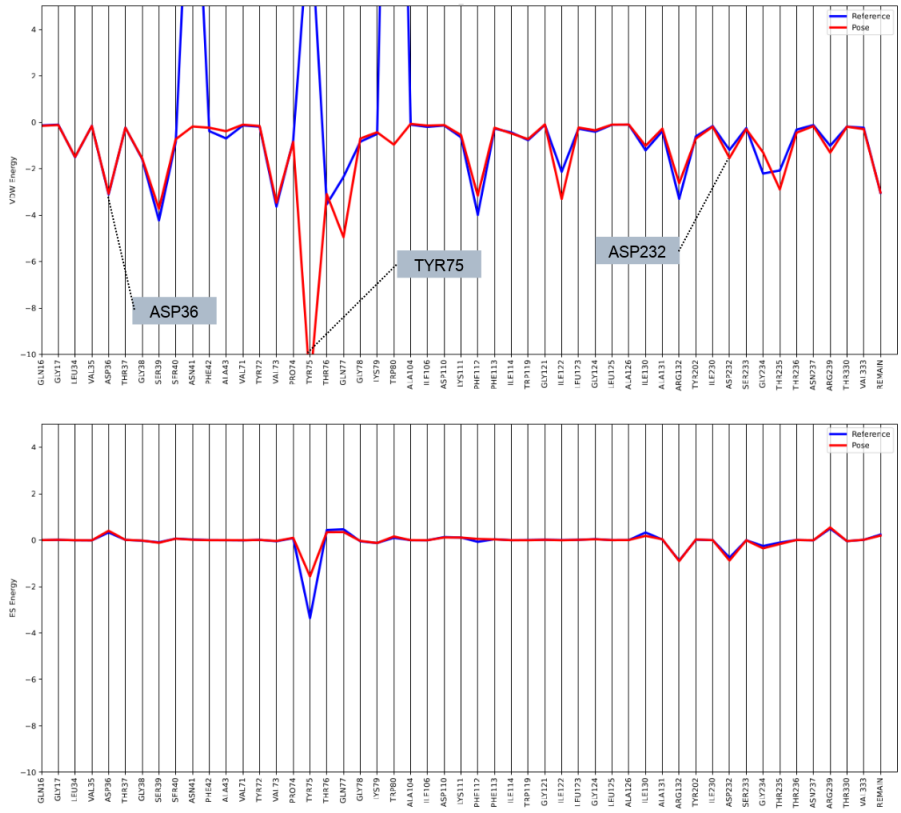

Figura A.12: Análise de contribuição energética residual para o composto 1342121 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

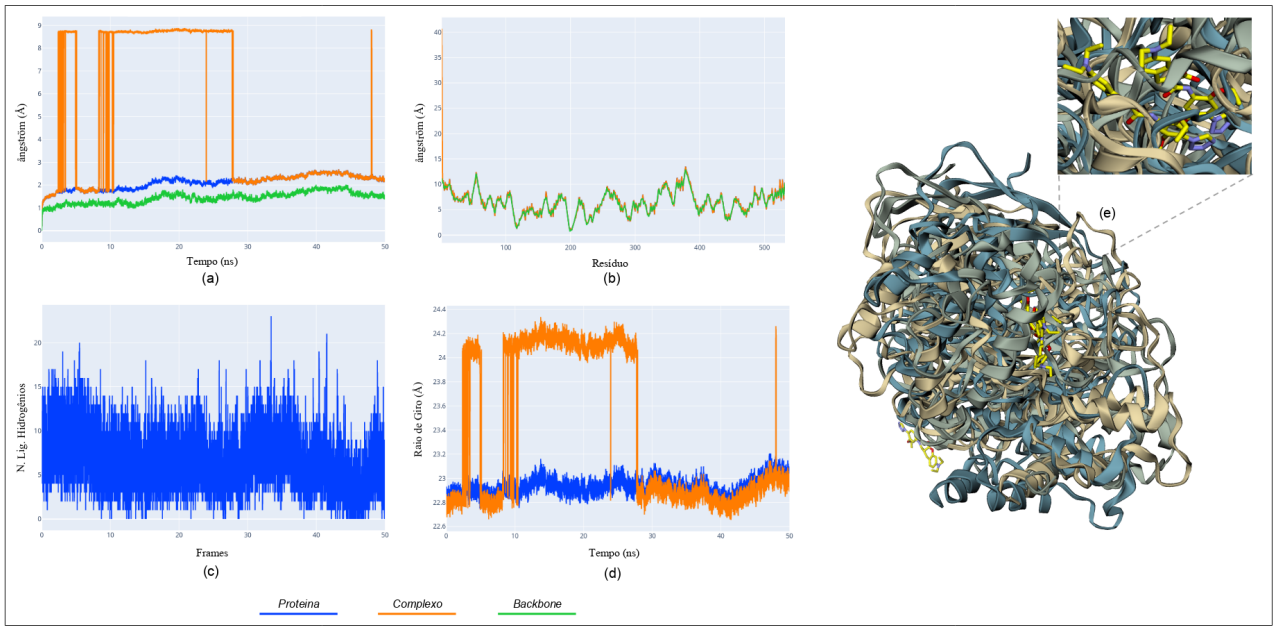

Figura A.13: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC `1342121`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE.

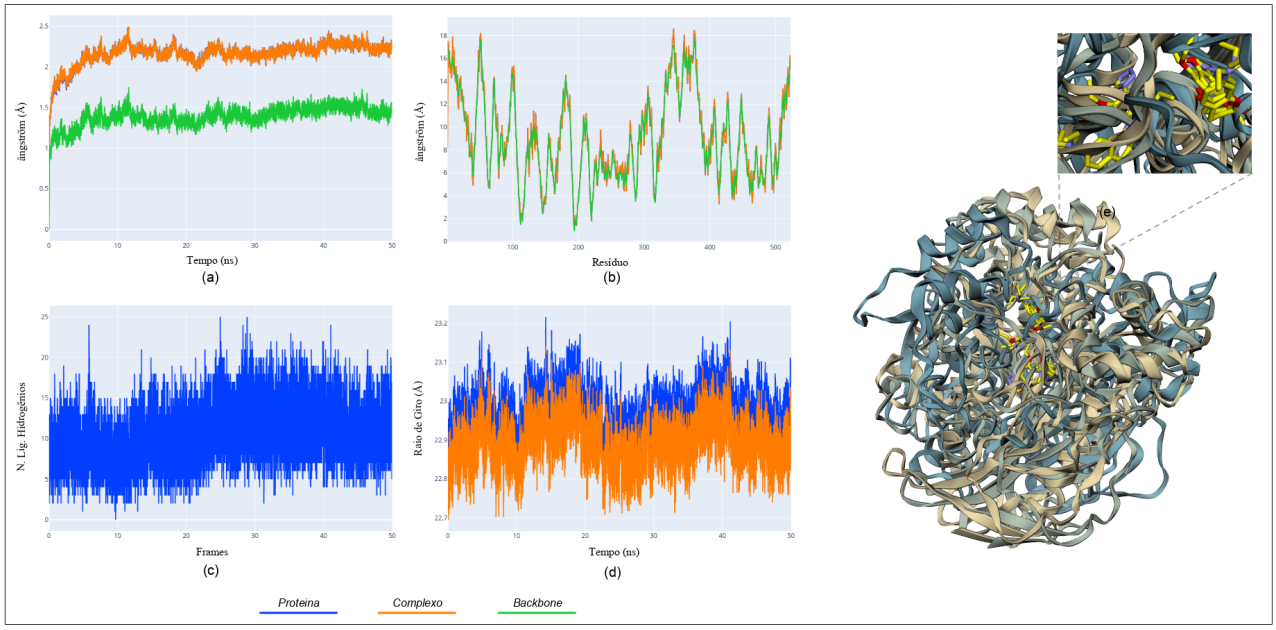

Figura A.14: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `1342121`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE.

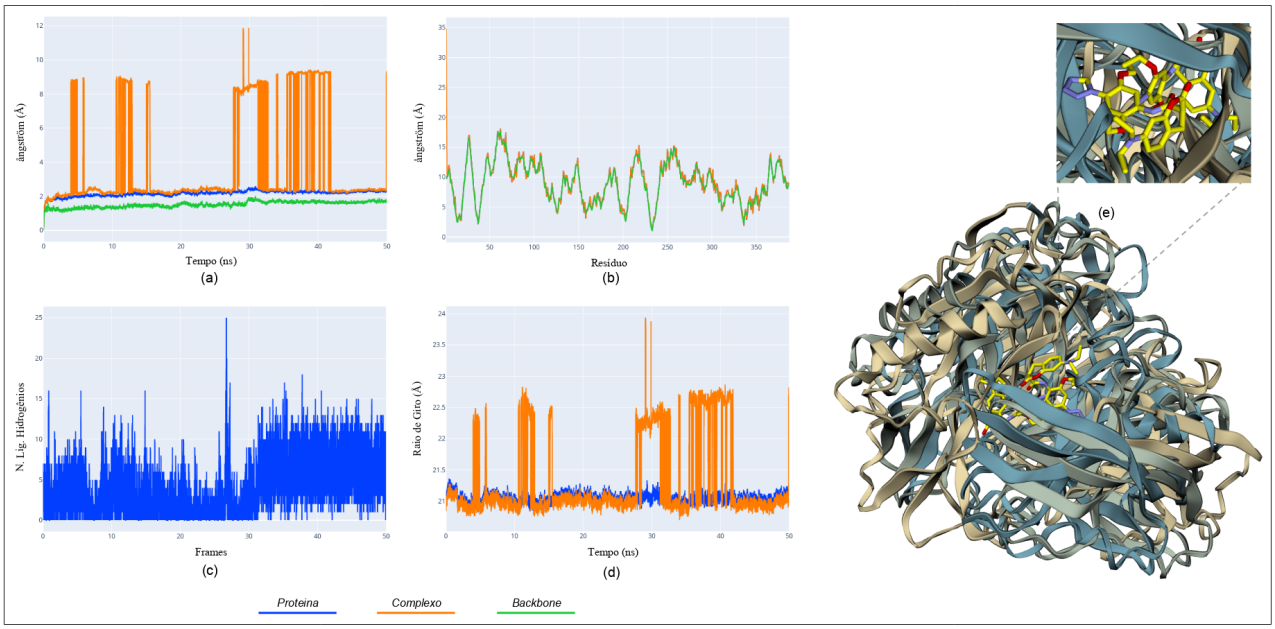

Figura A.15: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `1342121`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1.

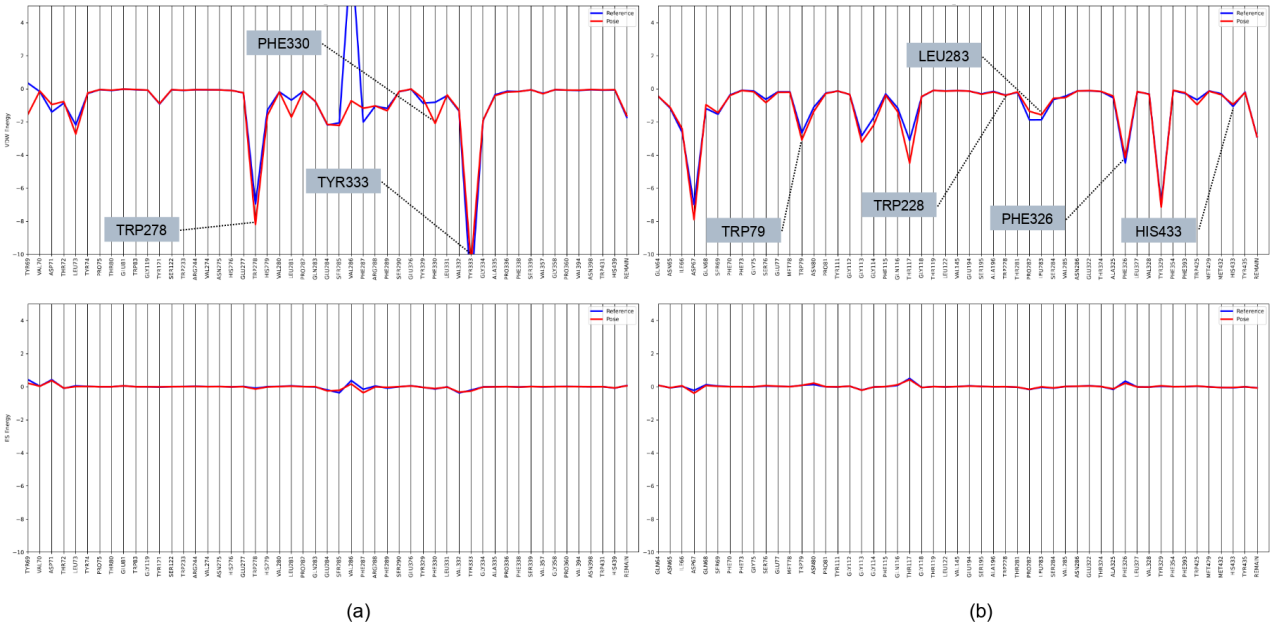

Figura A.16: Análise de contribuição energética residual para o composto `16429338` em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

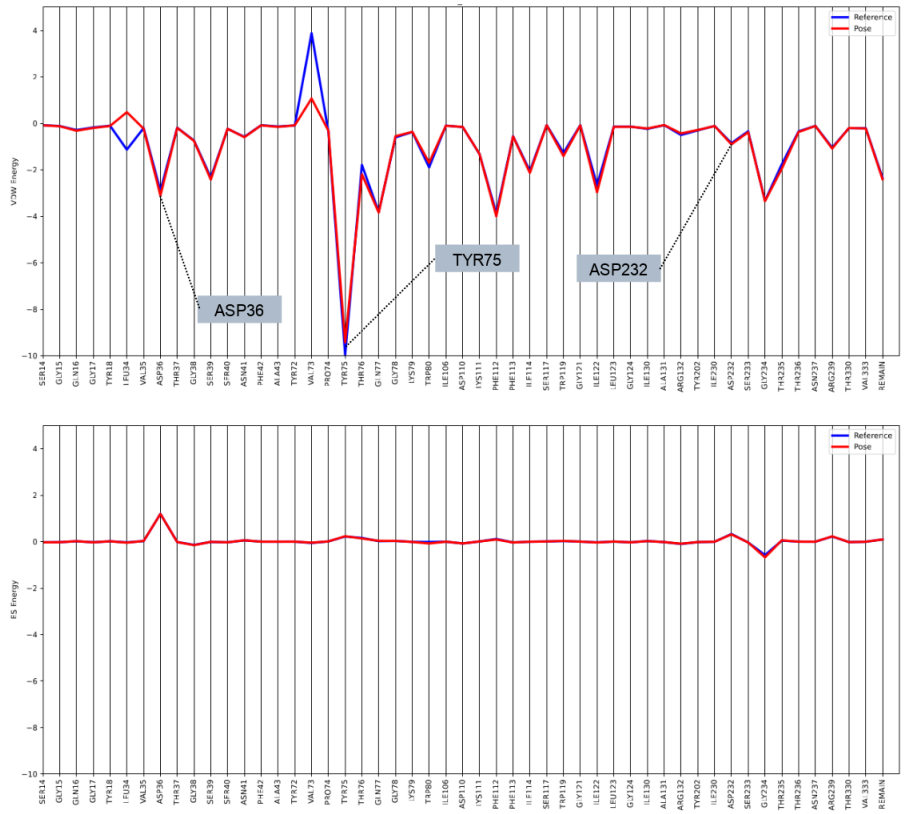

Figura A.17: Análise de contribuição energética residual para o composto 16429338 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

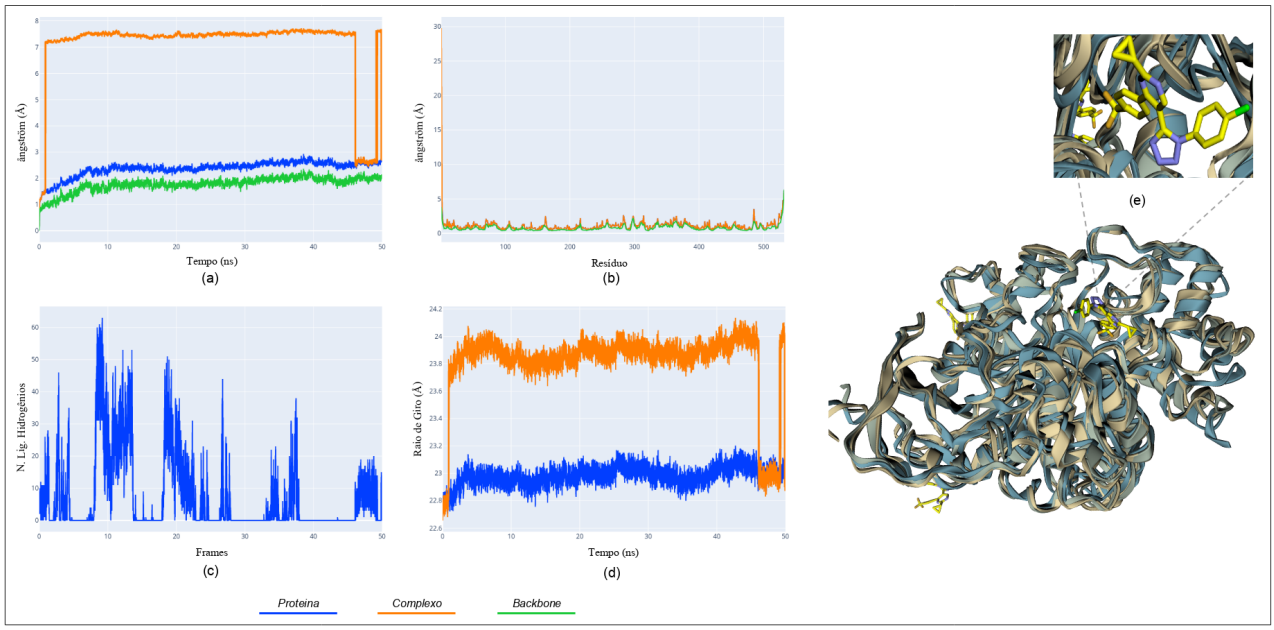

Figura A.18: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC 16429338, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE.

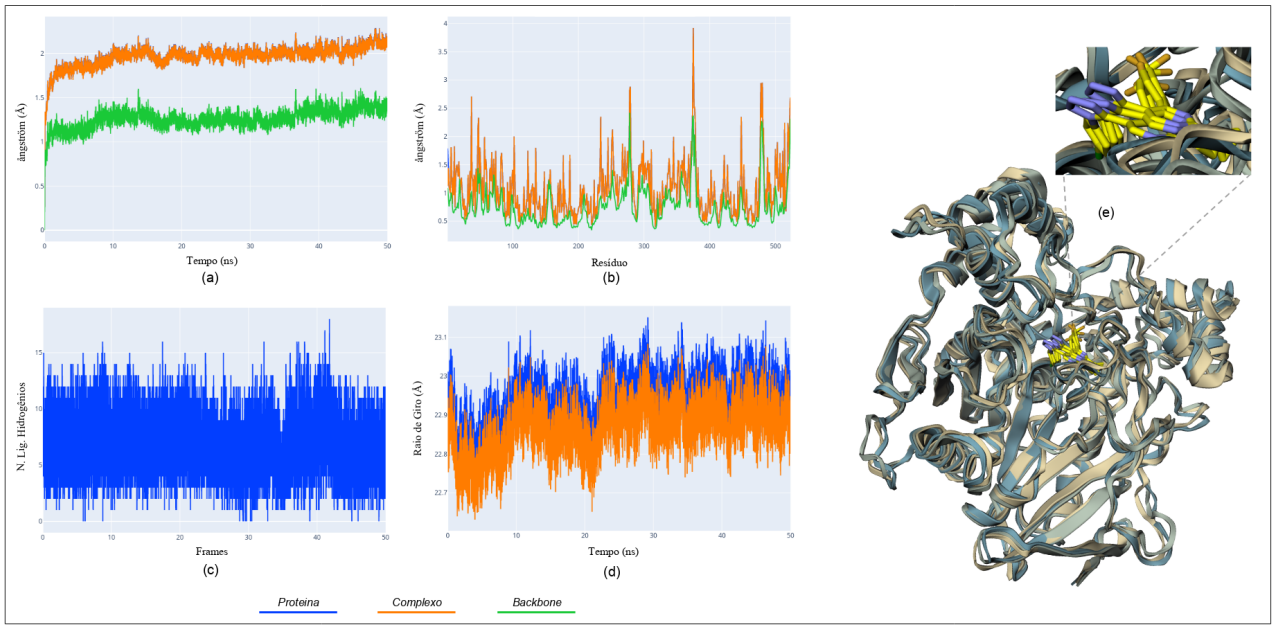

Figura A.19: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `16429338`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE.

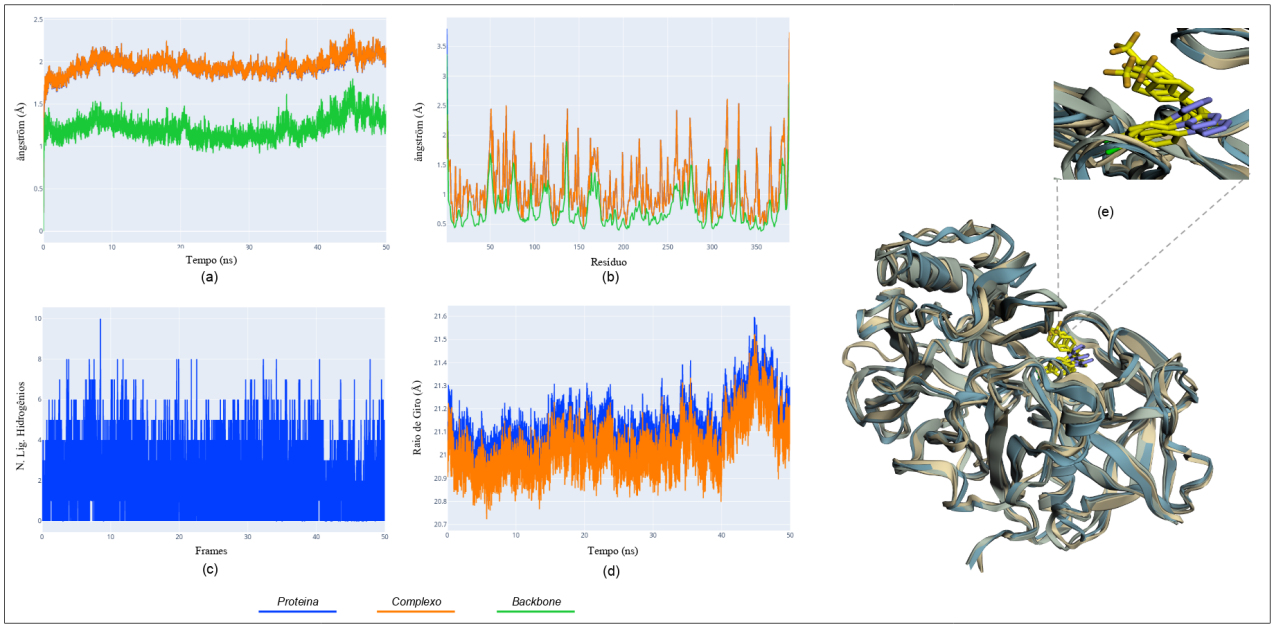

Figura A.20: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `16429338`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1.

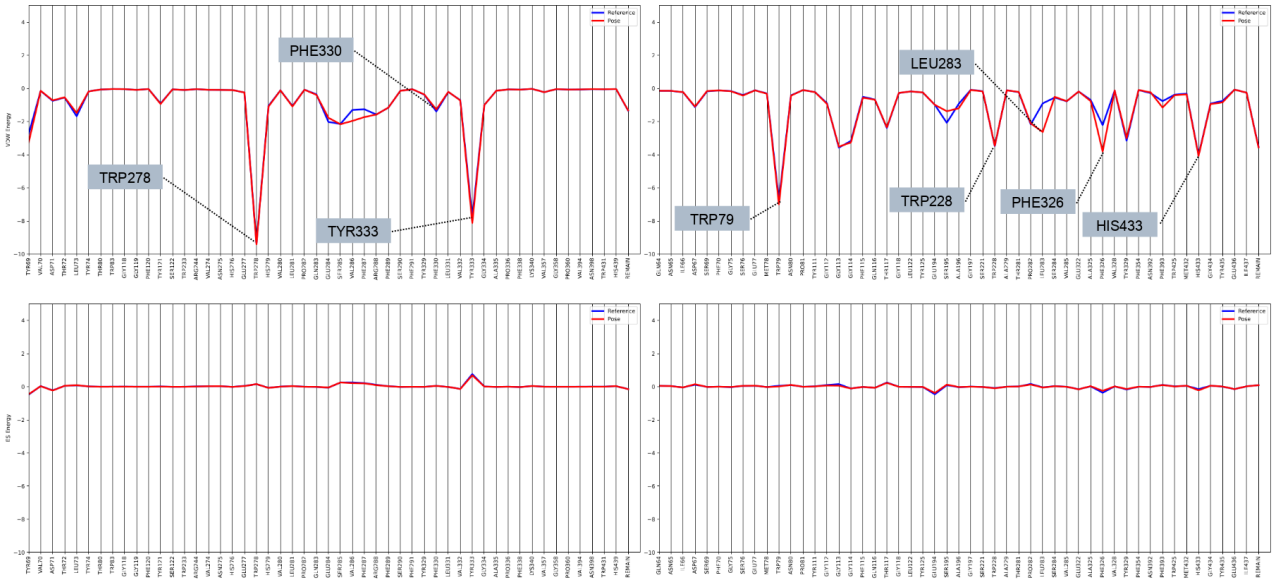

Figura A.21: Análise de contribuição energética residual para o composto 16523915 em complexos formados com as enzimas AChE (a) e BChE (b). Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

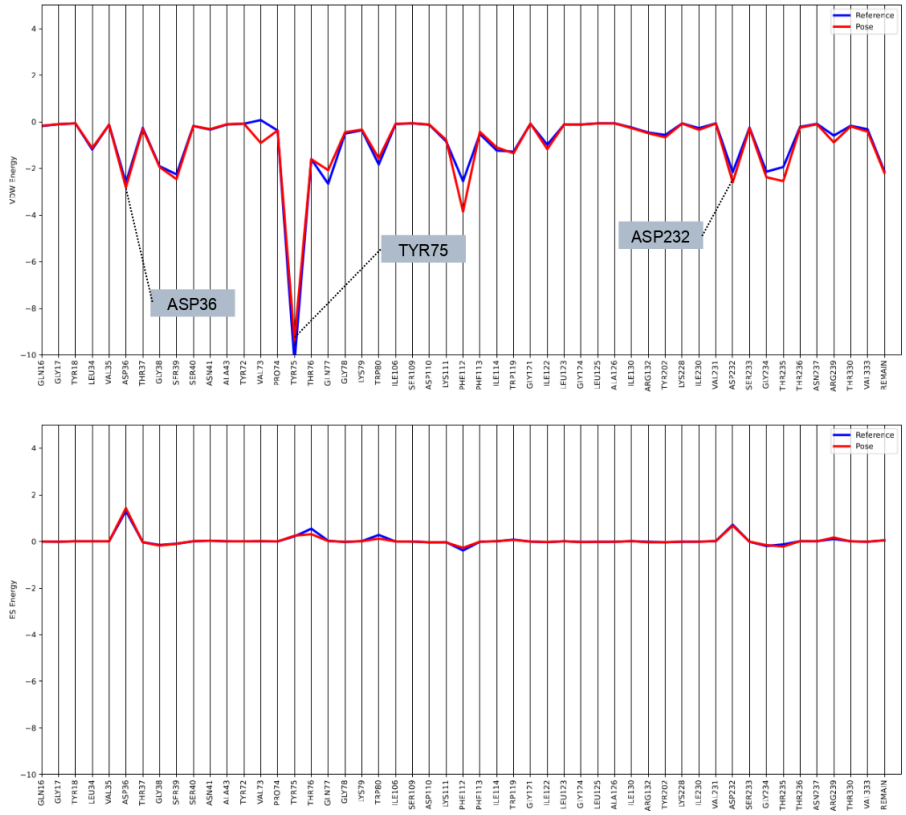

Figura A.22: Análise de contribuição energética residual para o composto 16523915 em complexos formados com a enzima BACE1. Os cinquenta resíduos com maior contribuição energética em cada interação são evidenciados, discriminando os componentes de energia de *Van der Waals* (VDW *Energy*) e eletrostática (*ES Energy*), conforme estimativas geradas pelo *Dock6*.

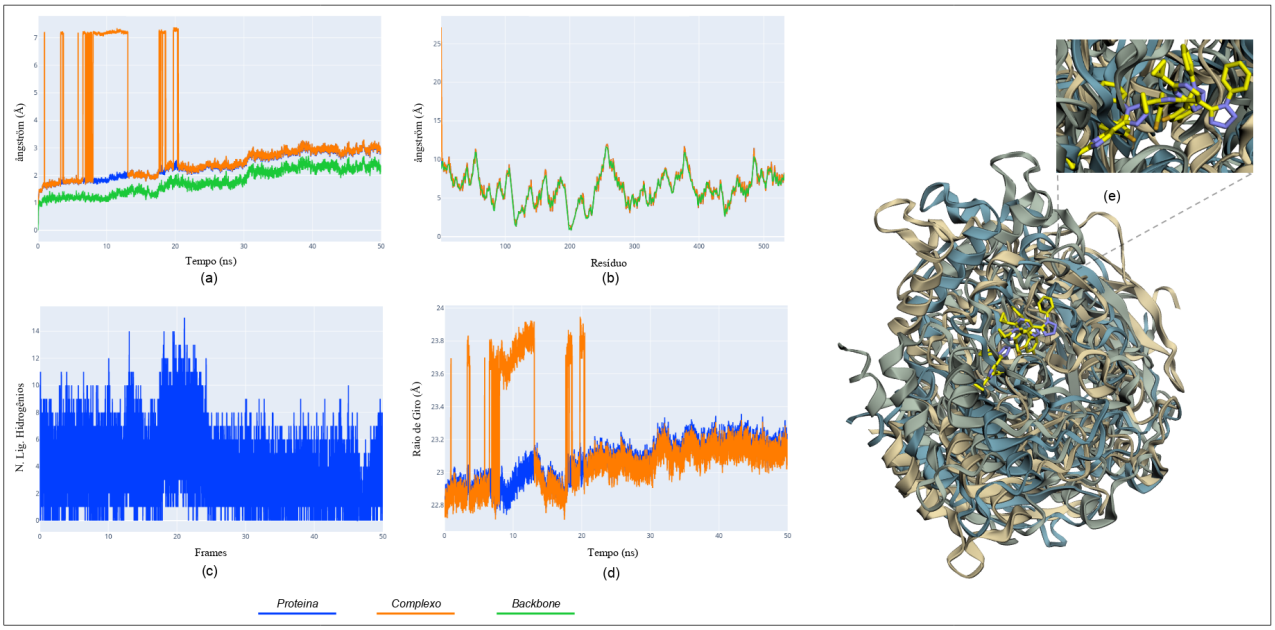

Figura A.23: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 4M0E e o composto ZINC `16523915`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína isolada (curva azul), do complexo proteína-ligante (curva laranja) e do *backbone* (curva verde). Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio periférico (PAS) da AChE.

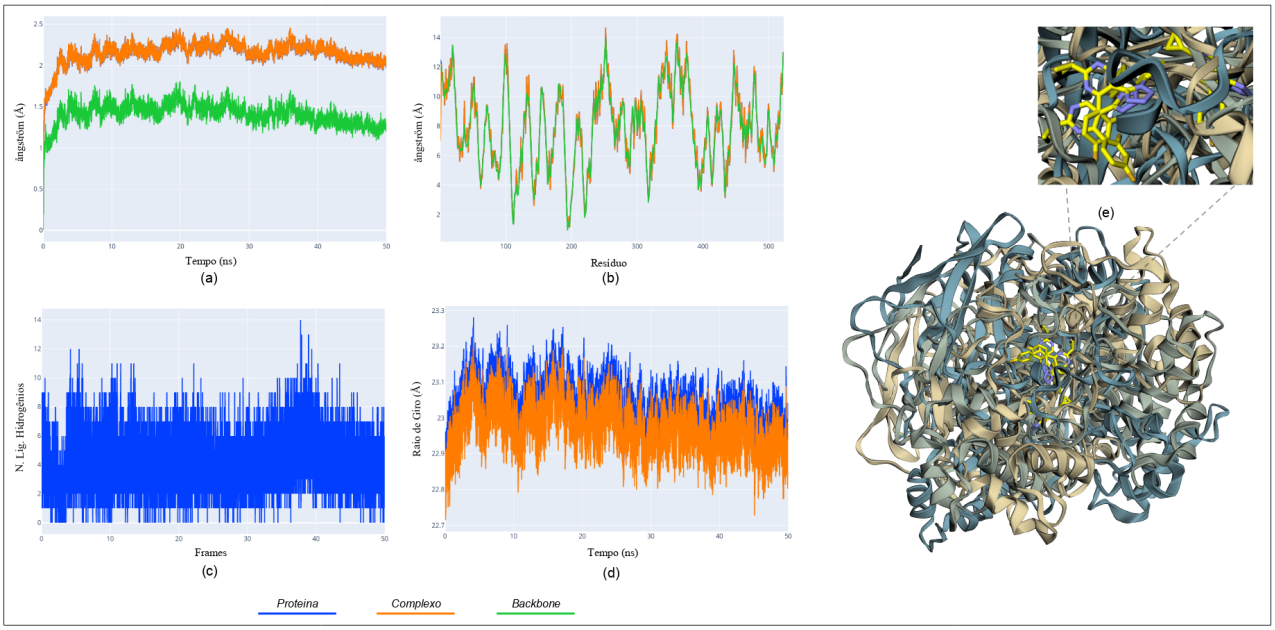

Figura A.24: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 1P0I e o ligante `16523915`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BChE.

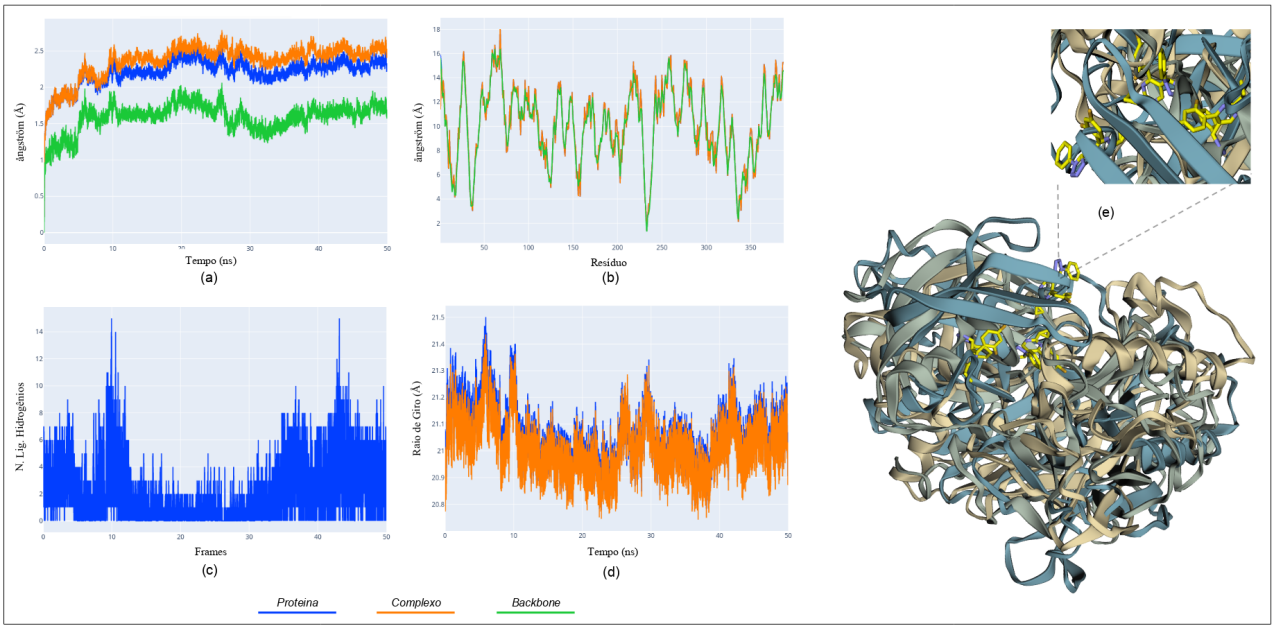

Figura A.25: Resultados obtidos das simulações de dinâmica molecular conduzidas com o receptor 5HE5 e o ligante `16523915`, incluindo: (a) o desvio quadrático médio da estrutura (RMSD), (b) as flutuações residuais médias (RMSF) dos resíduos, (c) o número de ligações de hidrogênio e (d) o raio de giro (Rg), com o objetivo de caracterizar o comportamento estrutural da proteína, do complexo e do *backbone*. Em (e), tem-se a sobreposição das conformações correspondentes aos *frames* inicial, intermediário e final da simulação, destacando-se também uma ampliação da interação do ligante com o sítio de ligação da enzima BACE1.

Apêndice

B

Relação de Aminoácidos

Figura B.1: Descrição dos vinte aminoácidos canônicos utilizados na síntese proteica, incluindo suas denominações completas, abreviações padrão (três letras e uma letra) e suas representações estruturais no formato SMILES.

Nome Completo	Sigla (3 letras)	Sigla (1 letra)	SMILES
Alanina	Ala	A	C[C@H](N)C(=O)O
Arginina	Arg	R	C(CC[C@H](N)C(=O)O)CN=C(N)N
Asparagina	Asn	N	C([C@H](N)C(=O)O)C(=O)N
Ácido Aspártico	Asp	D	C([C@H](N)C(=O)O)C(=O)O
Cisteína	Cys	C	C([C@H](N)C(=O)O)S
Fenilalanina	Phe	F	C1=CC=C(C=C1)C[C@H](N)C(=O)O
Glicina	Gly	G	C(C(=O)O)N
Glutamina	Gln	Q	C(CC(=O)N)[C@H](N)C(=O)O
Ácido Glutâmico	Glu	E	C(CC(=O)O)[C@H](N)C(=O)O
Histidina	His	H	C1=C(NC=N1)C[C@H](N)C(=O)O
Isoleucina	Ile	I	CC[C@H](C)[C@H](N)C(=O)O
Leucina	Leu	L	CC(C)C[C@H](N)C(=O)O
Lisina	Lys	K	C(CCCN)[C@H](N)C(=O)O
Metionina	Met	M	CSCC[C@H](N)C(=O)O
Prolina	Pro	P	C1CC(NC1)C(=O)O
Serina	Ser	S	C([C@H](N)C(=O)O)O
Tirosina	Tyr	Y	C1=CC(=CC=C1C[C@H](N)C(=O)O)O
Treonina	Thr	T	C[C@H]([C@H](N)C(=O)O)O
Triptofano	Trp	W	C1=CC=C2C(=C1)C(=CN2)C[C@H](N)C(=O)O
Valina	Val	V	CC(C)[C@H](N)C(=O)O

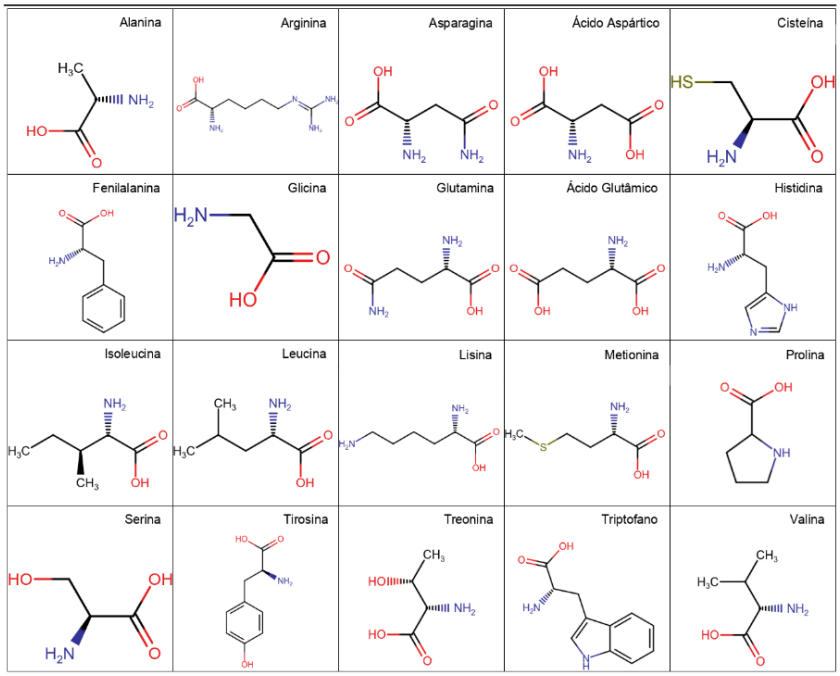

Referências Bibliográficas

ABRAHAMSSON, D. et al. Applications of machine learning to in silico quantification of chemicals without analytical standards. *Journal of chemical information and modeling*, ACS Publications, v. 60, n. 6, p. 2718–2727, 2020.

ADENIYI, P. A. et al. Ferroptosis of microglia in aging human white matter injury. *Annals of Neurology*, Wiley Online Library, 2023.

ADESHINA, Y. O.; DEEDS, E. J.; KARANICOLAS, J. Machine learning classification can reduce false positives in structure-based virtual screening. *Proceedings of the National Academy of Sciences*, National Academy of Sciences, v. 117, n. 31, p. 18477–18488, 2020.

AHMAD, S. et al. Molecular docking simplified: literature review. *Adv. Med. Dent. Health Sci*, v. 4, p. 37–44, 2021.

AHN, S.; LEE, S. E.; KIM, M.-h. Random-forest model for drug–target interaction prediction via kullback–leibler divergence. *Journal of cheminformatics*, Springer, v. 14, n. 1, p. 67, 2022.

AJALA, A. et al. Qsar, simulation techniques, and admet/pharmacokinetics assessment of a set of compounds that target mao-b as anti-alzheimer agent. *Future Journal of Pharmaceutical Sciences*, Springer, v. 9, n. 1, p. 4, 2023.

ALAKHDAR, A.; POCZOS, B.; WASHBURN, N. Diffusion models in de novo drug design. *Journal of Chemical Information and Modeling*, ACS Publications, v. 64, n. 19, p. 7238–7256, 2024.

ANDRIO, P. et al. Bioexcel building blocks, a software library for interoperable biomolecular simulation workflows. *Scientific data*, Nature Publishing Group UK London, v. 6, n. 1, p. 169, 2019.

ANISHCHENKO, I. et al. De novo protein design by deep network hallucination. *Nature*, Nature Publishing Group UK London, v. 600, n. 7889, p. 547–552, 2021.

ATHAR, T.; BALUSHI, K. A.; KHAN, S. A. Recent advances on drug development and emerging therapeutic agents for alzheimer's disease. *Molecular biology reports*, Springer, v. 48, n. 7, p. 5629–5645, 2021.

BADAR, M. S. et al. Molecular dynamics simulations: concept, methods, and applications. In: *Transdisciplinarity*. [S.l.]: Springer, 2022. p. 131–151.

BAI, Q. et al. Application advances of deep learning methods for de novo drug design and molecular dynamics simulation. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, Wiley Online Library, v. 12, n. 3, p. e1581, 2022.

BALAMURALI, M. T-distributed stochastic neighbor embedding. In: *Encyclopedia of mathematical geosciences*. [S.l.]: Springer, 2023. p. 1527–1535.

BANDYOPADHYAY, S. Role of neuron and glia in alzheimer's disease and associated vascular dysfunction. *Frontiers in aging neuroscience*, Frontiers Media SA, v. 13, p. 653334, 2021.

BARIAMI, S. et al. A suite of tutorials for the biosimspace framework for interoperable biomolecular simulation [article v1. 0]. *Living Journal of Computational Molecular Science*, v. 5, n. 1, 2023.

BAYARRI, G. et al. Bioexcel building blocks workflows (biobb-wfs), an integrated web-based platform for biomolecular simulations. *Nucleic Acids Research*, Oxford University Press, v. 50, n. W1, p. W99–W107, 2022.

BEAR, M. F.; CONNORS, B. W.; PARADISO, M. A. *Neurociências: desvendando o sistema nervoso*. 4th. ed. [S.l.]: Artmed editora, 2017.

BENEK, O.; KORABECNY, J.; SOUKUP, O. A perspective on multi-target drugs for alzheimer's disease. *Trends in pharmacological sciences*, Elsevier, v. 41, n. 7, p. 434–445, 2020.

BENKENDORF, D. J. et al. Correcting for the effects of class imbalance improves the performance of machine-learning based species distribution models. *Ecological Modelling*, Elsevier, v. 483, p. 110414, 2023.

BENUSSI, A. et al. Increasing brain gamma activity improves episodic memory and restores cholinergic dysfunction in alzheimer's disease. *Annals of neurology*, Wiley Online Library, v. 92, n. 2, p. 322–334, 2022.

BOER, D. D. et al. A comprehensive review of cholinesterase modeling and simulation. *Biomolecules*, MDPI, v. 11, n. 4, p. 580, 2021.

BOLDINI, D. et al. Machine learning assisted hit prioritization for high throughput screening in drug discovery. *ACS Central Science*, ACS Publications, v. 10, n. 4, p. 823–832, 2024.

BOON, B. D. et al. Neuroinflammation connecting amyloid-beta and p-tau pathology, may explain clinical heterogeneity in alzheimer's disease. *Alzheimer's & Dementia*, Wiley Online Library, v. 18, p. e064056, 2022.

BORAH, K. et al. Potential therapeutic agents on alzheimer's disease through molecular docking and molecular dynamics simulation study of plant-based compounds. *Chemistry & biodiversity*, Wiley Online Library, v. 20, n. 1, p. e202200684, 2023.

CAI, H. et al. Fp-gnn: a versatile deep learning architecture for enhanced molecular property prediction. *Briefings in bioinformatics*, Oxford University Press, v. 23, n. 6, p. bbac408, 2022.

CAO, Z.; SCIABOLA, S.; WANG, Y. Large-scale pretraining improves sample efficiency of active learning-based virtual screening. *Journal of Chemical Information and Modeling*, ACS Publications, v. 64, n. 6, p. 1882–1891, 2024.

CAPECCHI, A.; PROBST, D.; REYMOND, J.-L. One molecular fingerprint to rule them all: drugs, biomolecules, and the metabolome. *Journal of cheminformatics*, Springer, v. 12, p. 1–15, 2020.

CASE, D. A. et al. *AMBER 2023*. 1st. ed. San Francisco, CA: University of California, San Francisco, 2023. https://ambermd.org/doc12/Amber23.pdf. University of California, San Francisco.

CASE, D. A. et al. Ambertools. *Journal of chemical information and modeling*, ACS Publications, v. 63, n. 20, p. 6183–6191, 2023.

CATACUTAN, D. B. et al. Machine learning in preclinical drug discovery. *Nature Chemical Biology*, Nature Publishing Group US New York, v. 20, n. 8, p. 960–973, 2024.

CHANDRASEKHAR, V. et al. Cheminformatics microservice: unifying access to open cheminformatics toolkits. *Journal of Cheminformatics*, Springer, v. 15, n. 1, p. 98, 2023.

CHANG, Y. et al. A guide to in silico drug design. *Pharmaceutics*, Multidisciplinary Digital Publishing Institute, v. 15, n. 1, p. 49, 2023.

CHEMBL. *ChemBL Data Web Services - Getting Started*. 2023. https://chembl.gitbook.io/chembl-interface-documentation/web-services/chembl-data-web-services#getting-started. Acessado em: 16 de novembro de 2023.

ChEMBL. *ChEMBL Webresource Client*. 2023. https://github.com/chembl/chembl_webresource_client. Acessado em: 12 de junho de 2025.

ChEMBL Team. *ChEMBL Data Web Services Documentation*. 2024. https://chembl.gitbook.io/chembl-interface-documentation/web-services/chembl-data-web-services. Acessado em: 12 de maio de 2025.

CHEN, Y. et al. Molecular language models: Rnns or transformer? *Briefings in Functional Genomics*, Oxford University Press, v. 22, n. 4, p. 392–400, 2023.

CHEN, Y.; YU, Y. Tau and neuroinflammation in alzheimer's disease: interplay mechanisms and clinical translation. *Journal of neuroinflammation*, Springer, v. 20, n. 1, p. 165, 2023.

CHEN, Z.-R. et al. Role of cholinergic signaling in alzheimer's disease. *Molecules*, MDPI, v. 27, n. 6, p. 1816, 2022.

CHENG, F. et al. Artificial intelligence and open science in discovery of disease-modifying medicines for alzheimer's disease. *Cell Reports Medicine*, Elsevier, v. 5, n. 2, 2024.

CHISHOLM, T. S.; MACKEY, M.; HUNTER, C. A. Discovery of high-affinity amyloid ligands using a ligand-based virtual screening pipeline. *Journal of the American Chemical Society*, ACS Publications, v. 145, n. 29, p. 15936–15950, 2023.

CHO, H.-J. et al. A multifunctional chemical agent as an attenuator of amyloid burden and neuroinflammation in alzheimer's disease. *ACS Chemical Neuroscience*, American Chemical Society, v. 11, n. 10, p. 1471–1481, 2020. ISSN 1471-1481. Doi: 10.1021/acschemneuro.0c00114.

CHOUDHARY, P. et al. Pdb nextgen archive: centralizing access to integrated annotations and enriched structural information by the worldwide protein data bank. *Database*, Oxford University Press UK, v. 2024, p. baae041, 2024.

CHOUDHURY, M.; SAIKIA, R. Essential basic protocol in computer aided drug designing: Efficiency and challenges. *Int. J. Biotechnol. Bioeng*, v. 4, p. 77–80, 2018.

COCK, P. J. et al. Biopython: freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics*, Oxford University Press, v. 25, n. 11, p. 1422, 2009.

COPELAND, M. M. et al. Gaussian accelerated molecular dynamics in openmm. *The Journal of Physical Chemistry B*, ACS Publications, v. 126, n. 31, p. 5810–5820, 2022.

CUMMINGS, J. et al. Alzheimer's disease drug development pipeline: 2024. *Alzheimer's & Dementia: Translational Research & Clinical Interventions*, Wiley Online Library, v. 10, n. 2, p. e12465, 2024.

DAVID, B. et al. Discovery of new acetylcholinesterase inhibitors for alzheimer's disease: virtual screening and in vitro characterisation. *Journal of enzyme inhibition and medicinal chemistry*, Taylor & Francis, v. 36, n. 1, p. 491–496, 2021.

DAVID, B. et al. Discovery of new acetylcholinesterase inhibitors for alzheimer's disease: Virtual screening and in vitro characterization. *Journal of enzyme inhibition and medicinal chemistry*, Taylor & Francis, v. 36, n. 1, p. 491–496, 2021.

DAVID, L. et al. Molecular representations in ai-driven drug discovery: a review and practical guide. *Journal of cheminformatics*, Springer, v. 12, n. 1, p. 56, 2020.

DELANO, W. L. et al. Pymol: An open-source molecular graphics tool. *CCP4 Newsl. Protein Crystallogr*, Citeseer, v. 40, n. 1, p. 82–92, 2002.

DENG, J. et al. A systematic study of key elements underlying molecular property prediction. *Nature Communications*, Nature Publishing Group UK London, v. 14, n. 1, p. 6395, 2023.

DING, Y. et al. Molecular fingerprint-based machine learning assisted qsar model development for prediction of ionic liquid properties. *Journal of Molecular Liquids*, Elsevier, v. 326, p. 115212, 2021.

DOERR, S. et al. High-throughput automated preparation and simulation of membrane proteins with htmd. *Journal of Chemical Theory and Computation*, ACS Publications, v. 13, n. 9, p. 4003–4011, 2017.

DOERR, S. et al. Torchmd: A deep learning framework for molecular simulations. *Journal of chemical theory and computation*, ACS Publications, v. 17, n. 4, p. 2355–2363, 2021.

DOKHOLYAN, N. V.; MOHS, R. C.; BATEMAN, R. J. Challenges and progress in research, diagnostics, and therapeutics in alzheimer's disease and related dementias. *Alzheimer's & Dementia: Translational Research & Clinical Interventions*, Wiley Online Library, v. 8, n. 1, p. e12330, 2022.

DOWDEN, H.; MUNRO, J. Trends in clinical success rates and therapeutic focus. *Nat. Rev. Drug Discov*, v. 18, n. 7, p. 495–496, 2019.

D'ERRICO, P.; MEYER-LUEHMANN, M. Mechanisms of pathogenic tau and aβ protein spreading in alzheimer's disease. *Frontiers in aging neuroscience*, Frontiers Media SA, v. 12, p. 265, 2020.

EASTMAN, P. et al. Openmm 8: molecular dynamics simulation with machine learning potentials. *The Journal of Physical Chemistry B*, ACS Publications, v. 128, n. 1, p. 109–116, 2023.

EBERHARDT, J. et al. Autodock vina 1.2. 0: New docking methods, expanded force field, and python bindings. *Journal of chemical information and modeling*, ACS Publications, v. 61, n. 8, p. 3891–3898, 2021.

EGAN, M. F. et al. Further analyses of the safety of verubecestat in the phase 3 epoch trial of mild-to-moderate alzheimer's disease. *Alzheimer's research & therapy*, Springer, v. 11, p. 1–12, 2019.

FASSIO, A. V. et al. napoli: a graph-based strategy to detect and visualize conserved protein-ligand interactions in large-scale. *IEEE/ACM transactions on computational biology and bioinformatics*, IEEE, v. 17, n. 4, p. 1317–1328, 2019.

FENG, H. et al. A random forest model for peptide classification based on virtual docking data. *International Journal of Molecular Sciences*, MDPI, v. 24, n. 14, p. 11409, 2023.

FLORES-HERNANDEZ, H.; MARTINEZ-LEDESMA, E. A systematic review of deep learning chemical language models in recent era. *Journal of Cheminformatics*, Springer, v. 16, n. 1, p. 129, 2024.

GALLY, J.-M. et al. Vsprep: a general knime workflow for the preparation of molecules for virtual screening. *Molecular informatics*, Wiley Online Library, v. 36, n. 10, p. 1700023, 2017.

GANDINI, E. et al. Molecular similarity perception based on machine-learning models. *International Journal of Molecular Sciences*, MDPI, v. 23, n. 11, p. 6114, 2022.

GARRIGA-ALONSO, A.; FORTUIN, V. Exact langevin dynamics with stochastic gradients. *arXiv preprint arXiv:2102.01691*, 2021.

GAUTAM, V. et al. Artificial intelligence and machine-learning approaches in structure and ligand-based discovery of drugs affecting central nervous system. *Molecular Diversity*, Springer, v. 27, n. 2, p. 959–985, 2023.

GIMENO, A. et al. The light and dark sides of virtual screening: what is there to know? *International journal of molecular sciences*, MDPI, v. 20, n. 6, p. 1375, 2019.

GKEKA, P. et al. Machine learning force fields and coarse-grained variables in molecular dynamics: application to materials and biological systems. *Journal of chemical theory and computation*, ACS Publications, v. 16, n. 8, p. 4757–4775, 2020.

GOH, G. B. et al. Smiles2vec: An interpretable general-purpose deep neural network for predicting chemical properties. *arXiv preprint arXiv:1712.02034*, 2017.

GÖLLER, A. H. et al. Bayer's in silico admet platform: a journey of machine learning over the past two decades. *Drug Discovery Today*, Elsevier, v. 25, n. 9, p. 1702–1709, 2020.

GRAFF, D. E.; SHAKHNOVICH, E. I.; COLEY, C. W. Accelerating high-throughput virtual screening through molecular pool-based active learning. *Chemical science*, Royal Society of Chemistry, v. 12, n. 22, p. 7866–7881, 2021.

GREENACRE, M. et al. Principal component analysis. *Nature Reviews Methods Primers*, Nature Publishing Group UK London, v. 2, n. 1, p. 100, 2022.

GUEDES, I. A. et al. New machine learning and physics-based scoring functions for drug discovery. *Scientific reports*, Nature Publishing Group UK London, v. 11, n. 1, p. 3198, 2021.

GUO, Q.; HERNANDEZ-HERNANDEZ, S.; BALLESTER, P. J. Scaffold splits overestimate virtual screening performance. In: SPRINGER. *International Conference on Artificial Neural Networks*. [S.l.], 2024. p. 58–72.

GUO, Z.-r. Perspective of cadd and aidd in medicinal chemistry. *Acta Pharmaceutica Sinica*, p. 2931–2941, 2023.

GUPTA, M. et al. The blood–brain barrier (bbb) score. *Journal of medicinal chemistry*, ACS Publications, v. 62, n. 21, p. 9824–9836, 2019.

HAGBERG, A.; SWART, P. J.; SCHULT, D. A. *Exploring network structure, dynamics, and function using NetworkX*. [S.l.], 2008.

HALGREN, T. A. et al. Glide: a new approach for rapid, accurate docking and scoring. 2. enrichment factors in database screening. *Journal of medicinal chemistry*, ACS Publications, v. 47, n. 7, p. 1750–1759, 2004.

HAMPEL, H. et al. The β-secretase bace1 in alzheimer's disease. *Biological psychiatry*, Elsevier, v. 89, n. 8, p. 745–756, 2021.

HAN, H. et al. Employing automated machine learning (automl) methods to facilitate the in silico admet properties prediction. *Journal of Chemical Information and Modeling*, ACS Publications, v. 65, n. 7, p. 3215–3225, 2025.

HEDGES, L. O. et al. Biosimspace: An interoperable python framework for biomolecular simulation. *Journal of Open Source Software*, Open Journals, v. 4, p. 1831, 2019.

HELLECKES, L. M. et al. Machine learning in bioprocess development: from promise to practice. *Trends in biotechnology*, Elsevier, v. 41, n. 6, p. 817–835, 2023.

HOLLINGSWORTH, S. A.; DROR, R. O. Molecular dynamics simulation for all. *Neuron*, Elsevier, v. 99, n. 6, p. 1129–1143, 2018.

HONG, Y. et al. Accurate prediction of protein–ligand interactions by combining physical energy functions and graph-neural networks. *Journal of Cheminformatics*, Springer, v. 16, n. 1, p. 121, 2024.

HOOGMARTENS, J.; CACACE, R.; BROECKHOVEN, C. V. Insight into the genetic etiology of alzheimer's disease: A comprehensive review of the role of rare variants. *Alzheimer's & Dementia: Diagnosis, Assessment & Disease Monitoring*, Wiley Online Library, v. 13, n. 1, p. e12155, 2021.

HUDSON, D. L.; COHEN, M. E. *Neural networks and artificial intelligence for biomedical engineering*. [S.l.]: John Wiley & Sons, 1999.

IAIZZO, P. A. Introduction to neurophysiology. *Neural engineering*, Springer, p. 1–64, 2020.

IRAJI, A. et al. Novel small molecule therapeutic agents for alzheimer disease: Focusing on bace1 and multi-target directed ligands. *Bioorganic Chemistry*, Elsevier, v. 97, p. 103649, 2020.

ISHFAQ, M. et al. Machine learning-assisted prediction of the biological activity of aromatase inhibitors and data mining to explore similar compounds. *ACS omega*, ACS Publications, v. 7, n. 51, p. 48139–48149, 2022.

JANICKA, M.; SZTANKE, M.; SZTANKE, K. Modeling the blood-brain barrier permeability of potential heterocyclic drugs via biomimetic iam chromatography technique combined with qsar methodology. *Molecules*, MDPI, v. 29, n. 2, 2024.

JASIECKI, J.; TARGOŃSKA, M.; WASĄG, B. The role of butyrylcholinesterase and iron in the regulation of cholinergic network and cognitive dysfunction in alzheimer's disease pathogenesis. *International journal of molecular sciences*, MDPI, v. 22, n. 4, p. 2033, 2021.

JAYATUNGA, M. K. et al. How successful are ai-discovered drugs in clinical trials? a first analysis and emerging lessons. *Drug discovery today*, Elsevier, p. 104009, 2024.

JEREMIC, D.; JIMÉNEZ-DÍAZ, L.; NAVARRO-LÓPEZ, J. D. Past, present and future of therapeutic strategies against amyloid-β peptides in alzheimer's disease: a systematic review. *Ageing research reviews*, Elsevier, v. 72, p. 101496, 2021.

JIANG, D. et al. Assessing the performance of mm/pbsa and mm/gbsa methods. 10. prediction reliability of binding affinities and binding poses for rna–ligand complexes. *Physical Chemistry Chemical Physics*, Royal Society of Chemistry, v. 26, n. 13, p. 10323–10335, 2024.

JIANG, H. et al. Predicting protein–ligand docking structure with graph neural network. *Journal of chemical information and modeling*, ACS Publications, v. 62, n. 12, p. 2923–2932, 2022.

JIANG, J. et al. Noisemol: A noise-robusted data augmentation via perturbing noise for molecular property prediction. *Journal of Molecular Graphics and Modelling*, Elsevier, v. 121, p. 108454, 2023.

JONES, G. et al. Development and validation of a genetic algorithm for flexible docking. *Journal of molecular biology*, Elsevier, v. 267, n. 3, p. 727–748, 1997.

JOO, S. et al. Generative model for proposing drug candidates satisfying anticancer properties using a conditional variational autoencoder. *ACS omega*, ACS Publications, v. 5, n. 30, p. 18642–18650, 2020.

KANG, P.-L.; SHANG, C.; LIU, Z.-P. Large-scale atomic simulation via machine learning potentials constructed by global potential energy surface exploration. *Accounts of Chemical Research*, ACS Publications, v. 53, n. 10, p. 2119–2129, 2020.

KASHEFOLGHETA, S. et al. Evaluation of nine condensed-phase force fields of the gromos, charmm, opls, amber, and openff families against experimental cross-solvation free energies. *Physical Chemistry Chemical Physics*, Royal Society of Chemistry, v. 23, n. 23, p. 13055–13074, 2021.

KC, G. B. et al. A machine learning platform to estimate anti-sars-cov-2 activities. *Nature Machine Intelligence*, Nature Publishing Group UK London, v. 3, n. 6, p. 527–535, 2021.

KE, Q. et al. Effects of thermostats/barostats on physical properties of liquids by molecular dynamics simulations. *Journal of Molecular Liquids*, Elsevier, v. 365, p. 120116, 2022.

KIKUCHI, Y. et al. Impact of smiles notational inconsistencies on chemical language model performance. *arXiv preprint arXiv:2505.07139*, 2025.

KIM, H. et al. Artificial intelligence in drug discovery: a comprehensive review of data-driven and machine learning approaches. *Biotechnology and Bioprocess Engineering*, Springer, v. 25, p. 895–930, 2020.

KIM, J. et al. Rotational variance-based data augmentation in 3d graph convolutional network. *Chemistry–An Asian Journal*, Wiley Online Library, v. 16, n. 18, p. 2610–2613, 2021.

KIM, S. et al. Pubchem in 2021: new data content and improved web interfaces. *Nucleic acids research*, Oxford University Press, v. 49, n. D1, p. D1388–D1395, 2021.

KIM, S. et al. Pubchem 2025 update. *Nucleic Acids Research*, Oxford University Press, v. 53, n. D1, p. D1516–D1525, 2025.

KING, A. Four ways to power-up ai for drug discovery. *Nature*, 2025.

KNOPMAN, D. S. et al. Alzheimer disease. *Nature reviews Disease primers*, Nature Publishing Group UK London, v. 7, n. 1, p. 33, 2021.

KNOX, C. et al. Drugbank 6.0: the drugbank knowledgebase for 2024. *Nucleic acids research*, Oxford University Press, v. 52, n. D1, p. D1265–D1275, 2024.

KUWAHARA, H.; GAO, X. Analysis of the effects of related fingerprints on molecular similarity using an eigenvalue entropy approach. *Journal of Cheminformatics*, Springer, v. 13, p. 1–12, 2021.

LANDRUM, G. Rdkit: Open-source cheminformatics. *Journal of Chemical Information and Modeling*, v. 26, n. 7, p. 1183–1194, 2006.

LAWLESS, M. S. et al. Using cheminformatics in drug discovery. *New Approaches to Drug Discovery*, Springer, p. 139–168, 2016.

LEE, J. W. et al. Big data and artificial intelligence (ai) methodologies for computer-aided drug design (cadd). *Biochemical Society Transactions*, Portland Press Ltd., v. 50, n. 1, p. 241–252, 2022.

LI, Z. et al. Applied machine learning in alzheimer's disease research: omics, imaging, and clinical data. *Emerging topics in life sciences*, Portland Press Ltd., v. 5, n. 6, p. 765–777, 2021.

LIANG, J.-W. et al. Identification of novel cdk2 inhibitors by a multistage virtual screening method based on svm, pharmacophore and docking model. *Journal of enzyme inhibition and medicinal chemistry*, Taylor & Francis, v. 35, n. 1, p. 235–244, 2020.

LIM, J. et al. Scaffold-based molecular design with a graph generative model. *Chemical science*, Royal Society of Chemistry, v. 11, n. 4, p. 1153–1164, 2020.

LIN, E.; LIN, C.-H.; LANE, H.-Y. De novo peptide and protein design using generative adversarial networks: an update. *Journal of Chemical Information and Modeling*, ACS Publications, v. 62, n. 4, p. 761–774, 2022.

LIU, E.; ZHANG, Y.; WANG, J.-Z. Updates in alzheimer's disease: from basic research to diagnosis and therapies. *Translational Neurodegeneration*, Springer, v. 13, n. 1, p. 45, 2024.

LIVINGSTON, G. et al. Dementia prevention, intervention, and care: 2024 report of the lancet standing commission. *The Lancet*, Elsevier, v. 404, n. 10452, p. 572–628, 2024.

LUONG, K.-D.; SINGH, A. Application of transformers in cheminformatics. *Journal of Chemical Information and Modeling*, ACS Publications, v. 64, n. 11, p. 4392–4409, 2024.

MACHADO, A.; HAERTEL, L. M. *Neuroanatomia funcional*. 4th. ed. [S.l.]: Atheneu, 2022.

MAIA, E. H. B. et al. Structure-based virtual screening: from classical to artificial intelligence. *Frontiers in chemistry*, Frontiers Media SA, v. 8, p. 343, 2020.

MALEKI, F. et al. Generalizability of machine learning models: quantitative evaluation of three methodological pitfalls. *Radiology: Artificial Intelligence*, Radiological Society of North America, v. 5, n. 1, p. e220028, 2022.

MANDAL, D. et al. Molecular dynamics simulation for serial and parallel computation using leaf frog algorithm. In: IEEE. *2022 Seventh International Conference on Parallel, Distributed and Grid Computing (PDGC)*. [S.l.], 2022. p. 552–557.

MANSOURIFAR, H.; SHI, W. Deep synthetic minority over-sampling technique. *arXiv preprint arXiv:2003.09788*, 2020.

MAO, J. et al. Comprehensive strategies of machine-learning-based quantitative structure-activity relationship models. *Iscience*, Elsevier, v. 24, n. 9, 2021.

MCDADE, E. et al. The case for low-level bace1 inhibition for the prevention of alzheimer disease. *Nature Reviews Neurology*, Nature Publishing Group UK London, v. 17, n. 11, p. 703–714, 2021.

MCGIBBON, R. T. et al. Mdtraj: a modern open library for the analysis of molecular dynamics trajectories. *Biophysical journal*, Elsevier, v. 109, n. 8, p. 1528–1532, 2015.

MCNUTT, A. T. et al. Gnina 1.0: molecular docking with deep learning. *Journal of cheminformatics*, Springer, v. 13, n. 1, p. 43, 2021.

MCNUTT, A. T. et al. Gnina 1.3: the next increment in molecular docking with deep learning. *Journal of Cheminformatics*, Springer, v. 17, n. 1, p. 28, 2025.

MEDINA, S. G. et al. Cali: A novel visual model for frequent pattern mining in protein-ligand graphs. In: *"17th International Conference on Bioinformatics and Bioengineering (BIBE)"*. "Washington, DC": "IEEE", 2017. p. 352–358.

MENDES, G. O. et al. Identification of potential multitarget compounds against alzheimer's disease through pharmacophore-based virtual screening. *Pharmaceuticals*, v. 16, p. 1–23, 2023.

MENDES, G. O. et al. Molecular multi-target approach for human acetylcholinesterase, butyrylcholinesterase and β-secretase 1: Next generation for alzheimer's disease treatment. *Pharmaceuticals*, v. 16, n. 6, 2023. ISSN 1424-8247.

MESITI, F. et al. The chemistry toolbox of multitarget-directed ligands for alzheimer's disease. *European Journal of Medicinal Chemistry*, v. 181, p. 111572, 2019. ISSN 0223-5234.

MICHINO, M. et al. Shape-based virtual screening of a billion-compound library identifies mycobacterial lipoamide dehydrogenase inhibitors. *ACS Bio & Med Chem Au*, ACS Publications, v. 3, n. 6, p. 507–515, 2023.

MILLER, C. et al. A review of model evaluation metrics for machine learning in genetics and genomics. *Frontiers in Bioinformatics*, Frontiers Media SA, v. 4, p. 1457619, 2024.

MolSSI Education. *Velocity Verlet Algorithm*. 2021. `https://education.molssi.org/ab-initio-md/06-Velocity-Verlet/index.html`. Accessed: 2025-05-15.

MORIWAKI, H. et al. Mordred: a molecular descriptor calculator. *Journal of cheminformatics*, BioMed Central, v. 10, n. 1, p. 1–14, 2018.

MOTEBENNUR, S. L.; NANDESHWARAPPA, B. P.; KATAGI, M. S. Drug candidates for the treatment of alzheimer's disease: New findings from 2021 and 2022. *Drugs and Drug Candidates*, MDPI, v. 2, n. 3, p. 571–590, 2023.

MUEGGE, I.; MUKHERJEE, P. An overview of molecular fingerprint similarity search in virtual screening. *Expert opinion on drug discovery*, Taylor & Francis, v. 11, n. 2, p. 137–148, 2016.

MUHAMMED, M. T.; AKI-YALCIN, E. Molecular docking: Principles, advances, and its applications in drug discovery. *Letters in Drug Design & Discovery*, Bentham Science Publishers direct, v. 21, n. 3, p. 480–495, 2024.

NASER, M.; ALAVI, A. Insights into performance fitness and error metrics for machine learning. *arXiv preprint arXiv:2006.00887*, 2020.

NASER, M.; ALAVI, A. H. Error metrics and performance fitness indicators for artificial intelligence and machine learning in engineering and sciences. *Architecture, Structures and Construction*, Springer, v. 3, n. 4, p. 499–517, 2023.

NASSER, M. et al. Feature reduction for molecular similarity searching based on autoencoder deep learning. *Biomolecules*, MDPI, v. 12, n. 4, p. 508, 2022.

NAUGHTON, F. B. et al. Mdanalysis 2.0 and beyond: fast and interoperable, community driven simulation analysis. *Biophysical Journal*, Elsevier, v. 121, n. 3, p. 272a–273a, 2022.

NITESH, V. C. Smote: synthetic minority over-sampling technique. *J Artif Intell Res*, v. 16, n. 1, p. 321, 2002.

NOOR, F. et al. Deep learning pipeline for accelerating virtual screening in drug discovery. *Scientific Reports*, Nature Publishing Group UK London, v. 14, n. 1, p. 28321, 2024.

NOVAK, G. et al. Long-term safety and tolerability of atabecestat (jnj-54861911), an oral bace1 inhibitor, in early alzheimer's disease spectrum patients: a randomized, double-blind, placebo-controlled study and a two-period extension study. *Alzheimer's research & therapy*, Springer, v. 12, p. 1–16, 2020.

NOVELLI, P. et al. Characterizing metastable states with the help of machine learning. *Journal of Chemical Theory and Computation*, ACS Publications, v. 18, n. 9, p. 5195–5202, 2022.

NUNES-ALVES, A.; KOKH, D. B.; WADE, R. C. Recent progress in molecular simulation methods for drug binding kinetics. *Current Opinion in Structural Biology*, Elsevier, v. 64, p. 126–133, 2020.

O'BOYLE, N. M. et al. Open babel: An open chemical toolbox. *Journal of cheminformatics*, BioMed Central, v. 3, n. 1, p. 1–14, 2011.

OLIVEIRA, T. A. d. et al. Virtual screening algorithms in drug discovery: A review focused on machine and deep learning methods. *Drugs and Drug Candidates*, MDPI, v. 2, n. 2, p. 311–334, 2023.

OLIVEIRA, T. A. d. et al. Virtual screening algorithms in drug discovery: a review focused on machine and deep learning methods. *Drugs and Drug Candidates*, MDPI, v. 2, n. 2, p. 311–334, 2023.

OLIVEIRA, T. A. de. *Predição de Classes Farmacológicas para o Descobrimento e Reposicionamento de Fármacos por Redes Neurais Convolucionais*. Tese (Tese de Doutorado) — Universidade Federal de São João del-Rei, São João del-Rei, MG, Brasil, fevereiro 2025. Orientador: Alex Gutterres Taranto; Coorientador: Alisson Marques da Silva.

ONYANGO, I. G. et al. Neuroinflammation in alzheimer's disease. *Biomedicines*, v. 9, n. 5, p. 524, 2021.

PAGADALA, N. S.; SYED, K.; TUSZYNSKI, J. Software for molecular docking: a review. *Biophysical reviews*, Springer, v. 9, n. 2, p. 91–102, 2017.

PAGGI, J. M.; PANDIT, A.; DROR, R. O. The art and science of molecular docking. *Annual Review of Biochemistry*, Annual Reviews, v. 93, 2024.

PÁLL, S. et al. Heterogeneous parallelization and acceleration of molecular dynamics simulations in gromacs. *The Journal of chemical physics*, AIP Publishing, v. 153, n. 13, 2020.

PAN, X. et al. Molgpka: A web server for small molecule p k a prediction using a graph-convolutional neural network. *Journal of Chemical Information and Modeling*, ACS Publications, v. 61, n. 7, p. 3159–3165, 2021.

PANT, S. et al. Dissecting large-scale structural transitions in membrane transporters using advanced simulation technologies. *The Journal of Physical Chemistry B*, ACS Publications, v. 129, n. 15, p. 3703–3719, 2025.

PHILLIPS, J. C. et al. Scalable molecular dynamics on cpu and gpu architectures with namd. *The Journal of chemical physics*, AIP Publishing, v. 153, n. 4, 2020.

PRAJAPAT, M. Identification of novel anti-alzheimer's drugs through inhibition of lrp-dkk interaction: A computational approach using high throughput virtual screening and molecular dynamics studies. *Alzheimer's & Dementia*, Wiley Online Library, v. 17, p. e049676, 2021.

PRENTIS, L. E. et al. A molecular evolution algorithm for ligand design in dock. *Journal of computational chemistry*, Wiley Online Library, v. 43, n. 29, p. 1942–1963, 2022.

RÁCZ, A.; BAJUSZ, D.; HÉBERGER, K. Life beyond the tanimoto coefficient: similarity measures for interaction fingerprints. *Journal of cheminformatics*, BioMed Central, v. 10, n. 1, p. 1–12, 2018.

RASCHKA, S. Biopandas: Working with molecular structures in pandas dataframes. *J. Open Source Softw.*, v. 2, n. 14, p. 279, 2017.

REDKAR, A. S.; RAMAKRISHNAN, V. Molecular dynamics simulations. In: *Biophysical characterization of functional peptides*. [S.l.]: Springer, 2023. p. 17–22.

RODRIGUEZ, S. et al. Machine learning identifies candidates for drug repurposing in alzheimer's disease. *Nature communications*, Nature Publishing Group UK London, v. 12, n. 1, p. 1033, 2021.

RONG, G. et al. Artificial intelligence in healthcare: review and prediction case studies. *Engineering*, Elsevier, v. 6, n. 3, p. 291–301, 2020.

RYCKER, M. D. et al. Challenges and recent progress in drug discovery for tropical diseases. *Nature*, Nature Publishing Group UK London, v. 559, n. 7715, p. 498–506, 2018.

SÁ, V.; NOGUEIRA, P. *New Biopython Library to Support Molecular Biology*. A Coruña, Espanha: Universidade da Coruña, Servizo de Publicacións, 2024. ISBN 978-84-9749-891-3.

SABE, V. T. et al. Current trends in computer aided drug design and a highlight of drugs discovered via computational techniques: A review. *European Journal of Medicinal Chemistry*, Elsevier, v. 224, p. 113705, 2021.

SADYBEKOV, A. V.; KATRITCH, V. Computational approaches streamlining drug discovery. *Nature*, Nature Publishing Group UK London, v. 616, n. 7958, p. 673–685, 2023.

SAHAKYAN, H. Improving virtual screening results with mm/gbsa and mm/pbsa rescoring. *Journal of Computer-Aided Molecular Design*, Springer, v. 35, n. 6, p. 731–736, 2021.

SAHU, M. K. et al. Exploring recent updates on molecular docking: Types, method, application, limitation & future prospects. *International Journal of Pharmaceutical Research and Allied Sciences*, v. 13, n. 2-2024, p. 24–40, 2024.

SALMAN, M. M. et al. Advances in applying computer-aided drug design for neurodegenerative diseases. *International journal of molecular sciences*, MDPI, v. 22, n. 9, p. 4688, 2021.

SALMASO, V.; MORO, S. Bridging molecular docking to molecular dynamics in exploring ligand-protein recognition process: An overview. *Frontiers in pharmacology*, Frontiers Media SA, v. 9, p. 923, 2018.

SANTANA, C. A. et al. Grasp: a graph-based residue neighborhood strategy to predict binding sites. *Bioinformatics*, Oxford University Press, v. 36, n. Supplement_2, p. 726–734, 2020.

SCALFANI, V. F.; PATEL, V. D.; FERNANDEZ, A. M. Visualizing chemical space networks with rdkit and networkx. *Journal of Cheminformatics*, Springer, v. 14, n. 1, p. 1–87, 2022.

SCHNEUING, A. et al. Structure-based drug design with equivariant diffusion models. *Nature Computational Science*, Nature Publishing Group, v. 4, n. 12, p. 899–909, 2024.

SHAFIEE, N. et al. Degeneration in nucleus basalis of meynert signals earliest stage of alzheimer's disease progression. *Neurobiology of Aging*, Elsevier, v. 139, p. 54–63, 2024.

SHAH, P. et al. Deepdtagen: a multitask deep learning framework for drug-target affinity prediction and target-aware drugs generation. *Nature Communications*, Nature Publishing Group, v. 16, n. 1, p. 5021, 2025.

SHAN, W. et al. Convolutional neural network-based virtual screening. *Current Medicinal Chemistry*, Bentham Science Publishers, v. 28, n. 10, p. 2033–2047, 2021.

SHEN, C. et al. From machine learning to deep learning: Advances in scoring functions for protein–ligand docking. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, Wiley Online Library, v. 10, n. 1, p. e1429, 2020.

SHI, Y. et al. Cryo-em structures of tau filaments from alzheimer's disease with pet ligand apn-1607. *Acta neuropathologica*, Springer, v. 141, p. 697–708, 2021.

SHIRALI, A. et al. A comprehensive survey of scoring functions for protein docking models. *BMC bioinformatics*, Springer, v. 26, n. 1, p. 25, 2025.

SHUKLA, R.; TRIPATHI, T. Molecular dynamics simulation of protein and protein–ligand complexes. *Computer-aided drug design*, Springer, p. 133–161, 2020.

SIDKY, H.; CHEN, W.; FERGUSON, A. L. Molecular latent space simulators. *Chemical Science*, Royal Society of Chemistry, v. 11, n. 35, p. 9459–9467, 2020.

SINGH, D. Astrocytic and microglial cells as the modulators of neuroinflammation in alzheimer's disease. *Journal of neuroinflammation*, Springer, v. 19, n. 1, p. 206, 2022.

SON, M. et al. Discovery of novel acetylcholinesterase inhibitors as potential candidates for the treatment of alzheimer's disease. *International journal of molecular sciences*, MDPI, v. 20, n. 4, p. 1000, 2019.

SON, M. et al. Discovery of novel acetylcholinesterase inhibitors as potential candidates for the treatment of alzheimer's disease. *International Journal of Molecular Sciences*, MDPI AG, v. 20, n. 4, p. 1000, Feb 2019. ISSN 1422-0067.

STANZIONE, F.; GIANGRECO, I.; COLE, J. C. Use of molecular docking computational tools in drug discovery. *Progress in medicinal chemistry*, Elsevier, v. 60, p. 273–343, 2021.

SUN, M. et al. Mocl: data-driven molecular fingerprint via knowledge-aware contrastive learning from molecular graph. In: *Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining*. [S.l.: s.n.], 2021. p. 3585–3594.

SUN, M. et al. Graph convolutional networks for computational drug development and discovery. *Briefings in bioinformatics*, Oxford University Press, v. 21, n. 3, p. 919–935, 2020.

TELEANU, D. M. et al. An overview of oxidative stress, neuroinflammation, and neurodegenerative diseases. *International journal of molecular sciences*, MDPI, v. 23, n. 11, p. 5938, 2022.

TERVEN, J. et al. A comprehensive survey of loss functions and metrics in deep learning. *Artificial Intelligence Review*, Springer, v. 58, n. 7, p. 195, 2025.

TINGLE, B. I. et al. Zinc–22: A free multi-billion-scale database of tangible compounds for ligand discovery. *Journal of chemical information and modeling*, ACS Publications, v. 63, n. 4, p. 1166–1176, 2023.

TONG, X. et al. Generative models for de novo drug design. *Journal of Medicinal Chemistry*, ACS Publications, v. 64, n. 19, p. 14011–14027, 2021.

TOPOL, E. Predicting and preventing alzheimer's disease. *Science*, American Association for the Advancement of Science, v. 388, n. 6750, p. eady3217, 2025.

TOXVAERD, S. Discrete newtonian dynamics with nosé-hoover thermostats. *Molecular Physics*, Taylor & Francis, v. 122, n. 21-22, p. e2314701, 2024.

TRIPATHI, N. M.; BANDYOPADHYAY, A. High throughput virtual screening (htvs) of peptide library: Technological advancement in ligand discovery. *European Journal of Medicinal Chemistry*, Elsevier, v. 243, p. 114766, 2022.

UCAK, U. V.; ASHYRMAMATOV, I.; LEE, J. Reconstruction of lossless molecular representations, smiles and selfies, from fingerprints. *Journal of Cheminformatics*, Springer Nature, v. 15, n. 1, p. 26, 2023.

VATANSEVER, S. et al. Artificial intelligence and machine learning-aided drug discovery in central nervous system diseases: State-of-the-arts and future directions. *Medicinal research reviews*, Wiley Online Library, v. 41, n. 3, p. 1427–1473, 2021.

VÁZQUEZ, J. et al. Merging ligand-based and structure-based methods in drug discovery: An overview of combined virtual screening approaches. *Molecules*, MDPI, v. 25, n. 20, p. 4723, 2020.

VEMULA, D. et al. Cadd, ai and ml in drug discovery: A comprehensive review. *European Journal of Pharmaceutical Sciences*, Elsevier, v. 181, p. 106324, 2023.

WAN, S.; SINCLAIR, R. C.; COVENEY, P. V. Uncertainty quantification in classical molecular dynamics. *Philosophical Transactions of the Royal Society A*, The Royal Society Publishing, v. 379, n. 2197, p. 20200082, 2021.

WAN, Y.; WANG, Z.; LEE, T.-Y. Incorporating support vector machine with sequential minimal optimization to identify anticancer peptides. *BMC bioinformatics*, Springer, v. 22, n. 1, p. 286, 2021.

WANG, D. D. et al. Predicting the impacts of mutations on protein-ligand binding affinity based on molecular dynamics simulations and machine learning methods. *Computational and structural biotechnology journal*, Elsevier, v. 18, p. 439–454, 2020.

WANG, F. et al. Improving de novo molecule generation by embedding lstm and attention mechanism in cyclegan. *Frontiers in Genetics*, Frontiers Media SA, v. 12, p. 709500, 2021.

WANG, J. et al. Gaussian accelerated molecular dynamics: Principles and applications. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, Wiley Online Library, v. 11, n. 5, p. e1521, 2021.

WANG, Y.; LI, Z.; FARIMANI, A. B. Graph neural networks for molecules. In: *Machine learning in molecular sciences*. [S.l.]: Springer, 2023. p. 21–66.

WANG, Y.; WEI, Z.; XI, L. Sfcnn: a novel scoring function based on 3d convolutional neural network for accurate and stable protein–ligand affinity prediction. *BMC bioinformatics*, Springer, v. 23, n. 1, p. 222, 2022.

WEGMANN, S.; BIERNAT, J.; MANDELKOW, E. A current view on tau protein phosphorylation in alzheimer's disease. *Current Opinion in Neurobiology*, v. 69, p. 131–138, 2021. ISSN 0959-4388. Molecular Neuroscience.

WEINBERG, N. et al. A newtonian algorithm for constant pressure molecular dynamics with periodic boundary conditions. *Molecular Physics*, Taylor & Francis, v. 120, n. 10, p. e2060145, 2022.

WONG, K. H. et al. Review of current strategies for delivering alzheimer's disease drugs across the blood-brain barrier. *International journal of molecular sciences*, MDPI, v. 20, n. 2, p. 381, 2019.

World Health Organization. *Global status report on the public health response to dementia*. Geneva: World Health Organization, 2021. Licence: CC BY-NC-SA 3.0 IGO.

XU, H. et al. Long-term effects of cholinesterase inhibitors on cognitive decline and mortality. *Neurology*, Lippincott Williams & Wilkins Hagerstown, MD, v. 96, n. 17, p. e2220–e2230, 2021.

YAMAZAKI, Y. et al. Apolipoprotein e and alzheimer disease: pathobiology and targeting strategies. *Nature Reviews Neurology*, Nature Publishing Group UK London, v. 15, n. 9, p. 501–518, 2019.

YANG, C.; ZHANG, Y. Lin_f9: a linear empirical scoring function for protein–ligand docking. *Journal of chemical information and modeling*, ACS Publications, v. 61, n. 9, p. 4630–4644, 2021.

YANG, D. et al. Cocrystal virtual screening based on the xgboost machine learning model. *Chinese Chemical Letters*, Elsevier, v. 34, n. 8, p. 107964, 2023.

YANG, J. et al. Concepts and applications of chemical fingerprint for hit and lead screening. *Drug discovery today*, v. 27, n. 11, p. 103356, 2022.

YANG, Y. et al. Efficient exploration of chemical space with docking and deep learning. *Journal of Chemical Theory and Computation*, ACS Publications, v. 17, n. 11, p. 7106–7119, 2021.

YUAN, S.; CHAN, H. S.; HU, Z. Using pymol as a platform for computational drug design. *Wiley Interdisciplinary Reviews: Computational Molecular Science*, Wiley Online Library, v. 7, n. 2, p. e1298, 2017.

ZANG, C.; WANG, F. Moflow: an invertible flow model for generating molecular graphs. In: *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining*. [S.l.: s.n.], 2020. p. 617–626.

ZDRAZIL, B. et al. The chembl database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic acids research*, Oxford University Press, v. 52, n. D1, p. D1180–D1192, 2024.

ZENG, Q. et al. Active and machine learning-enhanced discovery of new fgfr3 inhibitor, rhapontin, through virtual screening of receptor structures and anti-cancer activity assessment. *Frontiers in Molecular Biosciences*, Frontiers Media SA, v. 11, p. 1413214, 2024.

ZERROUG, A. et al. Virtual screening in drug-likeness and structure/activity relationship of pyridazine derivatives as anti-alzheimer drugs. *Journal of King Saud University-Science*, Elsevier, v. 31, n. 4, p. 595–601, 2019.

ZHANG, C. Beem: fast and faithful conversion of mmcif format structure files to pdb format. *BMC bioinformatics*, Springer, v. 24, n. 1, p. 260, 2023.

ZHANG, J. et al. Recent advances in alzheimer's disease: Mechanisms, clinical trials and new drug development strategies. *Signal transduction and targeted therapy*, Nature Publishing Group UK London, v. 9, n. 1, p. 211, 2024.

ZHANG, P. et al. Multi-target design strategies for the improved treatment of alzheimer's disease. *European Journal of Medicinal Chemistry*, v. 176, p. 228–247, 2019. ISSN 0223-5234.

ZHANG, Y. et al. Amyloid β-based therapy for alzheimer's disease: challenges, successes and future. *Signal transduction and targeted therapy*, Nature Publishing Group UK London, v. 8, n. 1, p. 248, 2023.

ZHANG, Y. et al. Drug-protein interaction prediction via variational autoencoders and attention mechanisms. *Frontiers in genetics*, Frontiers Media SA, v. 13, p. 1032779, 2022.

ZHAO, X. et al. Iterative knowledge-based scoring function for protein–ligand interactions by considering binding affinity information. *The Journal of Physical Chemistry B*, ACS Publications, v. 127, n. 42, p. 9021–9034, 2023.

ZHOU, H.; SKOLNICK, J. Utility of the morgan fingerprint in structure-based virtual ligand screening. *The Journal of Physical Chemistry B*, ACS Publications, v. 128, n. 22, p. 5363–5370, 2024.

ZHOU, J. et al. Evaluating the quality of machine learning explanations: A survey on methods and metrics. *Electronics*, MDPI, v. 10, n. 5, p. 593, 2021.

ZHOU, K.; LIU, B. *Molecular dynamics simulation: Fundamentals and Applications*. [S.l.]: Academic Press, 2022.

ZHOU, S.; HUANG, G. The biological activities of butyrylcholinesterase inhibitors. *Biomedicine & pharmacotherapy*, Elsevier, v. 146, p. 112556, 2022.